



Auto-Encoding Variational Bayes

D. P. Kingma & M. Welling · ICLR 2014 · arXiv:1312.6114

유다연, 신은서


목차

#01 Abstract & Introduction	논문 0 · 1장
#02 Method	논문 2장 · 2.1 ~ 2.4
#03 Example : VAE	논문 3장
#04 Related work	논문 4장
#05 Experiments	논문 5장
#06 Conclusion	논문 6장
#07 Future work	논문 7장
#08 Discussion	토의 주제



01. Abstract & Introduction

논문이 풀려는 문제와 두 가지 기여



#01 논문이 말하는 두 가지 기여

한 줄 요약 · 다루기 힘든 사후분포를 가진 모델을, 표준 경사하강법으로 학습시키는 방법

① SGVB estimator

변분 하한(ELBO)을 재매개변수화해서

미분 가능 · 불편(unbiased) · 저분산 추정량으로 바꿈

→ 별도의 변분 최적화 루프 없이

기존 SGD / Adagrad 코드에 그대로 꽂힌다

▶ 어떻게 학습하나 를 해결

② AEVB algorithm

데이터포인트마다 잠재변수가 있는 i.i.d. 데이터셋에서

인식 모델 $q(z|x)$ 하나로 사후분포를 근사

→ 새 데이터가 와도 순전파 한 번이면 추론 끝


MCMC 같은 반복 추론이 불필요

▶ 어떻게 빠르게 추론하나 를 해결

제목에 'VAE' 가 없는 이유 · VAE 는 이 프레임워크를 신경망에 적용한 3장의 예시일 뿐이다

#01 왜 어려운가 · 적분 하나가 막히면 전부 막힌다

데이터는 이렇게 만들어졌다고 가정



z 를 뽑고 → x 를 만든다

그런데 학습하려면 이 값이 필요하다

$$p_{\theta}(\mathbf{x}) = \int p_{\theta}(\mathbf{z}) p_{\theta}(\mathbf{x}|\mathbf{z}) d\mathbf{z}$$

z 가 200차원이면 200중 적분

디코더가 신경망이면 닫힌 해가 없음

→ 계산 불가능 (intractable)

적분 계산 불가

$$p_{\theta}(\mathbf{x})$$

최대가능도 (MLE)

직접 최적화 불가

×

EM 알고리즘

E-step 계산 불가

×


mean-field VB

기댓값 적분 불가

×

기존 방법이 전부 막힌다 → 새로운 추정량이 필요하다


#01 해결의 실마리 · 인식 모델 하나를 모두가 공유한다




추론 비용을 전체 데이터에 상각한다는 뜻에서 amortized inference 라고 부른다

02. Method

ELBO $\rightarrow$ 분산 문제 $\rightarrow$ 재매개변수화 $\rightarrow$ SGVB



#02 변분 하한 ELBO · 계산 못 하는 값을 우회하는 법



식 (1)

$$\log p_{\theta}(\mathbf{x}^{(i)}) = D_{KL}(q_{\phi}(\mathbf{z}|\mathbf{x}^{(i)}) \parallel p_{\theta}(\mathbf{z}|\mathbf{x}^{(i)})) + \mathcal{L}(\theta, \phi; \mathbf{x}^{(i)})$$

θ 가 고정되면 좌변은 상수다. 따라서 ELBO 를 올리는 것 = KL 갭을 줄이는 것이 되고, 계산할 수 없는 KL 을 직접 건드리지 않고도 q 를 참 사후분포에 가깝게 만들 수 있다.

#02 ELBO 를 풀어 쓰면 · VAE 손실함수가 된다

$$\mathcal{L}(\theta, \phi; \mathbf{x}^{(i)}) = -D_{KL}(q_{\phi}(\mathbf{z}|\mathbf{x}^{(i)}) \parallel p_{\theta}(\mathbf{z})) + \mathbb{E}_{q_{\phi}}[\log p_{\theta}(\mathbf{x}^{(i)}|\mathbf{z})]$$

식 (3)

① 정규화 항 (KL)

인코더가 뽑는 분포를
사전분포 $N(0, I)$ 쪽으로 끌어당김

없으면 → 잠재공간에 구멍, 샘플링 불가

② 재구성 항

뽑은 z 로 원본을
얼마나 잘 복원하는지

없으면 → 모든 입력이 같은 출력으로 붕괴

교재 연계 · 《딥러닝 파이토치 교과서》 p.698 의 ① ② 항과 부호까지 같은 식이다. 구현에서는 부호를 뒤집어 $\text{reproduction_loss} + \text{KLD}$ 를 최소화한다.

#02 그런데 문제가 남는다 · ϕ 로 미분할 수가 없다

θ 는 기댓값 안쪽 함수에만 있지만, ϕ 는 기댓값을 취하는 분포 자체에 들어 있다

$$\nabla_{\phi} \mathbb{E}_{q_{\phi}(\mathbf{z})} [f(\mathbf{z})] \simeq \frac{1}{L} \sum_{l=1}^L f(\mathbf{z}^{(l)}) \nabla_{\phi} \log q_{\phi}(\mathbf{z}^{(l)})$$

score function estimator (강화학습의 REINFORCE 와 같은 형태)

수학적으로는 맞지만

$f(\mathbf{z})$ 의 값만 쓰고


f 가 어떻게 생겼는지는 모른다

→ 드물게 뽑힌 $\mathbf{z}$ 하나가

기울기를 통째로 흔든다

눈을 가린 채 '이쪽이 좋았다' 만 듣는 셈

기울기 추정치의 흔들림





재매개변수화 (다음 장)



평균은 같지만, 한 스텝마다 방향이 제멋대로면 학습이 안 된다

논문 2.2 마지막 문장 : "This gradient estimator exhibits very high variance and is impractical for our purposes."

#02 재매개변수화 트릭 · 논문의 심장



확률성은 그대로 두고, 그 위치만 옮긴다. ϵ 은 ϕ 와 무관한 분포에서 미리 뽑히므로 계산 그래프에서는 그냥 입력 상수다.

#02 그 결과 · SGVB 추정량과 AEVB 알고리즘

기댓값의 분포에서 ϕ 가 빠져나왔으므로, ∇ 를 기댓값 안으로 그냥 밀어 넣을 수 있다

Algorithm 1 Minibatch AEVB

```
 $\theta, \phi \leftarrow$  Initialize parameters
repeat
   $X^M \leftarrow$  Random minibatch of M datapoints
   $\varepsilon \leftarrow$  Random samples from noise distribution  $p(\varepsilon)$ 
   $g \leftarrow \nabla$  of minibatch estimator
   $\theta, \phi \leftarrow$  Update parameters (SGD or Adagrad)
until convergence of parameters
return  $\theta, \phi$ 
```

놀라울 만큼 평범하다

그리고 그것이 핵심이다

- E-step / M-step 교대 없음
- 좌표 상승법 내부 루프 없음
- MCMC 체인 없음
- 데이터포인트별 반복 추론 없음


표준 SGD 루프만 남았다

실험 설정은 $M = 100, L = 1$. 데이터포인트당 z 를 한 번만 뽑아도 미니배치 평균이 잡음을 상쇄하므로 학습이 된다.

→ VAE 의 학습 비용이 일반 오토인코더와 거의 같아진다는 뜻이다.


03. Example : VAE

일반론에 분포를 하나씩 골라 넣으면




#03 세 가지 설계 선택 · 이것이 VAE 구조의 전부다

논문 14쪽 중 단 1쪽. 여기서 처음 'variational auto-encoder' 라는 이름이 등장한다



- ① prior 에 학습할 파라미터가 없으므로 생성할 때 randn 으로 뽑기만 하면 되고, KL 항이 해석적으로 풀린다.
- ② BCE 나 MSE 나느 임의의 선택이 아니라, 디코더 분포를 무엇으로 가정했느냐의 필연적 귀결이다.
- ③ 대각 공분산은 단순화를 위한 선택일 뿐 방법론의 한계가 아니다 (논문 각주 2).

#03 VAE 구조 · 수식의 각 항이 어디에 대응하는가



ϵ 은 그래프 바깥에서 들어오고, KL 항은 디코더를 거치지 않고 μ, σ 만 보고 계산된다

#03 최종 목적함수 · 그리고 교재 코드와의 대응

$$\mathcal{L}(\theta, \phi; \mathbf{x}^{(i)}) \simeq \frac{1}{2} \sum_{j=1}^J \left(1 + \log(\sigma_j^{(i)})^2 - (\mu_j^{(i)})^2 - (\sigma_j^{(i)})^2 \right) + \frac{1}{L} \sum_{l=1}^L \log p_{\theta}(\mathbf{x}^{(i)} | \mathbf{z}^{(i,l)})$$

식 (10)

KL 항의 해석해 · 샘플링 불필요

$\mu=0, \sigma=1$ 일 때 0 으로 최대

재구성 항 · 여기만 샘플링


논문 실험에서는 $L = 1$

논문		교재 코드 (13.2.2)
식 (4) $z = g(\epsilon, x)$	재매개변수화 →	<code>z = mean + var * epsilon</code>
식 (10) 앞 · $\frac{1}{2} \sum (1 + \log \sigma^2 - \mu^2 - \sigma^2)$	KL 해석해 (부호 반대) →	<code>KLD = -0.5*torch.sum(1+log_var-mean.pow(2)-log_var.exp())</code>
식 (11) Bernoulli MLP decoder	재구성 손실 →	<code>binary_cross_entropy(x_hat, x, reduction='sum')</code>

논문의 수식이 교재 코드 한 줄 한 줄과 그대로 대응된다

04. Related work

이 논문은 어디에서 왔나



#04 사후분포 근사의 선행 연구: 같은 문제, 다른 해법

Wake-Sleep은 같은 모델 클래스에 쓸 수 있는 유일한 기존 온라인 학습법이었음


	Wake-Sleep Hinton et al. 1995	Stochastic / Black-box VI score function + control variate	AEVB 이 논문
추론 방식	인식 모델 $q(z x)$ 공유	데이터포인트별 변분 파라미터	인식 모델 $q(z x)$ 공유
목적함수	wake / sleep 두 개를 번갈아 합쳐도 $\log p(x)$ 의 하한이 아님	ELBO 하나	ELBO 하나
ϕ 의 기울기	sleep 단계: 모델이 만든 가짜 샘플로 인코더 학습	score function $\rightarrow$ 고분산 control variate 로 분산 줄이기	재매개변수화 $\rightarrow$ 저분산
이산 잠재변수	✓ 가능	✓ 가능	✗ 불가 (연속 전용)

목적함수 하나를 저분산으로 미분한다.

대신, 이산 잠재변수는 포기함 $\rightarrow$ 토의 2

#04 오토인코더 관련 선행 연구: 왜 이름이 Auto-Encoding인가


그 밖에 PSD, GSN, DARN 등도 인코더-디코더 구조를 썼지만, DARN은 이진 잠재변수 전용이다



“lacking the usual nuisance regularization hyperparameter”

05. Experiments

이론의 이점이 실험에서도 보이는가



#05 Experiments

Dataset

- MNIST
 - 손으로 쓴 0~9까지의 숫자 이미지
 - train 60,000개, test 10,000개, 이미지 크기 28 x 28
- Frey Face
 - Brendan Frey의 얼굴을 촬영한 영상에서 추출한 이미지
 - 1,956개, 이미지 크기 20 x 28

Metric

- Variational lower bound
- Marginal log-likelihood

#05 Experiments

Model

- 앞에서 제시한 VAE의 encoder & decoder 사용
 - encoder, decode의 hidden unit 수 동일
 - Frey Face data는 연속형이므로 decoder에 Gaussian MLP 사용

*Gaussian MLP as encoder or decoder


- Encoder와 동일하게 gaussian output을 내지만, 평균이 [0, 1] 범위로 제한되도록 sigmoid 활성화 함수를 거친다는 점에서 차이가 있다.

Train setting

- 최적화 방식
 - Stochastic gradient ascent: Lower bound estimator의 미분값 $\nabla_{\theta, \phi} L(\theta, \phi; X)$ 으로 업데이트
 - Small weight decay: 사전 지식 $p(\theta) = N(0, I)$ 과 일치
- 비교 모델: wake-sleep algorithm
 - 동일한 encoder를 사용하여 성능 비교
 - 모든 파라미터는 $N(0, 0.01)$ 에서 random sampling 하여 초기화
- Details
 - Optimizer: Adagrad (step size는 {0.01, 0.02, 0.1} 중 자동 선택)
 - Batch size : 100개
 - Sampling : datapoint 당 1개 sample 사용

#05 Experiments


Likelihood lower bound



- 실험 방법
 - Hidden unit : MNIST 500개, Frey Face 200개(더 작은 데이터셋에서 과적합 방지)
 - Latent variable 개수(N_z)를 다양하게 실험
- 결과
 - AEVB가 wake-sleep 보다 더 빠르게 수렴하며 더 좋은 성능을 보임
 - Latent variable 개수가 증가해도 overfitting이 발생하지 않음 <- lower bound의 규제 효과

#05 Experiments

Marginal likelihood



- 실험 방법
 - Hidden unit : MNIST 100개
 - Latent variable 개수(N_z) : 3개
- 결과
 - AEVB가 wake-sleep, MCEM 보다 더 빠르게 수렴하며 더 좋은 성능을 보임
 - MCEM은 On-line 알고리즘(Mini-batch)이 아니라 전체 MNIST 데이터셋에는 효율적이지 않음

Conclusion

- SGVB(Stochastic Gradient VB) 도입
 - 연속형 잠재 변수를 효율적으로 근사 추론 가능한 variational lower bound estimator
 - Reparameterization 트릭으로 미분 가능하도록 하여 경사 하강법으로 최적화 가능
- AEVB(Auto-Encoding VB) 도입
 - SGVB estimator를 활용해 효율적으로 학습 및 추론하는 알고리즘

SGVB estimator & AEVB algorithm

연속형 잠재 변수의 학습 추론 문제에 다양하게 적용 가능

1. Hierarchical generative architectures with deep neural network(e.g. CNN)
2. Time-series models
3. SGVB to global parameters
4. Supervised models with latent variable

#08 세션에서 함께 이야기해 볼 것

토의 ① KL 항은 정말 '공짜 정규화' 일까?

논문 근거 · 논문 4장 : "lacking the usual nuisance regularization hyperparameter" — 튜닝할 계수가 없다는 것을 장점으로 제시한다.

그런데 5장의 "잠재변수를 200개로 늘려도 과적합이 없다" 는 관찰은, 뒤집으면 쓰이지 않는 잠재 차원이 그냥 죽는다는 뜻이기도 하다.

실제로 β -VAE(2017) 는 KL 항에 계수 β 를 곱해 일부러 균형을 깬다. 논문이 없었다고 자랑한 하이퍼파라미터를 후속 연구가 되살린 셈인데, 재구성 결과 KL 의 균형을 사람이 정할 수 없다는 것은 장점인가 한계인가?

토의 ② '연속 잠재변수' 라는 전제는 얼마나 강한 제약인가?

논문 근거 · 2.4절의 세 가지 재매개변수화 전략은 모두 연속 분포 전용이다. 반면 비교 대상인 Wake-Sleep 은 이산 잠재변수에도 적용된다.

토픽, 객체 개수, 클러스터 소속처럼 이산 구조가 자연스러운 문제도 많다. 연속성 가정이 데이터에 없는 구조를 강요하는 것은 아닐까?

Gumbel-Softmax(2016) 는 이산 분포를 연속 완화해 이 문제를 풀었고, VQ-VAE(2017) 는 아예 다른 길을 갔다. 오늘날 이미지 토큰라이저의 표준이 된 쪽은 VQ-VAE 계열인데, 이것은 무엇을 시사할까?

THANK YOU

Kingma & Welling, Auto-Encoding Variational Bayes, ICLR 2014

