



AN IMAGE IS WORTH 16X16 WORDS : TRANSFORMERS FOR IMAGE RECOGNITION AT SCALE

김태희, 손현경

목차

#01 Introduction

#02 BackGround

#03 Related Work

#04 Method

#05 Experiments

#06 Conslusion

#07 Discussion



01 Introduction




01 Introduction

ViT = vision transformer

여전히 ResNet이 SOTA


NLP의 표준 방법론



Vision 분야에 Transformer를 접목 시도
Attention+CNN 구조의 모델 제시

ViT = **only Attention**만 활용하고 싶다!

01 Introduction





02 BackGround



02 BackGround ... Self Attention의 연산량

왜 pixel 대신 patch를 토큰으로 사용할까?




토큰 수 $1/256 \rightarrow$ 어텐션 점수 $1/65,536$ (N^2 에 비례)

03 Related Work



03 Related Work


local·sparse attention



■ 쿼리 픽셀
■ 로컬 이웃
이웃 안에서만
어텐션 계산

연산량을 줄이기 위해
local pixel만 보거나
Sparse pattern,
서로 다른 크기의 block,
축 방향 attention 등 사용


(a) 블록 크기 변화



레이어 A · 3×3

레이어 B · 7×7


(b) 이미지 분할 · 병렬



블록 1


블록 2

(c) 축 어텐션



■ ① 행 → ■ ② 열

CNN + attention



(a) 특징 맵에 더하기

(b) 출력에 적용

Cordonnier et al.의 연구

ViT와 가장 유사한 선행 논문
Image를 2*2 patch로 나누고
Full self-attention 적용


iGPT

Image의 해상도와
color space를
줄여 pixel을 대상으로
Transformer를 학습


04 Method



04 Method



Transformer Encoder



04 Method

$$\mathbf{z}_0 = [\mathbf{x}_{\text{class}}; \mathbf{x}_p^1 \mathbf{E}; \mathbf{x}_p^2 \mathbf{E}; \cdots; \mathbf{x}_p^N \mathbf{E}] + \mathbf{E}_{pos}$$


- ④ Class 토큰 : 각 이미지의 정보를 요약
- ③ D dim으로 mapping 된 각 patch
- ⑤ 위치 정보 추가

Patch + Position Embedding

* Extra learnable [class] embedding




① 원본 이미지 (HxWxC)



② 2D patch Sequence
 $N \times (P^2 \times C)$

필요한 patch 개수 각 patch의 사이즈

04 Method



04 Method

Inductive Bias

CNN

각 층에서 가까운 픽셀을 우선 처리

2차원 이웃 관계와 이동에 대한 대응이
구조에 반영됨

ViT


self-attention이 모든 patch를 볼 수 있음

patch 간 공간 관계를
학습으로 익혀야 함

CNN : locality, 2D neighborhood 구조, translation equivariance가 layer에 내재됨.

ViT에서 2차원 이미지 구조를 활용하는 지점
: patch 분할과 해상도 변경 시 위치 임베딩 보간

Hybrid Architecture



CNN을 앞단에 적용



Feature map
: 공간 관련 정보를 담고 있음

Transformer를 뒷단에 적용

공간 관련 정보를 global하게
학습 가능

04 Method

Fine-Tuning & Higher Resolution



05. Experiments



#05. Experiments

#5.1 Setup

#5.2 Comparison to State of the Art

#5.3 PRE-TRAINING DATA REQUIREMENTS

#5.4 SCALING STUDY

#5.5 INSPECTING VISION TRANSFORMER

#5.6 SELF-SUPERVISION

#05. Experiments

Setup - Datasets

데이터셋	이미지 수	목적	클래스
ImageNet	약 130만 장	상대적으로 작은 규모의 학습	약 1,000개
ImageNet-21k	약 1,400만 장	imagenet의 상위 집합. 더 큰 공개 데이터에서의 학습	약 21,000개
JFT-300M	약 3억 300만 장 (고해상도 이미지)	초대규모 사전학습	약 18,000 클래스

사전학습 데이터 셋

#05. Experiments

Setup - Datasets

평가 데이터셋	과제 특징	확인하려는 것
ImageNet	대표적인 대규모 이미지 분류	기본 분류 성능
ImageNet Real	수정된 ImageNet 레이블 사용	더 정확한 분류 성능
CIFAR-10 / 100	작은 저해상도 이미지 분류	작은 데이터셋으로의 전이
Oxford Pets	개·고양이 품종 분류	세밀한 객체 분류
Oxford Flowers-102	꽃 종류 분류	비슷한 시각적 특징 구분
VTAB-1k	19개 과제, 과제당 1,000개 학습 예제	적은 데이터에서의 전이

다운스트림 평가용 데이터 셋

큰 데이터셋에서 사전학습 → 작은 데이터셋이나 다른 과제에 전이 → 성능 비교

#05. Experiments

Setup - Model Variants

모델	구조	특징	비교 목적
ViT	이미지 패치 → Transformer	CNN 없이 패치 간 전역 관계를 학습	제안 모델
ResNet (BiT)	CNN 기반 ResNet	지역성, 2차원 구조 등 CNN의 inductive bias 사용	강력한 CNN 기준 모델
Hybrid	ResNet feature map → Transformer	CNN의 지역 특징과 Transformer의 전역 attention 결합	CNN 결합 효과 확인
Noisy Student	EfficientNet 기반 CNN	당시 최고 수준의 이미지 분류 모델	State-of-the-art와 비교

ViT가 CNN의 도움 없이도 강력한 ResNet과 경쟁할 수 있는지 비교

#05. Experiments

Setup - Training & Evaluation

Pre-training

- Optimizer: Adam
- Batch size: 4,096
- Weight decay: 0.1
- Learning rate warmup and decay
- 대규모 데이터셋에서 이미지 표현 학습

Fine-tuning

- Optimizer: Momentum SGD
- Batch size: 512
- 다운스트림 과제에 맞게 분류기와 모델을 추가 학습

Fine-tuning accuracy

: 사전학습 모델을 해당 과제에 맞게 추가 학습한 뒤 평가한다.

Few-shot linear accuracy

: 사전학습 표현을 고정하고, 소수의 레이블 예제로 선형 예측기를 학습해 평가한다.

#05. Experiments


Comparison to State of the Art

	Ours-JFT (ViT-H/14)	Ours-JFT (ViT-L/16)	Ours-I21k (ViT-L/16)	BiT-L (ResNet152x4)	Noisy Student (EfficientNet-L2)
ImageNet	88.55 ± 0.04	87.76 ± 0.03	85.30 ± 0.02	87.54 ± 0.02	88.4/88.5*
ImageNet Real	90.72 ± 0.05	90.54 ± 0.03	88.62 ± 0.05	90.54	90.55
CIFAR-10	99.50 ± 0.06	99.42 ± 0.03	99.15 ± 0.03	99.37 ± 0.06	—
CIFAR-100	94.55 ± 0.04	93.90 ± 0.05	93.25 ± 0.05	93.51 ± 0.08	—
Oxford-IIIT Pets	97.56 ± 0.03	97.32 ± 0.11	94.67 ± 0.15	96.62 ± 0.23	—
Oxford Flowers-102	99.68 ± 0.02	99.74 ± 0.00	99.61 ± 0.02	99.63 ± 0.03	—
VTAB (19 tasks)	77.63 ± 0.23	76.28 ± 0.46	72.72 ± 0.21	76.29 ± 1.70	—
TPUv3-core-days	2.5k	0.68k	0.23k	9.9k	12.3k

JFT-300M으로 사전학습한 ViT-H/14는 BiT-L보다 높은 정확도를 기록하면서, 사전학습 비용은 약 1/4을 사용했다.

#05. Experiments


Comparison to State of the Art



ViT의 성능 향상은 Natural과 Structured 과제에서 나타나며, Specialized에서는 BiT와 유사하다.

#05. Experiments

Pre-training Data Requirements



작은 데이터: 큰 모델의 이점 제한

대규모 데이터: 큰 ViT의 성능 향상

실험 설정

- ImageNet, ImageNet-21k, JFT-300M에서 각각 사전학습
- 작은 데이터셋에서는 weight decay, dropout, label smoothing 조정
- ImageNet에 fine-tuning한 뒤 Top-1 정확도 비교


주요 결과

- ImageNet에서는 큰 ViT가 작은 ViT보다 낮은 성능을 보이기도 함
- 대규모 사전학습에서 큰 ViT의 이점이 뚜렷해짐

=> 큰 ViT의 성능을 충분히 활용하려면 대규모 사전학습 데이터가 필요하다

#05. Experiments

Pre-training Data Requirements



ResNet 우세

ViT-L/16 우세

실험 설정

- JFT의 9M, 30M, 90M 부분집합과 전체 데이터 사용
- 작은 부분집합에 추가 정규화 없이 동일한 하이퍼파라미터 사용
- Early stopping을 적용하고, ImageNet 5-shot linear 정확도로 평가


주요 결과

- 작은 데이터에서는 비교 대상 ResNet이 유리
- 데이터가 증가하면 ViT의 성능 향상 폭이 더 큼
- ViT-L/16은 90M 이상에서 ResNet152 × 2를 앞섬

=>CNN의 inductive bias는 적은 데이터에서 유리하지만, 충분한 데이터에서는 ViT가 더 높은 성능을 보인다.

#05. Experiments

Scaling Study




실험 설정

- JFT-300M에서 ResNet, ViT, Hybrid를 사전학습
- 모델 크기와 학습 시간을 변화시키며 사전학습 계산량 대비 전이 정확도 비교

#05. Experiments

Scaling Study




핵심 결과


- ViT: 5개 데이터셋 평균 기준, ResNet과 같은 성능에 필요한 계산량이 약 1/2~1/4
- Hybrid: 작은 계산 예산에서는 ViT보다 약간 우세하지만, 큰 모델에서는 차이가 줄어들음
- 확장 가능성: 실험한 범위에서 ViT의 성능이 뚜렷하게 포화되지 않음

#05. Experiments

Inspecting Vision Transformer — 패치 특징과 위치 정보




패치를 벡터로 변환하는 가중치를 시각화하면,
이미지의 세부 패턴을 표현하는 기저가 나타남



가까운 위치의 패치끼리 유사도가 높고, 같은
행·열에 해당하는 공간적 구조가 나타남

#05. Experiments

Inspecting Vision Transformer — Attention의 범위



가로축: Transformer의 층 깊이

세로축: Attention 가중치로 계산한 평균 공간 거리

거리가 작음: 가까운 패치를 주로 참고

거리가 큼: 멀리 떨어진 패치까지 참고

- 초기 층부터 가까운 영역을 보는 head와 넓은 영역을 보는 head가 함께 존재
- 층이 깊어질수록 이미지 전반의 정보를 통합하는 경향
- 일부 초기 attention은 CNN의 초기 합성곱 층과 유사한 국소 정보 처리 역할을 할 가능성

#05. Experiments

Inspecting Vision Transformer — Attention 시각화



- 여러 층의 attention을 결합한 Attention rollout으로 입력 이미지에 대한 attention을 시각화



- 예시에서 분류와 관련된 물체 영역에 attention이 집중되는 경향을 확인



#06. Conclusion

1. 이미지 인식에 순수 Transformer 적용

- 이미지를 패치 단위의 시퀀스로 변환하여 표준 Transformer에 입력
- CNN 기반 특징 추출기 없이 이미지 분류 수행

2. 대규모 사전학습의 효과 확인

- 충분한 데이터로 사전학습하면 여러 이미지 분류 과제에서 기존 CNN과 대등하거나 더 높은 성능 달성
- 실험한 설정에서 높은 성능과 우수한 사전학습 계산 효율을 확인

3. 한계 및 향후 연구

- 적은 사전학습 데이터에서는 CNN보다 성능이 낮아, 데이터 규모에 대한 의존성이 존재
- 객체 탐지·분할 등 다양한 컴퓨터 비전 과제로 확장 필요
- 자기지도 사전학습의 가능성을 확인했으나, 지도 사전학습과의 성능 격차가 남음

대규모 사전학습을 통해, 순수 Transformer도 이미지 인식에서 강력한 성능을 발휘할 수 있다.

#07. Discussion

1. 데이터가 적은 상황에서도 ViT를 선택할까?

- 이 두 결과를 함께 보면, '데이터가 적다'는 말이 사전학습 데이터인지 다운스트림 데이터인지에 따라 의미가 달라진다. 우리가 가진 이미지가 적더라도 이미 대규모 데이터로 학습된 ViT를 활용할 수 있다면, 처음부터 학습하는 상황과 같은 기준으로 모델을 선택하기는 어렵다. 모델 선택의 기준은 보유한 데이터의 양일까, 활용할 수 있는 사전학습 모델일까?

2. CNN의 inductive bias는 장점일까, 제약일까?

- ViT는 이미지에 대한 구조적 가정이 상대적으로 적어도 충분한 데이터로 높은 성능을 얻을 수 있음을 보여준다. 하지만 이를 뒤집어 보면, CNN은 구조에 반영된 사전 지식 덕분에 데이터와 계산 자원을 절약할 수 있다는 뜻이기도 하다. 대규모 학습에서 얻는 최고 성능뿐 아니라 제한된 자원에서의 효율까지 고려한다면, inductive bias가 적은 구조를 더 좋은 방향이라고 볼 수 있을까?

3. ViT의 성능 향상은 구조의 효과일까, 학습 규모의 효과일까?

- Scaling Study는 ViT의 계산 효율을 뒷받침하지만, 특정 데이터와 학습 조건에서 얻은 결과라는 범위는 남아 있다. 또한 같은 파라미터 수, 같은 계산량, 같은 학습 시간은 서로 다른 비교 기준이다. 어떤 기준을 적용하느냐에 따라 유리한 모델이 달라질 수 있다면, '더 우수한 구조'라는 판단에는 어떤 조건이 붙어야 할까?

THANK YOU

