


CLIP

Contrastive Language–Image Pre-training

OpenAI · ICML 2021 · arXiv:2103.00020



Learning Transferable Visual Models From Natural Language Supervision

A. Radford, J. W. Kim, C. Hallacy, A. Ramesh, G. Goh, S. Agarwal, G. Sastry, A. Askell, P. Mishkin, J. Clark, G. Krueger, I. Sutskever

유다연

목차

#01 Introduction 왜 '자연어'로 비전을 배우나 · 1장

#02 Approach WIT 데이터 · 대조 학습 · 모델 · 2장

#03 Experiments Zero-shot · Linear probe · Robustness · 3장

#04 Limitations & Discussion 사람 비교 · 한계 · 후속 연구 · 토의 · 4장, 6장



01. Introduction

고정된 1,000개 라벨을 넘어서



#01 한눈에 보는 CLIP · 결론부터

한 줄 요약 · 인터넷의 (이미지, 텍스트) 4억 쌍으로 '이 이미지의 짝인 텍스트는?'만 맞게 학습했더니
→ 자연어만으로 새 분류기를 만들어 쓰는 비전 모델이 되었다



4억 쌍

(이미지, 텍스트) · WIT 데이터셋

검색어 50만 개로 인터넷에서
모으고, 검색어당 최대 2만 쌍으로
균형



4×

학습 효율 · 예측 → 대조

캡션 단어를 '예측'하는 대신 짝을
'고르게' 하자 zero-shot 효율 4배



76.2%

ImageNet zero-shot top-1

학습 이미지 128만 장을 하나도 쓰지
않고 원조 ResNet-50과 같은 정확도

Natural language supervision

Contrastive pre-training

Zero-shot transfer

Robustness

30개+ 데이터셋 zero-shot 평가


#01 문제의식 · 고정된 1,000개 라벨의 한계

지금까지의 비전 ImageNet 지도학습



출력층이 고정된 softmax → 새 개념마다 라벨 수집 + 재학습


같은 시기의 NLP GPT-3 (Brown et al., 2020)



웹 텍스트 사전학습 + text-to-text → 과제 전용 head 불필요

웹의 텍스트로, 비전에서도 같은 일이 가능할까?

선행 연구의 성적표 ImageNet zero-shot top-1




차이는 규모

선행 연구: 이미지 10~20만 장, 가속기로 며칠
→ CLIP: 4억 쌍


02. Approach

데이터 → 학습 목표 → 모델



#02 재료 ① 데이터 · WIT, 4억 쌍을 직접 모으다

학습 데이터 규모 (막대 길이는 로그 축 — 한 칸에 10배)



검색어 50만 개로 넓게

- 영어 위키백과에 100번 이상 나온 단어
- PMI가 높은 bi-gram
- 일정 검색량 이상의 위키백과 문서 제목
- 빠진 WordNet synset 보충

검색어당 최대 20,000쌍

→ 클래스 균형을 대략 맞춤

총 단어 수 $\approx$ GPT-2의 WebText

왜 기존 데이터로는 안 됐나

MS-COCO · Visual Genome 고품질이지만 약 10만 장

YFCC100M '20160716_113957.JPG' 같은 파일명 제목이 많아, 영어 설명만 남기면 1,500만 장

#02 재료 ② 학습 목표 · 예측에서 대조로




Figure 2 · zero-shot ImageNet 정확도 vs 학습에 사용한 이미지 수

① 캡션을 그대로 생성 (VirTex 방식)

63M Transformer 언어 모델 — 단어 가방(BoW)
예측보다 3배 느림

② 왜 느린가?

같은 사진에도 온갖 텍스트가 붙는다 → 정확한
단어 맞추기는 너무 어려운 문제

③ 문제를 바꾸다


'어떤 텍스트가 짝인가'만 맞추기 → 다시 4배,
합치면 약 12배

정답 단어를 '예측'하지 말고, 짝을 '고르게' 하라 — 같은 데이터로 zero-shot 효율 4배

#02 대조 사전학습 · N×N 중 정답 N개 찾기

배치 = (이미지, 텍스트) N쌍

- 정답 · 대각선 N개 → 유사도 ↑
- 오답 · $N^2 - N$ 개 → 유사도 ↓



배치 크기

$N = 32,768$

스텝마다 32,768지선다 × 2방향
오답 쌍 ≈ 10.7억 개

symmetric cross entropy
 $loss = \frac{1}{2} (CE_{\text{행}} + CE_{\text{열}})$
행: 이미지 → 텍스트 · 열: 텍스트 → 이미지

손실의 계보
N-pair loss (Sohn, 2016)
→ InfoNCE (Oord et al., 2018)
→ ConVIRT (2020, 의료 영상)
→ CLIP: 더 단순하게, 훨씬 크게

#02 손실 함수를 수식으로 · 결국 N지선다 분류

$$s_{ij} = \frac{\langle \mathbf{I}_i, \mathbf{T}_j \rangle}{\tau}$$

$\langle \cdot, \cdot \rangle$ L2 정규화된 벡터의 내적 = 코사인 유사도
 τ temperature · 학습되는 값

$$\mathcal{L}_{I \rightarrow T} = -\frac{1}{N} \sum_{i=1}^N \log \frac{\exp(s_{ii})}{\sum_{j=1}^N \exp(s_{ij})}$$

분자 정답 쌍 (대각선)
분모 같은 행의 후보 N개
→ 이미지마다 텍스트 고르기

$$\mathcal{L}_{T \rightarrow I} = -\frac{1}{N} \sum_{j=1}^N \log \frac{\exp(s_{jj})}{\sum_{i=1}^N \exp(s_{ij})}$$

합의 방향만 바뀐다
→ 텍스트마다 이미지 고르기


$$\mathcal{L} = \frac{1}{2} (\mathcal{L}_{I \rightarrow T} + \mathcal{L}_{T \rightarrow I})$$

두 방향의 평균 = symmetric loss

= N개 클래스 softmax 분류의 cross entropy (d2l 4.1 · 교재 손실 함수)

온도 τ 의 역할 $\exp(t) = 1/\tau$

같은 유사도 [0.32, 0.28, 0.25, 0.20]도
 $1/\tau$ 에 따라 softmax 확률이 달라진다



- $1/\tau$ 가 클수록 분포가 날카로움
- 초기 $\tau = 0.07 \rightarrow 1/\tau \approx 14.3$
- $1/\tau \leq 100$ 으로 clip (학습 안정성)
- log 스케일로 직접 학습 → 튜닝 불필요

#02 의사코드 해부 · Figure 3을 다섯 단계로

```
1 # extract feature representations
I_f = image_encoder(I) #[n, d_i]
T_f = text_encoder(T)  #[n, d_t]

2 # joint multimodal embedding [n, d_e]
I_e = l2_normalize(np.dot(I_f, W_i), axis=1)
T_e = l2_normalize(np.dot(T_f, W_t), axis=1)

3 # scaled pairwise cosine similarities [n, n]
logits = np.dot(I_e, T_e.T) * np.exp(t)

4 # symmetric loss function
labels = np.arange(n)

5 loss_i = cross_entropy_loss(logits, labels, axis=0)
loss_t = cross_entropy_loss(logits, labels, axis=1)
loss    = (loss_i + loss_t)/2
```

Radford et al. (2021) Figure 3 · Numpy-like pseudocode (주석 일부 축약)

- 1 인코더로 특징 추출
 $I_f : [n, d_i], T_f : [n, d_t]$ — 차원이 서로 다르다
- 2 같은 공간으로 투영 + L2 정규화
선형 W 로 둘 다 d_e 차원에 $\rightarrow$ 길이 1이면 내적 = 코사인 유사도
- 3 $N \times N$ 유사도 $\times \exp(t)$
 $\exp(t) = 1/\tau \rightarrow$ 앞 장의 s_{ij}
- 4 정답은 언제나 대각선
 i 번째 이미지 $\leftrightarrow i$ 번째 텍스트
- 5 양방향 cross entropy의 평균
axis=1: 이미지마다 텍스트 고르기
axis=0: 텍스트마다 이미지 고르기

④ `labels = arange(n)` $\rightarrow$ 오답을 따로 만들지 않는다 (in-batch negatives) — 배치가 클수록 비교하는 오답이 많아진다

#02 인코더와 학습 설정 · 모델 8개, 그리고 덜어 낸 것들

Image Encoder

ResNet × 5 RN50 · RN101 · RN50x4 · x16 · x64

- 평균 풀링 → attention pooling (QKV 1층)
- EfficientNet식 확장: 폭·깊이·해상도를 함께

ViT × 3 B/32 · B/16 · L/14 (+336px)

- patch + position embedding 뒤 LayerNorm 추가

Text Encoder

Transformer (GPT-2 구조) 63M · 12층 · 폭 512

- 소문자 BPE · 최대 76 토큰 · [SOS] ... [EOS]
- [EOS] 위치의 최상위 층 출력 → 선형 투영
- masked self-attention
- 폭만 키움 — 텍스트 쪽 용량에는 덜 민감

학습 설정

- 32 epochs · batch 32,768 · cosine LR
- Adam + decoupled weight decay · mixed precision
- RN50x64: V100 592장 × 18일
- ViT-L/14: V100 256장 × 12일

ConVIRT에서 오히려 덜어 낸 것

- ① 사전학습 가중치 없이 처음부터 학습
- ② 비선형 projection head → 선형 하나
- ③ 데이터 증강은 random square crop 하나
- ④ temperature τ 도 학습 (손으로 튜닝 X)

이유 · 4억 쌍이면 과적합 걱정이 적다


논문 속 'CLIP' = ViT-L/14@336px (최고 성능 모델)

03. Experiments

Zero-shot → Linear probe → Robustness



#03 Zero-shot 분류 · 텍스트 인코더가 분류기를 만든다



= 선형 분류기

multinomial logistic regression

- 입력·가중치 모두 L2 정규화
- bias 없음, 온도 $1/\tau$ 로 스케일
- W 는 학습하지 않고 '작성'
→ 텍스트 인코더 = hypernetwork

교재 연계

딥러닝 파이토치 교과서 5.3.1 특성 추출

```
resnet18.fc = nn.Linear(512, 2)
```

→ 가중치를 데이터로 학습

CLIP

→ 같은 자리의 가중치를 클래스 이름으로 생성

거꾸로 보면, 사전학습 한 스텝 =

'클래스 32,768개,
클래스당 사진 1장'

짜리 분류 문제를 매번 새로 풀
분류기는 한 번 만들어 캐시 → 비용 상각

#03 Prompt engineering · 클래스 이름만으로는 부족하다

문제 ① 다의어

crane — 크레인? 두루미?

ImageNet에 둘 다 있다

boxer — 개 품종? 권투 선수?

Oxford-IIIT Pets

문제 ② 분포 차이

사전학습 텍스트는 대부분

문장인데

라벨은 단어 하나

해결 — 문장으로 감싸고, 여러 개를 평균

"A photo of a {label}." ImageNet +1.3%p

"A photo of a {label}, a type of pet."

"a satellite photo of a {label}."

OCR 과제는 글자·숫자를 따옴표로 감싸기

80개 템플릿 앙상블 +3.5%p

텍스트 임베딩을 평균해 하나만 캐시 → 예측 비용 그대로




Figure 4 · 36개 데이터셋 평균 약 5%p 향상
= 연산 4배의 효과, 그러나 추론 비용은 그대로

#03 Zero-shot 결과 · 라벨 없이 지도학습 기준선과 경쟁

ImageNet zero-shot top-1


11.5% → 76.2%

Visual N-Grams (2017) → CLIP
top-5 95% · aYahoo 72.4→98.4 · SUN 23.0→58.5

Figure 5 · vs 지도학습 기준선
ResNet-50 특징 + 로지스틱 회귀 (라벨 전부 사용)

27개 중 16개 승 (ImageNet 포함)

- 강한 곳
- 차종 +28.9 · 음식 +22.5
- 행동 인식 Kinetics700 +14.5 ← 동사 개념
- 약한 곳
- 위성 -37.1 · 차까지 거리 -34.0
- 종양 -19.5 · 개수 세기 -18.2



출처: Radford et al. (2021) §3.1.3, §3.1.5, Table 1, Figure 5 · ※ 규모 차이가 커서 Visual N-Grams와의 직접적인 방법 비교는 아님 (§3.1.3)

#03 Zero-shot vs Few-shot · 말 한마디 = 라벨 몇 장?




Figure 6 · 20개 데이터셋 평균, 같은 특징 위
few-shot 선형 분류기와 비교

출처: Radford et al. (2021) §3.1.5, Figure 6–7

4-shot

같은 CLIP 특징 위
4-shot 분류기와 동급

16-shot

ImageNet에서는
16-shot과 동급

zero-shot을 따라잡는 데 필요한 클래스당 라벨 수
중앙값 5.4 · 평균 20.8 · 범위 0.9 ~ 184

왜 예시보다 말이 나올까?

- 사진 한 장에는 개념이 여러 개 — 예시만으로는 '무엇을' 가르치려는지 모호하다
- 자연어는 개념을 직접 '전달'한다
- 역설: CLIP 특징 위 1~2-shot 분류기는 zero-shot보다 낫다 → 사전지식을 few-shot에 녹이는 법이 숙제

#03 Linear probe · 표현 자체도 최고 수준




Figure 10 (오른쪽) · 27개 데이터셋 linear probe 평균 vs 연산량




Figure 11 · CLIP vs Noisy Student EfficientNet-L2

왜 linear probe?

인코더는 고정, 선형 분류기만 학습

fine-tuning은 사전학습의 실패를 가릴 수 있다

66개 모델 × 27개 데이터셋을 공정하게

결과

기존 최고 대비 +5%p (27개 평균)

27개 중 21개 승

ViT가 ResNet보다 연산 효율 약 3배

복습과제 연결

linear probe = 교재 5.3.1 특성 추출

#03 Robustness · 바나나는 어디서나 바나나




Figure 13 · (왼쪽) 7개 자연 분포 이동 데이터셋 평균 vs ImageNet 정확도 (오른쪽) '바나나' 예시 — ImageNet 정확도가 같은 두 모델

robustness gap
최대 75% 감소

effective robustness
ImageNet 정확도로 예상되는 수준보다 얼마나
더 강건한가

같은 ImageNet 76.2%인데
ImageNet-R 37.7 → 88.9
ImageNet-A 2.7 → 77.1

#03 ImageNet에 맞추면 · 정확도는 오르고, 강건성은 내려간다




Figure 14 (오른쪽) · zero-shot 분류기 대비 정확도 변화

Adapt to ImageNet

CLIP 특징 + ImageNet 로지스틱 회귀

ImageNet +9.2%p → 85.4%

그러나 분포 이동 7종 평균은 소폭 하락

ImageNet-R -4.7 · ObjectNet -3.8 · Sketch -2.8

Adapt to class shift

데이터셋별 클래스 이름으로 분류기를 다시 작성


effective robustness +5%p

분포 특화 데이터를 적게 쓸수록 강건,
대신 그 데이터셋 성능은 손해

원인은 데이터? 언어? — 저자들도 미해결 → 토의 ①

04. Limitations & Discussion

CLIP이 못 하는 것, 그리고 남은 질문



#04 한계 · 저자들이 스스로 밝힌 약점



아직 SOTA와 거리

zero-shot은 ResNet-50 선형 분류기 수준. SOTA까지 연산이 약 1,000배 더 필요하다고 추정



약한 과제

차종·꽃 같은 세분류, 개수 세기, 처음 보는 과제 (차까지 거리 → 거의 무작위)



진짜 OOD에 취약

손글씨 MNIST zero-shot 88% — 픽셀 위 로지스틱 회귀보다 낮다



선택지 안에서만

주어진 클래스 중 고를 뿐, 캡션처럼 새 답을 생성하지 못함 → 대조 + 생성 결합 제안



데이터 비효율

학습 중 본 이미지는 128억 장 — 1초에 한 장씩 봐도 405년이 걸린다



평가 방법론 · 편향

검증셋을 반복해서 봄 · 27개 데이터셋도 CLIP과 함께 고름 · 웹 데이터의 사회적 편향

사람 vs CLIP

4장 · 반려동물 37품종

53.7%

사람 zero-shot

75.7%

사람 one-shot

93.5%

CLIP zero-shot

사람은 예시 1장으로 크게 오르지만
CLIP의 few-shot은 오히려 하락하기도

#04 그 이후의 CLIP · 부품이 된 모델

CLIP을 부품으로 쓰는 모델 이미지·텍스트를 같은 공간에 놓는 인코더가 필요할 때



DALL-E 2 2022

텍스트 → 이미지 생성. CLIP 이미지 임베딩을 중간 표현으로 써서 그림을 만든다



Stable Diffusion 2022

v1은 프롬프트를 CLIP ViT-L/14 텍스트 인코더로 인코딩해 생성을 조건화



LLaVA 2023

CLIP ViT-L/14 이미지 인코더 + 대형 언어 모델 → 이미지를 보고 대화

학습 방법의 후속 더 크게 · 더 공개적으로 · 더 가볍게



ALIGN 2021

필터링을 최소화한 alt-text 18억 쌍 — 데이터의 노이즈를 규모로 이긴다



OpenCLIP 2021~

공개 데이터 LAION으로 CLIP을 재현하고, 스케일링 법칙까지 분석



SigLIP 2023

softmax 대신 쌍별 sigmoid 손실 → 배치 전체 정규화가 필요 없어 작은 배치에도 강함

CLIP = 이미지와 텍스트를 같은 공간에 놓는 범용 부품 생성 · 검색 · 멀티모달 LLM의 공통 기반

#04 토의 주제 · 세션에서 함께 이야기할 것

토의 ① CLIP의 강건성은 '언어' 덕분인가, '데이터' 덕분인가?

논문 근거 §3.3 — zero-shot CLIP은 robustness gap을 최대 75% 줄였지만, ImageNet에 맞추면 그 이점이 사라진다(Fig. 14).

저자들도 원인이 '크고 다양한 데이터'인지 '자연어 감독'인지 확신하지 못함

후속 연구 Fang et al. (ICML 2022) — 강건성의 주원인은 학습 데이터 분포의 다양성. 데이터 크기·언어 감독·대조 손실·테스트 시 프롬프트의 기여는 거의 없음

생각해 볼 질문 그렇다면 CLIP에서 '자연어'의 진짜 기여는? 대규모 데이터 수집을 가능하게 한 것? zero-shot이라는 인터페이스?

토의 ② 대조 학습은 무엇을 포기했나?

논문 근거 §2.3 — 정확한 단어 대신 '짝'만 맞혀 효율 4배 · §8 — 이미지와 텍스트는 내적 한 번으로만 만난다 · §6 — 대조 + 생성 목표의 결합을 제안

후속 연구 Yuksekgonul et al. (ICLR 2023) — "the horse is eating the grass"와 "the grass is eating the horse"를 잘 구분하지 못해 bag-of-words처럼 동작 (검색 데이터는 어순 없이도 풀리기 때문)

생각해 볼 질문 4배의 효율과 맞바꾼 이 선택은 정당했나? 지금 다시 설계한다면 무엇을 바꿀까?

THANK YOU

Radford et al., Learning Transferable Visual Models From Natural Language Supervision, ICML 2021

