



InstructGPT

2437003 강유진

논문 선정 이유

LLM과 강화학습의 연결

Transformer가 생성하는 토큰 확률을 정책으로 보고,
사람의 선호를 보상으로 학습하는 과정을 이해하고자 했다.

스터디에서 이어진 질문

지도학습으로 좋은 답변을 보여준 뒤,
왜 보상 모델과 PPO를 추가하는지 확인하고자 했다.

발표에서 확인할 내용

SFT와 RLHF의 역할 차이, 성능 개선의 근거,
사람의 선호를 학습할 때 생기는 한계를 함께 살펴본다.

목차

#01 Introduction

#02 Related work

#03 Methods and experimental details

#04 Results

#05 Discussion



#01 Introduction

문제: 학습 목표와 사용자 의도의 차이

다음 토큰을 예측하는 목표만으로는
지시 수행, 사실성, 유해성 억제를 충분히 보장하기 어렵다.

연구 질문

사전학습한 GPT-3를 사람의 시범과 선호도로 조정하면
다양한 사용자 지시를 더 잘 따를 수 있을까?

핵심 결과

API 프롬프트 평가에서 1.3B InstructGPT의 답변을
175B GPT-3의 답변보다 더 선호했다.

#02 Related work

사람의 피드백으로 학습

로봇·게임에서 시작한 RLHF를 텍스트 요약 등에 적용했다.
이 논문은 이를 여러 종류의 언어 지시로 확장한다.

Instruction tuning


FLAN·T0 등은 공개 NLP 과제를 지시문과 함께 학습한다.
InstructGPT는 사용자 프롬프트와 사람의 선호를 활용한다.

언어 모델의 위험과 행동 조정


독성·편향 평가, 데이터 필터링, 생성 제어와 연결된다.
RLHF는 언어 모델의 행동을 조정하는 방법 중 하나다.

03 Methods

Methods and experimental details



3.1 High-level methodology



사람의 시범으로 SFT를 학습하고, 선호도 점수로 정책을 추가 조정한다

3.2 Dataset

단계	학습 프롬프트	학습 신호
SFT	약 13k	사람이 작성한 시범 답변
RM	약 33k	여러 답변에 대한 선호 순위
PPO	약 31k	프롬프트와 RM의 보상

사용자 ID로 데이터를 분할하고, 중복과 학습 프롬프트의 개인정보를 줄인다

3.3 Tasks

실제 사용에 가까운 과제 분포

생성 45.6%, 브레인스토밍 11.2%로
개방형 과제가 큰 비중을 차지한다.

지시를 표현하는 여러 방식

직접적인 명령문 외에도 few-shot 예시나
문장의 이어쓰기를 통해 사용자의 의도를 전달한다.

데이터의 범위

학습 데이터의 96% 이상이 영어다.
비영어와 코드 과제는 뒤에서 정성적으로 확인한다.

3.4 Human data collection

약 40명의 라벨러

Upwork와 Scale AI를 통해 고용하고,
민감한 프롬프트 평가 등을 포함한 선별 시험을 진행했다.

시범 답변과 답변 순위 수집

지침과 연구진의 피드백을 공유하며 데이터를 만들었다.
학습 라벨러 간 선호 일치율은 $72.6 \pm 1.5\%$ 였다.

학습과 최종 평가의 우선순위

학습에서는 사용자에게 도움이 되는 답변을 우선했다.
최종 평가에서는 사실성과 무해성을 우선하도록 요청했다.

3.5 Models: SFT

출발점

GPT-3 사전학습 모델을 사용한다.
정책 모델의 크기는 1.3B, 6B, 175B다.

Supervised fine-tuning

프롬프트에 대해 사람이 작성한 답변을 학습한다.
좋은 응답을 직접 보여주는 단계다.

체크포인트 선택

16 epoch 학습 후, 검증셋의 RM 점수로 모델을 선택했다.
검증 손실과 사람의 선호가 항상 같은 방향으로 움직이지 않았다.

3.5 Models: Reward model

입력과 출력

프롬프트 x 와 답변 y 를 입력받아
선호도를 나타내는 스칼라 점수 $r_{\theta}(x, y)$ 를 출력한다.

사람의 순위를 쌍 비교로 변환

한 프롬프트에 $k = 4-9$ 개 답변을 순위화한다.
같은 프롬프트의 모든 쌍 비교를 한 묶음으로 학습한다.

학습 방향

선호 답변 y_w 의 점수가 비선호 답변 y_l 보다 높아지도록 한다.
이 논문은 계산량과 안정성을 고려해 6B RM을 사용했다.

쌍 비교 항: $-\log \sigma(r_{\theta}(x, y_w) - r_{\theta}(x, y_l))$

3.5 Models: LLM을 정책으로 보기

강화학습 개념	언어 생성에서의 의미
State	프롬프트와 지금까지 생성한 토큰
Action / Policy	다음 토큰 / LLM의 토큰 확률
Reward	완성된 응답의 RM 점수와 KL 페널티
Value / Advantage	기대 return / 기대보다 얼마나 더 좋은가

같은 Transformer를 정책으로 학습한다. Value 함수는 RM에서 초기화한다

3.5 Models: PPO 보충 설명

Advantage로 정책을 조정

기대보다 좋은 행동의 확률을 높이고,
기대보다 나쁜 행동의 확률을 낮춘다.

Clipping의 역할

이전 정책과 새 정책의 확률비를 이용해
지나친 개선 방향의 업데이트 유인을 줄인다.

InstructGPT의 KL 페널티

PPO clipping은 이전 정책과의 변화를 다룬다.
KL 페널티는 고정된 SFT 정책으로부터의 이탈을 억제한다.

$$r_t = \pi_{\text{new}}(a_t | s_t) / \pi_{\text{old}}(a_t | s_t)$$

3.5 Models: PPO와 PPO-ptx

RM 점수 최대화

사람이 선호할 것으로 예측한 응답을
정책이 더 자주 생성하도록 학습한다.

SFT 정책에 대한 KL 페널티

보상 모델의 점수만 과도하게 최적화하면서
기존 언어 능력을 손상하는 현상을 줄인다.

사전학습 데이터의 업데이트 혼합

PPO-ptx는 사전학습 데이터의 log-likelihood 항을 추가한다.
논문에서 InstructGPT는 기본적으로 PPO-ptx를 가리킨다.

목표 = 기대 RM 점수 - $\beta \cdot \text{KL}$ + $\gamma \cdot \text{사전학습 log-likelihood}$

3.6 Evaluation

API 분포의 사람 평가

학습에 포함하지 않은 고객의 프롬프트로 비교한다.
175B SFT 대비 선호 승률과 1–7점 품질 점수를 측정한다.

공개 데이터셋 평가


TruthfulQA, RealToxicityPrompts, 편향 데이터셋과
기존 NLP 과제의 zero-shot 성능을 함께 확인한다.

측정 범위


Helpful·honest·harmless를 여러 지표로 근사한다.
선호도와 사실성·안전성이 완전히 일치하지는 않는다.

04 Results

API 평가와 공개 데이터셋, 정성적 사례



4.1 API 분포: 사람의 선호



85 ± 3%

175B InstructGPT를
175B GPT-3보다 선호

71 ± 4%

few-shot 175B GPT-3와
직접 비교한 선호율

그림의 세로축은 175B SFT 대비 승률이다. 오른쪽 수치는 GPT-3와의 직접 비교다

4.1 API 분포: 지시 수행과 환각

평가 항목	GPT-3와 비교한 InstructGPT
올바른 지시 수행	더 자주 시도
명시한 제약 조건 준수	개선
고객 도우미에게 적절한 표현	개선
Closed-domain 환각률	41%에서 21%로 감소

환각률은 요약·입력 기반 QA처럼 입력에 근거해야 하는 과제에서 측정했다

4.1 API 분포: 일반화와 비교 모델

새로운 라벨러의 선호

학습에 참여하지 않은 라벨러도 InstructGPT를 선호했다.
RM 정확도는 학습 라벨러 72.4%, 새 라벨러 69.6%였다.


FLAN·T0와의 직접 비교

175B InstructGPT의 선호율은
FLAN 대비 $78 \pm 4\%$, T0 대비 $79 \pm 4\%$ 였다.

해석 범위

공개 과제 데이터만으로 실제 API 사용 분포를 충분히 담기 어렵다.
같은 공급업체의 라벨러 평가를 모든 사람에게 일반화할 수는 없다.

4.2 공개 데이터셋: 사실성



사실성 개선


PPO 모델의 전반적 개선

남은 차이

기권은 사실성을 높여도
정보성을 보장하지 않는다

회색은 사실성, 색 막대는 사실성과 정보성을 함께 만족하는 답변 비율이다

4.2 공개 데이터셋: 독성과 편향



독성

Respectful 조건에서 개선

편향

Winogender·CrowS-Pairs에서
유의한 개선 없음

독성 개선은 respectful 지시가 있을 때 관찰했다. 편향 감소는 확인하지 못했다

4.2 공개 데이터셋: Alignment tax

학습 방식	사람의 선호	기존 NLP 과제 성능
PPO	GPT-3보다 개선	일부 과제에서 감소
PPO-ptx	큰 감소 없이 유지	성능 저하를 대부분 완화
KL 계수만 증가	검증 보상 감소	성능을 완전히 복원하지 못함

PPO-ptx도 DROP·SQuADv2·번역에서 GPT-3와의 격차가 남았다

4.3 Qualitative results

학습 분포 밖의 지시 수행

비영어 지시와 코드 설명·QA에서 일반화 가능성을 보였다.
논문은 이를 정성적 예시로 제시했다.

잘못된 전제 수용


“명상 후 양말을 먹는 것이 왜 중요한가?”처럼
틀린 전제가 있는 질문을 그대로 받아들일 수 있었다.

과도한 유보와 복잡한 제약

간단한 질문에도 답변을 지나치게 유보하고,
여러 제약 조건을 동시에 따르는 데 실패할 수 있었다.

05 Discussion

정렬 대상, 한계와 사회적 영향



5.1 Implications for alignment research

기존 모델의 행동을 개선하는 비용

175B PPO-ptx 학습은 60 PF/s-days로,
GPT-3 사전학습 3,640 PF/s-days보다 작았다.

다른 과제로의 일반화 가능성

직접 감독한 데이터가 적은 과제에서도
지시 수행이 일부 일반화할 수 있음을 관찰했다.

실제 사용과 낮은 alignment tax

실제 사용자 프롬프트로 효과와 한계를 검증하고,
기존 능력의 손실을 줄이는 방법을 함께 평가했다.

5.2 Who are we aligning to?

라벨러가 제공한 시범과 선호

문화적 배경, 개인 경험, 지침에 따라 좋은 답변에 대한 판단이 달라진다.

연구진이 정한 평가 기준

연구진이 작성한 지침과 인터페이스, 경계 사례에 대한 설명도 학습 데이터에 영향을 준다.

API 고객의 사용 분포

당시 고객과 라벨러는 모든 사용자·영향받는 집단을 대표하지 않는다. 논문의 정렬 대상은 특정 집단의 선호다.

5.3 Limitations

데이터와 참여자의 대표성

약 40명의 라벨러와 영어 중심 데이터에 의존했다.
대부분의 비교는 비용 때문에 한 사람이 평가했다.

선호 평가의 불일치

라벨러 간 의견 차이가 존재한다.
평균 선호가 소수 집단의 요구를 충분히 반영하지 못할 수 있다.

모델의 남은 실패

환각·독성·편향과 잘못된 지시 수행이 남는다.
유해한 사용자 지시를 잘 따르는 문제가 생길 수 있다.

5.4 Open questions

유해한 지시와 사실 오류 대응

적대적으로 찾은 실패 사례, 데이터 필터링,
사실성을 높이는 방법과 RLHF를 함께 사용할 수 있다.

피드백과 학습 방식의 개선

순위 비교 외에 답변 수정·자연어 비평을 활용하고,
다른 정책 학습 알고리즘을 비교할 수 있다.

정렬 과정의 설계

누구의 선호를 어떤 절차로 반영할지,
참여·투명성·합의를 어떻게 확보할지 남아 있다.

5.5 Broader impacts

도움이 되는 방향

사용자 의도에 맞는 답변과 사실성을 개선할 가능성이 있다.
모델이 더 커질수록 정렬의 중요성도 커질 수 있다.

악용 가능성

지시 수행 능력이 좋아지면
허위정보나 유해한 내용의 생성도 쉬워질 수 있다.

배포 방식과 책임

API 제한·모니터링은 악용을 줄이는 수단이지만,
투명성과 접근성, 권한 집종의 문제를 함께 고려해야 한다.

References와 부록 안내

발표 논문

Ouyang et al. (2022), Training language models to follow instructions with human feedback, arXiv:2203.02155v1

PPO 보충 참고

Schulman et al. (2017), Proximal Policy Optimization Algorithms, arXiv:1707.06347

원문 부록

A: 데이터 / B: 인간 데이터 수집 / C: 모델과 학습 상세
D: 공개 NLP 평가 / E: 추가 실험 결과

THANK YOU

Q&A

