

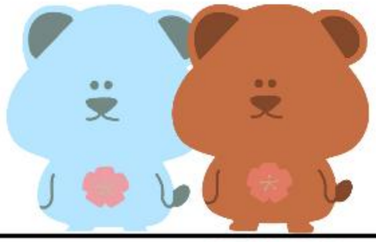
BERT

김재희

EWHA EURON

목차

1 Introduction
2 Related Work
    2.1 Unsupervised Feature-based Approaches
    2.2 Unsupervised Fine-tuning Approaches
    2.3 Transfer Learning from Supervised Data
3 BERT
    3.1 Pre-training BERT
    3.2 Fine-tuning BERT
4 Experiments
    4.1 GLUE
    4.2 SQuAD v1.1
    4.3 SQuAD v2.0
    4.4 SWAG
5 Ablation Studies
    5.1 Effect of Pre-training Tasks
    5.2 Effect of Model Size
    5.3 Feature-based Approach with BERT
6 Conclusion



EWHA EURON

1 Introduction



EWHA EURON

1 Introduction

- 언어 모델 사전학습은 많은 자연어 처리 과제의 성능을 높이는 데 효과적임이 입증되어 옴
- 여기에는 두 가지 과제가 모두 해당됨
- 문장 수준 과제(자연어 추론 등)
- 토큰 수준 과제(개체명 인식 등)
- 사전학습된 언어 표현을 downstream 과제에 적용하는 방식은 크게 두 가지
- Feature-based 방식: 사전학습된 표현을 추가 feature로 포함하는 과제별 구조 사용
- Fine-tuning 방식: 과제별 파라미터를 최소한으로 도입하고 사전학습된 모든 파라미터를 downstream 과제에서 그대로 미세조정
- 두 방식 모두 단방향 언어 모델 사용하는 것이 주류였음
- 예) OpenAI GPT는 왼쪽→오른쪽 구조를 사용하여, 모든 토큰이 Transformer의 self-attention 층에서 자기보다 앞에 있는 토큰에만 attention할 수 있음

EWHA EURON

1 Introduction

- BERT는 fine-tuning 기반 접근법을 개선한 것
- BERT는 Masked Language Model, MLM 사전학습 목적 함수 사용
- Masked Language Model: 입력 토큰 중 일부를 무작위로 가리고 가려진 단어를 오직 문맥만으로 예측하는 것을 목표로 함. 표현이 왼쪽과 오른쪽 문맥을 융합할 수 있게 해 주므로 깊은 양방향 트랜스포머를 사전학습할 수 있음

Contributions

- 양방향 사전학습의 중요성을 입증함
- 사전학습된 표현이 과제별로 고도로 설계된 구조의 필요성을 줄여 준다는 것을 보임
- 문장 수준, 토큰 수준의 대규모 과제들에서 SOTA 성능을 달성한 최초의 fine-tuning 기반 표현 모델
- 11개 NLP 과제의 SOTA를 갱신

EWHA EURON

2 Related Work



2.1 Unsupervised Feature-based Approaches

- 사전학습된 word embedding은 현대 NLP 시스템의 필수 요소로, 처음부터 학습한 embedding보다 성능이 훨씬 좋음
- Word embedding 벡터를 사전학습하기 위해 left-to-right 언어 모델링 목적 함수가 쓰였고, 왼쪽과 오른쪽 문맥에서 올바른 단어와 틀린 단어를 구분하는 목적 함수도 쓰임
- ELMo: left-to-right 언어 모델과 right-to-left 언어 모델에서 각각 문맥 의존적인 feature를 추출하고 각 토큰의 문맥 표현을 위해 이 둘을 이어 붙임
- ELMo는 질의응답, 감성 분석, 개체명 인식 등 여러 주요 NLP 벤치마크에서 SOTA 갱신
- Melamud et al. (2016)은 LSTM으로 좌우 문맥에서 단일 단어를 예측하는 과제를 통해 문맥 표현을 학습하는 방법을 제안함. 이 모델도 feature-based이며 깊은 양방향 모델은 아님.

EWHA EURON

2.2 Unsupervised Fine-tuning Approaches

- 초기 연구들은 라벨 없는 텍스트로 word embedding 파라미터만 사전학습함
- 최근에는 문장, 문서 인코더를 라벨 없는 텍스트로 사전학습한 뒤, 지도학습 downstream tasks에 맞춰 fine-tuning하는 방식이 등장. 이 접근법의 장점은 처음부터 학습해야 하는 파라미터가 적다는 것.
- 위 장점 덕분에 OpenAI GPT는 GLUE 벤치마크의 여러 문장 수준 과제에서 SOTA 달성. 해당 모델의 사전학습에는 left-to-right 언어 모델링과 auto-encoder 목적 함수가 사용됨

	ELMo	OpenAI GPT	BERT
방식	Feature-based	Fine-tuning	Fine-tuning
방향성	L->R, R->L을 이어붙임 (얕은 양방향)	L->R 단방향	깊은 양방향

EWHA EURON

2.3 Transfer Learning from Supervised Data

- 대규모 데이터셋을 가진 지도학습 과제로부터 효과적으로 transfer할 수 있음을 보인 연구도 존재
- 자연어 추론(Conneau et al., 2017)
- 기계 번역(McCann et al., 2017)
- 컴퓨터 비전에서도 대규모 사전학습 모델로부터의 전이 학습이 중요함이 입증됨. ImageNet으로 사전학습된 모델을 fine-tuning하는 것이 효과적(Deng et al., 2009; Yosinski et al., 2014)

EWHA EURON

3 BERT



EWHA EURON

3 BERT

- 크게 사전학습(pre-training)과 미세조정(fine-tuning) 두 단계로 나뉨
- 사전학습: 라벨 없는 데이터로 여러 사전학습 과제를 수행하며 모델 학습
- 미세조정: 사전학습된 파라미터로 BERT 초기화하고 downstream 과제의 라벨 데이터로 모든 파라미터 미세조정. 같은 사전학습 파라미터로 초기화하더라도 downstream 과제마다 별도의 모델이 생김.
- BERT의 큰 특징은 여러 과제에 걸쳐 구조가 통일되어 있다는 것. 사전학습 구조와 최종 downstream 구조의 차이가 매우 작음.

EWHA EURON

3 BERT

Model Architecture

- 전체 구조는 다층 양방향 Transformer 인코더
- L: transformer block(층) 수
- H: hidden size
- A: self-attention head 수
- Feed-forward 크기는 항상 4H
- 본 연구에서는 두 가지 모델의 결과를 보여줌
- BERT-BASE는 OpenAI GPT와 모델 크기 동일
- 결정적인 차이: BERT의 Transformer는 양방향 self-attention 사용, GPT의 Transformer는 모든 토큰이 자기 왼쪽만 attend하는 제약된 self-attention 사용

	L	H	A	총 파라미터
BERT-BASE	12	768	12	110M
BERT-LARGE	24	1024	16	340M

EWHA EURON

3 BERT

Input/Output Representations

- BERT가 다양한 downstream 과제를 처리할 수 있도록 입력 표현은 단일 문장과 문장 쌍(예: <질문, 답>)을 하나의 토큰 시퀀스로 모호함 없이 표현할 수 있게 설계함
- 본 논문에서 문장(sentence)은 실제 언어학적 문장이 아니라 연속된 임의의 텍스트 구간
- 시퀀스는 BERT의 입력 토큰열로 문장 하나일 수도, 문장 두 개를 합친 것일 수도 있음
- Wordpiece embedding 사용, vocabulary 크기 30,000
- 모든 시퀀스의 첫 토큰은 항상 특수 분류 토큰 [CLS]이며 이 토큰에 대응하는 마지막 hidden state를 분류 과제의 시퀀스 전체 표현으로 씀

EWHA EURON

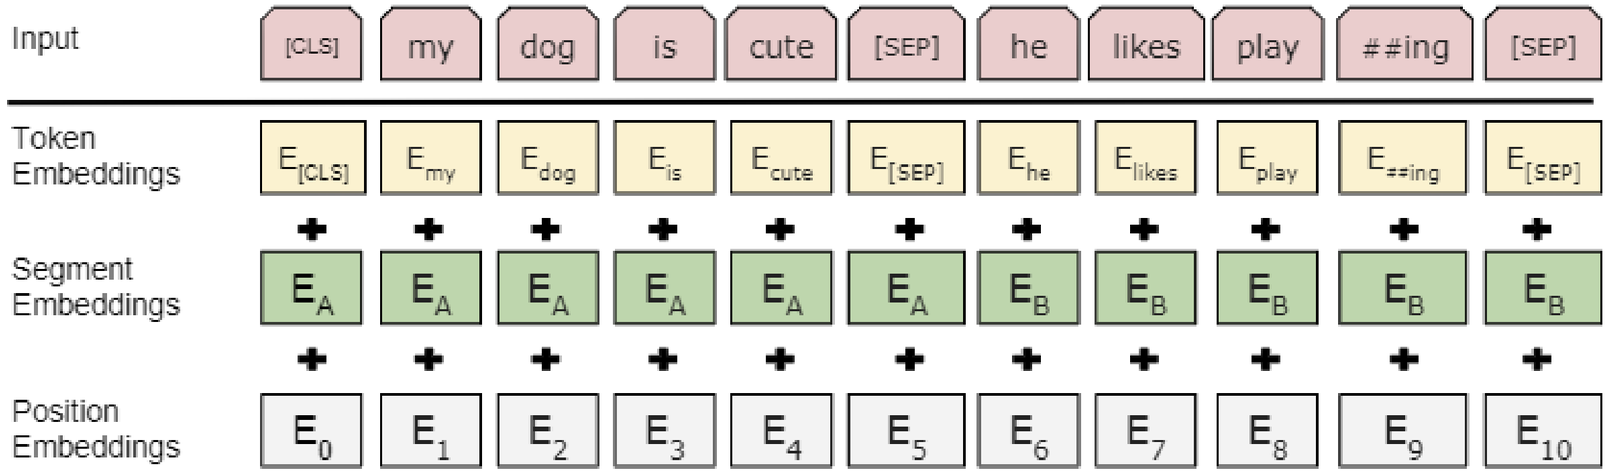
3 BERT

- 문장 쌍은 하나의 시퀀스로 합치고 두 문장을 두 가지 방법으로 구분

1. 특수 토큰 [SEP]으로 분리

2. 각 토큰이 문장 A에 속하는지 B에 속하는지를 나타내는 학습된 embedding 추가

- 토큰 하나의 입력 표현은 해당하는 토큰 + 세그먼트 + 위치 embedding을 모두 더해 만듦



3.1 Pre-training BERT

- BERT는 두 가지 비지도 과제로 사전학습함

1. **Masked LM (MLM)**

- 양방향 학습의 문제점: 각 단어가 간접적으로 자기 자신을 볼 수 있어서 다층 구조에서는 모델이 목표 단어를 너무 쉽게 맞혀버림
- 이를 해결하기 위해 입력 토큰의 일부를 무작위로 마스킹하고 그 마스킹된 토큰을 예측함. 이를 MLM 혹은 Cloze task라고 부름
- 모든 실험에서 각 시퀀스의 WordPiece 토큰 중 15%를 무작위로 마스킹함
- 문제점: pre-train / fine-tune 불일치 – [MASK] 토큰은 fine-tuning 때 나오지 않으므로 사전학습과 fine-tuning 사이에 불일치가 생김. 이를 완화하기 위해 마스킹된 단어를 항상 [MASK]로 바꾸지는 않음.

EWHA EURON

3.1 Pre-training BERT

- 학습 데이터 생성기가 예측 대상으로 토큰 위치의 15%를 무작위로 고르고 i번째 토큰이 선택되면 다음과 같이 처리함

확률	처리	예시
80%	[MASK] 토큰으로 교체	My dog is [MASK]
10%	무작위 토큰으로 교체	My dog is purple
10%	원래 토큰 그대로 유지	My dog is hairy

- 이후 Ti로 원래 토큰을 예측하고 cross entropy loss를 사용함.

EWHA EURON

3.1 Pre-training BERT

2. Next Sentence Prediction (NSP)

- downstream 과제들은 두 문장 사이의 관계를 이해하는 걸 기반으로 하는데 이는 언어 모델링만으로는 직접 학습되지 않음
- 문장 관계를 이해하는 모델을 만들기 위해 어떤 단일 언어 코퍼스에서도 쉽게 만들 수 있는 이진화된 문장 예측 과제로 사전학습함
- 사전학습 예시마다 문장 A와 B를 고를 때
  - 50%: B가 실제로 A 다음에 오는 문장 -> 라벨 IsNext
  - 50%: B가 코퍼스에서 뽑은 무작위 문장 -> 라벨 NotNext

EWHA EURON

3.1 Pre-training BERT

Pre-training Data

- BooksCorpus (8억 단어)
- English Wikipedia (25억 단어)
- 긴 연속 시퀀스를 뽑으려면 문장 단위로 섞인 코퍼스가 아니라 문서 단위 코퍼스를 쓰는 것이 매우 중요함

EWHA EURON

3.2 Fine-tuning BERT

- 텍스트 쌍을 다루는 기존 방식은 보통 각 텍스트를 독립적으로 인코딩한 뒤 양방향 cross attention을 적용하는 것
- 반면 BERT는 self-attention으로 이 두 단계를 하나로 통합함: 연결된 텍스트 쌍을 self-attention으로 인코딩하면 두 문장 사이의 양방향 cross attention이 사실상 포함됨
- 입력 측: 사전학습 문장 A, B는 각 과제에서 다음에 대응함

과제	문장 A / 문장 B
Paraphrasing	문장 쌍
Entailment	가설-전제 쌍
질의응답	질문-지문 쌍
텍스트 분류 / 시퀀스 태깅	텍스트-∅

3.2 Fine-tuning BERT

- 출력 측:

1. 토큰 수준 과제 (시퀀스 태깅, 질의응답): 각 토큰의 표현을 출력층에 넣음

2. 분류 과제 (entailment, 감성 분석): [CLS] 표현을 출력층에 넣음

- 사전학습에 비하면 fine-tuning 비용은 훨씬 적음

- 논문의 모든 결과는 동일한 사전학습 모델에서 시작해

단일 Cloud TPU로 최대 1시간, GPU로는 몇 시간이면

재현 가능

EWHA EURON

4 Experiments



EWHA EURON

4.1 GLUE

GLUE: 다양한 자연어 이해 과제를 모아놓은 것

Fine-tuning 방법

- 입력 시퀀스는 앞서 설명한 방식으로 표현
- 첫 입력 토큰([CLS])에 대응하는 최종 hidden vector $C \in \mathbb{R}^H$를 시퀀스 전체의 표현으로 씀

하이퍼파라미터

- batch size 32, 모든 GLUE 과제에서 3 epoch fine-tuning
- learning rate는 Dev set 기준으로 {5e-5, 4e-5, 3e-5, 2e-5} 중 최선을 선택

EWHA EURON

4.1 GLUE

핵심 결과

- BERT-BASE와 BERT-LARGE는 모든 과제에서 기존 시스템을 큰 격차로 능가했고 이전 SOTA 대비 평균 정확도가 각각 +4.5%, +7.0% 향상됨
- BERT-BASE와 OpenAI GPT는 attention masking을 빼면 모델 구조가 거의 동일
- 가장 큰 GLUE 과제인 MNLI에서 BERT는 +4.6% 절대 정확도 향상을 얻음
- 공식 GLUE 리더보드에서 BERT-LARGE는 80.5점으로 OpenAI GPT의 72.8점(논문 작성 시점)보다 높음
- BERT-LARGE는 모든 과제에서 BERT-BASE를 크게 앞서며 특히 학습 데이터가 매우 적은 과제에서 격차가 큼

EWHA EURON

4.2 SQuAD v1.1

SQuAD v1.1: 크라우드소싱으로 만든 10만 개의 질문/답 쌍. 질문과 답이 들어 있는 Wikipedia 지문이 주어지면 지문 안에서 답이 되는 텍스트 구간을 예측하는 과제

Fine-tuning 방법

- 질문과 지문을 하나의 시퀀스로 묶음. 질문은 A embedding, 지문은 B embedding 사용
- fine-tuning 중 새로 도입하는 파라미터는 시작 벡터 $S \in \mathbb{R}^H$와 끝 벡터 $E \in \mathbb{R}^H$ 두 개뿐
- 단어 i가 답의 시작일 확률은 T_i와 S의 내적에 지문 내 모든 단어에 대한 softmax를 적용해 계산
- 학습 목표는 정답 시작/끝 위치의 log-likelihood 합
- 3 epoch, learning rate 5e-5, batch size 32로 fine-tuning

4.2 SQuAD v1.1

핵심 결과

- 최고 성능 시스템이 리더보드 1위를 앙상블 +1.5 F1, 단일 모델 +1.3 F1로 능가
- 단일 BERT 모델이 리더보드 1위 앙상블보다 F10이 높음
- TriviaQA 데이터 없이도 F1 손실은 0.1~0.4에 그치고 여전히 기존 시스템들을 큰 폭으로 앞섬

4.3 SQuAD v2.0

SQuAD 2.0은 지문에 짧은 답이 존재하지 않을 가능성을 허용함. 그래서 문제 정의가 더 현실적

Fine-tuning 방법

- 답이 없는 질문은 시작과 끝이 모두 [CLS] 토큰인 답 구간으로 취급
- 시작/끝 위치의 확률 공간을 [CLS] 위치까지 포함하도록 확장
- TriviaQA 데이터는 사용하지 않음
- 2 epoch, learning rate 5e-5, batch size 48로 fine-tuning

결과

- 이전 SOTA 대비 F1+5.1 향상을 보임

EWHA EURON

4.4 SWAG

SWAG: 11만 3천 개의 문장 쌍 예제로 이루어져 상식 추론 능력을 평가함. 문장이 주어지면 네 개의 선택지 중 가장 그럴듯한 이어지는 문장을 고르는 과제

Fine-tuning 방법

- 주어진 문장(문장 A)과 가능한 이어지는 문장(문장 B)을 이어 붙인 입력 시퀀스 4개 만듦
- 새로 도입되는 과제별 파라미터는 벡터 하나. 이 벡터와 [CLS] 표현 C의 내적이 각 선택지의 점수가 되고 이 점수들을 softmax로 정규화함
- 3 epoch, learning rate 2e-5, batch size 16으로 fine-tuning

결과

- BERT-LARGE는 저자들의 baseline인 ESIM+ELMo보다 +27.1%, OpenAI GPT보다 +8.3% 높음
- 사람 expert 한 명 점수(85.0)를 뛰어넘음(86.3)

EWHA EURON

5 Ablation Studies



5.1 Effect of Pre-training Tasks

BERT-BASE와 사전학습 데이터, fine-tuning 방식, 하이퍼파라미터를 완전히 동일하게 두고 두 가지 변형을 비교해

깊은 양방향성이 얼마나 중요한지 확인함

- No NSP: MLM은 쓰되 NSP 과제 없이 학습한 양방향 모델
- LTR & No NSP: MLM 대신 표준 Left-to-Right LM으로 학습하고 NSP도 뺀 모델

EWHA EURON

5.1 Effect of Pre-training Tasks

결과

Tasks	Dev Set MNLI-m (Acc)	QNLI (Acc)	MRPC (Acc)	SST-2 (Acc)	SQuAD (F1)
$\text{BERT}_{\text{BASE}}$	84.4	88.4	86.7	92.7	88.5
No NSP	83.9	84.9	86.5	92.6	87.9
LTR & No NSP	82.1	84.3	77.5	92.1	77.8
+ BiLSTM	82.1	84.1	75.7	91.6	84.9

- NSP 효과: NSP를 빼면 QNLI, MNLI, SQuAD 1.1에서 성능이 눈에 띄게 하락함
- 양방향성 효과: LTR 모델은 모든 과제에서 MLM 모델보다 나쁘고 특히 MRPC와 SQuAD에서 하락 폭이 큼
- LTR 시스템을 강화하기 위해 랜덤 초기화 BiLSTM을 위에 얹음. SQuAD는 크게 개선되지만 사전학습된 양방향 모델에는 한참 못 미침.

EWHA EURON

5.1 Effect of Pre-training Tasks

ELMo와 비교하면 다음 이유로 BERT가 나음:

- 단일 양방향 모델보다 비용이 2배임
- QA 같은 과제에서 직관적이지 않음. RTL 모델은 답을 질문에 조건화할 수 없음
- 모든 층에서 좌우 문맥을 쓰는 깊은 양방향 모델보다 덜 강력함

EWHA EURON

5.2 Effect of Model Size

층 수, hidden unit 수, attention head 수를 달리한 여러 BERT 모델을 학습하고 나머지 하이퍼파라미터와 학습 절차는 앞과 동일하게 유지함

Hyperparams				Dev Set Accuracy		
#L	#H	#A	LM (ppl)	MNLI-m	MRPC	SST-2
3	768	12	5.84	77.9	79.8	88.4
6	768	3	5.24	80.6	82.2	90.7
6	768	12	4.68	81.9	84.8	91.3
12	768	12	3.99	84.4	86.7	92.9
12	1024	16	3.54	85.7	86.9	93.3
24	1024	16	3.23	86.6	87.8	93.7

LM(ppl): held-out 학습 데이터에 대한 masked LM perplexity. 낮을수록 좋음

- 모델이 클수록 네 개 데이터셋 모두에서 정확도가 향상됨
- 충분히 사전학습만 되어 있다면 극단적으로 큰 모델이 아주 작은 규모의 과제에서도 큰 개선을 보여준다는 것을 보인 첫 연구라고 주장함

EWHA EURON

5.2 Effect of Model Size

Feature-based 연구들은 결과가 엇갈림

- Peters et al. (2018b): 사전학습 bi-LM을 2층에서 4층으로 키웠을 때 downstream 효과가 엇갈림
- Melamud et al. (2016): hidden 차원을 200→600으로 키우면 도움이 되지만 1,000까지 키우면 추가 개선이 없다고 언급

모델을 downstream 과제에 직접 fine-tuning하고 랜덤 초기화 파라미터를 아주 조금만 추가하면 downstream 데이터가 매우 적어도 더 크고 표현력 있는 사전학습 표현의 이점을 얻을 수 있음

EWHA EURON

5.3 Feature-based Approach with BERT

지금까지 BERT 결과는 모두 fine-tuning 접근이었지만 feature-based 접근에도 장점이 있음

1. 모든 과제를 Transformer 인코더 구조로 쉽게 표현할 수 있는 건 아니라서 과제별 모델 구조를 추가해야 하는 경우가 있음
2. 비싼 학습 데이터 표현을 한 번만 미리 계산해두고 그 위에서 더 싼 모델로 여러 실험을 돌리면 이득이 큼

실험 설정: CoNLL-2003 개체명 인식(NER) 과제로 두 접근을 비교

- BERT 입력에 case-preserving WordPiece 모델을 쓰고 데이터가 제공하는 최대 문서 문맥을 포함
- 출력에 CRF 층은 쓰지 않음
- 첫 번째 sub-token의 표현을 토큰 수준 분류기의 입력으로 씀
- feature-based 접근은 BERT 파라미터를 fine-tuning하지 않고 하나 이상의 층에서 activation을 뽑아 랜덤 초기화된 2층 768차원 BiLSTM의 입력으로 쓴 뒤 분류층에 넣음

EWHA EURON

5.3 Feature-based Approach with BERT

결과

System	Dev F1	Test F1
ELMo (Peters et al., 2018a)	95.7	92.2
CVT (Clark et al., 2018)	-	92.6
CSE (Akbik et al., 2018)	-	**93.1**
Fine-tuning approach		
$\text{BERT}_{\text{LARGE}}$	96.6	92.8
$\text{BERT}_{\text{BASE}}$	96.4	92.4
Feature-based approach ($\text{BERT}_{\text{BASE}}$)		
Embeddings	91.0	-
Second-to-Last Hidden	95.6	-
Last Hidden	94.9	-
Weighted Sum Last Four Hidden	95.9	-
Concat Last Four Hidden	96.1	-
Weighted Sum All 12 Layers	95.5	-

하이퍼파라미터는 Dev set으로 선택했고 Dev/Test 점수는 그 설정으로 5번 random restart한 평균

- BERT-LARGE는 SOTA 방법들과 대등한 성능을 냄
- feature-based 중 최고는 상위 4개 층의 토큰 표현을 concat한 방식이고 전체 모델을 fine-tuning한 것보다 F10이 0.3만큼만 낮음
- 즉 BERT는 fine-tuning과 feature-based 두 방식 모두에서 효과적이다.

EWHA EURON

6 Conclusion



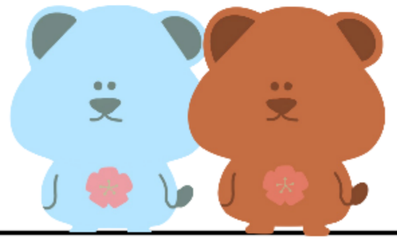
EWHA EURON

6 Conclusion

- 최근 연구들은 풍부한 비지도 사전학습이 많은 언어 이해 시스템의 필수적인 부분임을 보여줌
- 이런 결과 덕분에 자원이 적은 과제도 깊은 단방향 구조의 이점을 누릴 수 있게 됨
- 이 논문의 가장 큰 기여는 이런 발견을 깊은 양방향 구조로 일반화한 것
- 덕분에 동일한 사전학습 모델 하나로 다양한 NLP 과제를 성공적으로 처리할 수 있음

EWHA EURON

THANK YOU



EWHA EURON