

Language Models Can Easily Learn to Reason from Demonstrations

발표자 신아영

EMNLP 2025 Findings

EWHA EURON

목차

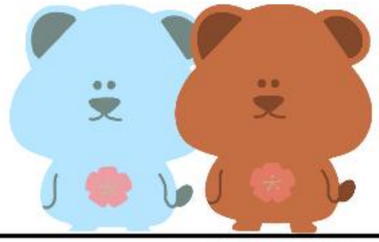
01 Introduction

02 Related Work

03 제안 방법론

04 실험 및 결과

05 결론 (배운 점)



EWHA EURON

01. Introduction



EWHA EURON

연구 분야 - Long CoT 추론

큰 추론 모델(LRM)은 어려운 문제를 풀 때 **Long CoT**(긴 사고 사슬)를 사용한다.

풀이 중간에 스스로 점검(reflection)하고, 막히면 되돌아가고(backtracking),
답을 다시 검증(self-validation)하면서 길게 이어서 생각하는 방식이다.

OpenAI o1, DeepSeek-R1, QwQ 같은 모델이 이 방식으로 수학·코딩 같은
어려운 추론 과제에서 성능을 크게 끌어올렸다.

하지만 **"이 Long CoT 능력을 어떻게 학습시키는가"**는 아직 잘 밝혀지지 않았다.

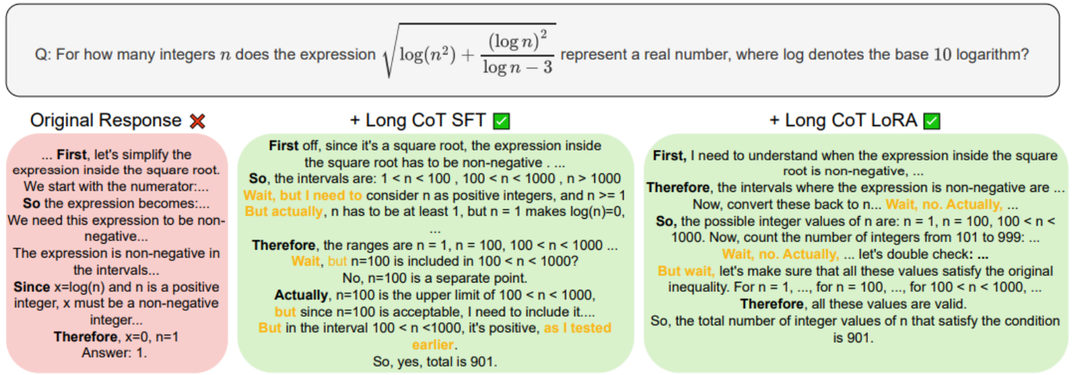


Fig 3. 미세조정된 모델이 실제로 'Wait / Actually'로 되짚으며 Long CoT를 생성

기존 연구의 한계

지금까지 Long CoT를 얻는 방법은 둘 다 문턱이 높았다.

- **닫혀 있음 :** o1처럼 학습 방법이 공개되지 않은 경우가 많다.
- **비용이 큼 :** 대규모 강화학습(RL)으로 처음부터 추론 능력을 키우려면 자원이 많이 든다.

또한 무엇이 Long CoT 학습의 '핵심'인지도 불분명했다.

데이터 양일까? 모델 크기일까? 추론 단계의 내용일까, 아니면 전체 구조일까?

→ 적은 자원으로, 그리고 무엇이 중요한지 규명하면서 Long CoT를 학습시킬 수 있을까?

EWHA EURON

논문의 Contribution

① 데이터 효율적

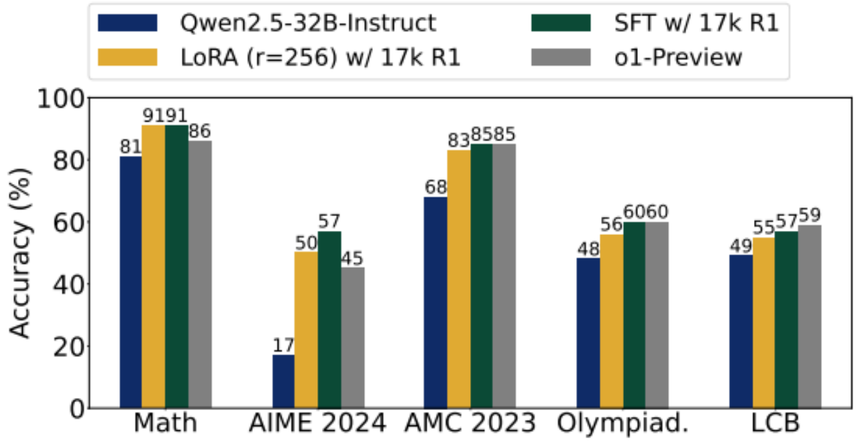
R1 기반 공개 17k 예시만으로 Qwen2.5-32B를 미세조정해 o1-preview급 성능 달성

② 파라미터 효율적

LoRA로 전체의 5% 미만 파라미터만 업데이트해도 Full 미세조정과 대등

③ 구조(structure)가 핵심

개별 추론 단계의 '내용'보다 전체 추론의 '구조'가 학습에 결정적임을 통제 실험으로 규명



02. Related Work



EWHA EURON

기존 연구와의 관계

Test-time scaling (추론 시 계산을 늘려 성능 향상)

단일 Long CoT(o1·R1·QwQ) vs 반복 샘플링(Best-of-N, MCTS). → **이 논문은 '하나의 Long CoT를 distill'하는 쪽에 집중.**

추론 능력 학습 (RL) (강화학습으로 추론을 키움)

RLVR·PRIME·DeepSeek-R1 등. Setlur et al.은 틀린 데이터로도 학습됨을 보임(RL). → **이 논문은 RL이 아니라 SFT로, 소량·소파라미터로 가능함을 보임.**

Distillation (강한 모델의 출력으로 약한 모델을 학습)

표준 기법이지만, **이 논문은 '추론 능력'도 distill되며 그 과정에서 Long CoT 구조의 역할을 규명한 점이 차별점.**

03. 제안 방법론



EWHA EURON

Main Idea

핵심 주장 : Long CoT 추론은 적은 데이터·적은 파라미터의 지도학습(SFT)만으로도 가르칠 수 있고,
이때 **추론의 '전역 구조'가 학습의 열쇠**다.

이를 확인하기 위해 두 종류의 통제 실험을 설계한다.

(A) 내용(content) 교란 : 개별 단계의 내용만 망가뜨림 — 오답 처리, 숫자 손상, 추론 키워드 제거

(B) 구조(structure) 교란 : 단계들의 전역 구조를 망가뜨림 — 단계 삭제·삽입·순서 섞기

→ 내용·구조 교란의 결과를 비교해 '전역 구조가 중요하다'는 실험적 근거를 제시한다.

EWHA EURON

어떻게 학습하고 검증했나

Distillation

Teacher(DeepSeek-R1, QwQ-32B)로 어려운 수학·코딩 문제의

Long CoT 응답을 생성 → Student(Qwen2.5-32B-Instruct)를 SFT/LoRA로 학습

학습 설정

Llama-Factory, batch 96. Full SFT는 lr 1e-5(8×H100·20h),

LoRA는 lr 1e-4로 학습.

통제 실험용 변형 데이터

QwQ로 만든 4,618개 정답 응답을 기준으로 내용·구조를 각각 교란.

구조 교란은 삭제·삽입·순서섞기 3종 × 비율 3종(33·67·100%) = 9가지.

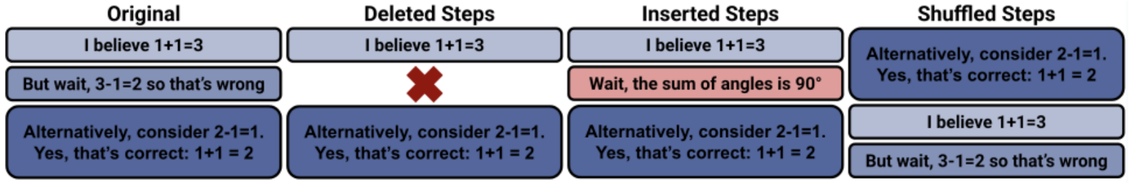


Figure 4: **Reasoning step modifications.** To evaluate perturbations to global structure across reasoning steps, we perform three modifications: deletion, insertion, and shuffling. These modifications break logical consistency across steps and degrade model accuracy far more than changes to local content within reasoning steps.

Fig 4. 구조 교란 방식 — 삭제 / 삽입 / 순서 섞기

04. 실험 및 결과



EWHA EURON

실험 셋업 - 데이터와 벤치마크

학습 데이터 — 두 종류의 Teacher로 distillation

- DeepSeek-R1 : 공개된 R1-17k reasoning dataset(Bespoke-Stratos-17k)을 그대로 사용
- QwQ-32B : 직접 수집한 수학 12k + 코딩 5k(≈17k). 7k·17k 규모로도 비교

Student / 비교 대상 : Qwen2.5-32B-Instruct(기준 모델) vs QwQ-32B, o1-preview.

벤치마크 5개 : MATH-500, AIME 2024, AMC 2023, OlympiadBench, LiveCodeBench (수학+코딩).

지표 : 정확도 (LiveCodeBench은 난이도별 가중 평균).

결과 ① Long CoT 학습의 데이터·파라미터 효율성

17k R1 예시로 SFT한 결과 (괄호는 기준 모델 대비 향상)

- Math-500 90.8% (+6.0)
- AIME 2024 56.7% **(+40.0)**
- AMC 2023 85.0% (+17.5)
- OlympiadBench 60.3% (+12.7)
- LiveCodeBench 57.0% (+8.1)

LoRA(5% 미만 파라미터)도 Full SFT와 대등하고,

QwQ는 7k만으로도 17k와 비슷 → 데이터·파라미터 모두 효율적.

[QwQ 17k의 SFT·LoRA 비교표]

	MATH500	AIME24	AMC23	Olymp.	LCB
Qwen2.5-32B-Inst	84.8	16.7	67.5	47.6	48.9
o1-preview	85.5	44.6	87.5	59.2	59.1
SFT (17k QwQ)	87.8	33.3	70.0	56.7	57.9
LoRA (17k QwQ)	86.6	33.3	90.0	56.0	56.2

결과 ② 내용이 틀려도 잘 배운다

개별 추론 내용에 오류가 있어도 성능 향상이 상당 부분 유지됐다.

오답만 학습 : 최종 답이 전부 틀린 데이터로 학습해도 평균 63.1% (정답 학습 대비 −3.2%p)

숫자 손상 : 70% 숫자를 무작위로 바꿔 '1+1=3' 같은 말이 돼도 평균 62% (−4.3%p)

키워드 제거 : 추론 키워드가 든 '문장'을 100% 제거해도 평균 63% (−3.3%p)

→ 개별 단계의 '내용 정확도'는 추론 학습에 생각보다 덜 중요했다.

결과 ③ 구조가 깨지면 치명적

반대로 전역 '구조'를 망가뜨리면 성능이 크게 떨어졌다.

순서 섞기 : 단계 67%를 섞으면 AIME24 −13.3%p (정상 데이터 학습 대비)

삭제 : 지울수록 성능이 기준 모델 수준으로 회귀

삽입 : 내용은 맞지만 맥락 없는 단계를 끼우면 기준 이하로

순서 섞기 후 응답 92%↑가 되돌아가기·자체 검증

표현으로 시작 → 표현 모방만으로는 정확도 개선이 어려움.

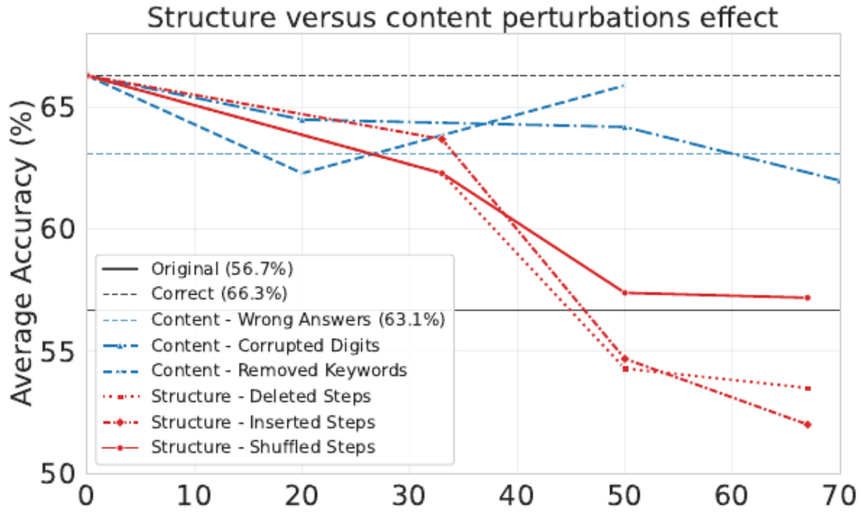


Fig 2. 구조(빨강) 교란은 내용(파랑) 교란보다 훨씬 치명적

추가 분석 (Ablations) ①

데이터 크기 (Fig 5)

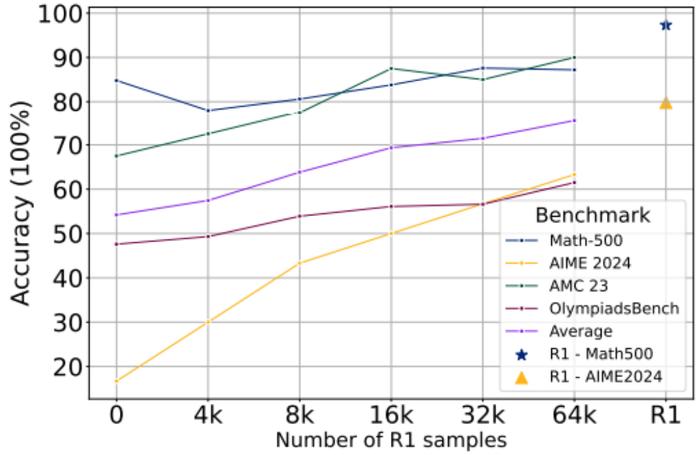
약 16k만으로 평균 +15.2%p 향상; 데이터 증가 시 추가 개선.

비추론 능력 유지 (Table 2)

MMLU·IEval은 상당 부분 유지, MGSM은 하락(42.3→33.7, R1 SFT).

다른 Student 모델 (Fig 6)

여러 모델에서 SFT 효과 확인(모델마다 향상 폭은 다름).



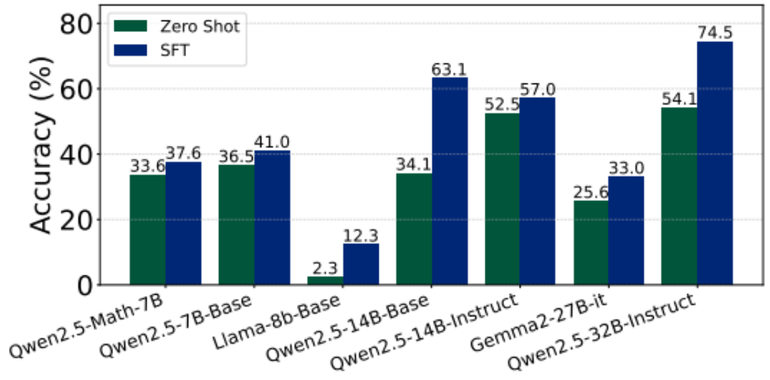


Figure 6: **Generalization to other models.** Averaged

추가 분석 (Ablations) ②

Best-of-N 비교 (Fig 7)

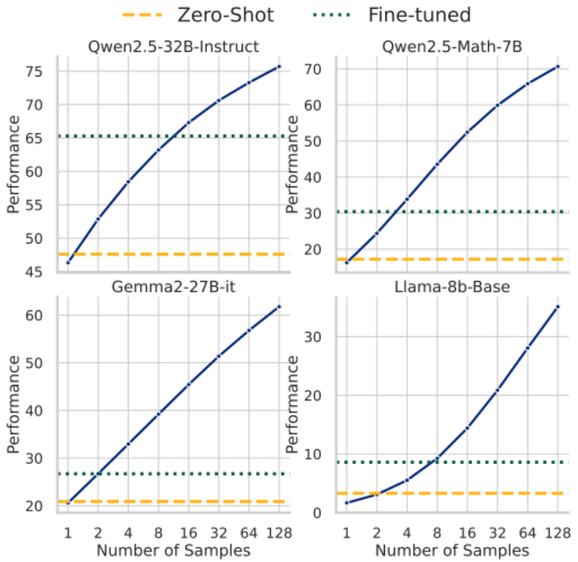
Long CoT 미세조정 ≈ 기준 모델을 Best-of 2~16으로 샘플링한 성능.

유사한 정확도 결과이며, 같은 추론 메커니즘을 뜻하지는 않음.

Short vs Long CoT (Table 3)

Long CoT가 어려운 문제일수록 더 긴 응답·더 많은 키워드로

Short CoT 대비 우위(AIME 13.3 → 40.0, +26.7%p).



성능	Original	Short	Long
MATH500	84.8	70.4	89.2
AMC23	67.5	55.0	77.5
Olympiad	47.6	36.4	58.5
AIME24	16.7	13.3	40.0

Table 3. 난이도↑일수록 Long CoT 우위 뚜렷

05. 결론



EWHA EURON

결론

의의

Long CoT 추론은 소량 데이터 + 소수 파라미터로 distill 가능하며, 개별 내용보다
전역 추론 구조가 중요하다는 실험적 근거를 제시했다. 코드·데이터 공개로 접근성↑
(단, Full SFT는 8×H100·20h 규모 - '아주 저렴'하다고 보긴 어려움).

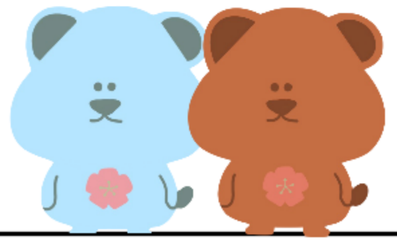
한계

SFT 기준 결론이라 RL로 학습한 추론 모델과 직접 비교는 하지 않았고,
소량(7k·17k) 기반이라 대규모 distillation으로의 일반화는 제한될 수 있다.

함께 토의할 질문

1. 오답이 포함된 추론 데이터로도 성능이 향상되었다면, 학습 데이터에서 정답의 정확성과 추론 구조 중 무엇을 더 우선해야 할까?
2. 순서 섞기 실험만으로 구조의 중요성을 충분히 설명할 수 있을까? 어떤 추가 실험이 필요할까?
3. 적은 수의 Long CoT 예시로 학습한 추론 방식이 수학·코딩 외의 새로운 과제에도 잘 일반화될까?

THANK YOU



EWHA EURON