

Language Models are Few-Shot Learners

김예나

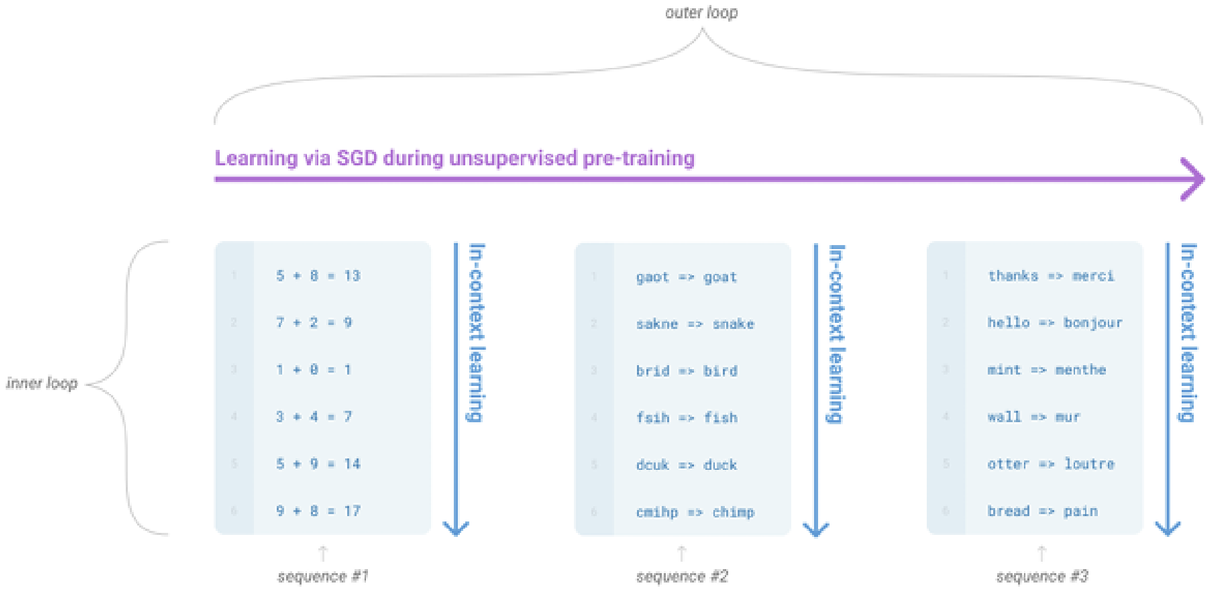
EWHA EURON

#01 Approach

#GPT-3는 무엇을 검증하는가?

- 기존 패러다임: 대규모 사전학습 후, 각 task마다 수천~수십만 개의 labeled data로 fine-tuning
- 문제 1: 새로운 task마다 데이터 수집 비용이 반복됨
- 문제 2: 좁은 fine-tuning 분포에 과적합하거나 spurious correlation을 활용할 위험
- 문제 3: 인간은 자연어 지시나 소수 예시만으로도 새로운 언어 task를 빠르게 수행함

"모델을 충분히 크게 만들면, weight update 없이도 문맥 속 예시만으로 새로운 task에 적응할 수 있는가?"



#01 Approach

Zero-shot / One-shot / Few-shot

Zero-shot

지시문만 제공
0 examples

One-shot

지시문 + 예시 1개
1 example

Few-shot

지시문 + 예시 여러 개
보통 10–100

세 설정 모두 inference 시 gradient update 없음 → “ forward pass only”

EWHA EURON

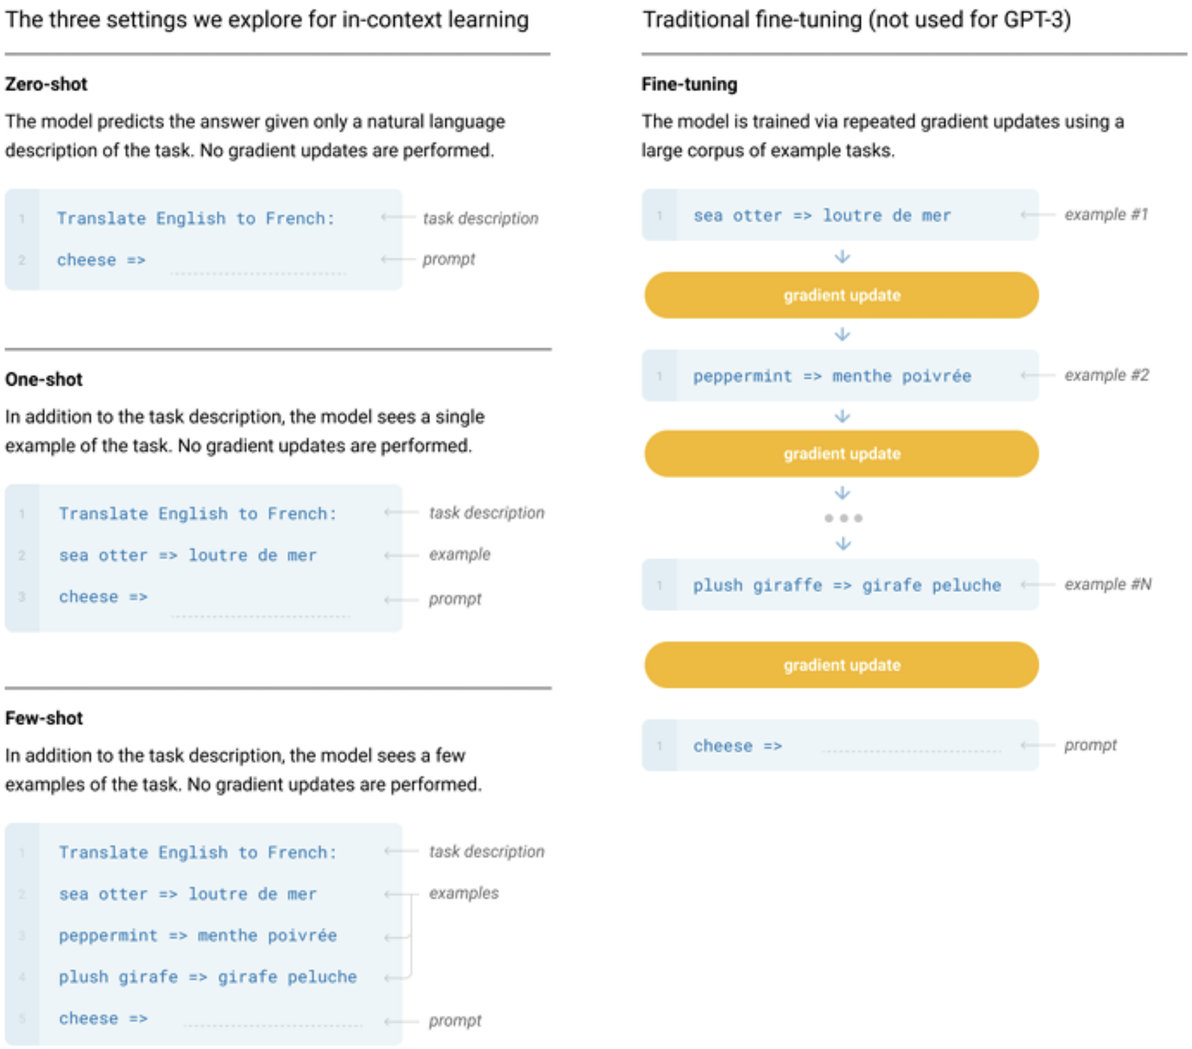
#01 Approach

Model Name	n_{params}	n_{layers}	d_{model}	n_{heads}	d_{head}	Batch Size	Learning Rate
GPT-3 Small	125M	12	768	12	64	0.5M	6.0×10^{-4}
GPT-3 Medium	350M	24	1024	16	64	0.5M	3.0×10^{-4}
GPT-3 Large	760M	24	1536	16	96	0.5M	2.5×10^{-4}
GPT-3 XL	1.3B	24	2048	24	128	1M	2.0×10^{-4}
GPT-3 2.7B	2.7B	32	2560	32	80	1M	1.6×10^{-4}
GPT-3 6.7B	6.7B	32	4096	32	128	2M	1.2×10^{-4}
GPT-3 13B	13.0B	40	5140	40	128	2M	1.0×10^{-4}
GPT-3 175B or “GPT-3”	175.0B	96	12288	96	128	3.2M	0.6×10^{-4}

- GPT-2 계열 autoregressive Transformer를 확장하고 dense / locally banded sparse attention을 교차 사용
- 8개 모델: 125M → 350M → 760M → 1.3B → 2.7B → 6.7B → 13B → 175B parameters
- 모든 모델 context window = 2,048 tokens, 총 300B tokens로 학습
- Training mix: filtered Common Crawl 60%, WebText2 22%, Books1 8%, Books2 8%, Wikipedia 3%
- 고품질 데이터는 실제 크기보다 더 자주 sampling하여 quality를 우선

EWHA EURON

#02 Results

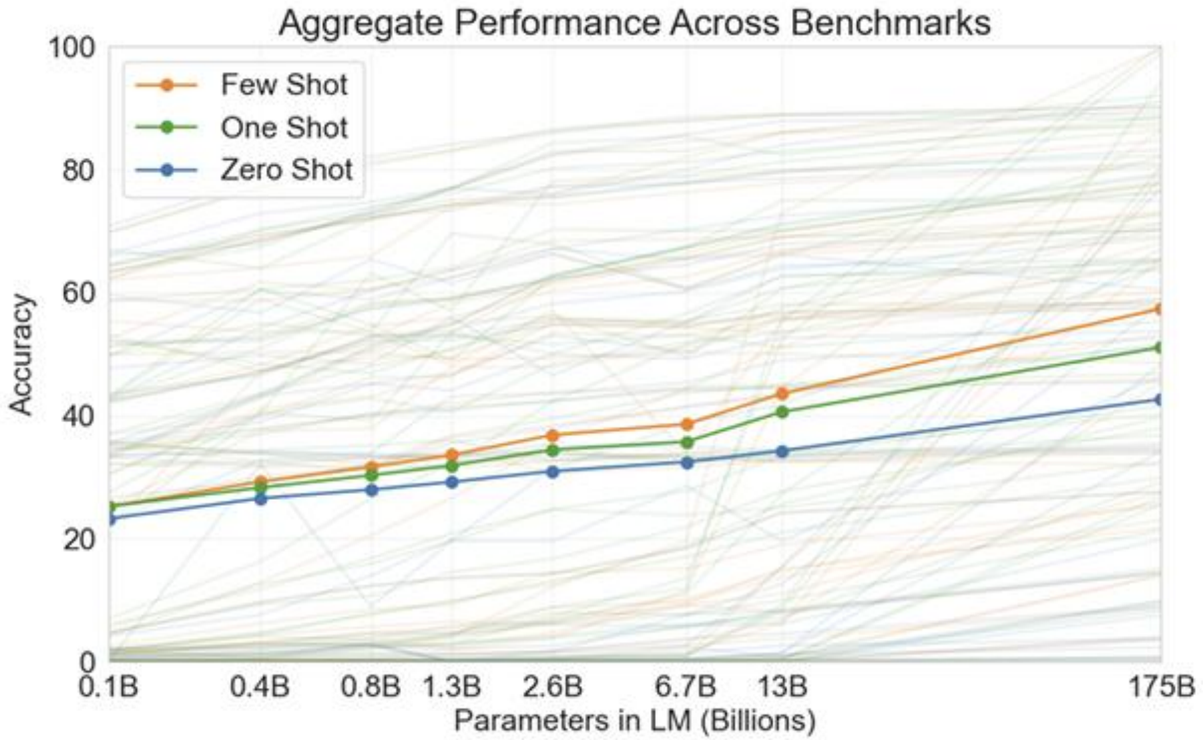


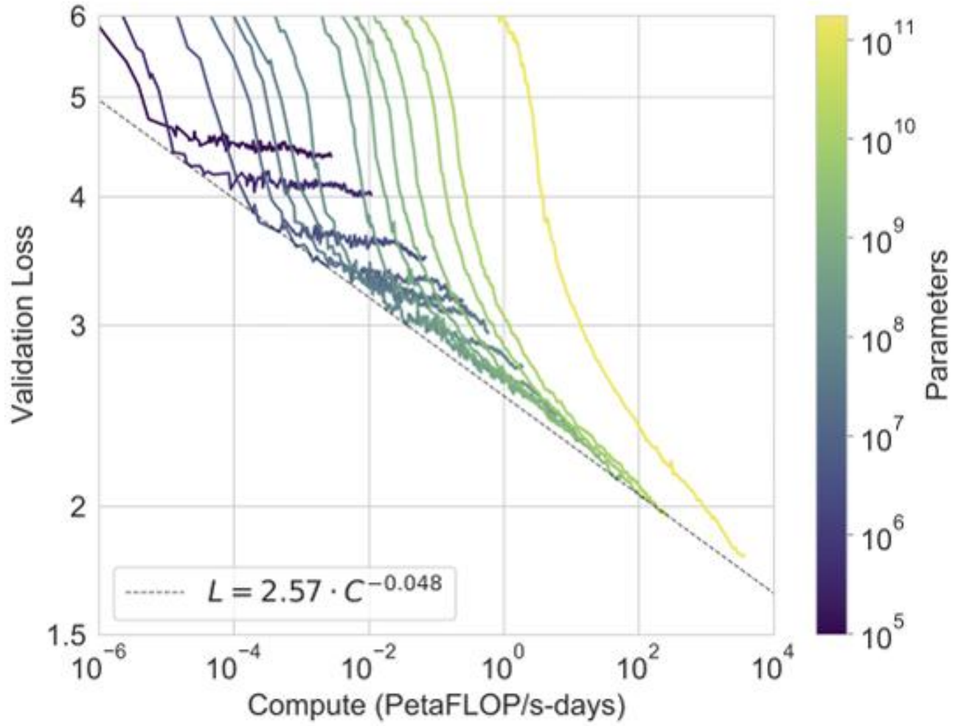
모델 크기 × 제공 예시 수(K) × 다양한 NLP task

- Few-shot: task의 training set에서 K개 예시를 무작위로 뽑아 context에 넣음
- K는 context window가 허용하는 범위에서 보통 10–100개
- Multiple-choice: 후보 completion의 LM likelihood를 비교
- Free-form: task 관례에 따라 F1, BLEU, exact match 등으로 평가
- 중요: GPT-3 자체를 각 downstream task에 fine-tuning하지 않음

EWHA EURON

#02 Results





- 모델이 커질수록 zero-shot 성능도 꾸준히 상승
- 하지만 few-shot 성능은 더 빠르게 상승 → 큰 모델일수록 context의 예시를 더 효율적으로 활용
- validation loss는 compute 증가에 따라 power-law 형태로 개선되고, downstream task에서도 전반적으로 성능 향상

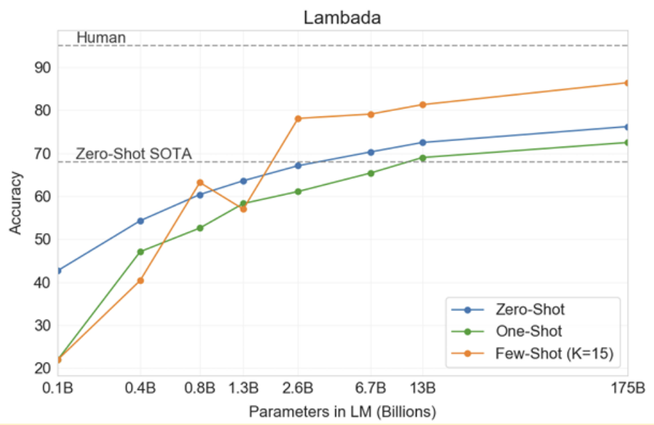
EWHA EURON

#02 Results : Language Modeling/QA/Translation

LAMBADA

Few-shot 86.4%

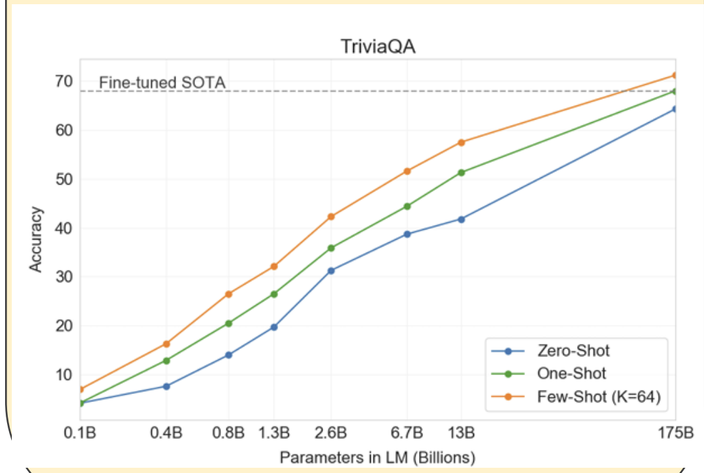
기존 SOTA 대비 큰 폭 개선



Closed-book QA

TriviaQA 71.2%

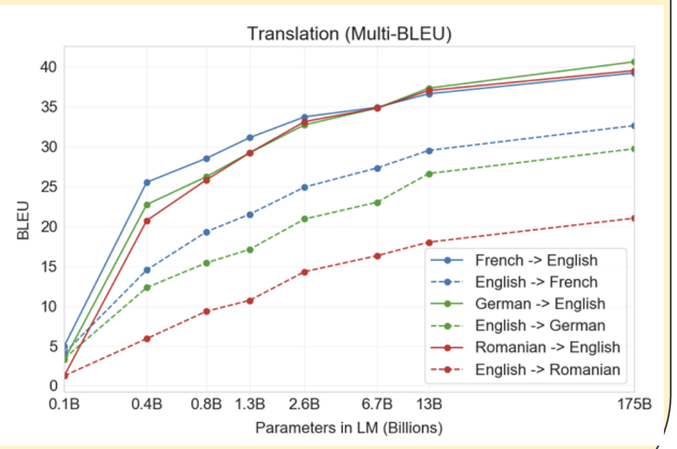
retrieval 없이 강한 성능



Translation

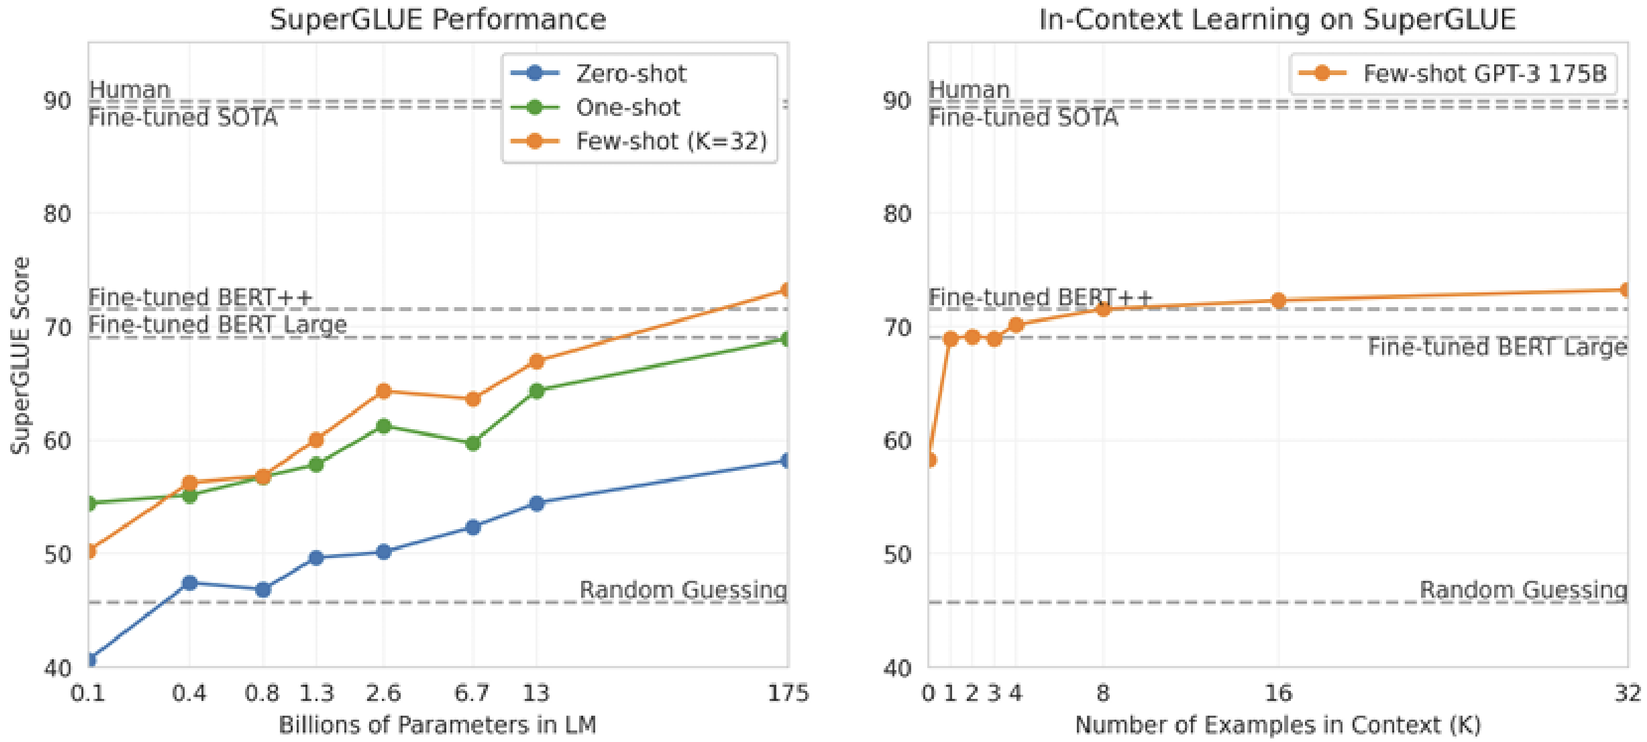
→ 영어에서 강함

Few-shot이 unsupervised NMT 경쟁력



→ 단, task마다 개선 폭은 다르며 “scale = 모든 문제 해결”은 아님

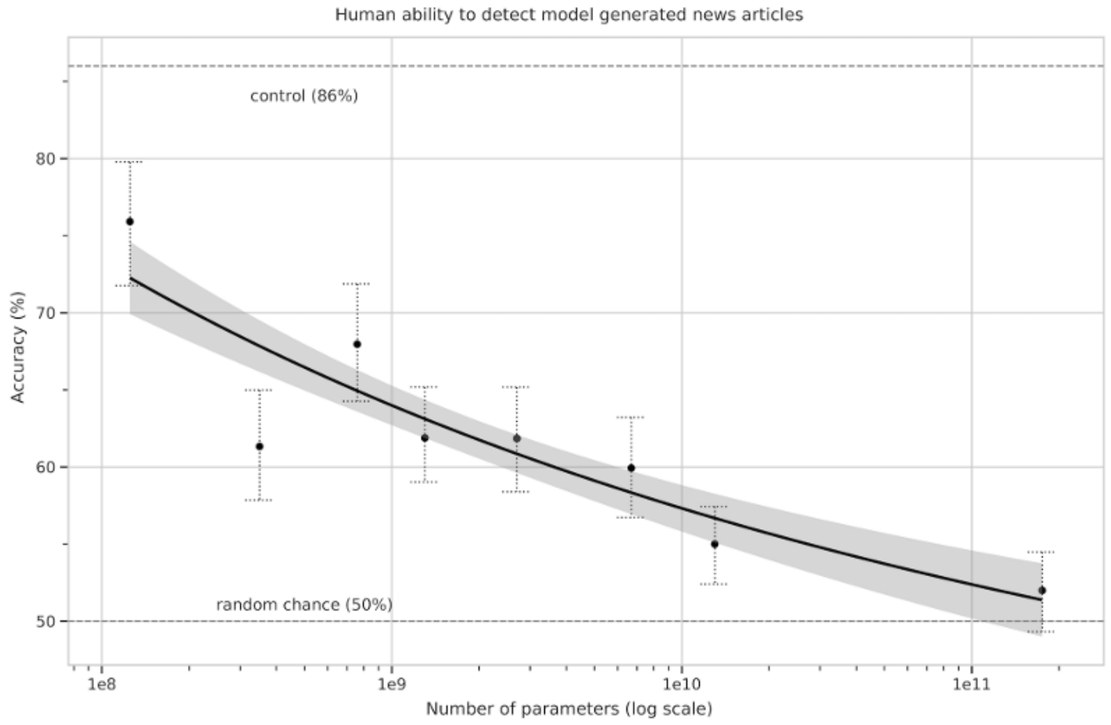
#02 Results : Reasoning, Reading Comprehension, SuperGLUE



- Winogrande: few-shot 77.7%, fine-tuned RoBERTa에 근접하지만 human 94%에는 큰 격차
- Commonsense: PIQA는 강하지만 ARC / OpenBookQA는 SOTA와 큰 차이 → 일관된 개선 아님
- Reading comprehension: CoQA 85.0 F1로 강한 반면 QuAC, RACE 등에서는 약함
- SuperGLUE few-shot 평균 71.8: fine-tuned BERT-Large(69.0)는 넘지만 fine-tuned SOTA(89.0)에는 못 미침
- 특히 WiC와 NLI 계열에서 약점 → 두 문장 간 의미 관계 판단이 어려운 패턴

EWHA EURON

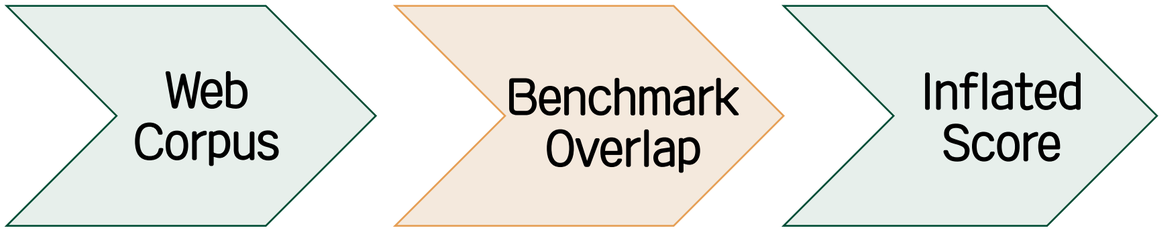
#02 Results : 생성품질도 Scale과 함께 상승

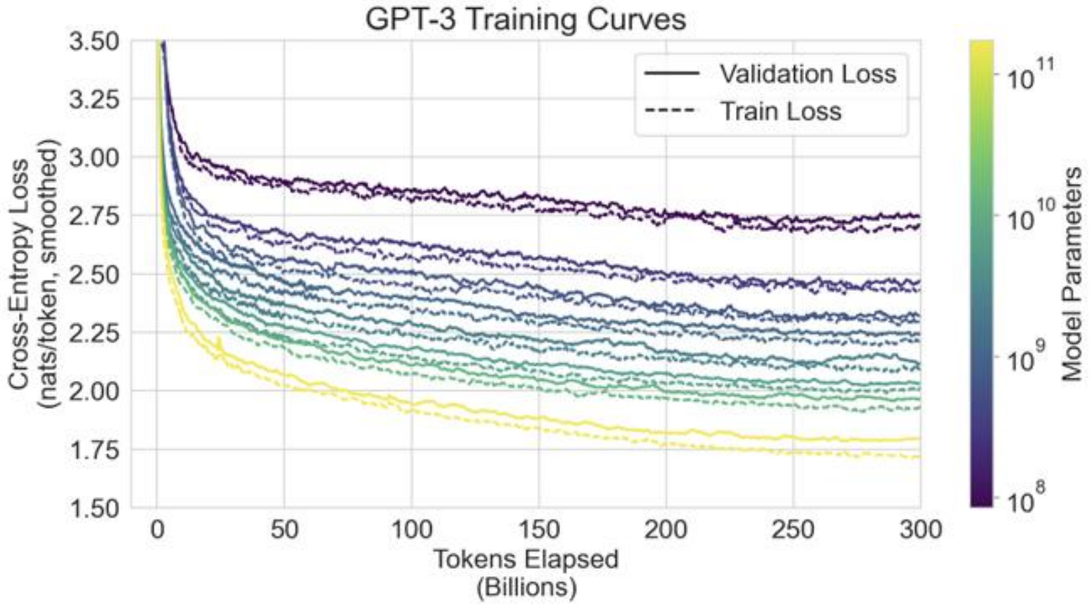


- 약 200단어 뉴스 기사에서 사람이 GPT-3 175B 생성물을 판별한 정확도는 52% → 거의 chance level(50%)
- 모델 크기가 커질수록 인간의 판별 정확도가 감소
- 새 단어를 정의 한 번만 보고 문장에 사용하는 task, 문법 교정에서도 few-shot 적응 사례 제시
- 동시에 factual inaccuracy, 반복, 비약 등 생성 모델 특유의 오류가 남음

EWHA EURON

#Measuring & Preventing memorization





- 인터넷 규모 pretraining에서는 benchmark의 test/dev 문장이 training corpus에 섞일 수 있음
- 저자들은 benchmark overlap을 탐지하고 제거하려 했지만 filtering bug로 일부 overlap이 남음
- 오염된(clean vs dirty) subset 성능을 비교해 결과 왜곡 정도를 사후 분석
- 대부분의 dataset에서는 영향이 작다고 판단했지만, 일부 결과에는 별표(*)를 붙이거나 보고에서 제외
- 이 문제를 독립 Section 4로 다룬 것 자체가 대규모 web-scale LM 평가의 중요한 방법론적 이슈를 제기

EWHA EURON

#Limitations & Broader Impacts

Limitations

- 텍스트 생성은 강하지만 semantic / physical grounding이 부족
- 긴 문맥에서 반복, coherence 저하, factual error 발생 가능
- 양방향 모델보다 fill-in-the-blank 등 일부 task 구조에 불리
- sample efficiency는 개선됐지만 pretraining 자체는 매우 비쌈

Broader Impacts

- 허위정보, 스팸, 피싱 등 misuse 가능성
- 웹 데이터의 사회적 편향과 representation 문제를 재생산
- 대규모 학습의 에너지 및 비용 문제
- 모델 능력의 빠른 확대가 안전성 연구의 필요성을 함께 키움

EWHA EURON

#Key Takeaways

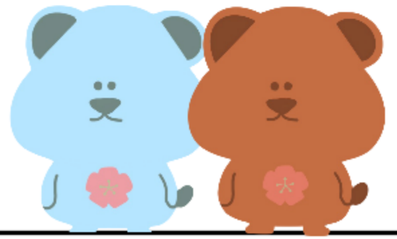
01 Scale은 단순히 언어모델의 “기억량”만 늘린 것이 아니라, context를 이용하는 능력까지 크게 향상시켰다.

02 GPT-3는 fine-tuning 없이도 다양한 task에서 강한 few-shot 성능을 보였지만, NLI · 독해 · 상식 추론 등에서는 명확한 한계가 남았다.

03 **따라서 이 논문의 진짜 메시지는 “GPT-3가 모든 문제를 푼다”가 아니라, “범용 LM + 자연어 인터페이스”라는 새로운 학습 패러다임의 가능성을 보였다는 것이다.**

EWHA EURON

THANK YOU



EWHA EURON