

Which Knowledge Should LLMs Trust? Uncovering a Generalizable Steering Direction Across Knowledge Conflicts

손현경 _ arXiv:2610.20067v1, 2026

EWHA EURON

목차

#01 Introduction

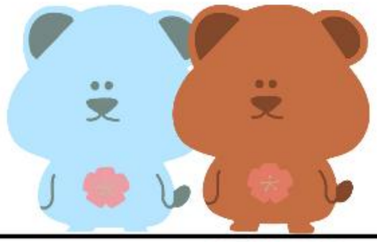
#02 Related Work

#03 Methodology

#04 Continuous Control Along a Single Direction

#05 Generalization of the Knowledge-Selection Direction

#06 Conclusion



EWHA EURON

01 Introduction

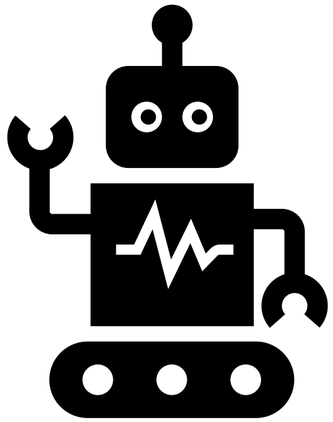


EWHA EURON

01 Introduction

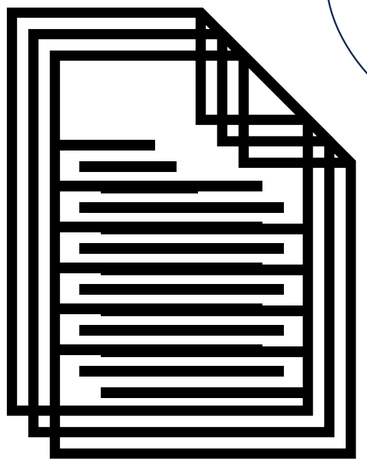
Knowledge Conflict 란 무엇인가!??

미국의 47대 대통령은 바이든이야



Parametric 지식

VS



외부 Context

미국의 47대 대통령은 트럼프야

➔ 둘이 서로 다른 말을 할 때 무엇을 믿어야 할까?

EWHA EURON

02 Related Work



EWHA EURON

Related Work

입력 수준의 접근

프롬프트 / 지시문 / RAG 템플릿

출처 선택을 입력으로 유도

단순한 사실 충돌 중심의 평가

모델 내부의 접근

Attention / SAE 특징* / 디코딩

모델 내부 과정에 직접 개입

작업별 탐색/적응 비용

**지식 선택을 하나의 방향으로 제어하고,
다른 작업에도 재사용할 수 있을까?**

EWHA EURON

03 Methodology



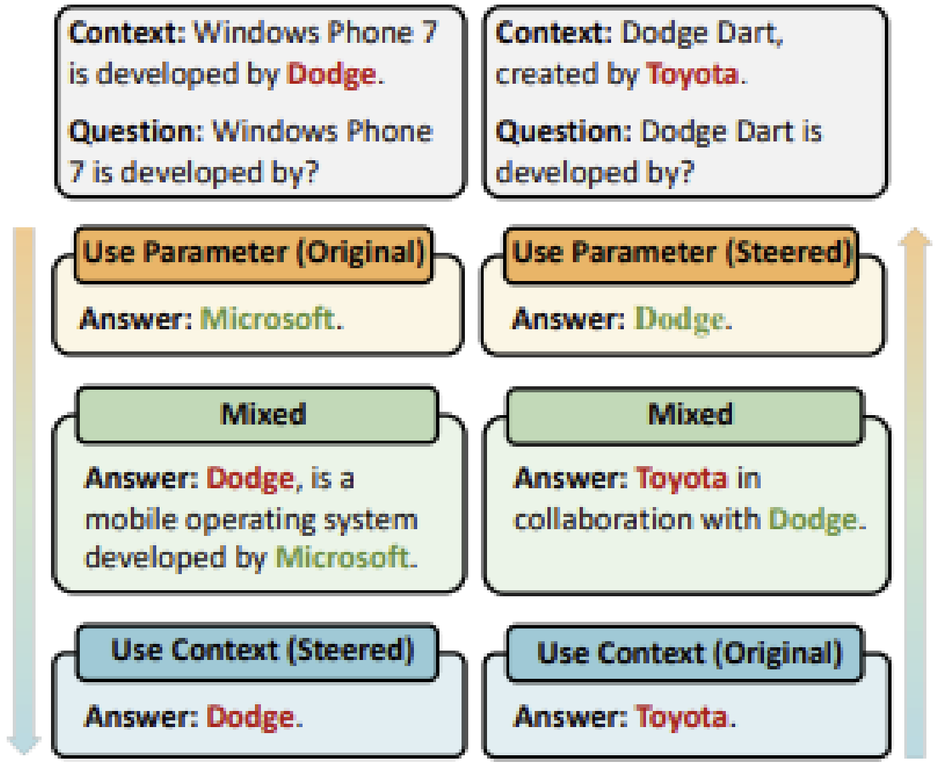
EWHA EURON

Methodology _ main idea

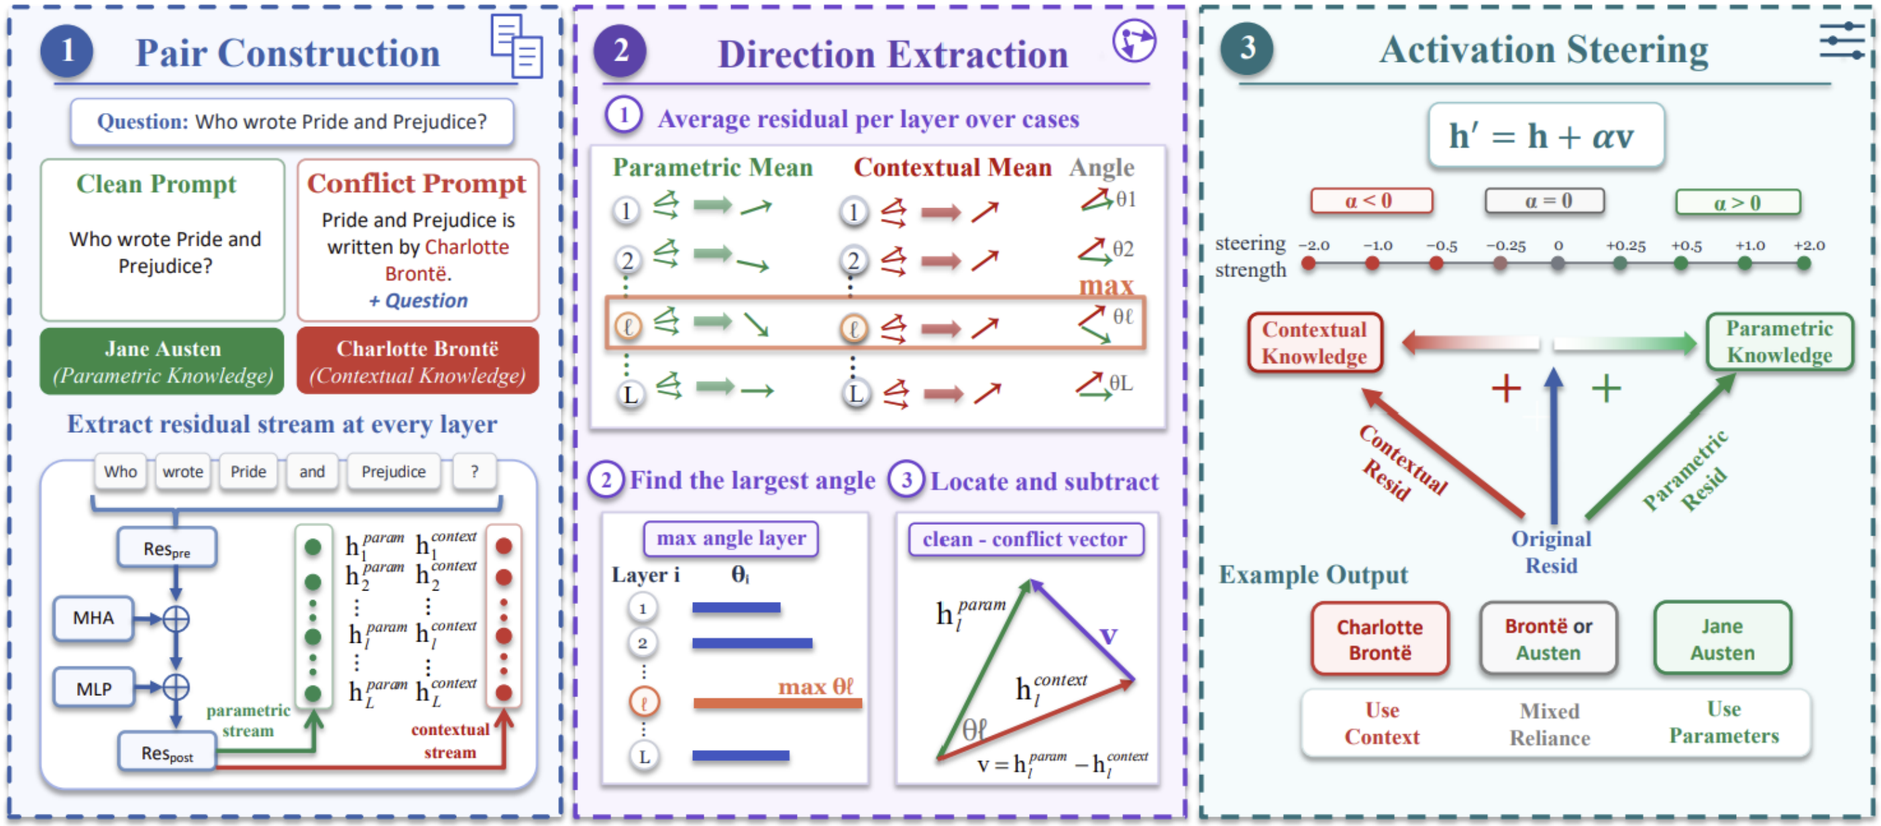
Hidden state에 **하나의 방향**을 더하거나 빼면,
어떤 knowledge를 선호할지 조절할 수 있다

$$h' = h + a \times v$$

- v : 지식 선택 방향
- $a > 0$: 내부 지식 선호 강화
- $a < 0$: 외부 문맥 선호 강화
- 같은 방향이 다른 형식/데이터셋/작업에서도 작동하는지 검증



Methodology _ overview



질문만 있는 입력과
충돌 문맥을 포함한
입력 구성

개입 층을 선택하고
두 조건의 평균 표현 차이 계산

추론 시점에 은닉 표현 수정

Methodology _ step 1 : Paired Prompts

Clean prompt

What is the capital of France?

Conflict prompt

The Capital of France is Lyon,

What is the capital of France?

원래 질문과 패러프레이즈 4개에는
정답으로 응답 (Paris)

충돌 문맥에서는 주입한 대안으로 응답
(Lyon)

두 조건을 모두 만족하는 문항만 사용

EWHA EURON

Methodology _ step 2 : 개입 층 선택

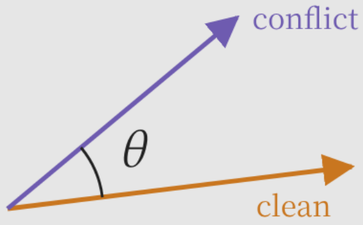
각 층 i에서 두 조건의 **마지막 토큰 표현**을 수집하고 사례 간 **평균** 계산

Clean 평균 μ^{i}_{clean} Conflict 평균 $\mu^{i}_{\text{conflict}}$

층별 유사도와 층 선택

$$s_i = \cos\left(\mu^{i}_{\text{clean}},\ \mu^{i}_{\text{conflict}}\right) \quad \rightarrow \quad \ell = \arg\min_i\ s_i$$

선택 기준



코사인 유사도가 가장 낮은 층 선택

= 두 평균 표현 사이의 **각도 차이가 가장 큰** 위치

$s_i = \cos\theta_i \downarrow \quad \Leftrightarrow \quad \theta_i \uparrow$

* 마지막 층 제외 조건 적용. 층 선택에 후속 작업 성능 탐색을 사용하지 않음.

Methodology _ step 3 : 방향 추출과 개입

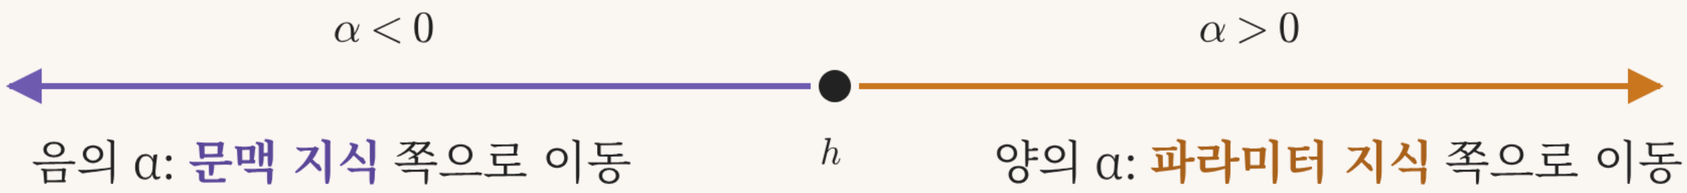
방향 추출

$$v = \mu^{\ell}_{\text{clean}} - \mu^{\ell}_{\text{conflict}}$$

추론 시 개입

$$h' = h + \alpha\, v$$

α의 부호



선택한 한 층의 **resid post**, 입력 **마지막 토큰**에 적용

Experimental Setup & Evaluation

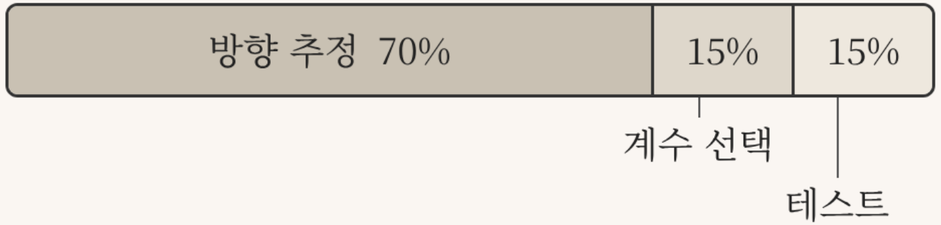
Models

Llama-3.1-8B-Instruct
Qwen3-8B
Gemma-2-9B-it
Mistral-7B-Instruct-v0.3

Primary benchmarks

NQ-Swap, MacNoise

NQ-Swap split



출력 분류	내부 답 지표	문맥 답 지표
내부 답만 포함	성공	—
문맥 답만 포함	—	성공
두 답 모두 포함	—	—
두 답 모두 없음	—	—

각 지표의 분모는 **전체 평가 문항 수**
출처 일치율과 **사실 정확도**를 구분해야 함

EWHA EURON

기본 결과 : 양방향 출처 제어

네 모델 모두 원하는 출처의 선택률이 상승

Llama-3.1-8B, NQ-Swap

내부 답 선택률 $\alpha > 0$

33.7% → **56.8%**



문맥 답 선택률 $\alpha < 0$

49.4% → **55.5%**



두 결과는 각각 다른 목표 방향으로 개입했을 때의 값

모델	내부 답		문맥 답	
	개입 전	개입 후	개입 전	개입 후
Llama	33.7	56.8	49.4	55.5
Qwen	46.5	54.6	36.7	56.0
Gemma	32.8	80.9	52.6	65.4
Mistral	42.2	59.0	45.8	60.2

* 모든 비교 방법보다 항상 높은 것은 아님. 수치는 Table 1의 NQ-Swap 결과 중 Unsteered(개입 전)와 Ours(개입 후)만 발췌 (단위: %).

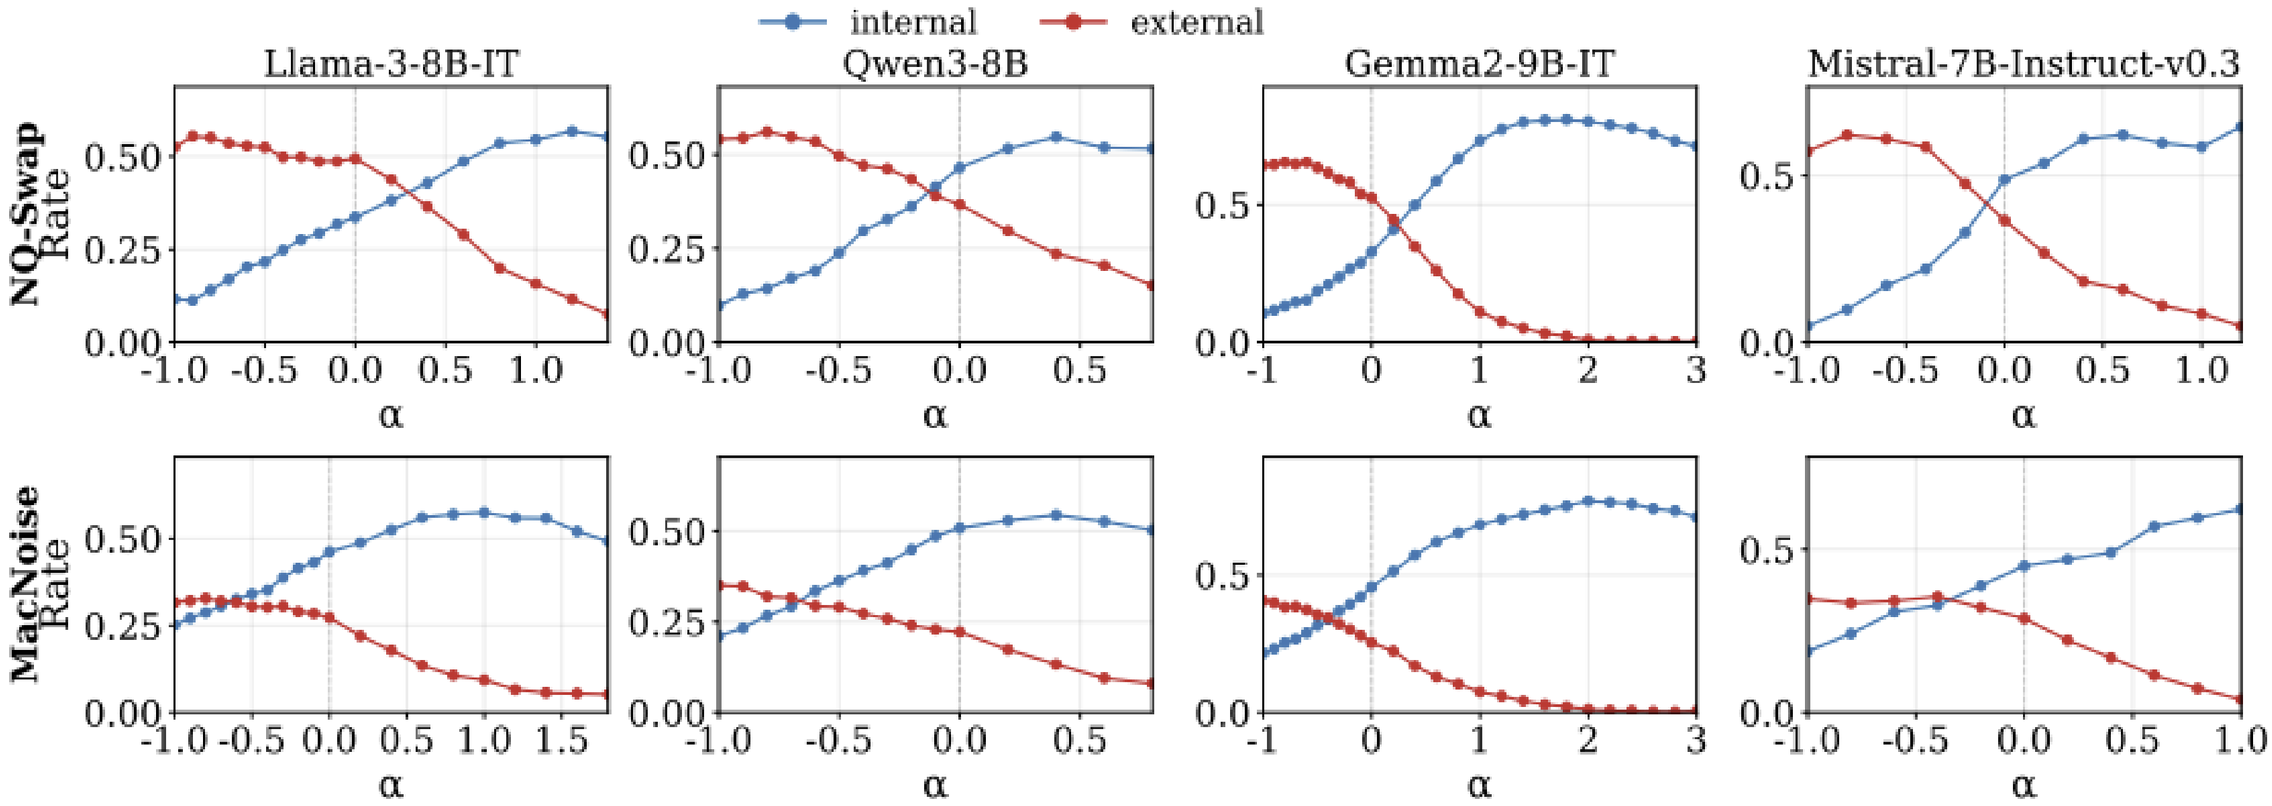
EWHA EURON

04 Continuous Control



EWHA EURON

Continuous Control



α에 따라 내부·외부 출처 선택률이 반대 방향으로 변화

양의 방향: 내부 지식 선택률 증가 | 음의 방향: 외부 문맥 선택률 증가

* 집계 곡선의 변화가 모든 개별 문항의 매끄러운 변화를 보장하지는 않음

05 Generalization



EWHA EURON

Robustness & Context Sensitivity

추가 검증 1

문맥 압력이 강해져도 효과가 남는가?

문맥 8회 반복 조건 · 내부 답 선택률

17.1% → 47.9%

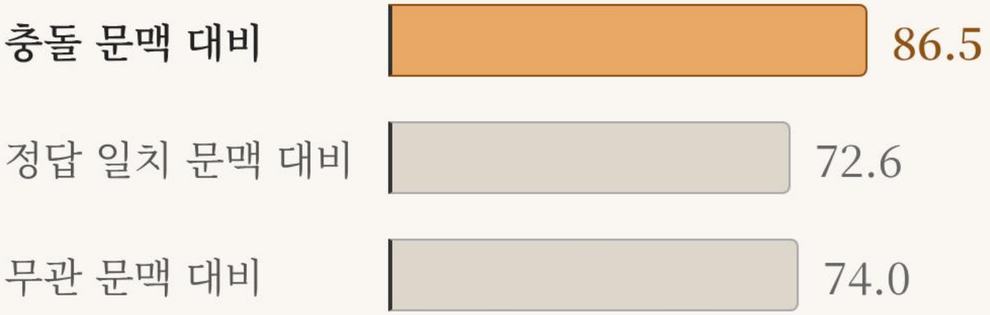
개입 전 → 개입 후



추가 검증 2

아무 문맥이나 대비해도 같은 방향이 나오는가?

ParaConflict · 방향 추정 조건별 내부 답 선택률 (%)



충돌 문맥을 이용한 방향이
정답 일치·무관 문맥을 이용한 방향보다 **강한 제어 효과**

* 문맥 조건은 방향 추정 시의 대조 조건을 의미함

EWHA EURON

Generalization Across Factual Conflicts

형식 간 전이	관계 간 전이	데이터셋 간 전이
짧은 치환형 충돌에서 얻은 방향을 서술형 문맥에 적용	국적·제조사·직업·종교·스포츠·방송사 사이에서 평가	NQ-Swap에서 선택한 방향과 계수를 다른 데이터셋에 적용

Table 6 요약 · 대상 데이터별 선택률 (%)

대상 데이터	내부 답		문맥 답	
	개입 전	개입 후	개입 전	개입 후
MacNoise	46.2	60.0 +13.8	27.0	34.1 +7.1
ParaConflict	15.8	83.9 +68.1	81.4	90.8 +9.4
CounterFact	35.7	38.9 +3.2	60.0	60.7 +0.7
MemoTrap	66.7	75.4 +8.7	30.0	53.3 +23.3

같은 방향이 전이되지만, **개선 폭은 데이터셋마다 다르다.**

EWHA EURON

Transfer to Complex Tasks

단순한 사실 충돌에서 얻은 방향을 복잡한 작업에 적용

RAG
검색 문서 활용

Memory
이전 대화의 정보 활용

Rule following
입력으로 주어진 제약 준수

대상 작업에서 **방향·층·계수를 새로 추정하지 않음**

작업	벤치마크	개입 전	개입 후
RAG	RGB	62.0	82.0 +20.0
	CRAG	23.7	25.8 +2.1
Memory	LoCoMo	8.5	13.2 +4.7
	LoCoMo-Plus	32.7	36.7 +4.0
	LongMemEval	43.2	45.4 +2.2
Rule	IFEval	33.6	35.0 +1.4
	FollowBench	14.5	14.9 +0.4

Llama 결과 (Table 7 발췌)

EWHA EURON

Trade-offs & Limitations

충돌이 없는 질문에서는 성능 손실 발생

MacNoise, 내부 방향 · 원래 답 정확도 100.0% → **80.8%**

데이터셋	개입 전	내부 방향	문맥 방향
ParaConflict	100.0	98.0 −2.0	85.5 −14.5
MacNoise	100.0	**80.8 −19.2**	86.7 −13.3
MemoTrap	100.0	84.2 −15.8	91.1 −8.9
CounterFact	100.0	88.8 −11.2	91.7 −8.3

Table 5 · 충돌 없는 질문의 원래 답 정확도 (%)

* 개입 전 100%는 해당 평가군의 결과

White-box 접근 필요

모델 내부 활성값을
읽고 수정해야 함

메커니즘 설명의 범위

유용한 제어 축을 발견했지만,
전체 지식 선택 회로를
설명하지는 못함

EWHA EURON

06 Conclusion



EWHA EURON

Conclusion

결론

1. 하나의 **residual-stream 방향**으로 지식 출처 선호를 **양방향 조절**
2. 형식·사실 관계·데이터셋 변화에도 **방향 재사용**
3. **RAG·대화 기억·규칙 따르기**로 전이

남는 질문

여러 작업이 공유하는
입력 정보 활용 과정은 무엇인가?

비충돌 성능 손실을 줄이면서
출처 선호를 조절할 수 있는가?

EWHA EURON

토의 주제

1. 개입 방향은 누가, 어떻게 정하는가?

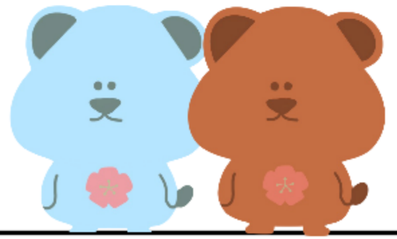
이 방법은 α의 부호에 따라 출처 선호를 바꾼다. 그런데 실제 입력에서는 문맥이 맞는지 틀린지 미리 알 수 없다. 그러면 " 언제 내부 쪽, 언제 문맥 쪽으로 밀지 " 를 정하는 판단이 따로 필요하다. 이 판단 없이도 실용적인 정확도 향상으로 이어질 수 있을까?

2. 이 방향은 "충돌 해소" 축인가, "문맥을 얼마나 따를지"라는 더 일반적인 축인가?

충돌 문맥으로 만든 방향이 가장 강했다. 하지만 정답 일치 문맥이나 무관 문맥으로 만든 방향도 70%대 효과를 냈다. 그리고 RAG·규칙 따르기처럼 충돌이 핵심이 아닌 작업으로도 전이됐다. 그렇다면 이 방향이 실제로 잡은 건 지식 충돌 자체가 아닐 수도 있다. 입력 문맥에 대한 일반적인 의존도일 가능성도 있지 않을까?

EWHA EURON

THANK YOU



EWHA EURON