



3주차

1. Introduction

논문이 다루는 분야

해당 task에서 기존 연구 한계점

논문의 contributions

2. Related Work

3. 제안 방법론

Main Idea

Contribution

4. 실험 및 결과

Dataset

Baseline

결과

5. 결론 (배운점)

연구의 의의

배운점

1. Introduction



논문에서 다루고 있는 주제가 무엇인지와 해당 주제의 필요성이 무엇인가
논문에서 제안하는 방법이 기존 방법의 문제점에 대응되도록 제안 되었는가

논문이 다루는 분야

• 확률적 생성모형

- 관측 데이터가 보이지 않는 잠재변수로부터 생성된다고 가정하는 모형
- 예를 들어 손글씨 이미지의 형태, 기울기, 획의 특성 등을 잠재변수로 표현할 수 있음

- 다만 개별 잠재변수가 특정 의미와 일대일로 대응하도록 보장하지는 않음
- **연속 잠재변수 모형**
 - 잠재변수가 연속적인 값을 가지는 모형
 - 사전분포에서 잠재변수를 샘플링한 뒤, 해당 잠재변수에 조건부로 관측 데이터를 생성
- **변분추론**
 - 직접 계산하기 어려운 실제 사후분포를 계산하기 쉬운 분포로 근사하는 방법
 - 근사분포를 최적화하여 관측 데이터에 대응하는 잠재변수의 분포를 추론
- **논문에서 해결하려는 문제**
 - 관측 데이터를 잘 설명하는 생성모형의 파라미터 학습
 - 새로운 입력에 대한 잠재변수의 효율적인 사후 추론
 - 데이터의 주변분포를 활용한 생성 및 복원 등의 작업

해당 task에서 기존 연구 한계점

① 주변우도와 사후분포를 직접 계산하기 어려움

- 주변우도를 계산하려면 가능한 잠재변수 전체에 대해 적분해야 함
- 생성 과정이 비선형 신경망으로 표현되면 해당 적분을 해석적으로 계산하기 어려움
- 주변우도가 사후분포의 정규화에도 필요하므로, 정확한 사후 추론 역시 어려워짐

② 기존 해석적 변분추론의 적용 범위가 제한됨

- 기존 평균장 변분추론의 해석적 갱신 방식은 특정 기댓값을 계산할 수 있어야 함
- 복잡한 생성모형에서는 해당 기댓값도 직접 계산하기 어려움
- 따라서 모형의 복잡성과 유연성을 높이는 데 제약이 발생

③ 일반적인 Monte Carlo 기울기 추정의 분산이 큼

- 샘플링으로 기댓값과 기울기를 근사할 수 있음
- 그러나 논문에서 설명하는 일반적인 score-function 기울기 추정량은 분산이 높음
- 적은 수의 샘플로 안정적인 학습을 수행하기 어려움

④ 데이터마다 반복 추론이 필요함

- MCMC 기반 접근에서는 각 데이터의 잠재변수를 추론하기 위해 반복적인 샘플링이 필요
- 데이터가 많아질수록 추론 비용이 누적됨
- 대규모 데이터와 미니배치 학습에 적합한 방법이 필요

논문의 contributions

① SGVB 추정량 제안

- SGVB: Stochastic Gradient Variational Bayes
- 재매개변수화를 이용해 변분 하한의 미분 가능한 확률적 추정량을 구성
- 계산하기 어려운 기댓값을 포함한 목적함수를 표준 확률적 기울기 방법으로 최적화

② AEVB 알고리즘 제안

- AEVB: Auto-Encoding Variational Bayes
- SGVB를 이용하여 생성모형과 근사 추론모형을 공동 학습
- 학습된 추론모형으로 새로운 입력의 잠재변수 분포를 빠르게 계산
- 데이터별로 비용이 큰 반복 추론을 수행할 필요를 줄임

③ 신경망 기반 VAE 제시

- 확률적 인코더와 디코더를 신경망으로 구성
- AEVB를 신경망에 적용한 구체적인 예제로 VAE를 제시
- 오토인코더 구조와 확률적 생성모형 사이의 연결을 설명

2. Related Work



Introduction에서 언급한 기존 연구들에 대해 어떻게 서술하는가
제안 방법의 차별성을 어떻게 표현하고 있는가

① Wake-Sleep Algorithm

- 생성모형과 사후분포를 근사하는 recognition model을 함께 사용
- 생성과 추론을 위한 별도의 모형이 있다는 점에서 AEVB와 유사
- 생성모형과 추론모형이 서로 다른 목적함수로 학습됨

- 두 학습 과정이 하나의 주변우도 하한을 공동으로 최적화하는 것은 아님
- AEVB는 두 모형이 동일한 변분 하한을 최적화한다는 점에서 차별화
- 다만 Wake-Sleep은 이산 잠재변수에도 적용 가능
- 논문에서는 데이터 한 개당 계산복잡도가 AEVB와 같다고 설명

② Stochastic Variational Inference

- 확률적 기울기를 이용해 변분추론을 수행하는 기존 연구
- 높은 기울기 분산을 줄이기 위해 control variate 등의 기법을 사용
- 본 논문은 샘플링을 미분 가능한 변환으로 표현하는 재매개변수화 방식을 활용
- 유사한 재매개변수화를 사용한 선행 연구도 관련 연구에서 언급
- 따라서 기여는 재매개변수화 자체뿐 아니라 이를 변분 하한 추정과 학습 가능한 추론모형에 결합한 데 있음

③ 기존 Auto-Encoder

- 입력을 잠재표현으로 압축한 뒤 원본을 재구성하도록 학습
- 재구성 오차만 최소화하면 유용한 표현을 충분히 학습하지 못할 수 있음
- 기존에는 denoising, sparse, contractive 등의 방식으로 정규화를 추가
- VAE에서는 정규화 항이 변분 하한의 유도 과정에서 자연스럽게 등장
- 재구성 항과 정규화 항을 하나의 확률적 목적함수로 설명할 수 있음

④ PCA 및 선형 Gaussian 모형

- 선형 오토인코더와 확률적 생성모형 사이의 기존 연결을 소개
- 본 논문은 비선형 신경망을 포함하는 더 일반적인 생성모형을 다룸

⑤ 기타 생성모형 연구

- Deep Boltzmann Machine 관련 연구
 - 추론모형을 활용하지만 비방향성 확률모형을 대상으로 함
- Generative Stochastic Networks
 - 노이즈가 있는 오토인코더를 이용해 데이터 분포를 샘플링하는 Markov chain을 학습
- DARN
 - 오토인코딩 구조를 사용하지만 이진 잠재변수를 대상으로 함

- Rezende 등의 연구
 - 재매개변수화와 확률적 추론의 연결을 독립적으로 제시한 연구로 언급

제안 방법의 차별성

- 연속 잠재변수를 가진 방향성 확률모형을 대상으로 함
- 생성모형과 추론모형을 동일한 변분 목적함수로 학습
- 미니배치와 역전파를 이용하여 효율적으로 최적화

3. 제안 방법론



Introduction에서 언급된 내용과 동일하게 작성되어 있는가
 Introduction에서 언급한 제안 방법이 가지는 장점에 대한 근거가 있는가
 제안 방법에 대한 설명이 구현 가능하도록 작성되어 있는가

Main Idea

- **핵심 아이디어**
 - 직접 계산하기 어려운 사후분포를 인코더로 근사
 - 샘플링을 외부 잡음과 미분 가능한 연산으로 표현
 - 생성모형과 추론모형을 하나의 목적함수로 공동 학습
- **① 확률적 인코더**
 - 입력 데이터에 대응하는 잠재변수의 분포를 예측
 - 하나의 고정된 잠재벡터를 출력하는 일반적인 오토인코더와 달리 분포의 파라미터를 출력
 - 논문의 VAE 예제에서는 평균과 대각 공분산을 가진 Gaussian 분포를 사용
 - 실제 구현에서는 평균과 로그 분산을 출력하도록 구성
 - 학습 후 새로운 입력의 잠재분포를 한 번의 순전파로 계산 가능
- **② 확률적 디코더**
 - 잠재변수를 입력받아 관측 데이터의 분포를 예측
 - 이진 데이터에는 Bernoulli 분포 사용
 - 실수값 데이터에는 Gaussian 분포 사용

- 입력을 재구성하는 동시에, 잠재변수로부터 새로운 데이터를 생성하는 역할 수행
- ③ **사전분포**
 - 관측 데이터를 보기 전에 가정하는 잠재변수의 분포
 - 논문의 VAE 예제에서는 표준정규분포를 사용
 - 새로운 데이터를 생성할 때 이 사전분포에서 잠재변수를 샘플링
- ④ **ELBO를 학습 목적함수로 사용**
 - ELBO: Evidence Lower Bound
 - 직접 계산하기 어려운 로그 주변우도의 하한
 - 로그 주변우도 대신 계산과 최적화가 가능한 ELBO를 최대화
 - ELBO는 기대 재구성 로그우도와 KL 정규화 항으로 구성
- ⑤ **기대 재구성 로그우도**
 - 인코더에서 추론한 잠재변수로 원래 입력을 얼마나 잘 설명하는지 평가
 - 디코더가 원본 데이터에 높은 확률 또는 확률밀도를 부여하도록 유도
 - 손실 최소화 관점에서는 재구성에 대한 음의 로그우도를 줄이는 것에 해당
- ⑥ **KL 정규화 항**
 - 입력별 근사 사후분포가 사전분포에서 지나치게 벗어나는 것을 억제
 - 입력을 재구성하기 위한 정보와 사전분포에 대한 제약 사이의 균형을 형성
 - Gaussian 근사 사후분포와 표준정규 사전분포를 사용하면 해석적으로 계산 가능
 - 따라서 이 항은 샘플링 없이 직접 계산하고 미분할 수 있음
- ⑦ **두 종류의 KL divergence 구분**
 - 근사 사후분포와 실제 사후분포 사이의 KL
 - 로그 주변우도와 ELBO 사이의 차이를 나타냄
 - 실제 사후분포가 필요하므로 직접 계산하기 어려움
 - 생성모형이 고정되어 있을 때 ELBO 최대화는 이 차이를 줄이는 방향으로 작용
 - 근사 사후분포와 사전분포 사이의 KL
 - 실제 ELBO에 포함되는 정규화 항
 - 논문의 Gaussian 설정에서는 직접 계산 가능
- ⑧ **Reparameterization Trick**

- 근사 사후분포에서 샘플을 얻는 과정을 다른 방식으로 표현
- 먼저 파라미터와 독립적인 표준정규 잡음을 샘플링
- 인코더가 예측한 표준편차로 잡음의 크기를 조절하고 평균만큼 이동
- 이렇게 얻은 잠재변수는 원래 근사 사후분포에서 샘플링한 것과 동일한 분포를 가짐
- 무작위성은 외부 잡음에 두고, 인코더 파라미터에서 잠재변수로 이어지는 연산은 미분 가능하게 구성
- 디코더의 재구성 손실을 인코더까지 역전파할 수 있게 됨
- 확률성을 제거하는 것이 아니라, 확률성을 유지하면서 미분 경로를 확보하는 방법
- ⑨ **SGVB 추정량**
 - 재매개변수화한 잠재변수 샘플로 ELBO를 추정
 - 일반적인 형태에서는 로그 결합분포와 로그 근사 사후분포를 샘플링으로 평가
 - KL 항을 직접 계산할 수 있는 경우에는 재구성 항만 샘플링으로 추정
 - 논문은 후자의 방식이 통상 더 낮은 분산을 가진다고 설명
 - 추정한 목적함수의 기울기로 인코더와 디코더를 업데이트
- ⑩ **AEVB 학습 과정**
 - 데이터에서 미니배치를 추출
 - 인코더가 각 입력의 평균과 로그 분산을 계산
 - 표준정규분포에서 잡음을 샘플링
 - 재매개변수화로 잠재변수를 계산
 - 디코더가 관측 데이터의 분포를 계산
 - 재구성 손실과 KL 정규화 항을 계산
 - 역전파로 인코더와 디코더를 공동 업데이트
 - 수렴할 때까지 반복
- **학습 후 활용**
 - 입력 데이터의 잠재표현 추론
 - 인코더로 해당 입력의 잠재분포를 계산
 - 입력 데이터 재구성

- 인코더에서 얻은 잠재변수를 디코더에 입력
- 새로운 데이터 생성
 - 사전분포에서 잠재변수를 샘플링한 뒤 디코더에 입력

Contribution

- **SGVB: 추정량 수준의 기여**
 - 변분 하한과 그 기울기를 효율적으로 추정
 - 해석적으로 계산하기 어려운 기댓값을 확률적 최적화로 다룰 수 있게 함
- **AEVB: 알고리즘 수준의 기여**
 - SGVB를 이용하여 생성모형과 근사 추론모형을 공동 학습
 - 데이터별 반복 추론 비용을 공유된 추론모형의 학습으로 줄임
- **VAE: 구체적인 모형 수준의 기여**
 - 신경망 기반 확률적 인코더와 디코더로 AEVB를 구현
 - 오토인코더를 확률적 생성모형으로 해석하고 학습
- **Introduction과 방법론의 대응**
 - 계산하기 어려운 주변우도 → ELBO 최적화
 - 기울기 계산의 어려움 → 재매개변수화와 SGVB
 - 데이터별 반복 추론 비용 → 학습된 인코더
 - 대규모 데이터 학습 비용 → 미니배치 기반 AEVB
- **구현 가능성**
 - 목적함수, 샘플링 방식, 미니배치 학습 알고리즘을 제시
 - 부록에서 Gaussian KL 계산과 인코더·디코더의 MLP 구조를 설명
 - 핵심 모형을 구현하는 데 필요한 절차를 제공

4. 실험 및 결과



Introduction에서 언급한 제안 방법의 장점을 검증하기 위한 실험이 있는가

Dataset

- **MNIST**

- 손글씨 숫자 이미지 데이터셋
- Bernoulli 출력분포를 사용하는 디코더 적용
- 변분 하한, 주변우도, 생성 샘플을 평가

- **Frey Face**

- 표정과 자세가 변하는 얼굴 이미지 데이터셋
- 실수값 데이터를 다루기 위해 Gaussian 디코더 사용
- 디코더의 평균 출력이 0과 1 사이에 있도록 sigmoid 적용
- MNIST보다 작은 데이터셋이므로 은닉 유닛 수를 줄여 실험

- **평가 목적**

- 분류 정확도보다 생성모형 학습의 효율성과 성능에 초점
- 변분 하한의 수렴
- 추정 주변 로그우도
- 잠재변수 차원의 영향
- 잠재공간과 생성 결과의 시각화

Baseline

- ① **Wake-Sleep**

- 생성모형과 recognition model을 함께 학습
- AEVB와 동일한 인코더 구조를 사용하여 학습 방법 비교
- ELBO 비교와 주변우도 비교에 모두 포함

- ② **Monte Carlo EM**

- 학습된 인코더 없이 HMC로 잠재변수의 사후분포에서 샘플링
- 반복적인 샘플링으로 추론한 결과를 생성모형 학습에 사용
- 주변우도 비교 실험에 포함
- 데이터마다 수행하는 추론의 비용이 큰 데이터셋에서 어떤 영향을 주는지 확인

- **공통 및 주요 실험 설정**

- 인코더와 디코더: 은닉층이 하나인 MLP

- 은닉층 활성화 함수: tanh
- 최적화 방법: Adagrad
- 미니배치 크기: 100
- 데이터 한 개당 잠재변수 샘플 수: 1
- 전역 학습률 후보: 0.01, 0.02, 0.1
- Gaussian 파라미터 사전에 대응하는 작은 weight decay 적용
- **ELBO 비교 설정**
 - MNIST: 은닉 유닛 500개
 - Frey Face: 은닉 유닛 200개
 - 여러 잠재공간 차원에서 성능 비교
- **주변우도 비교 설정**
 - MNIST 사용
 - 은닉 유닛 100개
 - 잠재변수 3개
 - 학습 데이터 1,000개와 50,000개 비교

결과

• ① ELBO 비교




Figure 2: Comparison of our AEVB method to the wake-sleep algorithm, in terms of optimizing the lower bound, for different dimensionality of latent space (N_z). Our method converged considerably faster and reached a better solution in all experiments. Interestingly enough, more latent variables does not result in more overfitting, which is explained by the regularizing effect of the lower bound. Vertical axis: the estimated average variational lower bound per datapoint. The estimator variance was small (< 1) and omitted. Horizontal axis: amount of training points evaluated. Computation took around 20-40 minutes per million training samples with a Intel Xeon CPU running at an effective 40 GFLOPS.

- 비교 대상: AEVB와 Wake-Sleep

- MNIST 잠재차원: 3, 5, 10, 20, 200
 - Frey Face 잠재차원: 2, 5, 10, 20
 - AEVB가 모든 비교 설정에서 더 빠르게 수렴하고 더 높은 하한에 도달했다고 보고
 - 특히 Frey Face에서는 Wake-Sleep이 일찍 정체되는 반면 AEVB는 계속 개선
 - 동일한 변분 하한을 공동 최적화하는 학습 방식의 효과를 뒷받침
 - 다만 높은 ELBO는 생성모형과 근사 추론모형 양쪽의 영향을 받으므로, 주변우도 개선과 완전히 같은 의미는 아님
- ② 잠재변수 수와 과적합
 - 실험한 설정에서는 잠재변수 수를 늘려도 추가적인 과적합이 나타나지 않았다고 보고
 - 저자들은 이를 변분 하한의 정규화 효과로 설명
 - 단, VAE가 모든 상황에서 과적합을 방지한다는 의미는 아님
 - 정규화 항을 제거한 별도의 비교 실험으로 효과를 분리하지는 않음
 - ③ 주변우도 비교




Figure 3: Comparison of AEVB to the wake-sleep algorithm and Monte Carlo EM, in terms of the estimated marginal likelihood, for a different number of training points. Monte Carlo EM is not an on-line algorithm, and (unlike AEVB and the wake-sleep method) can't be applied efficiently for the full MNIST dataset.

- 비교 대상: AEVB, Wake-Sleep, MCEM
 - 실제 주변우도를 직접 계산하기 어려워 MCMC 기반 추정량 사용
 - 높은 잠재차원에서는 추정이 불안정하여 3차원 잠재공간으로 제한
- 학습 데이터 1,000개에서의 결과
 - AEVB가 빠르게 높은 학습 주변우도에 도달
 - MCEM도 학습이 진행되면서 비슷한 수준에 도달

- 테스트 주변우도에서는 MCEM이 AEVB와 비슷하거나 조금 더 높은 결과를 보임
- 따라서 AEVB가 모든 조건과 지표에서 가장 우수한 것은 아님

• 학습 데이터 50,000개에서의 결과

- AEVB가 빠르게 높은 주변우도에 도달
- MCEM은 개선 속도가 훨씬 느림
- AEVB가 Wake-Sleep보다 좋은 주변우도 결과를 보임
- 큰 데이터에서 학습된 인코더와 미니배치 최적화의 효율성이 드러남

• 수렴 속도 해석 시 주의점

- 그래프의 가로축은 실제 시간이 아니라 누적 평가한 학습 데이터 수
- 따라서 그래프만으로 실제 시간이 몇 배 단축되었다고 해석할 수는 없음

• 생성 샘플




Figure 5: Random samples from learned generative models of MNIST for different dimensionalities of latent space.

- 2, 5, 10, 20차원 잠재공간에서 생성한 MNIST 샘플 제시
- 학습된 생성모형으로 새로운 숫자 이미지를 만들 수 있음을 확인
- 생성 품질에 대한 평가는 주로 정성적인 시각화에 의존

• Introduction의 장점이 검증되었는지

- 효율적인 학습 → ELBO 수렴 곡선으로 확인
- 생성모형 성능 → 추정 주변우도로 확인
- 큰 데이터에서의 효율성 → 서로 다른 학습 데이터 크기에서 비교
- 잠재표현과 생성 능력 → 잠재공간 및 생성 이미지 시각화
- 정규화 효과 → 잠재차원 변화에 따른 관찰로 제시하되, 독립적인 제거 실험은 부족

5. 결론 (배운점)



연구의 의의 및 한계점, 본인이 생각하는 좋았던/아쉬웠던 점 (배운점)

연구의 의의

- **확률적 생성모형과 신경망 학습을 연결**
 - 복잡한 사후분포를 직접 계산하지 않고도 근사 추론과 생성모형 학습을 수행
 - 역전파와 미니배치 최적화를 활용할 수 있는 형태로 문제를 구성
- **추론 과정을 학습 가능한 함수로 표현**
 - 데이터마다 반복적인 추론을 수행하는 비용을 줄임
 - 공유 인코더가 새로운 입력의 잠재분포를 빠르게 계산
 - 오늘날 amortized inference라고 부르는 관점으로 이해 가능
- **재구성과 정규화의 확률적 근거 제시**
 - 재구성 항과 KL 정규화 항이 변분 하한에서 함께 도출됨
 - 각 손실 항이 왜 필요한지 확률모형 관점에서 설명 가능
- **일반적인 추론·학습 방법을 제안**
 - VAE 구조뿐 아니라 SGVB 추정량과 AEVB 알고리즘을 함께 제시
 - 다른 연속 잠재변수 모형으로 확장할 수 있는 기반 제공

배운점

- **같은 확률분포도 계산 방식에 따라 학습 가능성이 달라짐**
 - 분포에서 직접 샘플링하는 표현을 외부 잡음과 미분 가능한 변환으로 바꿈
 - 분포 자체를 유지하면서 역전파 경로를 만들 수 있음
 - 수학적 표현과 실제 계산 과정의 설계가 모두 중요함을 보여줌
- **잠재표현을 분포로 학습할 수 있음**
 - 입력에 대응하는 하나의 벡터뿐 아니라 가능한 표현의 분포를 학습
 - 데이터 생성과 추론을 하나의 확률적 틀에서 다룰 수 있음
- **학습 목적함수와 최종 성능 지표를 구분해야 함**
 - 높은 ELBO가 반드시 높은 주변우도를 의미하지는 않음

- 어떤 지표가 무엇을 측정하는지 이해하고 결과를 해석해야 함

딤러닝 파이토치 교과서 6.1.5