



Attention is All You Need

1. Introduction

논문이 다루는 분야

해당 task에서 기존 연구 한계점

논문의 contributions

2. Related Work

RNN-based Model

CNN-based Model

Attention / Self-Attention

3. 제안 방법론

Main Idea

1. Encoder

2. Decoder

3. Scaled Dot-Product Attention

4. Multi-Head Attention

5. Positional Encoding

Contribution

4. 실험 및 결과

Dataset

Machine Translation

English Constituency Parsing

Baseline

결과

1. Machine Translation

2. Self-Attention의 계산적 장점

3. Model Variation / Ablation

4. 다른 Task로의 Generalization

5. 결론 (배운점)

연구의 의의

한계점

1. Introduction



논문에서 다루고 있는 주제가 무엇인지와 해당 주제의 필요성이 무엇인가
논문에서 제안하는 방법이 기존 방법의 문제점에 대응되도록 제안 되었는가

논문이 다루는 분야

이 논문은 **Sequence Transduction**, 즉 하나의 sequence를 입력받아 다른 sequence를 출력하는 문제를 다룬다. 대표적인 응용은 Neural Machine Translation(NMT)이며, 당시 sequence modeling과 translation에서는 **RNN, LSTM, GRU 기반 encoder-decoder 구조**가 사실상 표준적인 접근이었다.

기존 모델들은 일반적으로

Input sequence → RNN/LSTM Encoder → Attention → RNN/LSTM Decoder → Output sequence

와 같은 구조를 사용했다.

이 논문은 여기서 한 단계 더 나아가 “RNN이나 CNN 없이 Attention만으로 sequence modeling이 가능한가?”라는 문제를 제기하고, 이에 대한 답으로 **Transformer**를 제안한다. Transformer는 recurrence와 convolution을 완전히 제거하고 **Attention mechanism**만을 기반으로 input-output 간의 **global dependency**를 모델링한다.

해당 task에서 기존 연구 한계점

1. RNN의 Sequential Computation

- RNN은 현재 위치를 계산하기 위해 이전 위치의 hidden state가 필요함.
- 따라서 sequence를 앞에서부터 순차적으로 처리해야 하며, 하나의 sequence 내부를 병렬 계산하기 어려움.
- Sequence가 길어질수록 이러한 문제가 커지고 GPU를 이용한 효율적인 학습에도 제약이 발생함.
- 기존에도 factorization이나 conditional computation 등을 이용해 효율을 개선하려는 연구가 있었지만, 순차 계산이라는 근본적인 제약은 해결되지 않았음.

2. Long-range Dependency 학습의 어려움

- RNN에서는 멀리 떨어진 두 token의 정보를 연결하기 위해 여러 recurrent step을 거쳐야 함.
- CNN 역시 멀리 떨어진 위치를 연결하려면 여러 convolution layer가 필요함.
- 반면 Self-Attention에서는 모든 token이 서로 직접 연결될 수 있어 멀리 떨어진 정보 사이의 관계를 더 짧은 경로로 학습할 수 있음.

3. 기존 Attention의 한계

- Attention 자체는 이미 machine translation, reading comprehension, summarization 등 다양한 task에서 사용되고 있었음.
- 하지만 대부분의 경우 Attention은 RNN을 보조하는 요소로 사용됨.
- 즉, 기존 연구에서는 Attention만으로 전체 sequence transduction model을 구성하지 않았음.

논문의 contributions

1. Transformer Architecture 제안

- RNN과 CNN을 사용하지 않고 Self-Attention을 중심으로 구성된 새로운 Encoder-Decoder architecture를 제안함.
- Sequence transduction 전체를 Attention 기반으로 수행할 수 있음을 보임.

2. 높은 Parallelization

- RNN처럼 token을 하나씩 순차적으로 계산할 필요가 없어 sequence 내부의 여러 위치를 병렬로 처리할 수 있음.
- 이를 통해 학습 시간을 크게 줄일 수 있음.

3. Long-range Dependency의 효율적인 Modeling

- Self-Attention을 통해 모든 token이 서로 직접 정보를 주고받을 수 있도록 함.
- 멀리 떨어진 token 사이의 관계를 짧은 경로로 학습할 수 있음.

4. 높은 성능과 낮은 Training Cost

- WMT 2014 machine translation에서 기존 모델보다 높은 성능을 기록함.
- 동시에 기존 SOTA 모델보다 적은 training cost를 사용하여 성능과 효율성을 함께 보여줌.

2. Related Work



Introduction에서 언급한 기존 연구들에 대해 어떻게 서술하는가
제안 방법의 차별성을 어떻게 표현하고 있는가

RNN-based Model

- LSTM, GRU를 포함한 recurrent architecture가 당시 sequence modeling과 machine translation의 대표적인 방법이었음.
- 높은 성능을 보였지만 sequence를 순차적으로 처리해야 한다는 근본적인 문제가 존재함.

CNN-based Model

- Extended Neural GPU, ByteNet, ConvS2S 등의 연구에서는 RNN의 sequential computation을 줄이기 위해 convolution을 사용함.
- CNN은 여러 위치를 병렬로 계산할 수 있다는 장점이 있음.
- 하지만 멀리 떨어진 두 token의 정보를 연결하기 위해서는 여러 convolution operation 또는 layer를 거쳐야 함.
- Transformer는 Self-Attention을 사용하여 두 위치 사이를 직접 연결할 수 있다는 점에서 차별화됨.

Attention / Self-Attention

- Self-Attention 자체는 Transformer에서 처음 제안된 개념은 아님.
- 이전에도 reading comprehension, abstractive summarization, textual entailment, sentence representation 등에 활용됨.
- 그러나 기존에는 대부분 RNN 등의 다른 architecture와 함께 사용됨.


3. 제안 방법론



Introduction에서 언급된 내용과 동일하게 작성되어 있는가
Introduction에서 언급한 제안 방법이 가지는 장점에 대한 근거가 있는가
제안 방법에 대한 설명이 구현 가능하도록 작성되어 있는가

Main Idea

Transformer는 기존의 Encoder-Decoder 구조 자체는 유지하면서, 내부의 RNN이나 CNN을 Self-Attention과 Feed-Forward Network로 대체



1. Encoder

각 Encoder layer는 다음 두 부분으로 구성됨.

Multi-Head Self-Attention
→ Feed-Forward Network

- Self-Attention을 통해 sequence 내 모든 token 사이의 관계를 학습함.
- Feed-Forward Network를 통해 각 위치의 representation을 추가적으로 변환함.
- 각 sub-layer에는 Residual Connection과 Layer Normalization을 적용하여 안정적인 학습을 도움

2. Decoder

Decoder layer는 다음 세 부분으로 구성됨.

Masked Multi-Head Self-Attention

→ Encoder-Decoder Attention

→ Feed-Forward Network

Masked Self-Attention

- 현재 token을 예측할 때 미래에 등장할 token을 미리 볼 수 없도록 masking함.
- 이를 통해 기존 autoregressive generation 방식을 유지함.

Encoder-Decoder Attention


- Decoder가 Encoder의 전체 output을 참고하여 다음 token을 생성

3. Scaled Dot-Product Attention

Attention에서는 크게 Query, Key, Value를 사용함.

- Query: 현재 어떤 정보를 찾고 있는지를 나타냄.
- Key: 각 token이 어떤 정보를 가지고 있는지를 나타냄.
- Value: 실제로 전달할 정보를 나타냄.

Scaled Dot-Product Attention



Query와 Key의 유사도 계산

→ Scaling

→ Softmax로 Attention Weight 계산

→ Attention Weight를 이용해 Value 결합


- Query와 Key의 유사도가 높을수록 해당 Value의 정보를 더 많이 가져오게 됨.
- Dot Product Attention은 matrix multiplication으로 효율적으로 구현할 수 있다는 장점이 있음.

Scaling을 사용하는 이유

- Key의 dimension이 커질수록 dot product 값도 커질 가능성이 있음.
- 값이 지나치게 커지면 Softmax가 극단적인 값을 만들고 gradient가 작아져 학습이 어려워질 수 있음.
- 이를 방지하기 위해 dot product의 크기를 조정하는 scaling을 적용함.

4. Multi-Head Attention

- 하나의 Attention만 수행하는 대신 여러 개의 Attention Head를 병렬로 수행함.
- 각 head는 서로 다른 projection을 사용하기 때문에 서로 다른 종류의 관계와 representation을 학습할 수 있음.
- 기본 Transformer에서는 8개의 Attention Head를 사용함.



ex) 서로 다른 head가 각각

- 문법적 관계
- 의미적 관계
- 멀리 떨어진 단어 사이의 관계
- 특정 token 간 dependency

등 서로 다른 정보를 학습 가능

5. Positional Encoding

- RNN은 token을 순서대로 처리하기 때문에 sequence의 순서 정보가 자연스럽게 반영 됨.
- 하지만 Self-Attention은 모든 token을 동시에 처리하기 때문에 그 자체로는 token의 순서를 알 수 X
- 이를 해결하기 위해 각 token embedding에 Positional Encoding을 추가
- 즉, token 자체의 의미뿐만 아니라 해당 token이 sequence에서 몇 번째 위치에 있는 지에 대한 정보도 함께 제공
- 논문에서는 sine/cosine 기반 positional encoding을 사용
- Learned positional embedding도 실험했지만 성능은 거의 동일했음.
- 저자들은 학습 때보다 긴 sequence에도 적용될 가능성을 고려하여 sinusoidal positional encoding을 선택

Contribution

Transformer의 방법론적 핵심은 단순히 Attention이라는 하나의 기술을 제안한 것이 아니라, Self-Attention + Multi-Head Attention + Positional Encoding을 결합하여 RNN 이나 CNN 없이 완전한 Sequence Transduction Architecture를 구성한 것

4. 실험 및 결과



Introduction에서 언급한 제안 방법의 장점을 검증하기 위한 실험이 있는가

Dataset

Machine Translation

WMT 2014 English-German

- 약 450만 개의 sentence pair
- Byte-Pair Encoding 사용
- 약 37,000개의 shared source-target vocabulary

WMT 2014 English-French

- 약 3,600만 개의 sentence pair
- 약 32,000개의 word-piece vocabulary 사용

English Constituency Parsing

- Transformer가 translation 이외의 task에도 적용 가능한지 확인하기 위한 추가 실험
- Penn Treebank의 Wall Street Journal(WSJ) dataset 사용
- WSJ-only setting에서는 약 40K training sentence 사용
- Semi-supervised setting에서는 약 17M sentence를 추가적으로 활용

Baseline

Machine Translation에서는 당시 대표적인 sequence transduction model들과 비교

- ByteNet
- Deep-Att + PosUnk
- GNMT + RL
- ConvS2S
- Mixture-of-Experts
- 기존 모델들의 Ensemble

주요 평가 지표는 BLEU Score이며, 성능뿐만 아니라 Training Cost도 함께 비교

결과

1. Machine Translation

WMT 2014 English-German

- Transformer Base: 27.3 BLEU
- Transformer Big: 28.4 BLEU
- Transformer Big은 당시 기존 최고 결과를 ensemble까지 포함하여 2 BLEU 이상 넘어섬.

WMT 2014 English-French

- Transformer 역시 기존 single model보다 높은 수준의 성능을 기록함.
- 특히 기존 SOTA 모델보다 훨씬 적은 training cost로 높은 성능을 달성함.

→ Introduction에서 주장했던 높은 병렬화와 학습 효율성을 유지하면서도 높은 성능을 얻을 수 있다는 주장을 실제 실험으로 뒷받침

2. Self-Attention의 계산적 장점

구분	병렬화	두 위치 간 정보 전달 경로
Self-Attention	매우 용이	짧음
RNN	어려움	Sequence가 길수록 길어짐
CNN	가능	여러 layer가 필요할 수 있음

- Self-Attention은 모든 위치를 동시에 계산할 수 있음.
- 또한 한 layer에서 모든 token이 직접 연결될 수 있기 때문에 long-range dependency 학습에 유리함.
- 반면 sequence가 길어지면 모든 token pair 사이의 Attention을 계산해야 하므로 계산량이 크게 증가할 수 있다는 한계가 있음.

3. Model Variation / Ablation

논문에서는 Transformer의 여러 구성 요소를 변경하면서 성능 변화를 확인함.

Attention Head 수

- Single-Head Attention은 최적 설정보다 BLEU가 0.9 낮았음.
- 반대로 head 수를 지나치게 많이 증가시켜도 성능이 감소함.
- 적절한 수의 Multi-Head Attention이 중요하다는 것을 보여줌.

Attention Key Dimension

- Key dimension을 줄이면 성능이 감소함.
- Query와 Key 사이의 compatibility를 충분히 표현할 수 있는 dimension이 필요함을 보여줌.

Model Size

- 전반적으로 더 큰 모델이 더 높은 성능을 보임.

Dropout

- Dropout이 overfitting 방지에 중요한 역할을 하는 것으로 나타남.

Positional Encoding

- Sinusoidal positional encoding을 learned positional embedding으로 변경했을 때 거의 동일한 성능을 보임.
- Transformer의 성능이 특정 positional encoding 방식에 크게 의존하지 않는다는 것을 확인

4. 다른 Task로의 Generalization

- English Constituency Parsing에서도 Transformer를 적용함.
- WSJ-only setting에서 91.3 F1
- Semi-supervised setting에서 92.7 F1을 기록함.
- 많은 task-specific tuning 없이도 기존 모델들과 경쟁력 있는 결과를 기록함.

→ Transformer가 단순히 machine translation에만 특화된 architecture가 아니라 다른 sequence modeling task에도 적용될 가능성을 보여줌.

5. 결론 (배운점)



연구의 의의 및 한계점, 본인이 생각하는 좋았던/아쉬웠던 점 (배운점)

연구의 의의

- 당시 Sequence Modeling에서 사실상 기본적으로 사용되던 **RNN의 recurrence가 반드시 필요한 것은 아니라는 것을 보여준 연구임.**
- 기존에는 Attention이 RNN을 보조하는 역할이었다면, Transformer에서는 **Attention 자체를 architecture의 중심으로 이동시킴.**
- RNN과 CNN 없이도 sequence transduction이 가능하며, 오히려 높은 병렬화와 높은 성능을 동시에 얻을 수 있음을 보임.

한계점

1. 긴 Sequence에서 Self-Attention의 높은 계산량

- 모든 token pair 사이의 관계를 계산하기 때문에 sequence가 길어질수록 연산량과 memory 사용량이 빠르게 증가함.

- 논문에서도 긴 sequence를 효율적으로 처리하기 위해 local/restricted attention을 향후 연구 방향으로 제시함.

2. 실험 Task의 범위

- 주요 실험이 Machine Translation에 집중되어 있음.
- Constituency Parsing에서도 추가 검증했지만, 논문 발표 당시에는 다양한 task와 modality에 대한 범용성이 충분히 검증된 것은 아님
- 저자들도 향후 image, audio, video 등의 다른 modality로 확장하는 것을 future work로 제시