

9/22 논문 - Auto-Encoding Variational Bayes (VAE)

1. Introduction

<https://arxiv.org/pdf/1312.6114>

논문이 다루는 분야

연속 잠재변수를 가진 directed probabilistic model에서의 근사 추론과 학습을 다룬다. 데이터가 관측되지 않은 연속 변수 z 로부터 생성된다고 가정하고, 사후분포 $p(z|x)$ 를 근사 하면서 동시에 모델 파라미터를 학습하는 문제다. 실험은 MNIST와 Frey Face 이미지의 생성 모델 학습으로 수행한다.

가정하는 생성 과정은 두 단계다. 먼저 prior $p_{\theta}(z)$ 에서 z 를 뽑고, 그 z 를 조건으로 $p_{\theta}(x|z)$ 에서 x 를 생성한다. 관측되는 것은 x 뿐이고 참 파라미터 θ^* 와 각 데이터의 z 값은 모두 알 수 없다.

논문은 이 상황에서 marginal likelihood의 variational lower bound를 reparameterization으로 다시 쓰면, 표준 stochastic gradient 방법으로 바로 최적화할 수 있는 추정량이 나온다는 것을 보인다. (원문 §1, §2.1)

해당 task에서 기존 연구 한계점

논문은 두 가지 조건을 동시에 가정한다. 하나는 intractability, 다른 하나는 큰 데이터셋이다.

1. Intractability

marginal likelihood는 다음과 같이 z 에 대한 적분으로 정의된다.

$$p_{\theta}(x) = \int p_{\theta}(z) p_{\theta}(x|z) dz$$

$p_{\theta}(x|z)$ 가 비선형 은닉층을 가진 신경망처럼 조금만 복잡해져도 이 적분은 계산할 수 없다. 그러면 $p_{\theta}(z|x) = p_{\theta}(x|z)p_{\theta}(z) / p_{\theta}(x)$ 도 계산할 수 없으므로, E step에서 사후분포가 필요한 EM은 사용할 수 없다. mean-field VB 역시 근사 사후분포에 대한 기댓값을 해석적으로 풀 수 있어야 하는데, 일반적인 경우에는 그 해가 존재하지 않는다.

2. 큰 데이터셋

데이터가 많으면 전체 배치 최적화는 비용이 너무 크므로 미니배치나 단일 데이터로 파라미터를 갱신하고 싶다. 그런데 Monte Carlo EM 같은 샘플링 기반 방법은 데이터 하나마다 비싼 샘플링 루프를 돌려야 해서 일반적으로 너무 느리다.

3. 기존 gradient 추정량의 분산

변분 파라미터 ϕ 에 대한 lower bound의 gradient를 구할 때 흔히 쓰는 Monte Carlo 추정량은 다음과 같다.

$$\nabla_{\phi} E_q[f(z)] = E_q[f(z) \nabla_{\phi} \log q_{\phi}(z)]$$

형태 자체는 성립하지만 분산이 매우 커서 실제로 쓰기 어렵다. 논문은 이 점을 기존 방식의 직접적인 걸림돌로 지목한다. (원문 §2.1, §2.2)

논문의 contributions

1. SGVB (Stochastic Gradient Variational Bayes) estimator 제안

- variational lower bound를 reparameterization으로 다시 쓰면, 미분 가능하고 unbiased인 lower bound 추정량을 얻는다. 이 추정량은 표준 stochastic gradient ascent로 그대로 최적화할 수 있다.

1. AEVB (Auto-Encoding VB) 알고리즘 제안

- i.i.d. 데이터셋이고 데이터마다 연속 잠재변수를 가지는 경우, recognition model $q_{\phi}(z|x)$ 를 intractable한 사후분포에 맞추어 학습시킨다. 이후 사후추론은 ancestral sampling만으로 끝나므로, MCMC처럼 데이터마다 반복적인 추론 절차를 돌릴 필요가 없다.

1. Variational Auto-Encoder

- recognition model을 신경망으로 두면 VAE가 된다. 학습된 recognition model은 인식, denoising, 표현 학습, 시각화 등에 재사용할 수 있다. (원문 §1)

2. Related Work



Introduction에서 언급한 기존 연구들에 대해 어떻게 서술하는가
제안 방법의 차별성을 어떻게 표현하고 있는가

Wake-Sleep 알고리즘

논문이 아는 범위에서 같은 종류의 연속 잠재변수 모델에 적용 가능한 유일한 다른 온라인 학습 방법으로 wake-sleep을 든다. wake-sleep도 참 사후분포를 근사하는 recognition model을 사용한다는 점에서 AEVB와 공통점이 있다.

차이는 목적함수다. wake-sleep은 두 개의 목적함수를 동시에 최적화하는데, 이 둘을 합쳐도 marginal likelihood의 bound를 최적화하는 것에 대응하지 않는다. 반면 이산 잠재변수

에도 적용할 수 있다는 점은 wake-sleep의 장점으로 명시한다. 데이터당 계산 복잡도는 AEVB와 같다.

Stochastic Variational Inference 계열

naive한 gradient 추정량의 큰 분산을 줄이려는 연구들이 이어졌다. control variate를 도입해 분산을 낮춘 연구, 보다 일반적인 control variate 기법을 제시한 Black Box Variational Inference, 그리고 이 논문과 유사한 reparameterization을 지수족 근사 분포 학습에 사용한 연구가 있다. 즉 문제의식은 공유하되, 해결 방식이 control variate 쪽인지 reparameterization 쪽인지가 갈린다.

Auto-Encoder와의 연결

AEVB는 directed probabilistic model과 auto-encoder 사이의 연결을 드러낸다. 선형 auto-encoder와 linear-Gaussian 모델의 관계는 이미 알려져 있었고, PCA가

$p(z)=N(0, I)$, $p(x|z)=N(x; Wz, \epsilon I)$ 인 선형 가우시안 모델의 ML 해에 대응한다는 결과가 그 예다.

정규화가 없는 auto-encoder의 학습 기준은 입력 X 와 표현 Z 사이의 상호정보량 하한을 최대화하는 것에 해당한다는 연구도 있다. 다만 reconstruction 기준만으로는 유용한 표현을 학습하기에 충분하지 않다는 점이 알려져 있어, denoising, contractive, sparse auto-encoder 같은 정규화 기법이 제안되어 왔다.

여기서 논문의 차별성이 드러난다. SGVB의 목적함수에는 variational bound 자체가 요구하는 정규화 항, 즉 KL 항이 이미 들어 있다. 따라서 유용한 표현을 얻기 위해 따로 정규화 하 이퍼파라미터를 도입할 필요가 없다.

동시기 연구

DARN은 auto-encoding 구조로 directed probabilistic model을 학습하지만 이진 잠재 변수를 대상으로 한다. Rezende 등의 연구는 이 논문과 독립적으로, auto-encoder와 directed probabilistic model, 그리고 동일한 reparameterization 사이의 연결을 제시했다. 논문은 이를 AEVB에 대한 추가적인 관점으로 소개한다. (원문 §4)

3. 제안 방법론



Introduction에서 언급된 내용과 동일하게 작성되어 있는가
Introduction에서 언급한 제안 방법이 가지는 장점에 대한 근거가 있는가
제안 방법에 대한 설명이 구현 가능하도록 작성되어 있는가

Main Idea

1. Recognition model: encoder와 decoder

intractable한 참 사후분포 $p_{\theta}(z|x)$ 를 근사하기 위해 recognition model $q_{\phi}(z|x)$ 를 도입한다. mean-field 변분추론과 달리 이 근사 사후분포는 factorial일 필요가 없고, 변분 파라미터 ϕ 를 닫힌 형태의 기댓값으로 구하지도 않는다. 대신 ϕ 를 생성 파라미터 θ 와 함께 학습한다.

코딩 관점에서 보면 z 는 code이고, $q_{\phi}(z|x)$ 는 데이터 x 를 받아 그 x 를 만들어냈을 code의 분포를 내놓는 probabilistic encoder다. 반대로 $p_{\theta}(x|z)$ 는 code z 를 받아 대응하는 x 의 분포를 내놓는 probabilistic decoder다. (원문 §2.1)

2. Variational lower bound

데이터 하나의 log marginal likelihood는 다음과 같이 분해된다.

$$\log p_{\theta}(x) = D_{KL}(q_{\phi}(z|x) \parallel p_{\theta}(z|x)) + L(\theta, \phi; x)$$

KL은 항상 0 이상이므로 두 번째 항이 lower bound가 된다.

$$\log p_{\theta}(x) \geq L(\theta, \phi; x) = E_q[-\log q_{\phi}(z|x) + \log p_{\theta}(x, z)]$$

이를 다시 쓰면 다음 형태가 된다.

$$L(\theta, \phi; x) = -D_{KL}(q_{\phi}(z|x) \parallel p_{\theta}(z)) + E_q[\log p_{\theta}(x|z)]$$

첫 항은 근사 사후분포를 prior에 가깝게 붙잡는 정규화 항이고, 두 번째 항은 기대 reconstruction error에 음수를 붙인 것에 해당한다. 문제는 이 bound를 ϕ 로 미분할 때 생긴다. 앞서 본 naive Monte Carlo gradient는 분산이 너무 커서 쓸 수 없다. (원문 §2.2)

3. Reparameterization trick

핵심 장치다. z 를 $q_{\phi}(z|x)$ 에서 직접 뽑는 대신, 보조 잡음 변수 ϵ 를 먼저 뽑고 결정론적 변환을 거쳐 z 를 만든다.

$$\tilde{z} = g_{\phi}(\epsilon, x), \quad \epsilon \sim p(\epsilon)$$

이렇게 하면 기댓값이 ϕ 에 의존하지 않는 분포 $p(\epsilon)$ 에 대한 기댓값으로 바뀐다.

$$E_{q_{\phi}(z|x)}[f(z)] = E_{p(\epsilon)}[f(g_{\phi}(\epsilon, x))] \approx (1/L) \sum_l f(g_{\phi}(\epsilon^{(l)}, x))$$

샘플링 자체가 ϕ 바깥으로 빠지므로, 추정량 전체가 ϕ 에 대해 미분 가능해진다. 가우시안이 라면 $z = \mu + \sigma \cdot \epsilon$, $\epsilon \sim N(0, 1)$ 형태가 된다.

논문은 이런 변환을 고를 수 있는 세 가지 경우를 정리한다.

- **Tractable inverse CDF:** $\epsilon \sim U(0, 1)$ 로 두고 g 를 q 의 역누적분포함수로 둔다. Exponential, Cauchy, Logistic, Rayleigh, Pareto, Weibull 등.
- **Location-scale family:** 표준 분포를 보조 변수로 두고 $g = \text{location} + \text{scale} \cdot \epsilon$. Laplace, Student's t, Logistic, Uniform, Gaussian 등.
- **Composition:** 보조 변수들의 변환으로 표현되는 경우. Log-Normal, Gamma, Dirichlet, Beta, Chi-Squared, F 등. (원문 §2.4)

4. SGVB estimator와 AEVB 알고리즘

reparameterization을 lower bound에 적용하면 일반형 추정량이 나온다.

$$\tilde{L}^A = (1/L) \sum_l [\log p_\theta(x, z^l) - \log q_\phi(z^l|x)], \quad z^l = g_\phi(\epsilon^l, x)$$

KL 항을 해석적으로 적분할 수 있는 경우에는 두 번째 형태를 쓴다. 이쪽이 분산이 더 작다.

$$\tilde{L}^B = -D_{KL}(q_\phi(z|x) \parallel p_\theta(z)) + (1/L) \sum_l \log p_\theta(x | z^l)$$

전체 데이터셋에 대해서는 미니배치로 근사한다.

$$L(\theta, \phi; X) \approx (N/M) \sum_{i=1}^M \tilde{L}(\theta, \phi; x^{(i)})$$

논문은 $M=100$ 정도로 미니배치가 충분히 크면 데이터당 샘플 수 L 은 1로 두어도 된다고 보고한다. 알고리즘은 미니배치를 뽑고, 잡음 ϵ 를 뽑고, 추정량의 gradient를 구해 SGD나 Adagrad로 갱신하는 반복이다. (원문 §2.3, Algorithm 1)

5. Variational Auto-Encoder

위 틀에 구체적인 분포를 넣으면 VAE가 된다.

- **Prior:** $p_\theta(z) = N(z; \theta, I)$. 파라미터가 없다.
- **근사 사후분포:** 대각 공분산을 갖는 다변량 가우시안 $\log q_\phi(z|x) = \log N(z; \mu, \sigma^2 I)$. 이때 μ 와 $\log \sigma^2$ 는 x 를 입력으로 받는 MLP의 출력이다. 논문은 이 형태가 방법의 제약이 아니라 단순화를 위한 선택임을 각주로 밝힌다.
- **샘플링:** $z = \mu + \sigma \odot \epsilon$, $\epsilon \sim N(0, I)$.
- **Decoder:** 이진 데이터면 Bernoulli MLP, 실수 데이터면 Gaussian MLP를 쓴다.

prior와 근사 사후분포가 모두 가우시안이므로 KL 항을 해석적으로 계산할 수 있고, 최종 목적함수는 다음과 같다.

$$L(\theta, \phi; x) \approx (1/2) \sum_j (1 + \log(\sigma_j^2) - \mu_j^2 - \sigma_j^2) + (1/L) \sum_l \log p_\theta(x | z^l)$$

앞부분이 정규화 항, 뒷부분이 reconstruction 항이다. (원문 §3, Appendix B, C)

4. 실험 및 결과

Dataset

- **MNIST:** 손글씨 숫자 이미지. 인코더와 디코더의 은닉 유닛 수는 500개로 두었다.
- **Frey Face:** 얼굴 이미지. 데이터셋이 작아 과적합을 막기 위해 은닉 유닛 수를 200개로 줄였다. 값이 연속이므로 디코더는 가우시안 출력을 쓰되, 평균을 (0,1) 구간으로 제한하기 위해 sigmoid를 적용했다.
- 잠재공간 차원 N_z 를 바꾸어 가며 비교했고(MNIST는 3, 5, 10, 20, 200), marginal likelihood 비교에서는 학습 데이터 수를 1,000개와 50,000개로 나누어 실험했다. (원문 §5)

Baseline

- **Wake-Sleep:** 같은 encoder 구조를 공유하도록 맞추고 비교했다. 두 실험 모두에서 비교 대상이다.
- **Monte Carlo EM (MCEM):** Hybrid Monte Carlo 샘플러를 쓰는 방식으로, marginal likelihood 비교에서만 등장한다. 온라인 알고리즘이 아니므로 전체 MNIST에는 효율적으로 적용할 수 없다.

공통 설정은 파라미터를 $N(0, 0.01)$ 에서 랜덤 초기화하고 MAP 기준으로 함께 최적화하며, Adagrad의 stepsize는 $\{0.01, 0.02, 0.1\}$ 중에서 초기 학습 성능을 보고 골랐다. 미니배치 $M=100$, 데이터당 샘플 $L=10$ 이다. weight decay는 $p(\theta)=N(0, I)$ prior에 대응한다.

평가는 두 가지 기준으로 한다. 하나는 데이터당 추정 variational lower bound, 다른 하나는 MCMC 기반 추정량으로 구한 marginal likelihood다. (원문 §5)

결과

1. Lower bound 비교 — Figure 2

모든 잠재공간 차원 설정에서 AEVB가 wake-sleep보다 빠르게 수렴했고, 더 좋은 해에 도달했다.

흥미로운 지점은 잠재변수 수를 늘려도 과적합이 나타나지 않았다는 것이다. 논문은 이를 lower bound가 가진 정규화 효과로 설명한다. KL 항이 근사 사후분포를 prior에 가깝게 붙잡기 때문에, 쓰이지 않는 잠재 차원이 늘어도 자유도가 그대로 과적합으로 이어지지 않는다는 해석이다.

계산 비용은 40 GFLOPS 수준의 Intel Xeon CPU에서 학습 샘플 100만 개당 약 20~40 분이었다.

2. Marginal likelihood 비교 — Figure 3

잠재공간 차원이 매우 낮을 때만 MCMC 추정량으로 marginal likelihood를 추정할 수 있으므로, 은닉 유닛 100개에 잠재변수 3개로 설정했다. 차원이 더 높아지면 추정치를 신뢰할 수 없게 된다.

학습 데이터 1,000개와 50,000개에 대해 AEVB, wake-sleep, MCEM의 수렴 속도를 비교했다. MCEM은 온라인 알고리즘이 아니라서 전체 MNIST에는 효율적으로 적용할 수 없다는 제약이 함께 지적된다.

3. 잠재공간 시각화 — Figure 4, 5

잠재공간을 2차원으로 두면 학습된 encoder를 고차원 데이터의 저차원 사영으로 쓸 수 있다. 단위 정사각형 위의 균등 좌표를 가우시안 역누적분포함수로 변환해 z 값을 만들고, 각 z 에 대해 $p_{\theta}(x|z)$ 의 생성 파라미터를 그렸다. MNIST에서는 숫자 모양이, Frey Face에서는 표정과 각도가 연속적으로 변하는 manifold가 나타난다.

잠재공간 차원을 2, 5, 10, 20으로 바꾸며 랜덤 샘플도 비교했다. (원문 §5, Appendix A)

5. 결론 (배운점)

의의

핵심은 샘플링 단계를 파라미터 바깥으로 밀어낸 것이다. 잠재변수를 분포에서 직접 뽑으면 그 지점에서 gradient가 끊기지만, 잡음을 먼저 뽑고 결정론적 변환을 통과시키면 목적함수 전체가 미분 가능해진다. 덕분에 특별한 추론 알고리즘 없이 표준 stochastic gradient 방법으로 학습할 수 있다.

또 하나는 recognition model을 함께 학습한다는 점이다. 데이터마다 반복적인 추론 절차를 돌리는 대신 사후분포를 내놓는 신경망을 한 번 학습해 두고 재사용한다. 그 결과 auto-encoder 구조가 자연스럽게 나타나고, 정규화 항도 임의로 붙인 것이 아니라 variational bound에서 따라 나온다. (원문 §6)

한계

- **이산 잠재변수에는 적용할 수 없다.** reparameterization은 잠재변수가 연속이고 변환이 미분 가능할 때 성립한다. 논문 스스로 이산 잠재변수에 적용 가능하다는 점을 wake-sleep의 장점으로 적고 있다.
- **Marginal likelihood 평가의 범위가 좁다.** MCMC 기반 추정량은 샘플링 공간의 차원이 낮을 때(5 미만) 정도에서만 좋은 추정치를 낸다. 그보다 높은 차원에서는 추정이 불안정해진다.
- **실험 규모.** 검증은 MNIST와 Frey Face 두 데이터셋, 은닉층 하나짜리 MLP 수준에서 이루어졌다. 더 깊거나 다른 형태의 모델로 결과를 바로 일반화할 수는 없다.
- **Full VB는 미완.** 파라미터 θ 에 대해서도 변분추론을 수행하는 알고리즘은 부록에 유도만 실려 있고 실험은 future work로 남겼다.
- **향후 방향:** 합성곱 신경망을 쓴 계층적 생성 구조, 시계열 모델, 전역 파라미터에 대한 SGVB 적용, 잠재변수를 가진 지도 학습 모델 등을 제시한다. (원문 §7)

배운 점

읽으면서 가장 오래 걸린 것은 lower bound를 올리는 일이 왜 두 가지를 동시에 하는 일인지였다. $\log p_{\theta}(x) = D_{KL}(q||p_{\theta}(z|x)) + L$ 에서 좌변은 ϕ 와 무관하게 고정되어 있으므로, ϕ 를 움직여 L을 올리면 그만큼 KL이 줄어든다. 즉 같은 목적함수가 θ 쪽으로는 데이터의 likelihood를 올리고, ϕ 쪽으로는 근사 사후분포를 참 사후분포에 가깝게 만든다. 처음에는 bound를 최대화하는 것과 사후분포를 근사하는 것이 별개의 작업처럼 보였는데, 하나의 식에서 갈라져 나온다는 점을 확인하고 나서 정리가 되었다.

Reparameterization도 샘플링을 없애는 기법으로 잘못 이해했었다. 실제로는 샘플링을 없애는 것이 아니라 위치를 옮기는 것이다. z 를 $q_\phi(z|x)$ 에서 직접 뽑으면 무작위성이 ϕ 안쪽에 있어서 gradient가 그 지점에서 끊기고, 그래서 $f(z)\nabla_\phi \log q_\phi(z)$ 형태의 추정량을 쓸 수밖에 없다. 이 형태는 f 의 값 자체가 곱해지는 구조라 f 가 조금만 흔들려도 추정량이 크게 흔들린다. 잡음을 바깥에서 먼저 뽑으면 기댓값을 취하는 분포가 ϕ 와 무관해지므로, 무작위성은 남아 있어도 gradient가 f 내부를 그대로 통과한다.

분산을 줄이는 원리도 같은 맥락에서 이해하게 되었다. 추정량 B 가 A 보다 분산이 작은 이유는 새로운 기법을 더해서가 아니라, KL 항을 해석적으로 적분해 몬테카를로로 추정해야 하는 부분을 줄였기 때문이다. 계산할 수 있는 것은 계산하고 남은 것만 샘플링한다는 단순한 방향이다. 미니배치가 $M=100$ 정도면 데이터당 샘플 L 을 1로 두어도 된다는 것도, 데이터 하나에서 생긴 잡음이 배치 단위에서 평균되며 상쇄된다는 점으로 읽었다.

마지막으로 KL 항을 정규화 항이라고 부르는 것이 해석이라는 점을 구분하게 되었다. 목적 함수에 정규화를 붙인 것이 아니라 variational bound를 전개하면 원래 그 항이 나오고, 그것을 auto-encoder 관점에서 다시 읽으면 정규화 항으로 보이는 것이다. 하나의 식을 확률 모델로도, auto-encoder로도 읽을 수 있다는 것이 이 논문의 구조였다.

남은 학습 과제는 Appendix B의 KL 해석해 유도를 직접 따라가 식 (10)이 어떻게 나오는지 확인하는 것과, decoder를 Bernoulli로 둘 때와 Gaussian으로 둘 때 reconstruction 항이 각각 어떤 손실 형태가 되는지 작은 예제로 확인하는 것이다.