



Week3_예습과제_김재희

교재 정리

13장 생성 모델

13.1 생성 모델이란

13.1.1 생성 모델 개념

13.1.2 생성 모델의 유형

13.2 변형 오토인코더

13.2.1 오토인코더란

13.2.2 변형 오토인코더

Auto-Encoding Variational Bayes (VAE) 리뷰

용어 정리

1. Introduction

논문이 다루는 분야

해당 task에서 기존 연구 한계점

논문의 contributions

2. Related Work

3. 제안 방법론

Main Idea

풀고 싶은 문제 3개

Contribution

4. 실험 및 결과

Dataset

Dataset

Baseline

실험 설정

결과

교재 정리

13장 생성 모델

13.1 생성 모델이란

생성 모델: 주어진 데이터를 학습해 데이터 분포를 따르는 유사한 데이터를 생성하는 모델

13.1.1 생성 모델 개념

판별자 모델: 이미지 데이터셋이 주어졌을 때 그 이미지를 분류하는 모델. 일반적으로 이미지를 정확히 분류하고자 해당 이미지를 대표하는 특성들을 잘 찾는 것을 목표로 한다. 예를 들어 개, 고양이를 구별하려면 귀, 꼬리 등의 특성을 찾는 것이 중요하다.

생성자 모델: 판별자 모델에서 추출한 특성들의 조합을 이용해 새로운 개와 고양이 이미지를 생성하는 모델

13.1.2 생성 모델의 유형

- 변형 오토인코더 모델: 모델의 확률 변수를 구함. 명시적 방법. 확률 변수 $p(x)$ 를 정의하여 사용한다. 이미지의 잠재 공간에서 샘플링하여 완전히 새로운 이미지나 기존 이미지를 변형하는 방식으로 학습을 진행한다.
- GAN 모델: 모델의 확률 변수를 이용하지 않음. 암시적 방법. 확률 변수 $p(x)$ 에 대한 정의 없이 $p(x)$ 를 샘플링하여 사용한다. 생성자와 판별자가 서로 경쟁하면서 가짜 이미지를 최대한 진짜 이미지와 비슷하게 만들도록 학습을 진행한다.

13.2 변형 오토인코더

변형 오토인코더는 오토인코더의 확장이다.

13.2.1 오토인코더란

입력을 출력으로 복사하는 신경망으로 은닉층 노드 수가 입력 값보다 적은 것이 특징이다. 은닉층은 입출력 뉴런보다 훨씬 적는데, 즉 적은 수의 은닉층 뉴런으로도 데이터를 가장 잘 표현할 수 있는 방법이다. 오토인코더는 네 가지 주요 부분으로 구성된다.

1. 인코더: 특성에 대한 학습을 수행하는 부분


2. 병목층(은닉층): 뉴런 개수가 최소인 계층. 차원이 가장 낮은 입력 데이터의 압축 표현이 포함된다.
3. 디코더: 병목층에서 압축된 데이터를 원래대로 재구성함. 최대한 입력에 가까운 출력을 생성하도록 한다.
4. 손실 재구성: 오토인코더는 입력층과 출력층 뉴런 개수가 동일하다는 것만 제외하면 일반적인 다층 퍼셉트론과 구조가 동일하다. 손실 함수는 입력과 출력(인코더와 디코더)의 차이를 가지고 계산한다.

오토인코더가 중요한 이유

1. 데이터 압축: 메모리 측면에서 상당한 장점. 이미지, 음성 파일의 중요 특성만 압축하면 용량도 작고 품질도 더 좋아진다.
2. 차원의 저주 예방: 특성 개수를 줄여 주기 때문에 데이터 차원이 감소한다.
3. 특성 추출: 비지도 학습으로 자동으로 중요한 특성을 찾는다.

13.2.2 변형 오토인코더


▼ 그림 13-9 오토인코더 실행 과정



오토인코더는 차원을 줄이는 것이 목표이기 때문에 새롭게 생성된 데이터의 확률 분포에는 관심이 없다.


반면 변형 오토인코더는 표준편차와 평균을 이용해 확률 분포를 만들고, 거기에서 샘플링하여 디코더를 통과시킨 후 새로운 데이터를 만들어 낸다. 즉, 변형 오토인코더는 입력 데이터와 조금 다른 출력 데이터를 만들어 내는데, 이때 z 라는 가우시안 분포를 이용한다(z 를 잠재 벡터라고 한다). 중요한 특성의 파라미터를 담고 있는 z 분포에서 벡터를 랜덤하게 샘플링하고 이 분포의 오차를 이용해 입력 데이터와 유사한 다양한 데이터를 만들어 내는 것이 변형 오토인코더이다.

▼ 그림 13-10 변형 오토인코더 실행 과정



오토인코더는 데이터 벡터 차원을 축소해 실제 이미지와 동일한 이미지를 출력하는 것이 목적이었다면, 변형 오토인코더는 데이터가 만들어지는 확률 분포를 찾아 비슷한 데이터를 생성하는 것이 목적이다.

▼ 그림 13-11 변형 오토인코더의 인코더와 디코더



q: x를 입력받아 잠재 벡터 z와 대응되는 평균과 분산을 구하는 네트워크로 인코더 네트워크를 의미한다.

p: z를 입력받아 x와 대응되는 평균과 분산을 구하는 네트워크로 디코더 네트워크를 의미한다.

Auto-Encoding Variational Bayes (VAE) 리뷰

용어 정리

용어	쉬운 뜻
intractable	계산이 사실상 불가능
mean-field	기존 VB 방식. 모델마다 수식을 손으로 풀어야 해서 범용성이 낮음
SGVB	ELBO의 미분 가능한 추정량
AEVB	SGVB로 인코더를 학습 시키는 알고리즘
MCMC	데이터 하나마다 반복 샘플링을 돌려야 하는 정확하지만 느린 방법
ancestral sampling	인코더 통과 → 샘플 뽑기로 끝나는 단순한 샘플링

1. Introduction



논문에서 다루고 있는 주제가 무엇인지와 해당 주제의 필요성이 무엇인가
논문에서 제안하는 방법이 기존 방법의 문제점에 대응되도록 제안 되었는가

논문이 다루는 분야

- 인식
- 노이즈 제거
- 표현 학습
- 시각화

해당 task에서 기존 연구 한계점

- z 가 연속일 때 신경망 디코더를 쓰면 $p(z|x)$ 를 구하지 못함
- $p(x)$ 의 적분이 intractable해서 posterior, EM, mean-field 모두 사용 불가
- 일반 Monte Carlo gradient 추정량은 분산이 커서 비실용적이고, 데이터마다 샘플링 (MCMC, MCEM)은 큰 데이터셋에서 너무 느림

논문의 contributions

1. variational lower bound를 reparameterization하면, 표준적인 확률적 경사법으로 쉽게 최적화할 수 있는 lower bound 추정량이 나온다는 것을 보임.
2. 데이터포인트마다 연속 잠재 변수가 있는 i.i.d. 데이터셋에서, 제안한 lower bound 추정량으로 intractable한 posterior에 근사 추론 모델을 맞추면 posterior 추론을 특히 효율적으로 할 수 있음을 보임. 이론적 장점은 실험 결과에도 반영됨.

2. Related Work



Introduction에서 언급한 기존 연구들에 대해 어떻게 서술하는가
제안 방법의 차별성을 어떻게 표현하고 있는가

기존 방법으로는 근사 VB가 있는데, 그 중 mean-field는 수식으로 기댓값을 풀어야 해서 복잡한 모델엔 못 씀.

기존 연구	논문의 서술	차별점
Wake-sleep	같은 종류의 모델에 쓸 수 있는 유일한 온라인 방법	두 목적함수를 따로 최적화해서 marginal likelihood의 bound를 최적화하는 것과 대응되지 않음. AEVB는 하나의 bound 를 최적화 (wake-sleep은 이산 latent도 가능한 게 장점)
Stochastic VI (control variate 계열)	분산을 줄이려고 control variate를 도입	reparameterization으로 추정량 자체를 미분 가능하게 만듦
일반 오토인코더	재구성 기준만으로는 유용한 표현을 못 배움. denoising, sparse 등 정규화 변형이 필요	SGVB의 KL 항이 정규화 역할을 하고, 별도의 정규화 하이퍼파라미터가 필요 없음
PCA와의 관계	선형-가우시안 모델의 ML 해가 PCA	VAE는 이것의 비선형 확장으로 볼 수 있음
DARN, Rezende et al.	DARN은 이산 latent 대상, Rezende et al.은 같은 연결을 독립적으로 발견	연속 latent + 일반적인 directed 모델
Boltzmann machine, sparse coding 계열	무방향 모델이거나 sparse coding에 한정	일반적인 directed 확률 모델


3. 제안 방법론



Introduction에서 언급된 내용과 동일하게 작성되어 있는가
Introduction에서 언급한 제안 방법이 가지는 장점에 대한 근거가 있는가
제안 방법에 대한 설명이 구현 가능하도록 작성되어 있는가

Main Idea

용어	쉬운 뜻
i.i.d.	데이터 각각이 서로 독립이고 같은 분포에서 나옴
전역 파라미터 (θ)	모든 데이터가 공유 하는 파라미터 (디코더 가중치)
잠재 변수 (z)	데이터마다 따로 있는 숨은 변수
ML	데이터를 가장 잘 설명하는 θ 하나 를 찾는 방법
MAP	ML인데 θ 에 대한 사전 믿음(prior)까지 반영
변분 추론	근사 분포 q 로 posterior를 근사하는 방법
온라인 / 비정상	데이터가 계속 흘러들어오고 분포가 변하는 상황



요소	의미
x	우리가 관측 하는 데이터 (색칠 = 관측됨)
z	관측 안 되는 숨은 변수
실선 $z \rightarrow x$	생성 : z 로 x 를 만듦 (디코더 $p_{\theta}(x z)$)
점선 $x \rightarrow z$	근사 추론 : x 로 z 를 추정 (인코더 $q_{\phi}(z x)$)
θ (실선 화살표)	생성 모델의 파라미터
ϕ (점선 화살표)	인코더의 파라미터
N	이 구조가 N번 반복됨을 의미

posterior를 직접 구하지 못하기 때문에 인코더로 근사함.

데이터가 만들어지는 과정

- $z \sim p(z)$ ← ① 숨은 요인을 뽑고
 $x \sim p(x|z)$ ← ② 그 요인으로 데이터를 만든다

기호	의미
θ^*	진짜 파라미터 (하지만 아무도 모름)
θ	학습으로 찾아가는 파라미터
$z^{(i)}$	데이터 i번의 숨은 요인 (우리한테 안 보임)

어려움	원인	쉬운 뜻
Intractability	$p(x) = \int p(z)p(x z)dz$	아까 본 분포 $p(x)$ 를 못 구함 → posterior도, EM도, mean-field도 다 막힘
큰 데이터셋	데이터마다 샘플링 루프 (MCEM 등)	데이터가 많으면 너무 느림 → 미니배치로 학습해야 함

풀고 싶은 문제 3개

#	문제	쉬운 뜻	활용
1	θ 추정	생성 과정 자체를 학습	새 데이터 생성
2	z 추론	x 를 보고 숨은 요인 추정	표현 학습, 압축
3	x 자체의 분포	"정상 데이터란 이런 것" 을 학습	노이즈 제거, 이미지 복원

$$L = E_q[\log p(x,z) - \log q(z|x)]$$

$$\log p(x) = KL(q \parallel \text{진짜 posterior}) + L$$

여기서 $\log p(x)$ 는 고정, KL 은 0 이상이며 직접 측정 불가능하고, L 은 계산 가능하다.

$$L = -KL(q(z|x) \parallel p(z)) + E_q[\log p(x|z)]$$

L 정규화 항 L 재구성 항

Reparameterization

- $z \sim q_\phi(z|x)$ 를 $z = \mu + \sigma \odot \epsilon$, $\epsilon \sim N(0, I)$ 로 바꿈
- 랜덤성을 ϕ 와 무관한 ϵ 으로 빼서 gradient가 흐름

SGVB 추정량

	추정량 A (식 6)	추정량 B (식 7)
방식	$\log p(x,z) - \log q$ 전체를 샘플링	KL 은 closed form, 재구성 항만 샘플링
분산	큼	작음

AEVB 알고리즘

- 미니배치 M 개 샘플링 (실험에서 $M=100$)
- ϵ 샘플링 (샘플 수 $L=1$)

3. 미니배치 ELBO (식 8, N/M 배율)의 gradient 계산
4. θ (디코더)와 ϕ (인코더)를 **동시에** 업데이트 (SGD, Adagrad)
5. 수렴할 때까지 반복

VAE 구체 구현

- prior: $N(0, I)$
- 인코더: MLP가 $(\mu, \log \sigma^2)$ 를 출력 (대각 공분산 가우시안)
- 디코더: 이진 데이터(MNIST)는 Bernoulli MLP, 연속 데이터(Frey Face)는 Gaussian MLP
- 가우시안이라 KL이 closed form

Contribution

- **SGVB**: reparameterization으로 ELBO의 미분 가능한 추정량을 만들 → 표준 SGD로 최적화 가능
- **AEVB**: 그 추정량으로 인식 모델(인코더)을 학습 → 데이터마다 MCMC 없이 효율적으로 근사 추론

4. 실험 및 결과



Introduction에서 언급한 제안 방법의 장점을 검증하기 위한 실험이 있는가

Dataset

Dataset

- MNIST
- Frey Face

Baseline

- **Wake-sleep**: 같은 인코더를 써서 비교
- **Monte Carlo EM (MCEM)**: marginal likelihood 비교에서만 사용

실험 설정

항목	값
은닉 유닛	MNIST 500개, Frey Face 200개 (작은 데이터라 과적합 방지)
최적화	Adagrad, M=100, L=1
latent 차원	MNIST 3~200, Frey Face 2~20
marginal likelihood 실험	은닉 100개, latent 3개 (고차원에선 추정이 불안정해서)

결과

실험	결과
Fig 2 (lower bound)	모든 설정에서 AEVB가 wake-sleep보다 더 빨리 수렴하고 더 좋은 값에 도달
Fig 2 (차원)	latent 차원을 늘려도 과적합이 없음 → KL 항의 정규화 효과 덕분이라고 설명
Fig 3 (marginal likelihood)	AEVB가 wake-sleep보다 좋고, MCEM은 온라인 방식이 아니라서 큰 데이터(N=50000)에선 매우 느림
Fig 4, 5	2차원 latent manifold 시각화와 차원별 생성 샘플 (생성 모델로서의 성능 평가)

5. 결론 (배운점)



연구의 의의 및 한계점, 본인이 생각하는 좋았던/아쉬웠던 점 (배운점)

연구의 의의

- 오토인코더와 확률적 생성 모델(변분 추론)을 연결함
- 신경망 인코더를 쓰면 VAE가 되고, SGD로 쉽게 학습됨

한계점

- reparameterization은 **연속 latent**에만 적용됨 (이산은 wake-sleep, DARN 쪽)
- 실험이 MNIST, Frey Face 같은 작은 데이터, 단일 은닉층 MLP 위주
- marginal likelihood 추정은 latent가 낮은 차원(3개)일 때만 신뢰 가능
- 논문이 스스로 밝힌 future work: 합성곱 등 깊은 구조, 시계열, 전역 파라미터에도 SGVB 적용, 지도 학습