

9/22 교재 - 딥러닝 파이토치 교과서

13.1 생성 모델 / 13.2 변형 오토인코더



교재: 『딥러닝 파이토치 교과서』 13장 생성 모델

범위: 13.1 생성 모델이란 / 13.2 변형 오토인코더 (p.682~708)

범위 중간의 코드(코드 13-1 ~ 13-21)는 다음 주차 복습과제이므로 개념 위주로 정리함

13.1 생성 모델이란

13.1.1 생성 모델 개념

기존 합성곱 신경망에서 다룬 이미지 분류, 이미지 검출은 입력 이미지 x 가 있을 때 그에 따른 정답 y 를 찾는 문제였다. 개와 고양이 이미지 데이터셋이 주어졌을 때 그 이미지를 개와 고양이로 분류하는 식이다. 이렇게 이미지를 분류하는 모델을 **판별(자) 모델 (discriminative model)**이라고 한다. 판별자 모델의 목표는 이미지를 정확히 분류하는 것이고, 그러기 위해 해당 이미지를 대표하는 특성을 찾는다. 개와 고양이를 구별하려면 귀, 꼬리 같은 특성을 찾는 것이 중요하다.

생성(자) 모델(generative model)은 판별자 모델에서 추출한 특성들의 조합을 이용해 새로운 개와 고양이 이미지를 생성한다. 즉 입력 이미지에 대한 데이터 분포 $p(x)$ 를 학습하여 새로운 이미지를 생성하는 것이 목표다. 이때 생성된 이미지는 새로운 이미지이면서도 기존 이미지에서 특성을 추출해 만든 것이므로 입력 이미지와 최대한 유사하다.

정리하면 두 모델은 특성을 대하는 방향이 다르다. 판별자 모델은 특성을 **추출**해서 분류에 쓰고, 생성자 모델은 그 특성을 **이용**해서 새 데이터를 만든다. (그림 13-1)

13.1.2 생성 모델의 유형

생성 모델은 모델의 확률 변수를 구하는지 여부에 따라 크게 두 가지로 나뉜다.

유형	확률 변수 $p(x)$ 를 다루는 방식	대표 모델
명시적 방법(explicit density)	확률 변수 $p(x)$ 를 정의하여 사용	변형 오토인코더 (VAE)
암시적 방법(implicit density)	$p(x)$ 에 대한 정의 없이 $p(x)$ 를 샘플링하여 사용	GAN

변형 오토인코더는 이미지의 **잠재 공간(latent space)**에서 샘플링하여 완전히 새로운 이미지를 만들거나 기존 이미지를 변형하는 방식으로 학습한다. GAN은 생성자와 판별자가 서로 경쟁하면서 가짜 이미지를 진짜 이미지와 최대한 비슷하게 만들도록 학습한다.

여기서 잠재 공간은 이미지를 저차원으로 표현한 좌표평면을 말한다. 교재 각주의 예를 그대로 쓰면, 숫자 5 이미지를 인코더에 넣어 분석한 결과가 좌표평면 위의 점 (5,5)로 표현될 때 그 2차원 좌표평면이 잠재 공간이고, 점 (5,5)에 해당하는 벡터가 잠재 벡터다.

13.2 변형 오토인코더

변형 오토인코더는 오토인코더의 확장이므로, 오토인코더를 먼저 확인한 뒤 변형 오토인코더로 넘어간다.

13.2.1 오토인코더란

1. 구조

오토인코더는 단순히 입력을 출력으로 복사하는 신경망이다. 입력과 출력이 동일한 이미지라면 의미가 없어 보이지만, 은닉층(병목층)의 노드 수가 입력 값보다 적다는 점이 핵심이다. 병목층의 뉴런은 입력과 출력의 뉴런보다 훨씬 적으므로, 적은 수의 뉴런으로 데이터를 가장 잘 표현하는 방법을 찾게 된다.

오토인코더는 네 부분으로 구성된다. (그림 13-3)

1. **인코더**: 인지 네트워크(recognition network)라고도 하며, 특성에 대한 학습을 수행한다.
2. **병목층(은닉층)**: 뉴런 개수가 최소인 계층이며, 차원이 가장 낮은 입력 데이터의 압축 표현이 담긴다.
3. **디코더**: 생성 네트워크(generative network)라고도 하며, 병목층에서 압축된 데이터를 원래대로 재구성(reconstruction)한다. 최대한 입력에 가까운 출력을 생성하도록 한다.
4. **손실 재구성**: 입력층과 출력층의 뉴런 개수가 동일하다는 것만 제외하면 일반적인 다층 퍼셉트론(MLP)과 구조가 같다. 손실 함수는 입력과 출력의 차이로 계산한다.

2. 수식

입력 x 와 출력 y 는 같은 차원(R^d)에 존재한다는 가정하에, 입력 데이터를 인코더 네트워크에 통과시켜 압축된 잠재 벡터 z 를 얻는다.

$$z = h(x)$$

압축된 z 에서 입력 데이터와 크기가 같은 출력 값을 계산한다.

$$y = g(z) = g(h(x))$$

손실 값은 입력 x 와 디코더를 통과한 y 의 차이로 계산한다.

$$\text{Loss} = \sum L(x, g(h(x))) = ||x - y||^2$$

즉 디코더 네트워크를 통과한 출력 값은 입력 값의 크기와 같아야 한다. (그림 13-4)

3. 오토인코더가 중요한 이유

- **데이터 압축**: 메모리 측면에서 장점이 크다. 이미지나 음성 파일의 중요 특성만 압축하면 용량도 작고 품질도 더 좋아진다.
- **차원의 저주(curse of dimensionality) 예방**: 특성 개수를 줄여 주기 때문에 데이터 차원이 감소하여 차원의 저주를 피할 수 있다.
- **특성 추출**: 비지도 학습으로 중요한 특성을 자동으로 찾아 준다. 눈 모양, 털 색, 꼬리 길이 같은 특성이 여기에 해당한다.

4. 교재 예제의 구조

교재 예제는 **입력(노이즈) → 인코더 → 잠재 벡터 → 디코더 → 출력** 구조다. (그림 13-5) MNIST 데이터셋을 사용하고, 원본 이미지에 노이즈를 더해 손상시킨 뒤 그것을 복원하도록 학습시킨다. 레이블을 사용하지 않으므로 비지도 학습이다.

손실 함수는 **평균 제곱 오차**와 **이진 크로스 엔트로피**가 가장 널리 쓰인다. 입력 값이 (0,1) 범위에 있으면 이진 크로스 엔트로피를, 그렇지 않으면 평균 제곱 오차를 사용한다. 옵티마이저는 아담을 사용했지만 RMSProp이나 아다델타로 바꿔 비교해 보는 것도 학습에 도움이 된다고 언급한다.

결과를 보면 에포크가 진행될수록 훈련과 검증 데이터셋에 대한 오차가 함께 줄어들고(1에포크 train 0.089 / val 0.050 → 30에포크 train 0.049 / val 0.037), 노이즈를 이용해 생성된 이미지도 점점 선명해진다. (그림 13-6 ~ 13-8)

13.2.2 변형 오토인코더

1. 오토인코더와의 차이

오토인코더는 **입력(숫자 2) → 인코더 → 압축(차원 축소) → 디코더 → 출력(숫자 2)** 이 나오게 하는 방법이다. 차원을 줄이는 것이 목표이기 때문에 새롭게 생성된 데이터의 확률 분포에는 관심이 없다. (그림 13-9)

반면 변형 오토인코더는 표준편차와 평균을 이용해 확률 분포를 만들고, 거기에서 샘플링하여 디코더를 통과시킨 후 새로운 데이터를 만들어 낸다. 즉 입력 데이터와 조금 다른 출력 데이터를 만들어 내는데, 이때 **z** 라는 가우시안 분포를 이용한다. 중요한 특성의 파라미터를 담고 있는 **z** 분포에서 벡터를 랜덤하게 샘플링하고, 이 분포의 오차를 이용해 입력 데이터와 유사한 다양한 데이터를 만들어 내는 것이 변형 오토인코더다. (그림 13-10)

정리하면 오토인코더는 데이터 벡터의 차원을 축소해 실제 이미지와 동일한 이미지를 출력하는 것이 목적이고, 변형 오토인코더는 데이터가 만들어지는 **확률 분포**를 찾아 비슷한 데이터를 생성하는 것이 목적이다.

2. 인코더와 디코더 네트워크

- $q_{\phi}(z|x)$: x 를 입력받아 잠재 벡터 z 와 대응되는 평균과 분산을 구하는 인코더 네트워크
- $p_{\theta}(x|z)$: z 를 입력받아 x 와 대응되는 평균과 분산을 구하는 디코더 네트워크

두 네트워크 모두 값을 하나로 내보내는 것이 아니라 **평균과 분산**을 내보낸다는 점이 오토인코더와 다르다. (그림 13-11)

3. 인코더 네트워크의 동작 (그림 13-12)

1. 입력 x 를 인코더 네트워크 $q_{\phi}(z|x)$ 에 보내 $(\mu_z|x, \Sigma_z|x)$ 를 출력하고, 이를 이용해 아래 수식의 ②항 값을 구한다.

$$L(x^{(i)}, \theta, \phi) = E_z[\log p_{\theta}(x^{(i)}|z)] - D_{KL}(q_{\phi}(z|x^{(i)}) \parallel p_{\theta}(z))$$

1. $(\mu_z|x, \Sigma_z|x)$ 의 가우시안 분포에서 z 를 샘플링한다.

$$z \leftarrow z|x \sim N(\mu_z|x, \Sigma_z|x)$$

이렇게 구해진 z 가 디코더 네트워크의 입력으로 사용된다.

4. 디코더 네트워크의 동작 (그림 13-13)

1. 샘플링한 z 를 디코더 네트워크 $p_{\theta}(x|z)$ 에 보내 $(\mu_x|z, \Sigma_x|z)$ 를 출력하고, 이를 이용해 ①항의 값을 구한다.
2. $(\mu_x|z, \Sigma_x|z)$ 의 가우시안 분포에서 z 를 샘플링한 후 x' 를 구한다.

$$x' \leftarrow x|z \sim N(\mu_x|z, \Sigma_x|z)$$

1. 역전파를 이용해 $L(x^{(i)}, \theta, \phi)$ 값이 높아지는 방향으로 기울기를 업데이트한다. 즉 가
능도(likelihood)가 증가하는 방향으로 파라미터 θ 와 ϕ 를 업데이트한다.

최종적으로 x 와 유사한 x' 이미지가 생성된다.

5. 두 항의 의미

$$E_z[\log p_{\theta}(x^{(i)}|z)] - D_{KL}(q_{\phi}(z|x^{(i)}) \parallel p_{\theta}(z))$$

- ①항은 z 가 주어졌을 때 x' 를 표현하기 위한 확률밀도 함수로 디코더 네트워크를 나타낸다. 디코더 네트워크의 가능도가 크면 클수록 θ 가 그 데이터를 잘 표현한다고 해석할 수 있으므로, ①항이 크면 클수록 모델 가능도가 커진다.
- ②항은 x 에서 z 를 표현하는 확률밀도 함수로, 인코더 네트워크와 가우시안 분포가 얼마나 유사한지를 나타낸다. 쿨백-라이블러 발산(KL Divergence)은 유사도가 높을수록 낮은 값을 나타내므로, 인코더 네트워크가 가우시안 분포를 최대한 잘 표현할수록 가능도가 최대화된다. 따라서 ②항이 작을수록 모델 가능도가 커진다.

즉 ①항은 클수록, ②항은 작을수록 가짜 데이터를 잘 생성한다고 할 수 있다.

6. reparameterization과 log_var

평균과 표준편차가 주어졌을 때 잠재 벡터 z 를 만들기 위해 `reparameterization()` 함수를 사용한다. z 는 가우시안 분포라고 가정했기 때문에 인코더에서 받아 온 평균 μ 와 표준편차 σ 를 이용해 z 를 생성하고, 그 z 를 디코더에 통과시켜 입력과 동일한 데이터 x' 를 만든다.

이때 표준편차는 값을 그대로 사용하지 않는다. 값이 음수가 되지 않도록 로그를 취하며, 다음 방식을 따른다.

$$\sigma = \log \sigma^2$$

그래서 변수 이름도 `var` 에서 `log_var` 로 바뀐다.

7. 손실 함수

변형 오토인코더의 손실 함수는 쿨백-라이블러 발산이 되며, 다음 수식을 사용한다.

$$L = -E_{z \sim q(z|x)} [\log p(x|z)] + D_{KL}(q(z|x) \parallel p(z))$$

㉑는 재구성 오차(reproduction_loss), ㉒는 KLD에 해당한다. 변분추론으로 $p(z|x)$ 와 $q(z)$ 사이의 쿨백-라이블러 발산을 계산하고, KLD가 줄어드는 쪽으로 $q(z)$ 를 조금씩 업데이트한다. 최종 손실 함수는 두 값을 더한 것이다.

8. 학습 결과 (그림 13-14 ~ 13-19)

텐서보드로 확인한 결과는 다음과 같다.

- KLD와 재구성 오차가 **반비례**하면서, 전체 오차는 에포크가 진행될수록 작아진다.
- 재구성 오차가 감소하는 것으로 보아 기존 이미지를 이용한 새로운 이미지 생성이 잘 진행되고 있음을 유추할 수 있다.
- KLD가 계속 증가하는 것이 아니라 일정 범위에서 수렴하는 것으로 보아 $q_{\phi}(z|x^{(i)})$ 가 $p_{\theta}(z)$ 와 가까워지고 있음을 의미한다.
- 테스트 데이터셋에서도 같은 경향이 나타난다.

정리

오토인코더 vs 변형 오토인코더

구분	오토인코더	변형 오토인코더
목적	차원 축소, 입력과 동일한 이미지 복원	데이터가 만들어지는 확률 분포를 찾아 유사한 데이터 생성
인코더 출력	잠재 벡터 z 하나	평균 μ 와 분산 Σ (그 분포에서 z 를 샘플링)
잠재 공간	확률 분포에 관심 없음	가우시안 분포를 가정하고 그 분포에서 샘플링
손실 함수	재구성 오차 (MSE 또는 BCE)	재구성 오차 + KL Divergence
출력	입력과 같은 이미지	입력과 조금 다른 새로운 이미지

확인할 점



직접 채울 부분

- 13.2.2의 ①항·②항 설명에서 수식의 부호(음수 KLD)와 손실 함수의 부호(양수 KLD)가 반대로 쓰이는데, 목적함수를 최대화하는 것과 손실을 최소화하는 것의 차이로 정리해 둘 것
- 표준편차에 로그를 취하는 부분에서 교재는 $\sigma = \log \sigma^2$ 로 적고 코드에서는 `torch.exp(0.5 * log_var)` 를 쓰는데, 두 표기가 대응되는 방식 확인
- 다음 주차 복습과제에서 코드 13-1 ~ 13-21 실습