

Week3_예습과제

1. 논문 리뷰 — Auto-Encoding Variational Bayes (Kingma & Welling, 2013)

<https://arxiv.org/pdf/1312.6114>

1. Introduction

논문이 다루는 분야

연속 잠재변수(continuous latent variable) z 를 갖는 directed probabilistic model에서, intractable한 사후분포 $p_{\theta}(z|x)$ 를 근사 하면서 동시에 생성 파라미터 θ 를 학습하는 문제를 다룬다. 가정하는 생성 과정은 2단계다: ① prior $p_{\theta}(z)$ 에서 z 를 뽑고, ② 그 z 를 조건으로 $p_{\theta}(x|z)$ 에서 x 를 생성한다. 실제로 관측되는 것은 x 뿐이고, 참 파라미터 θ^* 와 각 데이터포인트의 z 는 모두 알려져 있지 않다. 실험은 MNIST와 Frey Face 이미지에 대한 생성 모델 학습으로 수행한다.

해당 task에서 기존 연구의 한계점

논문은 두 조건을 동시에 문제로 지목한다.

1. **Intractability** marginal likelihood는 $p_{\theta}(x) = \int p_{\theta}(z) p_{\theta}(x|z) dz$ 로 정의되는데, $p_{\theta}(x|z)$ 가 비선형 은닉층을 가진 신경망처럼 조금만 복잡해져도 이 적분은 계산할 수 없다. 그러면 $p_{\theta}(z|x) = p_{\theta}(x|z)p_{\theta}(z) / p_{\theta}(x)$ 도 계산 불가능해지므로, E-step에서 사후분포가 필요한 EM 알고리즘을 쓸 수 없다. mean-field VB 역시 근사 사후분포에 대한 기댓값을 해석적으로 풀어야 하는데, 일반적인 경우 그 해가 존재하지 않는다.
2. **대규모 데이터셋** 데이터가 많으면 배치 전체를 매번 최적화하는 것은 비용이 너무 커서, 미니배치나 단일 데이터포인트 단위로 파라미터를 갱신하고 싶다. 그런데 Monte Carlo EM 같은 샘플링 기반 방법은 데이터 하나마다 비싼 샘플링 루프를 돌려야 해서 너무 느리다.
3. **기본 gradient 추정량의 분산** 변분 파라미터 ϕ 에 대해 lower bound의 gradient를 구할 때 쓰는 naive Monte Carlo 추정량은 $\nabla_{\phi} E_{q_{\phi}}[f(z)] = E_{q_{\phi}}[f(z) \nabla_{\phi} \log q_{\phi}(z)]$ 형태인데, 형태 자체는 성립해도 분산이 매우 커서 실제 학습에는 쓰기 어렵다.

논문의 contributions

1. **SGVB(Stochastic Gradient Variational Bayes) estimator** — variational lower bound를 reparameterization으로 다시 써서, 미분 가능하고 unbiased인 lower bound 추정량을 얻는다. 표준 stochastic gradient ascent로 바로 최적화할 수 있다.
2. **AEVB(Auto-Encoding VB) 알고리즘** — i.i.d. 데이터셋이고 데이터마다 연속 잠재변수를 갖는 경우, recognition model $q_{\phi}(z|x)$ 를 intractable한 사후분포에 맞춰 학습시킨다. 이후 사후추론은 ancestral sampling만으로 끝나, 데이터마다 반복적인 MCMC 같은 절차가 필요 없다.
3. **Variational Auto-Encoder** — recognition model을 신경망으로 두면 VAE가 되며, 학습된 recognition model은 인식·denoising·표현 학습·시각화 등에 재사용할 수 있다.

2. Related Work

Wake-Sleep 알고리즘

논문이 아는 범위에서 같은 종류의 연속 잠재변수 모델에 적용 가능한 유일한 다른 온라인 학습 방법으로 wake-sleep을 든다. wake-sleep도 참 사후분포를 근사하는 recognition model을 쓴다는 점에서 AEVB와 공통점이 있다. 다만 wake-sleep은 두 개의 목적함수를 따로 최적화하는데, 이 둘을 합쳐도 marginal likelihood의 bound를 최적화하는 것과 대응하지 않는다는 점을 논문은 한계로 지적한다. 반대로 이산 잠재변수에도 적용 가능하다는 점은 wake-sleep의 장점으로 인정한다.

Stochastic Variational Inference 계열

naive gradient 추정량의 큰 분산을 줄이려는 연구들(control variate를 도입한 연구, Black Box Variational Inference, 지수족 근사 분포에 reparameterization을 적용한 연구 등)이 이어졌다. 문제의식은 이 논문과 같지만, 해결 방식이 control variate 쪽인지 reparameterization 쪽인지가 달린다.

Auto-Encoder와의 연결

AEVB는 directed probabilistic model과 auto-encoder 사이의 연결을 드러낸다. 선형 auto-encoder와 linear-Gaussian 모델의 관계는 이미 알려져 있었으며(PCA가 $p(z)=N(0, I)$, $p(x|z)=N(x; Wz, \epsilon I)$ 인 선형 가우시안 모델의 ML 해에 대응), 정규화 없는 auto-encoder의 학습 기준이 입력과 표현 사이 상호정보량의 하한을 최대화하는 것에 대응한다는 연구도 있다. 다만 reconstruction 기준만으로는 유용한 표현을 학습하기에 충분하지 않다는 점이 알려져 있어 denoising·contractive·sparse auto-encoder 같은 정규화 기법들이 제안

되어 왔는데, 논문은 이 지점에서 SGVB의 차별성을 강조한다 — SGVB의 목적함수에는 variational bound 자체가 요구하는 정규화 항 (KL 항)이 이미 포함되어 있어, 별도의 정규화 하이퍼파라미터를 도입할 필요가 없다.

동시기 연구

DARN은 auto-encoding 구조로 directed probabilistic model을 학습하지만 이전 잠재변수를 대상으로 한다. Rezende 등의 연구는 이 논문과 독립적으로 auto-encoder·directed probabilistic model·동일한 reparameterization 사이의 연결을 제시했으며, 논문은 이를 AEVB에 대한 추가적인 관점으로 소개한다.

3. 제안 방법론

① Recognition model: encoder와 decoder

intractable한 참 사후분포 $p_{\theta}(z|x)$ 를 근사하기 위해 recognition model $q_{\phi}(z|x)$ 를 도입한다. mean-field 변분추론과 달리 이 근사 사후분포는 factorial일 필요가 없고, ϕ 를 닫힌 형태의 기댓값으로 구하지도 않는다. 대신 ϕ 를 생성 파라미터 θ 와 함께 (동시에) 학습한다. 코딩 관점에서 z 는 code이며, $q_{\phi}(z|x)$ 는 x 를 받아 그 x 를 만들어냈을 code의 분포를 내놓는 probabilistic encoder, $p_{\theta}(x|z)$ 는 code z 를 받아 대응하는 x 의 분포를 내놓는 probabilistic decoder다.

② Variational lower bound

데이터 하나의 log marginal likelihood는 다음처럼 분해된다.

$$\log p_{\theta}(x) = D_{\text{KL}}(q_{\phi}(z|x) \parallel p_{\theta}(z|x)) + L(\theta, \phi; x)$$

KL은 항상 0 이상이므로 둘째 항 L 이 lower bound가 되고($\log p_{\theta}(x) \geq L$),

$$L(\theta, \phi; x) = E_{\mathbf{q}}[-\log q_{\phi}(z|x) + \log p_{\theta}(x, z)] = -D_{\text{KL}}(q_{\phi}(z|x) \parallel p_{\theta}(z)) + E_{\mathbf{q}}[\log p_{\theta}(x|z)]$$

로 다시 쓸 수 있다. 첫 항은 근사 사후분포를 prior에 붙잡는 정규화 항, 둘째 항은 기대 reconstruction error에 음수를 붙인 것이다. 문제는 이 L 을 ϕ 로 미분할 때, naive Monte Carlo gradient의 분산이 너무 커서 그대로 쓸 수 없다는 점이다.

③ Reparameterization trick

이 논문의 핵심 장치다. z 를 $q_{\phi}(z|x)$ 에서 직접 뽑는 대신, ϕ 와 무관한 보조 잡음변수 ϵ 을 먼저 뽑고 결정론적 변환 g_{ϕ} 를 거쳐 z 를 만든다.

$$\tilde{z} = g_{\phi}(\epsilon, x), \epsilon \sim p(\epsilon)$$

이러면 기댓값을 취하는 대상이 ϕ 와 무관한 분포 $p(\epsilon)$ 이 되어

$$E_{\mathbf{q}}\{q_{\phi}(z|x)\}[f(z)] = E_{\mathbf{p}}\{p(\epsilon)\}[f(g_{\phi}(\epsilon, x))] \approx (1/L) \sum_l f(g_{\phi}(\epsilon^l(l), x))$$

처럼 몬테카를로로 근사하면서도 ϕ 에 대해 미분 가능한 추정량을 얻는다. 가우시안이면 $z = \mu + \sigma \cdot \epsilon$, $\epsilon \sim N(0,1)$ 형태가 된다. 논문은 이런 g_{ϕ} 를 고를 수 있는 세 경우를 정리한다: (1) tractable inverse CDF($\epsilon \sim U(0,1)$), g 는 q 의 역누적분포함수 — Exponential, Cauchy, Logistic 등), (2) location-scale family($g = \text{location} + \text{scale} \cdot \epsilon$ — Laplace, Student's t, Gaussian 등), (3) composition(보조 변수들의 변환으로 표현 — Log-Normal, Gamma, Dirichlet 등).

④ SGVB estimator와 AEVB 알고리즘

reparameterization을 lower bound에 적용하면 일반형 추정량

$$\hat{L}^A(\theta, \phi; x) = (1/L) \sum_l [\log p_{\theta}(x, z^l(l)) - \log q_{\phi}(z^l(l)|x)], z^l(l) = g_{\phi}(\epsilon^l(l), x)$$

를 얻는다. KL 항을 해석적으로 적분할 수 있는 경우엔 분산이 더 작은 두 번째 형태

$$\hat{L}^B(\theta, \phi; x) = -D_{\text{KL}}(q_{\phi}(z|x) \parallel p_{\theta}(z)) + (1/L) \sum_l \log p_{\theta}(x|z^l(l))$$

를 쓴다. 전체 데이터셋에 대해서는 미니배치로 근사한다: $L(\theta, \phi; X) \approx (N/M) \sum_{i=1}^M \hat{L}(\theta, \phi; x^i(i))$. 미니배치 크기 $M=100$ 정도면 데이터포인트당 샘플 수 $L=1$ 로 두어도 충분하다고 보고하며, 알고리즘(Algorithm 1)은 미니배치를 뽑고, ϵ 를 뽑고, 추정량의 gradient를 구해 SGD나 Adagrad로 갱신하는 것을 반복한다.

⑤ Variational Auto-Encoder

위 틀에 구체적인 분포를 넣으면 VAE가 된다. - Prior: $p_{\theta}(z) = N(z; 0, I)$ — 파라미터가 없다. - 근사 사후분포: 대각공분산 다변량 가우시안 $\log q_{\phi}(z|x) = \log N(z; \mu, \sigma^2 I)$. μ 와 $\log \sigma^2$ 는 x 를 입력받는 MLP(인코더)의 출력이며, 이 형태는 방법의 제약이 아니라 단순화를 위한 선택이라고 각주에서 밝힌다. - 샘플링: $z = \mu + \sigma \odot \epsilon$, $\epsilon \sim N(0, I)$ - Decoder: 이전 데이터면 Bernoulli MLP, 실수 데이터면 Gaussian MLP.

prior와 근사 사후분포가 모두 가우시안이므로 KL 항이 해석적으로 계산되고, 최종 목적함수는

$$L(\theta, \phi; x) \approx (1/2) \sum_j (1 + \log(\sigma_j^2) - \mu_j^2 - \sigma_j^2) + (1/L) \sum_l \log p_{\theta}(x|z^l(l))$$

가 된다. 앞부분이 정규화 항, 뒷부분이 reconstruction 항이다.

4. 실험 및 결과

Dataset - MNIST: 손글씨 숫자 이미지. 인코더·디코더 은닉 유닛 500개. - Frey Face: 얼굴 이미지. 데이터셋이 작아 과적합 방지를 위해 은닉 유닛을 200개로 줄였고, 연속값이므로 가우시안 디코더를 쓰되 평균을 (0,1) 범위로 제한하기 위해 시그모이드를 적용했다. - 잠재공간 차원 N_z (MNIST는 3, 5, 10, 20, 200)를 바꾸며 lower bound를 비교했고, marginal likelihood 비교에서는 학습 데이터 수를 1,000개/50,000개로 나누어 실험했다.

Baseline - Wake-Sleep: 동일한 encoder 구조를 공유하도록 맞춰 비교(두 실험 모두). - Monte Carlo EM(MCEM): Hybrid Monte Carlo 샘플러 기반. 온라인 알고리즘이 아니어서 전체 MNIST에는 적용하지 못해 marginal likelihood 비교에서만 등장. - 공통 설정: 파라미터는 $N(0, 0.01)$ 에서 무작위 초기화, MAP 기준으로 최적화, Adagrad stepsize는 {0.01, 0.02, 0.1} 중 선택, $M=100$, $L=1$.

결과 1. Lower bound 비교(Figure 2): 모든 잠재공간 차원 설정에서 AEVB가 wake-sleep보다 빠르게 수렴하고 더 좋은 해에 도달했다. 잠재변수 수를 늘려도 과적합이 나타나지 않는데, 이는 KL 항이 근사 사후분포를 prior에 붙잡는 정규화 효과 때문이라고 설명한다. 2. **Marginal likelihood 비교(Figure 3):** 잠재공간 차원이 낮을 때(은닉 유닛 100, 잠재변수 3)만 MCMC 추정량이 신뢰할 수 있으므로 이 설정으로 AEVB·wake-sleep·MCEM을 비교했다. AEVB가 가장 빠르게 수렴했고, MCEM은 온라인 알고리즘이 아니라는 한계가 다시 지적된다. 3. **잠재공간 시각화(Figure 4, 5):** 2차원 잠재공간으로 학습한 encoder를 이용해 단위 정사각형 위 균등 좌표를 가우시안 역CDF로 변환한 뒤 각 z 에 대한 $p_\theta(x|z)$ 를 그리면, MNIST에서는 숫자 모양이, Frey Face에서는 표정·각도가 연속적으로 변하는 manifold가 나타난다.

5. 결론 (배운점)

의의

핵심은 샘플링이라는 확률적 연산을 파라미터 바깥(ϵ)으로 밀어낸 것이다. z 를 분포에서 직접 뽑으면 그 지점에서 gradient가 끊기지만, 잡음을 먼저 뽑고 결정론적 변환을 통과시키면 목적함수 전체가 ϕ 에 대해 미분 가능해진다. 그 결과 특별한 근사 추론 알고리즘 없이 표준 SGD로 학습이 가능해지고, recognition model을 한 번 학습해 재사용할 수 있게 되면서 auto-encoder 구조가 자연스럽게 나타난다. 정규화 항도 임의로 붙인 것이 아니라 variational bound 전개에서 그대로 따라 나온다.

한계 - reparameterization은 잠재변수가 연속이고 변환이 미분 가능할 때만 성립하므로, 이산 잠재변수에는 적용할 수 없다(논문 스스로 이 점을 wake-sleep의 장점으로 인정). - MCMC 기반 marginal likelihood 추정량은 샘플링 공간 차원이 낮을 때(5 미만)만 신뢰할 수 있어, 평가 범위가 좁다. - 검증이 MNIST·Frey Face 두 데이터셋, 은닉층 하나짜리 MLP 수준에서만 이루어져 더 깊거나 복잡한 모델 결과를 바로 일반화하기는 어렵다. - θ 에 대해서도 변분추론을 하는 Full VB 알고리즘은 부록에 유도만 있고 실험은 future work로 남겨졌다.

배운 점

이 논문을 읽으며 가장 오래 걸린 부분은 lower bound를 올리는 것이 왜 두 가지 작업(생성 모델 학습 + 사후분포 근사)을 동시에 하는 셈이 되는지였다. $\log p_\theta(x) = D_{KL}(q \parallel p_\theta(z|x)) + L$ 에서 좌변은 ϕ 와 무관하게 고정되어 있으므로, ϕ 를 움직여 L 을 키우면 그만큼 KL이 줄어든다. 즉 같은 목적함수 하나가 θ 방향으로는 데이터의 likelihood를 올리고, ϕ 방향으로는 근사 사후분포를 참 사후분포에 가깝게 만든다는 것을 식 하나에서 확인하고 나서야 정리가 되었다.

또한 reparameterization을 처음에는 “샘플링을 없애는 기법”으로 오해했는데, 실제로는 무작위성을 없애는 것이 아니라 그 위치를 옮기는 것이었다. z 를 $q_\phi(z|x)$ 에서 직접 뽑으면 무작위성이 ϕ 안쪽에 있어 그 지점에서 gradient가 끊기므로 $f(z) \nabla_\phi \log q_\phi(z)$ 형태의 (분산이 큰) 추정량을 쓸 수밖에 없다. 반면 잡음을 바깥에서 먼저 뽑으면 기댓값을 취하는 분포 $p(\epsilon)$ 이 ϕ 와 무관해지므로, 무작위성 자체는 그대로 남아 있어도 gradient가 f 내부를 그대로 통과할 수 있게 된다는 점이 이 트릭의 실제 원리라는 것을 이해했다.

마지막으로 KL 항을 “정규화 항”이라 부르는 것은 목적함수에 정규화를 인위적으로 추가한 것이 아니라, variational bound를 전개하면 원래 그 자리에 있던 항을 auto-encoder 관점에서 다시 읽은 해석이라는 점을 구분하게 되었다. 하나의 식을 확률모델(변분추론)로도, auto-encoder(재구성+정규화)로도 읽을 수 있다는 것이 이 논문의 구조라고 정리했다. 남은 학습 과제는 Appendix B의 가우시안 KL 해석해 유도를 직접 손으로 따라가 보는 것과, decoder를 Bernoulli/Gaussian으로 둘 때 reconstruction 항이 각각 어떤 손실(BCE, MSE 등) 형태로 대응되는지 작은 예제로 확인해 보는 것이다.

2. 교재 개념정리 — 13.1 생성 모델이란 / 13.2 변형 오토인코더 (p.682~708)

13.1 생성 모델이란

13.1.1 생성 모델 개념 - 기존 합성곱 신경망이 다루던 이미지 분류·검출은 입력 이미지 x 가 주어졌을 때 정답 y 를 찾는 문제로, 이런 모델을 **판별자 모델(discriminative model)**이라 한다. 판별자 모델은 이미지를 정확히 분류하기 위해 그 이미지를 대표하는 특성을 잘 찾는

것이 목표다. - 판별자 모델이 추출한 특성들의 조합을 이용해 새로운 이미지를 생성할 수 있는데, 이를 **생성(자) 모델(generative model)**이라 한다. 즉 생성 모델은 입력 이미지에 대한 데이터 분포 $p(x)$ 를 학습하여, 기존 이미지에서 추출한 특성을 바탕으로 원본과 유사한 새 이미지를 생성하는 것을 목표로 한다.

13.1.2 생성 모델의 유형 - 생성 모델은 확률 변수를 다루는 방식에 따라 크게 두 가지로 나뉜다. - **명시적 방법(explicit density)**: 확률 변수 $p(x)$ 를 명시적으로 정의하여 사용. 대표 모델이 **변형 오토인코더(VAE)**. - **암시적 방법(implicit density)**: $p(x)$ 에 대한 명시적 정의 없이 샘플링을 통해 사용. 대표 모델이 **GAN**. - 변형 오토인코더는 이미지의 잠재 공간(latent space)에서 샘플링하여 새로운 이미지를 생성하거나 기존 이미지를 변형하는 방식으로 학습하고, GAN은 생성자와 판별자가 서로 경쟁하며 가짜 이미지를 진짜와 최대한 비슷하게 만들도록 학습한다.

13.2 변형 오토인코더

13.2.1 오토인코더란 - 오토인코더(autoencoder)는 입력을 그대로 출력으로 복사하는 신경망이지만, 은닉층(병목층)의 노드 수가 입력보다 훨씬 적다는 점이 핵심이다. 이 좁은 병목을 통과시키면서 데이터를 가장 잘 표현할 수 있는 압축된 특성을 학습하게 된다. - 4가지 구성 요소 1. **인코더**: 인지 네트워크. 특성 학습을 수행. 2. **병목층(은닉층)**: 뉴런 개수가 최소인 계층으로, 입력의 저차원 압축 표현을 담음. 3. **디코더**: 생성 네트워크. 압축된 데이터를 원래 차원으로 재구성. 4. **손실(재구성 오차)**: 입력과 출력(복원 결과)의 차이로 손실을 계산. $z=h(x)$, $y=g(z)=g(h(x))$, $Loss=\sum \|x-y\|^2$ - 오토인코더가 중요한 이유 1. **데이터 압축**: 중요 특성만 압축하므로 용량은 줄고 품질 손실은 적음. 2. **차원의 저주 예방**: 특성 개수를 줄여 데이터 차원을 감소시킴. 3. **특성 추출**: 비지도 학습으로 자동으로 중요 특성(예: 눈 모양, 털 색 등)을 찾음.

13.2.2 변형 오토인코더 - 오토인코더는 차원 축소 자체가 목표라 새로 생성된 데이터의 확률 분포에는 관심이 없다. 반면 **변형 오토인코더(VAE)**는 인코더가 만든 평균과 표준편차로 확률 분포(가우시안)를 만들고, 그 분포에서 벡터 z (잠재 벡터, latent vector)를 랜덤 샘플링하여 디코더에 통과시킨다. 즉 입력과 완전히 같지는 않지만 유사한 새로운 데이터를 만들어낸다는 점이 오토인코더와의 결정적 차이이다. - 인코더·디코더 네트워크 표기 - $q_\phi(z|x)$: x 를 입력받아 잠재 벡터 z 의 평균·분산을 구하는 인코더 네트워크. - $p_\theta(x|z)$: z 를 입력받아 x 의 평균·분산을 구하는 디코더 네트워크. - **인코더 동작** 1. 입력 x 를 인코더 $q_\phi(z|x)$ 에 통과시켜 (μ_z, Σ_z) 를 얻는다. 2. 이 가우시안 분포 $N(\mu_z, \Sigma_z)$ 에서 z 를 샘플링한다. - **디코더 동작** 1. 샘플링한 z 를 디코더 $p_\theta(x|z)$ 에 통과시켜 (μ_x, Σ_x) 를 얻는다. 2. 이 분포에서 재구성된 x' 를 샘플링한다. 3. 역전파를 이용해 아래 식(변분 하한, ELBO)의 값이 커지는 방향으로 θ, ϕ 를 업데이트한다.

$$L(x^{(i)}, \theta, \phi) = E_z[\log p_\theta(x^{(i)}|z)] - D_{KL}(q_\phi(z|x^{(i)}) \| p_\theta(z)) \quad \textcircled{1} \quad \textcircled{2}$$

- ①항(재구성 항): z 가 주어졌을 때 x' 을 표현하는 확률밀도. 값이 클수록 디코더가 데이터를 잘 표현한다는 의미이며, 모델 가능성도(likelihood)가 커진다.
- ②항(정규화 항, KL divergence): 인코더가 만든 분포가 가우시안 사전분포와 얼마나 다른지를 나타내며, 값이 작을수록(두 분포가 유사할수록) 모델 가능성이 커진다.
- 즉 ①은 클수록, ②는 작을수록 좋은 모델이며, 이 둘을 동시에 최적화하는 것이 변형 오토인코더 학습의 핵심이다.

재매개변수화(reparameterization) - 평균 μ 와 표준편차 σ 가 주어졌을 때 잠재 벡터 z 를 만드는 방법. $\epsilon \sim N(0,1)$ 인 노이즈를 이용해 $z = \mu + \sigma \cdot \epsilon$ 형태로 z 를 생성한다. - 이때 표준편차가 음수가 되지 않도록 $\log \sigma^2(\log_var)$ 로 값을 다루고, 실제 구현에서는 $\sigma = \exp(0.5 \cdot \log_var)$ 로 변환해 사용한다. - 이 과정을 통해 “샘플링”이라는 확률적 연산을 미분 가능한 연산으로 바꿔, 역전파로 인코더·디코더 파라미터를 동시에 학습할 수 있게 된다.

손실 함수 - 변형 오토인코더의 손실 함수는 변분추론의 쿨백-라이블러 발산(KLD)을 기반으로 하며, 실제 구현에서는 재구성 오차(reconstruction loss, 예: binary cross-entropy)와 KL divergence 두 값을 더한 것을 최종 손실로 사용한다.

$$Loss = reconstruction_loss + KLD, KLD = -(1/2) \cdot \sum (1 + \log \sigma^2 - \mu^2 - \sigma^2)$$

- 학습이 진행될수록 KLD와 재구성 오차가 반비례 관계를 가지며 전체 오차는 감소한다. 재구성 오차 감소는 기존 이미지를 이용한 새 이미지 생성이 잘 이루어지고 있음을, KLD가 일정 범위에서 수렴(발산하지 않음)하는 것은 $q_\phi(z|x^{(i)})$ 가 $p_\theta(z)$ (가우시안 사전분포)에 가까워지고 있음을 의미한다.

(코드 실습 부분은 다음 주차 복습과제 범위이므로 본 예습과제에서는 제외했습니다.)