

4주차

1. Introduction



논문에서 다루고 있는 주제가 무엇인지와 해당 주제의 필요성이 무엇인가
논문에서 제안하는 방법이 기존 방법의 문제점에 대응되도록 제안 되었는가

논문이 다루는 분야

- Vision Transformer(ViT)를 이용한 이미지 분류 및 이미지 표현 학습 연구
- NLP에서 성공한 **Transformer**를 **이미지에 직접 적용**할 수 있는지 탐구
- CNN 구조에 의존하지 않고 **순수 Transformer만으로 이미지 인식**을 수행하는 방법 제안
- 이미지를 고정 크기의 **patch**로 나누고, 각 patch를 NLP의 token처럼 처리하는 방식 사용

해당 task에서 기존 연구 한계점

- 당시 이미지 인식 분야에서는 **CNN이 지배적인 구조**였음
- 기존 Transformer 기반 vision 연구는
 - CNN과 self-attention을 결합하거나
 - convolution 일부만 attention으로 대체하거나
 - 이미지에 특화된 복잡한 attention 구조를 사용함
- 픽셀 단위로 global self-attention을 적용하면 연산량이 매우 커져 고해상도 이미지에 적용하기 어려움
- 기존의 specialized attention 구조는 실제 하드웨어에서 효율적으로 구현하기 위한 **복잡한 engineering**이 필요함

논문의 contributions

- 이미지를 patch sequence로 변환하여 **표준 Transformer를 거의 수정하지 않고 이미지 분류에 적용**
- CNN 없이도 **pure Transformer가 이미지 인식에 효과적임을 보임**

- ViT는 CNN보다 이미지에 특화된 inductive bias가 적지만, **충분히 큰 데이터셋으로 pre-training하면 이러한 한계를 극복할 수 있음**
- ImageNet-21k, JFT-300M 등 대규모 데이터로 pre-training 후 여러 downstream task에 transfer하는 전략 제시
- 대규모 pre-training 환경에서 기존 CNN 기반 SOTA와 경쟁하거나 이를 넘어서는 성능을 보이면서도 더 적은 pre-training 연산량을 사용함

2. Related Work



Introduction에서 언급한 기존 연구들에 대해 어떻게 서술하는가
제안 방법의 차별성을 어떻게 표현하고 있는가

- Transformer는 원래 NLP를 위해 제안되었으며, BERT·GPT 등의 성공으로 **대규모 pre-training → downstream fine-tuning** 방식이 일반화됨
- Vision에서는 이미지의 모든 pixel 사이에 self-attention을 적용할 경우 연산량이 너무 커지는 문제가 존재
- 이를 해결하기 위해 기존 연구들은
 - local self-attention
 - sparse attention
 - axial attention
 - CNN + self-attention등의 방식을 사용함
- **Cordonnier et al.**
 - 이미지를 2×2 patch로 나누고 full self-attention 적용
 - ViT와 가장 유사한 선행 연구
 - 작은 patch 크기로 인해 주로 저해상도 이미지에 제한됨
- **iGPT**
 - 이미지 pixel을 Transformer로 처리
 - 이미지 해상도와 color space를 줄인 뒤 generative pre-training 수행
 - ImageNet에서 최대 72% 정확도를 기록함
- **ViT의 차별점**

- 복잡한 vision-specific attention 구조를 설계하지 않음
- 이미지를 patch sequence로 바꾼 뒤 **vanilla Transformer**를 그대로 활용
- 대규모 pre-training을 통해 CNN 없이도 높은 성능을 달성할 수 있음을 실험적으로 입증

3. 제안 방법론



Introduction에서 언급된 내용과 동일하게 작성되어 있는가
Introduction에서 언급한 제안 방법이 가지는 장점에 대한 근거가 있는가
제안 방법에 대한 설명이 구현 가능하도록 작성되어 있는가

Main Idea

Image → Patches → Linear Projection → Position Embedding → Transformer Encoder → MLP Head → Class

- 입력 이미지 $H \times W \times C$ 를 $P \times P$ 크기의 patch로 분할
- 각 patch를 flatten한 뒤 trainable linear projection을 통해 **D차원 patch embedding**으로 변환
- 따라서 이미지를 NLP의 token sequence와 유사한 **patch sequence**로 표현함

[class] token

- BERT의 **[class]** token과 유사한 learnable embedding을 patch sequence 앞에 추가
- Transformer의 마지막 layer에서 나온 class token을 **전체 이미지 representation**으로 사용
- 해당 representation을 classification head에 입력하여 최종 클래스 예측

Position Embedding

- patch의 위치 정보를 보존하기 위해 **learnable 1D position embedding** 추가
- 별도의 복잡한 2D positional embedding을 사용해도 유의미한 성능 향상이 나타나지 않아 단순한 1D 방식을 채택함 2010.11929v2

Transformer Encoder

- 기본 Transformer 구조를 그대로 활용
- 각 block은

- Layer Normalization
- Multi-head Self-Attention(MSA)
- Residual Connection
- MLP + GELU로 구성됨

Contribution

- CNN의 convolution 없이 **global self-attention**을 중심으로 이미지 특징을 학습
- CNN은 locality, 2D neighborhood structure, translation equivariance 등의 inductive bias를 구조적으로 가지고 있음
- 반면 ViT는 이러한 image-specific inductive bias가 훨씬 적어 **공간적 관계를 데이터로부터 직접 학습함**
- 작은 데이터에서는 이러한 특성 때문에 CNN보다 불리하지만, **대규모 데이터에서는 ViT의 scalability가 강점으로 작용**
- pre-training 후 downstream task에 fine-tuning할 때 classification head를 새로운 task에 맞게 교체
- 더 높은 해상도로 fine-tuning할 경우 position embedding을 **2D interpolation**하여 재사용함

4. 실험 및 결과



Introduction에서 언급한 제안 방법의 장점을 검증하기 위한 실험이 있는가

Dataset

Pre-training

- ImageNet
 - 약 1.3M images
 - 1K classes
- ImageNet-21k
 - 약 14M images
 - 21K classes

- JFT-300M
 - 약 303M images
 - 18K classes

Downstream Evaluation

- ImageNet / ImageNet-Real
- CIFAR-10 / CIFAR-100
- Oxford-IIIT Pets
- Oxford Flowers-102
- VTAB
 - 총 19개 task
 - Natural / Specialized / Structured task로 구성

Baseline

- **ResNet (BiT)**
 - 대표적인 CNN 기반 모델
- **Noisy Student**
 - EfficientNet 기반 semi-supervised 모델
- **Hybrid**
 - ResNet feature map을 Transformer에 입력하는 CNN + ViT 구조
- 모델 크기에 따른 비교를 위해
 - ViT-Base
 - ViT-Large
 - ViT-Huge사용

결과

1. SOTA 모델과 비교

- JFT-300M으로 pre-training한 **ViT-H/14**
 - ImageNet: **88.55%**
 - ImageNet-Real: **90.72%**

- CIFAR-100: **94.55%**
- VTAB: **77.63%**
- JFT-300M 기반 ViT가 여러 benchmark에서 ResNet 기반 BiT보다 높은 성능을 기록
- ViT-H/14의 pre-training 비용은 약 **2.5k TPuv3-core-days**, BiT-L은 약 **9.9k**로 상당한 차이를 보임

2. 데이터 크기의 영향

- 작은 ImageNet만 사용하면 ViT가 ResNet보다 불리함
- ImageNet-21k로 데이터가 증가하면서 성능 차이가 감소
- JFT-300M에서는 **큰 ViT 모델의 성능이 크게 향상**
- ResNet은 작은 데이터에서 강하지만 데이터가 커질수록 성능 향상이 상대적으로 빨리 둔화
- ViT는 대규모 데이터에서 지속적으로 성능이 향상됨 → **ViT는 충분한 규모의 pre-training data가 특히 중요함**

3. 연산 효율성

- 동일한 transfer performance 기준 ViT가 ResNet보다 약 **2~4배 적은 pre-training compute** 사용
- 작은 모델에서는 CNN+Transformer hybrid가 일부 우세
- 모델 규모가 커지면 hybrid와 pure ViT의 차이가 거의 사라짐

4. Attention 분석

- 낮은 layer에서도 일부 attention head가 이미지 전체 영역을 참조함
- 다른 head는 가까운 영역에 집중하여 local feature를 처리함
- layer가 깊어질수록 attention 범위가 넓어짐
- 학습된 position embedding에서도 이미지의 행·열 및 거리 관계가 자연스럽게 나타남
- → CNN처럼 구조적으로 locality를 강제하지 않아도 **local/global spatial relationship**을 학습할 수 있음

5. 결론 (배운점)



연구의 의의 및 한계점, 본인이 생각하는 좋았던/아쉬웠던 점 (배운점)

연구의 의의

- 이미지 인식에 CNN이 반드시 필요하다는 기존 관점에서 벗어나 **순수 Transformer만으로 높은 성능을 달성할 수 있음을 보여준 연구**
- 이미지 자체를 **patch = token**으로 변환함으로써 NLP Transformer를 거의 그대로 Vision에 적용
- 복잡한 vision-specific architecture보다 **단순한 architecture + 대규모 데이터 + pre-training**이라는 방향의 가능성을 보여줌

한계점

- ViT는 CNN보다 inductive bias가 적어 **데이터가 부족하면 성능이 떨어지고 overfitting하기 쉬움**
- 좋은 성능을 얻기 위해 ImageNet-21k, JFT-300M 같은 대규모 pre-training dataset에 크게 의존
- 논문에서는 주로 **image classification**을 다루며 detection, segmentation 등 다른 vision task 적용은 향후 연구로 남김
- self-supervised pre-training도 초기 실험 수준이며 supervised large-scale pre-training과 여전히 성능 차이가 존재함

배운점

- 모델의 inductive bias가 적다는 것이 항상 단점은 아니며, **데이터 규모가 충분하면 모델이 필요한 구조를 직접 학습할 수 있음**
- CNN의 convolution 대신 self-attention을 사용하면 이미지 전체의 관계를 초기 layer부터 고려할 수 있음
- ViT의 핵심 아이디어 자체는 매우 단순함
 - **Image → Patch**
 - **Patch → Token**
 - **Transformer 적용**

- 새로운 복잡한 구조를 만드는 것뿐 아니라, **다른 분야에서 성공한 구조에 입력 표현을 적절히 변환하여 적용하는 것도** 중요한 연구 아이디어가 될 수 있다는 점이 인상적임.

교재 정리 (p.600~608)

10장. 비전 트랜스포머

ViT (Vision Transformer)

1. ViT란?

- Vision Transformer(ViT)는 자연어 처리에서 사용되던 Transformer 구조를 이미지 분류에 적용한 모델
- 기존 CNN처럼 합성곱 연산을 중심으로 이미지를 처리하지 않고, **이미지를 여러 개의 패치(patch)로 분할하여 하나의 시퀀스로 처리**
- 각 이미지 패치를 NLP에서의 토큰(token)처럼 취급하여 Transformer Encoder에 입력




그림 10.3 합성곱 신경망과 ViT 계층의 차이

2. 이미지 패치 분할

- 입력 이미지를 일정한 크기의 작은 패치(patch)로 나눔

- 각 패치를 1차원 벡터 형태로 펼친 뒤 **선형 변환(Linear Projection)** 수행
- 변환된 각 패치 벡터를 **Patch Embedding**이라고 함
- 즉, Transformer가 처리할 수 있도록 이미지를 다음과 같은 형태로 변환

이미지 → 여러 개의 패치 → 벡터화 → Patch Embedding

3. 클래스 토큰(Class Token)

- 패치 임베딩 앞에 학습 가능한 Class Token([CLS])을 추가
- Transformer Encoder를 모두 통과한 후 **Class Token의 출력값을 이미지 전체를 대표하는 특징 벡터로 사용**
- 최종적으로 이 값을 이용해 이미지의 클래스를 분류

4. 위치 임베딩(Position Embedding)

- Transformer 자체는 입력 패치의 순서나 위치 정보를 알 수 없음
- 따라서 각 패치가 이미지의 어느 위치에서 나온 것인지 알려주기 위해 **Position Embedding**을 추가
- 최종 입력은 다음과 같이 구성됨

Patch Embedding + Position Embedding + Class Token

5. Transformer Encoder

- 만들어진 패치 시퀀스를 **Transformer Encoder**에 입력
- 주요 구성
 - Multi-Head Self-Attention
 - Layer Normalization
 - MLP
 - Residual Connection
- **Self-Attention**을 통해 이미지의 서로 다른 패치 사이의 관계를 학습
- CNN의 지역적인 필터 연산과 달리 이미지의 넓은 영역 간 관계를 직접 고려할 수 있음

6. ViT의 전체 처리 과정




그림 10.4 ViT 모델 구조

입력 이미지

- 이미지를 고정 크기 패치로 분할
- 패치 Flatten
- Linear Projection을 통한 Patch Embedding
- Class Token 추가
- Position Embedding 추가
- Transformer Encoder
- Class Token 출력
- MLP Head
- 이미지 분류

7. ViT의 특징

- CNN의 합성곱 구조에 의존하지 않고 **Transformer**만으로 이미지 특징을 학습
- Self-Attention을 이용해 **패치 간 전역적인 관계**를 학습할 수 있음
- 이미지도 텍스트와 마찬가지로 **시퀀스 형태로 변환하여 Transformer로 처리**할 수 있음
- 충분한 데이터로 학습할 경우 이미지 분류에서 높은 성능을 보일 수 있음

최종 정리

- ViT의 핵심 아이디어 = 이미지를 패치 단위의 토큰 시퀀스로 변환하여 Transformer에 입력
- 핵심 구성 요소
 - **Patch Embedding**: 이미지를 패치 단위의 벡터로 변환
 - **Class Token**: 이미지 전체를 대표하여 최종 분류에 사용
 - **Position Embedding**: 각 패치의 위치 정보 제공
 - **Transformer Encoder**: Self-Attention으로 패치 간 관계 학습
 - **MLP Head**: 최종 이미지 클래스 예측