



Week4_예습과제_김재희

교재 정리

10장 비전 트랜스포머

ViT

합성곱 모델과 ViT 모델 비교

ViT의 귀납적 편향

ViT 모델

패치 임베딩

인코더 계층

An Image is Worth 16×16 Words: Transformers for Image Recognition at Scale 리뷰

1. Introduction

논문이 다루는 분야

해당 task에서 기존 연구 한계점

논문의 contributions

2. Related Work

3. 제안 방법론

Main Idea

3.1 Vision Transformer(ViT)

3.2 Fine-tuning and Higher Resolution

Contribution

4. 실험 및 결과

Dataset

Baseline

4.1 Comparison to State of the Art

결과

4.2 Pre-training Data Requirements

4.3 Scaling Study

4.4 Inspecting Vision Transformer

4.5 Self-supervision

5. 결론 (배운점)

교재 정리

10장 비전 트랜스포머

ViT는 2020년 구글의 논문을 통해 소개된 이미지 인식을 위한 딥러닝 모델이다. 이미지를 자연어 처리 방식처럼 분류해 보려는 시도에 의해 탄생했다.

ViT는 이미지 분류 모델에서 사용되는 CNN 모델의 합성곱 계층 방법을 사용하지 않고 트랜스포머 모델에서 사용되는 셀프 어텐션을 적용한다. 합성곱 모델이 이미지 분류를 위해 지역 특징을 추출했다면 ViT는 셀프 어텐션을 사용해 전체 이미지를 한 번에 처리하는 방식으로 구현됐다.

하지만 ViT는 이미지 패치가 왼쪽에서 오른쪽, 위에서 아래 방향으로 순차적으로 입력되어 2차원 구조의 이미지 특성을 온전히 반영한다고 할 수 없다. 이러한 문제를 해결하기 위해 물체의 크기나 해상도를 계층적으로 학습하는 스윈 트랜스포머와 CvT 모델이 제안됐다.

스윈 트랜스포머는 로컬 원도를 활용해 각 계층의 어텐션이 되는 패치의 크기와 개수를 다양하게 구성해 이미지의 특성을 학습시킨다. ViT 구조와 비교할 때 셀프 어텐션을 로컬 원도 안에 대한 어텐션, 로컬 원도 간의 어텐션으로 수행해 이미지 특징을 계층적으로 학습시켰다. 이 어텐션 함수에는 상대적 위치 편향을 반영하여 어텐션 값 자체에 위치적 정보를 포함시켰다.

CvT는 기존 합성곱 연산 과정을 ViT에 적용한 모델로, 저수준 특징과 고수준 특징을 계층적으로 반영할 수 있다. 예를 들어 사람 얼굴의 저수준 특징은 눈, 코, 입과 같은 작은 단위이며 고수준 특징은 눈, 코, 입을 포함한 전체 얼굴로 비유할 수 있다. 또 어텐션 연산 과정에서 쿼리, 키, 값 중 키와 값을 기존 특징 벡터보다 축소해 계산 복잡도는 감소시켰다.

ViT 계열 모델들은 이미지 분류 작업에서 매우 효과적인 모델임이 여러 번 입증됐으며, 광범위한 다른 컴퓨터 비전 작업에도 적용할 수 있다.

ViT

ViT는 트랜스포머 구조 자체를 컴퓨터비전 분야에 적용한 첫 번째 연구다.

BERT와 ViT 모두 트랜스포머 모델 구조를 그대로 사용하지만 입력 데이터를 만드는 과정이 서로 다르다.

BERT는 문장보다 작은 단위의 토큰들이 순차적으로 입력되며 ViT 모델은 이미지가 격자로 작은 단위의 이미지 패치로 나뉘어 순차적으로 입력된다는 차이가 있다. 따라서 ViT 모델에 사용되는 입력 이미지 패치는 왼쪽에서 오른쪽, 위에서 아래로 표현된 시퀀셜 배열을 가정한다.

합성곱 모델과 ViT 모델 비교

합성곱 신경망과 트랜스포머는 이미지 특징을 잘 표현하는 임베딩을 만들고자 하는 목적은 같지만 그 과정에는 큰 차이가 있다. 합성곱 신경망의 임베딩은 이미지 패치 중 일부만 선택하여 학습하며 이를 통해 이미지 전체의 특징을 추출한다.

반면 ViT 임베딩은 이미지를 작은 패치들로 나뉘 각 패치 간의 상관관계를 학습한다. 이를 위해 셀프 어텐션 방법을 사용해 모든 이미지 패치가 서로에게 주는 영향을 고려해 이미지 전체 특징을 추출한다. 그러므로 모든 이미지 패치가 학습에 관여하며 높은 수준의 이미지 표현을 제공할 수 있다.




그림 10.3 합성곱 신경망과 ViT 계층의 차이

고양이의 오른쪽 눈을 표현하는 데 합성곱 신경망 같은 경우엔 1, 2, 4, 5만 학습되고 나머지 3, 6, 7, 8, 9 이미지 패치는 학습에 관여하지 않는다. 반면에 ViT 임베딩은 셀프 어텐션 방법으로 모든 이미지 패치가 학습에 관여한다.

따라서 좁은 수용 영역(RF)을 가진 CNN은 이미지 정보를 표현하는 데 수많은 계층이 필요하지만 트랜스포머 모델은 어텐션 거리를 계산하여 오직 한 개의 ViT 레이어로 전체 이미지 정보를 쉽게 표현할 수 있다. 또 ViT는 픽셀 단위로 처리하는 CNN과 달리 패치 단위로 이미지를 처리하기 때문에 더 작은 모델로도 높은 성능을 낼 수 있다는 장점도 있다. ViT 모델은 입력 이미지 크기가 고정되어 있어 크기가 다른 이미지를 처리하려면 이미지 크기를 맞추는 전처리가 필요하며, CNN이 이미지의 공간적인 위치 정보를 고려하는 반면 ViT는 패치 간의 상대적인 위치 정보만 고려하기 때문에 이미지 변환에 취약할 수 있다.

ViT의 귀납적 편향

귀납적 편향: 일반화 성능 향상을 위한 모델의 가정, 예를 들어 이미지 데이터는 공간적 관계를 잘 표현하므로 지역적 편향을 가진 CNN이 많이 사용된다.

시계열 데이터는 시간적 관계를 잘 표현하므로 시퀀셜 편향을 가진 RNN 모델이 많이 사용된다. RNN은 이전 시간의 상태를 기억하고 현재 입력과 결합해 다음 상태를 예측한다. 하지만 이러한 특정 관계 편향이 강할수록 다른 다양한 관계를 표현하기 어려워 귀납적 편향이 약한 모델을 선호하게 된다.

ViT는 입력 데이터의 다양한 쿼리, 키, 값의 임베딩 형태로 일반화된 관계를 학습하기 때문에 귀납적 편향이 거의 없고 대용량 데이터에 대해서 이미지 특징들의 관계를 잘 학습하는 모델이다.

표 10.1 딥러닝 모델의 귀납적 편향

딥러닝 모델	귀납적 편향
합성곱 신경망(CNN)	지역적 편향
순환 신경망(RNN)	순차적 편향
ViT	귀납적 편향이 거의 없음

ViT 모델

ViT 모델은 입력 이미지를 트랜스포머 구조에 맞게 일정한 크기의 패치로 나눈 다음 각 패치를 벡터 형태로 변환하는 패치 임베딩과 각 패치와의 관계를 학습하는 인코더 계층으로 구성된다.




그림 10.4 ViT 모델 구조

패치 임베딩

패치 임베딩: 입력 이미지를 작은 패치로 분할하는 과정

작은 패치로 분할하기 위해서는 이미지 크기를 맞추는 전처리가 필요하다. 예를 들어 입력 이미지 크기가 640x480이었다면 224x224 크기와 같은 정방향 크기로 이미지 크기를 조절한다.

이미지 크기를 일정한 크기로 변경했다면 전체 이미지를 패치 크기로 분할해 시퀀셜 배열을 만든다. 이때 CNN 계층을 활용한다.




그림 10.5 이미지 패치 생성 과정

패치 임베딩을 위해서는 커널 크기와 간격을 설정해야 한다. 이 둘은 하이퍼파라미터이다. 커널은 패치 크기를 의미하며, 간격은 패치가 이동하는 폭을 의미한다.

수식 10.1 패치 계산 과정

$$patch\ size = \frac{image\ size - kernel\ size}{stride} = \frac{9 - 3}{3} + 1 = 3$$

일반적으로 분할된 이미지 패치들을 배열 형태로 나열할 때 왼쪽에서 오른쪽, 위에서 아래 순서로 배열한다. 이 배열 가장 왼쪽에 분류 토큰(CLS)을 추가한다. 분류 토큰은 전체 이미지를 대표하는 벡터로 특정 문제를 예측하는 데 사용된다.

또 위치 임베딩을 사용해 인접한 패치 간의 관계를 학습한다. 위치 임베딩은 패치의 위치 정보를 임베딩 벡터로 변환하고 기존 이미지 패치 벡터들과 더한다. 마지막으로 계층 정규화를 적용하면 패치 임베딩이 만들어진다. 이렇게 작은 패치로 나눠 처리하면 GPU 메모리의 한계를 극복하고 더 큰 이미지를 처리할 수 있다.

인코더 계층

ViT 모델은 이미지를 일정한 크기의 패치로 나눠 각 패치를 벡터로 변환한 후 인코더 계층에 입력으로 전달해 다양한 쿼리, 키, 값 임베딩의 관계를 학습한다. N개의 인코더 레이어를 반복적으로 적용한 후, 마지막 레이어에서는 분류 토큰이라고 불리는 특별한 패치의 특징 벡터를 추출한다. 이 분류 토큰 벡터는 이미지 데이터를 잘 표현하는 특징 벡터로 간주된다. 이러한 특징 벡터는 이후 다양한 이미지 분류 및 검색 문제를 해결하는 데 사용된다.

An Image is Worth 16x16 Words: Transformers for Image Recognition at Scale 리뷰

1. Introduction



논문에서 다루고 있는 주제가 무엇인지와 해당 주제의 필요성이 무엇인가
논문에서 제안하는 방법이 기존 방법의 문제점에 대응되도록 제안되었는가

논문이 다루는 분야

- 이미지 인식
- 이미지 분류

해당 task에서 기존 연구 한계점

컴퓨터 비전에서는 여전히 CNN 구조가 지배적이다. 여러 연구가 CNN 계열 구조에 self-attention을 결합하려 시도했고 일부는 CNN을 완전히 대체하려고도 했다. 하지만 후자의 경우에도 attention 패턴을 사용해 최신 하드웨어 가속기에서 효과적으로 확장할 수는 없었다. 이로 인해 대규모 이미지 인식에서는 여전히 고전적인 ResNet 계열 구조가 state of the art이다.

논문의 contributions

Transformer 구조는 자연어처리 분야의 표준이 되었지만 컴퓨터 비전에 적용된 사례는 제한적이었다. 본 연구에서는 CNN 의존을 배제하고 이미지 패치들의 시퀀스에 순수 transformer를 직접 적용해도 이미지 분류 과제에서 매우 잘 작동함을 보였다. 이를 위해 이미지들을 패치로 나누고, 이 패치들의 선형 임베딩 시퀀스를 Transformer의 입력으로 주었다. 이미지 패치는 NLP에서의 토큰과 똑같은 방식으로 취급한다. 이 모델을 지도학습 방식으로 이미지 분류에 대해 학습시켰다. 대량의 데이터로 사전학습하고 중간, 소규모 이미지 인식 벤치마크로 transfer했을 때, ViT는 훨씬 적은 계산 자원으로도 최신 CNN에 준하는 우수한 결과를 얻었다. 특히 큰 데이터셋(1400만~3억)으로 학습시켰을 때 ViT는 CNN의 inductive bias를 이겼다. 최고 모델은 ImageNet에서 88.55%, ImageNet-Real에서 90.72%, CIFAR-100에서 94.55%, 19개 과제로 구성된 VTAB 스위트에서 77.63%의 정확도를 달성했다.

2. Related Work



Introduction에서 언급한 기존 연구들에 대해 어떻게 서술하는가
제안 방법의 차별성을 어떻게 표현하고 있는가

Transformer는 2017년에 기계 번역을 위해 제안되었고 이후 많은 NLP 과제에서 state of the art가 되었다. 대형 Transformer 기반 모델들은 보통 큰 코퍼스로 사전학습된 후 각각 과제에 맞춰 미세조정된다. BERT는 노이즈 제거 방식의 self-supervised 사전학습 과제를 쓰고 GPT 계열은 언어 모델링을 사전학습 과제로 쓴다.

self-attention을 이미지에 그대로 적용하려면 각 픽셀이 다른 모든 픽셀에 attention을 줘야 한다. 픽셀 수에 대해 quadratic으로 비용이 커지기 때문에 실제 크기의 입력에는 적용할 수 없다. 그래서 Transformer를 이미지 처리에 적용하기 위해 여러 근사법이 시도되어 왔다. Parmar et al.(2018)은 각 쿼리 픽셀에 대해 self-attention을 전역이 아닌 지역 이웃에만 적용했다. 이런 지역적 multi-head dot-product self-attention 블록은 convolution을 완전히 대체할 수 있다. 다른 계열의 연구인 Sparse Transformer는 이미지에 적용 가능하도록 확장 가능한 전역 self-attention 근사법을 사용한다. attention을 확장하는 다른 방법으로는 다양한 크기의 블록 단위로 적용하거나 극단적인 경우 개별 축을 따라서만 적용하는 방식이 있다. 이런 특수화된 attention 구조들은 컴퓨터 비전 과제에서 유망한 결과를 보이지만, 하드웨어 가속기에서 효율적으로 구현하려면 복잡한 엔지니어링이 필요하다.

본 연구와 가장 관련 있는 것은 Cordonnier et al.(2020)의 모델로, 입력 이미지에서 2x2 크기의 패치를 추출하고 그 위에 완전한 self-attention을 적용하는 것이다. 이 모델은 ViT와 매우 유사하지만 본 연구에서는 대규모 사전학습이 바닐라 transformer를 최신 CNN만큼 경쟁력 있게 만든다는 것을 보여준다. 그리고 Cordonnier et al.(2020)은 2x2의 작은 패치를 쓰기 때문에 해상도 이미지에만 적용 가능한 반면, 본 연구는 중간 해상도 이미지도 다룬다.

CNN을 self-attention의 여러 형태와 결합하는 데에도 많은 시도가 있었다. 예를 들어 이미지 분류를 위해 feature map을 보강하거나 객체 탐지, 비디오 처리, 이미지 분류, 비지도 객체 발견, 또는 통합 텍스트-비전 과제를 위해 CNN의 출력을 self-attention으로 추가 처리하는 방식 등이 있다.

또 다른 관련 연구는 image GPT(iGPT)로, 이미지 해상도와 색 공간을 줄인 뒤 이미지 픽셀에 Transformer를 적용한다. 이 모델은 생성 모델로서 비지도 방식으로 학습되며 결과로 얻은 표현은 미세조정하거나 선형으로 probe해서 분류 성능을 평가할 수 있는데, ImageNet에서 최대 72%의 정확도를 달성한다.

본 연구는 표준 ImageNet 데이터셋보다 더 큰 규모에서 이미지 인식을 탐구하는 연구들에 기여한다. Sun et al.(2017)은 CNN 성능이 데이터셋 크기에 따라 어떻게 확장되는지 연구했고, Kolesnikov et al.(2020), Djolonga et al.(2020)은 ImageNet-21k, JFT-300M 같은 대규모 데이터셋에서 CNN의 전이학습을 실증적으로 탐구했다.

3. 제안 방법론




Introduction에서 언급된 내용과 동일하게 작성되어 있는가
Introduction에서 언급한 제안 방법이 가지는 장점에 대한 근거가 있는가
제안 방법에 대한 설명이 구현 가능하도록 작성되어 있는가

Main Idea

모델 설계는 원조 Transformer(Vaswani et al., 2017)를 최대한 따랐다. 이를 통해 확장성 있는 NLP Transformer 구조와 그 효율적인 구현체를 거의 그대로 가져다 쓸 수 있었다.

3.1 Vision Transformer(ViT)



표준 Transformer는 1D 토큰 임베딩 시퀀스를 입력으로 받는다. 2D 이미지를 다루기 위해 이미지 $x \in \mathbb{R}^{(H \times W \times C)}$ 를 평평하게 만든 2D 패치들의 시퀀스 $x_p \in \mathbb{R}^{(N \times (P^2 \cdot C))}$ 로 재구성했다. 여기서 (H, W) 는 원본 이미지의 해상도, C 는 채널 수, (P, P) 는 각 이미지 패치의 해상도, $N = HW/P^2$ 는 결과적인 패치의 개수로, 이것이 Transformer의 실질적인 입력 시퀀스 길이 역할도 한다. Transformer는 모든 레이어에서 고정된 latent 벡터 크기 D 를 쓰기 때문에 패치들을 평평하게 만들고 학습 가능한 선형 projection으로 D 차원에 매핑한다. 이 projection의 출력을 patch embedding이라 부른다.

BERT의 [class] 토큰과 비슷하게 임베딩된 패치 시퀀스 앞에 학습 가능한 임베딩을 하나 붙인다 ($z^0_o = x_{\text{class}}$). 이 토큰이 Transformer encoder 출력에서 갖는 상태(z^0_L)가 이미지 표현 y 로 쓰인다. 사전학습과 미세조정 모두에서 z^0_L 에 분류 head가 붙는다. 이 분류 head는 사전학습 시에는 은닉층 1개짜리 MLP로, 미세조정 시에는 단일 선형 레이어로 구현된다.

위치 정보를 유지하기 위해 patch embedding에 position embedding을 더한다. 본 연구는 표준적인 학습 가능한 1D position embedding을 쓴다. 더 발전된 2D 인식 position embedding을 써봐도 뚜렷한 성능 향상이 관찰되지 않았기 때문이다. 이렇게 만들어진 임베딩 벡터 시퀀스가 encoder의 입력이 된다.

Transformer encoder는 multiheaded self-attention과 MLP 블록이 번갈아 있는 구조다. MLP는 GELU 비선형 함수를 쓰는 두 개의 레이어로 되어 있다. 각 블록 전에 Layernorm이 적용되고, 각 블록 후에는 residual connection이 있다.

Inductive bias

Vision Transformer는 CNN보다 이미지 특화된 inductive bias가 훨씬 적다. CNN에서는 locality, 2차원 이웃 구조, translation equivariance가 모델 전체의 모든 레이어에 내재되어 있다. ViT에서는 MLP 레이어만 지역적이고 translation-equivariant하며, self-attention 레이어는 전역적이다. 2차원 이웃 구조는 매우 드물게만 쓰인다. 그 외에는 초기화 시점의 position embedding이 패치들의 2D 위치에 대한 정보를 전혀 담고 있지 않다. 패치들 간의 모든 공간적 관계는 처음부터 학습되어야 한다.

Hybrid Architecture: CNN + ViT

원본 이미지 패치의 대안으로 입력 시퀀스를 CNN의 feature map으로부터 만들 수도 있다. 이 하이브리드 모델에서는 patch embedding projection E 가 CNN feature map에서 추출된 패치들에 적용된다. 특수한 경우로 패치가 1×1 크기의 공간 크기를 가질 수도 있는데, 이는 입력 시퀀스를 feature map의 공간 차원을 단순히 평평하게 만들고 Transformer 차원으로 projection해서 얻는다는 뜻이다. 분류용 입력 임베딩과 position embedding은 그대로 추가된다.

3.2 Fine-tuning and Higher Resolution

보통 ViT는 큰 데이터셋으로 사전학습하고 더 작은 다운스트림 과제에 미세조정한다. 이를 위해 사전학습된 예측 head를 제거하고 0으로 초기화된 $D \times K$ 피드포워드 레이어를 붙인다(K 는 다운스트림 클래스 수). 사전학습 때보다 더 높은 해상도로 미세조정하는 것이 대체로 도움이 된다. 더 높은 해상도의 이미지를 넣을 때는 패치 크기를 그대로 유지하는데, 이는 실질적인 시퀀스 길이가 더 길어짐을 의미한다. Vision Transformer는 메모리 제약 내에서 임의의 시퀀스 길이를 다룰 수 있지만 사전학습된 position embedding은 더 이상 의미가 없을 수 있다. 그래서 본 연구에서는 원본 이미지 내 위치에 따라 사전학습된 position embedding을 2D 보간한다. 이 해상도 조정과 패치 추출이 Vision Transformer에 이미지의 2D 구조에 대한 inductive bias가 수동으로 주입되는 유일한 지점이다.

기호	의미
P	패치 한 변의 크기 (예: 16)
$N = HW/P^2$	패치 개수 = 시퀀스 길이 (NLP의 단어 개수에 대응)

기호	의미
D	모든 레이어가 공유하는 고정 차원 (NLP의 임베딩 차원)
x_class	맨 앞에 붙이는 학습 가능한 대표 토큰
E_pos	패치가 원래 이미지에서 어디 있었는지 알려주는 정보

부품	역할
LN (LayerNorm)	값들을 안정적인 범위로 정규화
MSA	패치들끼리 서로 정보를 주고받음 (누가 누구를 봐야 하는지)
MLP	각 패치 정보를 개별적으로 더 가공
(+ $z_{\{l-1\}}$)	residual connection — 원본 정보를 더해서 gradient가 잘 흐르게 함

Contribution

이미지를 16×16 패치로 나눠 선형 임베딩한 뒤 position embedding과 [class] 토큰을 더해 표준 Transformer encoder에 그대로 입력한다. 구조적으로 새로 설계한 요소가 거의 없고 CNN이 갖던 locality-translation equivariance 같은 inductive bias를 의도적으로 배제한 채 이런 관계를 데이터로부터 직접 학습하도록 한 것이 핵심이다. 해상도를 바꿔도 패치 크기만 고정하고 position embedding을 2D 보간으로 조정하면 되므로 임의의 입력 크기에도 유연하게 적용할 수 있다.

4. 실험 및 결과



Introduction에서 언급한 제안 방법의 장점을 검증하기 위한 실험이 있는가

Dataset

- ILSVRC-2012 ImageNet 데이터셋(이하 ImageNet): 1000개 클래스, 130만 장
- ImageNet-21k: 21000개 클래스, 1400만 장
- JFT: 18000개 클래스, 3억 3백만 장
- VTAB: 19개 과제, 1000장

Baseline

4.1 Comparison to State of the Art

baseline CNN으로는 ResNet을 쓰지만 Batch Normalization을 Group Normalization으로 바꾸고 표준화된 convolution을 썼다. 이 수정들은 전이 성능을 개선하며 이 수정된 모델을 ResNet (BiT)라 부른다.

가장 큰 모델인 ViT-H/14와 ViT-L/16을 문헌의 최신 CNN과 비교한다. 첫 번째 비교 대상은 Big Transfer(BiT)로, 큰 ResNet으로 지도 전이학습을 한다. 두 번째는 Noisy Student(CNN)로, 라벨을 제거한 ImageNet과 JFT-300M에서 반지도학습으로 학습한 큰 EfficientNet이다.

	ViT-H/14 (JFT)	ViT-L/16 (JFT)	ViT-L/16 (I21k)	BiT-L	Noisy Student
ImageNet	88.55	87.76	85.30	87.54	88.4/88.5
ImageNet Real	90.72	90.54	88.62	90.54	90.55

	ViT-H/14 (JFT)	ViT-L/16 (JFT)	ViT-L/16 (I21k)	BiT-L	Noisy Student
CIFAR-100	94.55	93.90	93.25	93.51	–
VTAB (19 tasks)	77.63	76.28	72.72	76.29	–
TPUv3-core-days	2.5k	0.68k	0.23k	9.9k	12.3k

더 작은 ViT-L/16 모델이 JFT-300M으로 사전학습됐을 때 같은 데이터셋으로 사전학습된 BiT-L을 모든 과제에서 능가하면서도 계산 자원은 훨씬 적게 든다. 더 큰 ViT-H/14는 특히 더 어려운 데이터셋(ImageNet, CIFAR-100, VTAB)에서 성능을 더 개선한다. 흥미롭게도 이 모델은 여전히 기존 최신 기술보다 훨씬 적은 계산으로 사전학습됐다. 마지막으로 공개 데이터셋 ImageNet-21k로 사전학습한 ViT-L/16도 대부분의 데이터셋에서 잘 작동하며 더 적은 자원으로 사전학습 가능하다. 표준 클라우드 TPUv3 8코어로 약 30일 안에 학습할 수 있다.

결과

ViT 설정은 BERT에 쓰인 것을 기반으로 했다. Base와 Large 모델은 BERT에서 그대로 가져왔고, 더 큰 Huge 모델을 추가했다. Transformer의 시퀀스 길이는 패치 크기의 제곱에 반비례하므로, 패치 크기가 작은 모델일수록 계산 비용이 더 크다.

모델	Layers	Hidden size D	MLP size	Heads	Params
ViT-Base	12	768	3072	12	86M
ViT-Large	24	1024	4096	16	307M
ViT-Huge	32	1280	5120	16	632M

4.2 Pre-training Data Requirements

ViT는 JFT-300M 같은 큰 데이터셋으로 사전학습했을 때 잘 작동한다. 비전에 대한 inductive bias가 ResNet보다 적는데 데이터셋 크기가 얼마나 중요한지에 대한 실험이 두 가지 진행됐다.

1. ImageNet, ImageNet-21k, JFT-300M처럼 크기가 커지는 데이터셋으로 ViT를 사전학습한다. 가장 작은 데이터셋 ImageNet으로 사전학습했을 때 ViT-Large 모델은 적절한 정규화를 해도 ViT-Base보다 성능이 낮다. ImageNet-21k 사전학습에서는 성능이 비슷하다. JFT-300M에서만 더 큰 모델의 이점이 완전히 드러난다.
2. JFT-300M의 무작위 부분집합(9M, 30M, 90M) 및 전체(300M)로 모델을 학습한다. 작은 부분집합에는 추가 정규화를 하지 않고 모든 설정에 같은 하이퍼파라미터를 쓴다. Vision Transformer는 비슷한 계산 비용의 ResNet보다 작은 데이터셋에서 더 과적합된다. 예를 들어 ViT-B/32는 ResNet50보다 약간 더 빠르는데 9M 부분집합에서는 훨씬 나쁘지만 90M+ 부분집합에서는 더 좋다. 이 결과는 convolutional inductive bias가 작은 데이터셋에는 유용하지만 큰 데이터셋에서는 데이터에서 직접 관련 패턴을 학습하는 것으로 충분하고 심지어 더 유리하다는 직관을 뒷받침한다.

4.3 Scaling Study

JFT-300M으로부터의 전이 성능을 평가해서 여러 모델의 통제된 스케일링 연구를 수행했다. 이 설정에서는 데이터 크기가 성능의 병목이 아니므로 각 모델의 사전학습 비용 대비 성능을 평가한다. 몇 가지 패턴이 관찰되었다. 첫째, Vision Transformer가 성능/계산 비용 트레이드오프에서 ResNet을 압도한다. ViT는 같은 성능을 내는 데 약 2~4배 적은 계산을 쓴다. 둘째, 하이브리드는 작은 계산 예산에서는 ViT를 약간 능가하지만 모

델이 커지면 그 차이가 사라진다. 셋째, Vision Transformer는 시도한 범위 내에서 성능이 포화되는 조짐이 보이지 않아서 앞으로 더 확장해볼 만하다.

4.4 Inspecting Vision Transformer

ViT가 이미지 데이터를 어떻게 처리하는지 이해하기 위해 내부 표현을 분석했다. 첫 레이어는 평평해진 패치를 저차원 공간에 선형으로 projection한다. 학습된 임베딩 필터의 주요 성분들은 각 패치 내부의 미세 구조를 표현하는 데 좋은 기저 함수처럼 보인다.

projection 후에는 학습된 position embedding이 패치 표현에 더해진다. 모델이 이미지 내 거리를 position embedding의 유사도로 인코딩하도록 학습한다는 것을 보여준다. 즉 더 가까운 패치일수록 position embedding이 더 유사하다. 또한 행렬 구조가 나타난다. 같은 행, 열에 있는 패치들이 유사한 임베딩을 갖는다.

self-attention은 ViT가 가장 낮은 레이어에서도 이미지 전체에 걸쳐 정보를 통합할 수 있게 한다. 일부 head는 가장 낮은 레이어에서도 이미지 대부분에 attention을 주는데, 이는 전역적으로 정보를 통합하는 능력이 실제로 모델에 쓰이고 있음을 보여준다. 다른 attention head들은 낮은 레이어에서 일관되게 작은 attention distance를 갖는다. 전반적으로 모델은 분류에 의미적으로 관련 있는 이미지 영역에 attention을 준다.

4.5 Self-supervision

Transformer는 NLP 과제에서 인상적인 성능을 보이는데 이 성공의 상당 부분은 확장성뿐 아니라 대규모 자기지도 사전학습에서도 나온다. 본 연구에서는 BERT의 masked language modeling 과제를 모방한 masked patch prediction으로 예비 자기지도 실험을 수행한다. 자기지도 사전학습으로 더 작은 ViT-B/16 모델은 ImageNet에서 79.9%의 정확도를 달성하는데, 이는 처음부터 학습한 것보다 2%p 유의미하게 개선된 것이지만 지도 사전학습보다는 여전히 4%p 뒤쳐진다.

5. 결론 (배운점)



연구의 의의 및 한계점, 본인이 생각하는 좋았던/아쉬웠던 점 (배운점)

컴퓨터 비전에서 self-attention을 사용한 이전 연구들과 달리 본 연구는 초기 패치 추출 단계를 제외하고는 이미지 특화된 inductive bias를 구조에 도입하지 않았다. 대신 이미지를 패치들의 시퀀스로 해석하고 NLP에서 쓰이는 것과 같은 표준 Transformer encoder로 처리했다. 이 단순한 전략은 대규모 데이터셋으로 사전학습과 결합했을 때 잘 작동한다. 따라서 Vision Transformer는 여러 이미지 분류 데이터셋에서 최신 기술과 맞먹거나 능가하면서도 사전학습 비용은 상대적으로 저렴하다.

하지만 아직 많은 과제가 남아 있다. 하나는 ViT를 탐지, 분할과 같은 다른 컴퓨터 비전 과제에 적용하는 것이다. 이 결과와 Carion et al.(2020)의 결과를 함께 보면 이 접근법이 유망하다는 것을 알 수 있다. 또 다른 과제는 자기지도 사전학습 방법을 계속 탐구하는 것이다. 초기 실험은 자기지도 사전학습에서 개선을 보였지만, 자기지도와 대규모 지도 사전학습 사이에는 여전히 큰 격차가 있다. 마지막으로 ViT를 더 확장하면 성능이 더 향상될 가능성이 높다.