

10/6 논문 - Training language models to follow instructions with human feedback

<https://arxiv.org/pdf/2203.02155>

1. Introduction

논문이 다루는 분야

이 논문은 인간 피드백을 활용해 언어 모델이 사용자의 지시와 의도를 따르도록 만드는 정렬 (Alignment)을 다룬다. 기존 언어 모델의 학습 목표인 '다음 토큰 예측'은 사용자가 원하는 답변을 제공하는 목표와 다르다. 따라서 모델의 규모를 키우는 것만으로는 지시를 정확하게 따르거나, 사실에 기반한 안전한 답변을 보장하기 어렵다. 연구진은 인간 피드백 기반 강화 학습(RLHF)으로 GPT-3를 미세 조정한 InstructGPT를 제안한다. 목표는 유용하고 (Helpful), 정직하며(Honest), 해롭지 않은(Harmless) 답변을 생성하는 것이다.

해당 task에서 기존 연구 한계점

- **학습 목표와 사용자 의도의 불일치:** 자연스러운 문장을 생성하는 능력이 사용자의 요청을 수행하는 능력으로 곧바로 이어지지 않는다.
- **모델 규모 확장의 한계:** 큰 모델도 사실을 지어내거나, 유해한 내용을 생성하거나, 지시의 조건을 무시할 수 있다.
- **기존 RLHF 연구의 적용 범위:** 요약 등 특정 작업에 집중되어, 다양한 실제 사용자 요청에서의 효과를 확인할 필요가 있었다.
- **공개 NLP 데이터와 실제 사용의 차이:** 벤치마크 중심의 학습·평가만으로는 다양한 API 사용자의 요구를 충분히 반영하기 어렵다.

논문의 contributions

1. 다양한 지시 수행에 RLHF 적용

인간이 작성한 모범 답변으로 지도 미세 조정(SFT)을 수행하고, 답변 선호 순위로 보상 모델(RM)을 학습한 뒤, PPO로 답변 생성 모델을 최적화했다.

2. 모델 크기보다 정렬 학습의 중요성 입증

API 프롬프트 평가에서 **13억 파라미터 InstructGPT의 답변이 1,750억 파라미터 GPT-3보다 선호**되었다. 이는 모든 작업에서 성능이 우수하다는 의미는 아니다.

3. 사실성과 지시 준수 개선

인간 평가에서 사용자 지시를 더 잘 따랐고, 사실성 평가와 일부 유해성 평가에서도 개선을 보였다. 다만 편향은 유의미하게 개선되지 않았다.

4. 정렬 과정의 성능 저하 완화

강화학습에 사전학습 데이터의 학습 목표를 함께 사용하는 **PPO-ptx**로, 일부 공개 NLP 작업의 성능 저하인 'alignment tax'를 줄였다.

단, 이 모델은 평가자와 연구진의 선호에 맞춰진 것이며, 보편적인 인간 가치에 완전히 정렬되었다고 볼 수는 없다.