

10/6 논문 - Learning Transferable Visual Models From Natural Language Supervision

<https://arxiv.org/pdf/2103.00020>

핵심 모델: CLIP — Contrastive Language-Image Pre-training

한 문장 요약: 인터넷의 이미지-텍스트 쌍으로 두 모달리티의 의미를 연결하여, 별도의 데이터셋별 학습 없이 자연어로 지정한 클래스를 분류하는 모델이다.

1. Introduction

논문이 다루는 분야

이 논문은 컴퓨터 비전과 자연어 처리를 연결하는 멀티모달 표현 학습과, 학습한 표현을 새로운 과제로 전이하는 zero-shot transfer를 다룬다. 기존 이미지 분류 모델은 ImageNet 처럼 사람이 정의한 클래스와 라벨을 학습한다. 반면 이 논문은 인터넷에 게시된 이미지와 자연어 설명을 학습 신호로 사용한다. 핵심 질문은 다음과 같다. 대규모 이미지-텍스트 데이터로 학습하면, 새로운 데이터셋의 라벨을 사용해 추가 학습하지 않고도 자연어 설명만으로 이미지를 분류할 수 있을까? 여기서 zero-shot은 사전 학습을 하지 않았다는 뜻이 아니라, 평가 대상 데이터셋의 학습 이미지와 라벨을 사용해 모델을 추가 학습하지 않는다는 뜻이다.

해당 task에서 기존 연구 한계점

- **고정된 클래스에 제한됨:** 기존 분류기는 학습 시 정해진 출력 클래스에 맞춰져 있어, 새로운 개념을 분류하려면 라벨 데이터와 추가 학습이 필요하다.
- **라벨 구축 비용이 큼:** 사람이 이미지를 분류하고 검수하는 방식으로는 데이터 규모와 개념의 다양성을 확대하기 어렵다.
- **기존 자연어 기반 학습의 규모와 성능이 부족함:** VirTex, ICMLM, ConVIRT 등은 가능성을 보였지만 상대적으로 작은 규모로 학습했다. Visual N-Grams의 ImageNet zero-shot 정확도는 11.5%였다.
- **텍스트 생성 목표의 학습 효율이 낮음:** 이미지에 대응하는 문장을 단어 단위로 정확히 생성하는 과제는 복잡하다. 저자들의 실험에서는 이미지 표현을 효율적으로 학습하기 어려웠다.

- 벤치마크 성능과 실제 일반화 사이에 차이가 있음: ImageNet에서 높은 정확도를 얻어도 촬영 조건이나 이미지 스타일이 달라지면 성능이 크게 떨어질 수 있다.

논문의 contributions

1. 4억 개 이미지-텍스트 쌍으로 구성된 WIT 데이터셋 구축

- 자연어 기반 시각 학습을 웹 규모로 확장했다.

2. 효율적인 대조학습 모델 CLIP 제안

- 문장을 생성하는 대신, 배치 안에서 어떤 이미지와 텍스트가 실제 짝인지 맞히도록 학습했다.

3. 자연어를 통한 zero-shot 분류 구현

- 클래스 이름과 설명을 텍스트 인코더에 넣어 새로운 분류기를 구성한다.

4. 다양한 과제에서 전이 성능 검증

- 30개 이상의 데이터셋에서 이미지 분류, OCR, 행동 인식, 위치 추정 등의 성능을 분석했다.

5. 표현의 품질·분포 변화에 대한 강건성·사회적 편향 분석

- 정확도뿐 아니라 모델의 일반화 범위와 실패 사례도 함께 제시했다.

2. Related Work

연구 흐름	대표 연구	CLIP과의 관계
자연어 기반 시각 표현 학습	Joulin et al., Visual N-Grams	이미지와 함께 있는 단어·구절을 예측해 표현을 학습했다. CLIP은 문장 전체와 이미지의 대응 관계를 학습한다.
언어 모델링 기반 이미지 학습	VirTex, ICMLM	캡션 생성 또는 마스킹된 단어 예측을 사용한다. CLIP은 대조학습으로 학습 효율을 높인다.
이미지-텍스트 대조 학습	ConVIRT	의료 이미지와 텍스트를 연결했다. CLIP은 유사한 원리를 일반 인터넷 데이터와 대규모 학습으로 확장한다.
대규모 약지도 학습	Instagram hashtag pre-training, JFT 기반 학습	많은 데이터를 활용하지만 미리 정한 라벨 집합에 의존한다. CLIP은 자연어를 통해 더 다양한 개념을 표현한다.
이미지 자기지도학습	SimCLR, MoCo, BYOL	이미지 표현을 학습하지만 언어와의 연결은 직접 제공하지 않는다. CLIP은 표현 학습과 자연어 기반 분류를 함께 가능하게 한다.

연구 흐름	대표 연구	CLIP과의 관계
NLP의 범용 사전학습	GPT 계열	대규모 사전학습으로 여러 과제에 전이한다는 접근에서 영향을 받았다.

차별점: 이미지와 자연어를 연결한다는 아이디어 자체보다, 효율적인 학습 목표와 대규모 데이터·모델을 결합하여 실용적인 zero-shot 성능을 보였다는 점이 중요하다.

Main Idea

이미지와 텍스트를 같은 임베딩 공간에 배치하고, 실제로 대응하는 쌍의 유사도가 높아지도록 학습한다.

예를 들어 강아지 사진은 강아지를 설명하는 문장과 가깝게, 자동차를 설명하는 문장과는 상대적으로 멀게 표현되도록 학습한다.

① 이미지 인코더와 텍스트 인코더

- **이미지 인코더:** 수정된 ResNet 또는 Vision Transformer(ViT)
- **텍스트 인코더:** Transformer
- 각 인코더의 출력을 선형 투영한 뒤 L2 정규화하여 같은 차원의 임베딩으로 만든다.
- 정규화된 벡터의 내적으로 이미지-텍스트 간 cosine similarity를 계산한다.

② 대조학습

배치에 N개의 이미지-텍스트 쌍이 있으면, 모든 조합의 유사도를 계산하여 N * N 행렬을 만든다.

- 실제 대응하는 N개 쌍은 **positive pair**
- 나머지 N^2-N개 조합은 **negative pair**
- 이미지에서 올바른 텍스트를 찾는 방향과 텍스트에서 올바른 이미지를 찾는 방향을 모두 학습한다.

정규화된 이미지 임베딩을 u_i , 텍스트 임베딩을 v_j 라 하면,

$$[s_{ij} = \frac{u_i^\top v_j}{\tau}]$$

여기서 tau는 학습 가능한 temperature로, 유사도에 대한 softmax 분포의 날카로움을 조절한다. 이미지에서 텍스트를 찾는 손실은 다음과 같다.

$$\mathcal{L}_{I \rightarrow T} = -\frac{1}{N} \sum_{i=1}^N \log \frac{\exp(s_{ii})}{\sum_{j=1}^N \exp(s_{ij})}$$

반대 방향의 손실도 계산한 뒤 평균한다.

$$\mathcal{L} = \frac{\mathcal{L}_{I \rightarrow T} + \mathcal{L}_{T \rightarrow I}}{2}$$

즉, 각 이미지와 텍스트가 배치 안에서 자신의 올바른 짝을 찾도록 하는 대칭적 cross-entropy loss이다.

③ Zero-shot 분류

학습이 끝난 뒤에는 분류하려는 클래스들을 자연어 문장으로 만든다. 예를 들어 클래스가 `dog`, `cat`, `car` 라면:

- `A photo of a dog.`
- `A photo of a cat.`
- `A photo of a car.`

이 문장들을 텍스트 인코더로 변환하고, 입력 이미지의 임베딩과 유사도를 비교한다. 가장 유사한 클래스 문장을 예측 결과로 선택한다. 텍스트 인코더가 클래스 설명으로부터 분류기의 가중치를 만들어 주는 역할을 하므로, 클래스가 바뀌어도 모델을 다시 학습할 필요가 없다.

④ Prompt engineering과 ensembling

클래스 이름만 사용하면 단어의 의미가 모호하거나 사전학습 텍스트와 형식이 다를 수 있다.

- `crane` 은 새 또는 건설용 기중기를 의미할 수 있다.
- `boxer` 는 운동선수 또는 개 품종을 의미할 수 있다.

따라서 클래스가 속한 분야와 이미지 유형을 문장에 명시한다. 여러 프롬프트의 텍스트 임베딩을 평균하는 prompt ensemble도 사용한다. 클래스별 평균 임베딩을 미리 계산해 저장할 수 있어, 이미지마다 여러 텍스트를 다시 인코딩할 필요는 없다.

⑤ 학습 설정

- ResNet 5종과 ViT 3종 학습
- 기본 학습: 32 epochs
- 배치 크기: 32,768
- Adam, decoupled weight decay, cosine learning-rate schedule 사용
- 대표 모델: ViT-L/14@336px
 - ViT-L/14를 학습한 뒤, 336픽셀 해상도에서 1 epoch 추가 사전학습한 모델

4. 실험 및 결과

Dataset

사전학습 데이터: WIT(WebImageText)

- 인터넷에서 수집한 4억 개 이미지-텍스트 쌍
- 약 50만 개 검색어를 사용해 다양한 시각 개념을 수집
- 검색어당 최대 2만 쌍을 포함하여 특정 검색어로 데이터가 과도하게 몰리는 것을 완화

평가 데이터

평가 영역	대표 데이터셋
일반 객체 분류	ImageNet, CIFAR-10/100, STL-10
세부 범주 분류	Food101, Stanford Cars, Oxford Pets, Flowers102, FGVC Aircraft
장면·위치 인식	SUN397, Country211
행동 인식	UCF101, Kinetics700
OCR·문자 관련 과제	MNIST, Rendered SST2
특수·추상 과제	EuroSAT, PatchCamelyon, CLEVRCounts, KITTI Distance
자연적 분포 변화	ImageNetV2, ImageNet Sketch, ImageNet-A/R, ObjectNet 등

논문 전체에서는 30개 이상의 데이터셋을 다루며, 실험 목적에 따라 12개·27개·36개 등의 서로 다른 평가 묶음을 사용한다.

Baseline

평가 방식에 따라 비교 대상을 구분한다.

실험	비교 대상	평가 목적
기존 zero-shot 방법 비교	Visual N-Grams	자연어 기반 전이 성능의 발전 확인
Zero-shot vs. 지도 학습	ImageNet 사전학습 ResNet-50 특징 위에 학습한 logistic regression	추가 라벨 학습 없이도 지도학습 기준선과 경쟁 가능한지 확인
Few-shot 비교	CLIP, BiT-M, SimCLRv2, ResNet 등의 특징 위에 학습한 소량 데이터 분류기	소량의 라벨을 사용하는 방법과 비교
표현 학습 비교	EfficientNet, Noisy Student, BiT, ViT, SimCLRv2, MoCo, BYOL 등	이미지 특징 자체의 품질 평가
학습 목표 비교	캡션 생성, bag-of-words 예측	대조학습의 효율 확인

Zero-shot은 평가 데이터의 라벨로 추가 학습하지 않는다. **Linear probe**는 인코더를 고정하고 평가 데이터의 학습 라벨로 선형 분류기를 학습한다.

3. 제안 방법론

결과

① ImageNet zero-shot 성능

모델	ImageNet Top-1 정확도
Visual N-Grams	11.5%
CLIP	76.2%

- CLIP은 ImageNet 학습용 128만 장으로 추가 학습하지 않고도 원래 ResNet-50에 준하는 성능을 달성했다.
- Top-5 정확도는 ****95.0%****였다.
- 다만 Visual N-Grams와는 데이터·모델·연산량이 크게 다르므로, 이 차이를 대조학습만의 효과로 해석할 수는 없다.

② 여러 과제로의 zero-shot transfer — Figure 5

- **27개 데이터셋 중 16개**에서 지도학습 ResNet-50 linear probe보다 높은 성능을 보였다.
- Food101, Stanford Cars, Country211, 행동 인식 등에서 강점을 보였다.
- 위성 영상, 의료 영상, 객체 수 세기, 거리 판단 같은 과제에서는 약했다.
- 이는 CLIP이 다양한 개념을 학습했지만, 모든 과제에 균일하게 일반화하는 것은 아님을 보여 준다.

③ Prompt engineering과 ensembling — Figure 4

- ImageNet에서 기본 프롬프트 사용으로 약 **1.3%p** 향상
- 80개 프롬프트 앙상블로 추가 약 **3.5%p** 향상
- 두 방법을 함께 적용하면 약 **5%p** 향상
- 36개 데이터셋 평균에서도 약 **5%p** 향상
- 같은 모델이라도 클래스를 어떻게 설명하느냐가 성능에 영향을 준다.

④ Few-shot과의 비교 — Figure 6

20개 데이터셋 평균에서 zero-shot CLIP은:

- 동일한 CLIP 특징 위에 학습한 **4-shot linear probe**와 비슷한 성능
- 비교한 공개 모델 중 가장 좋은 **16-shot linear probe**에 근접한 성능

자연어 설명이 분류하려는 개념을 직접 전달하므로, 적은 수의 이미지 예시만으로 개념을 추론하는 방법보다 유리할 수 있다.

⑤ 표현 학습 성능 — Figure 10, 11

CLIP 특징에 학습 라벨로 선형 분류기를 학습했을 때:

- 기존 12개 데이터셋 평가에서 최상위 비교 모델보다 평균 2.6%p 향상
- 확장된 27개 데이터셋 평가에서는 평균 약 5%p 향상
- 27개 중 21개에서 Noisy Student EfficientNet-L2의 특징보다 높은 성능
- 이 결과는 linear probe 결과이며 zero-shot 결과와 구분해야 한다.

⑥ 자연적 분포 변화에 대한 강건성 — Figure 13, 14

- Zero-shot CLIP은 ImageNet 성능이 비슷한 기존 모델보다 자연적 분포 변화에서 강했다.
- ImageNet과 분포 변화 데이터 사이의 정확도 격차를 최대 75% 줄였다.
- CLIP 특징에 ImageNet 라벨로 선형 분류기를 학습하면 ImageNet 정확도는 ****76.2% → 85.4%****로 상승했지만, 분포 변화 데이터의 평균 정확도는 소폭 감소했다.
- 특정 벤치마크에서의 성능 향상이 다른 환경에서의 일반화 향상으로 이어지지 않는다.

⑦ 학습 효율과 규모 확장 — Figure 2, 9

- 저자들의 비교에서 bag-of-words 예측은 캡션 생성보다 zero-shot ImageNet 성능을 약 3배 빠르게 학습했다.
- 예측 목표를 대조학습으로 바꾸면 추가로 약 4배의 효율 향상을 보였다.
- 모델 연산 규모가 증가할수록 평균 zero-shot 오류율이 대체로 매끄럽게 감소했다.

5. 결론 (배운점)

의의

- 자연어를 시각 학습의 감독 신호로 활용할 수 있음을 대규모로 입증했다.
 - 고정된 클래스 라벨보다 다양한 개념을 표현할 수 있다.

- 자연어가 새로운 분류 과제를 지정하는 인터페이스가 된다.
 - 사용자가 클래스 설명을 바꾸면 추가 학습 없이 새로운 분류기를 구성할 수 있다.
- 단순한 대조학습 목표로 다양한 과제에 전이 가능한 표현을 학습했다.
 - 이미지 분류뿐 아니라 OCR, 행동 인식, 위치 추정 관련 능력도 나타났다.
- 모델 평가에서 과제 다양성과 분포 변화가 중요함을 보여 줬다.
 - ImageNet 정확도 하나만으로 표현의 범용성을 판단하기 어렵다.

한계

1. 특수하거나 추상적인 과제에 약하다.
 - 객체 수 세기, 거리 판단, 의료 영상 등에서 낮은 성능을 보인다.
 - 손글씨 MNIST의 zero-shot 정확도는 약 88%로, 원시 픽셀 기반 logistic regression보다 낮았다.
2. 주어진 후보 클래스 중에서 선택한다.
 - 자연어로 후보를 자유롭게 지정할 수 있지만, 이미지 캡셔닝처럼 새로운 설명을 생성하는 모델은 아니다.
3. 많은 데이터와 연산 자원이 필요하다.
 - ViT-L/14 학습에 V100 GPU 256개로 12일이 소요됐다.
 - 라벨 구축 부담을 줄였지만, 적은 데이터로 학습하는 문제를 해결한 것은 아니다.
4. Zero-shot 평가에도 개발 과정의 영향을 받는다.
 - 모델과 프롬프트를 개발하면서 검증 세트 성능을 반복적으로 확인했다.
 - 검증 정보도 없는 엄격한 zero-shot 상황과는 차이가 있다.
5. 웹 데이터의 사회적 편향을 학습할 수 있다.
 - 클래스의 표현과 후보 집합에 따라 편향과 오분류 양상이 달라진다.
6. 성능 향상의 원인을 완전히 분리하지 못했다.
 - 자연어 감독, 대규모 데이터, 모델 구조, zero-shot 평가 방식이 함께 작용한다.

배운 점

- 학습 목표의 선택이 규모 확장의 효율을 좌우한다.

이미지의 문장을 정확히 생성하는 것보다, 이미지와 문장의 대응 관계를 학습하는 과제가 전이 가능한 표현을 더 효율적으로 만들 수 있다.

- **자연어 설명 자체가 유용한 과제 정보다.**

클래스 이름과 문맥은 단순한 표시가 아니라, 모델에게 분류하려는 개념을 전달하는 정보가 된다.

- **좋은 표현과 좋은 zero-shot 분류기는 구분해야 한다.**

CLIP 특징이 충분한 정보를 담고 있어도, 텍스트로 만든 분류기가 그 정보를 완전히 활용하지 못할 수 있다.

- **프롬프트도 모델 성능을 결정하는 요소다.**

같은 클래스라도 맥락과 이미지 유형을 명시하면 성능이 달라진다.

- **범용성을 판단하려면 다양한 평가가 필요하다.**

여러 과제, 분포 변화, 실패 사례를 함께 확인해야 모델이 어디에서 유용한지 알 수 있다.