

InstructGPT

1. Introduction

논문이 다루는 분야

대규모 언어 모델(LM)의 alignment, 즉 모델이 사용자의 의도(intent)에 맞게 행동하도록 만드는 문제를 다룬다. GPT-3와 같은 LM은 few-shot prompting으로 다양한 NLP task를 수행할 수 있지만, 사실을 지어내거나(hallucination), 편향되거나 유해한 텍스트를 생성하거나, 단순히 사용자의 지시를 따르지 않는 문제를 보인다. 저자들은 그 원인을 학습 목적함수의 불일치에서 찾는다. 사전학습 목적은 "인터넷 웹사이트의 다음 토큰 예측"인 반면, 실제로 원하는 것은 "사용자의 지시를 helpful하고 safe하게 따르는 것"이며, 이 둘이 다르기 때문에 language modeling objective가 misaligned되어 있다고 정의한다. 실제 API 형태로 수많은 애플리케이션에 배포되는 모델이라는 점에서 이 문제의 해결은 실용적으로도 중요하다.

목표는 Askell et al. (2021)의 프레임워크를 따라 helpful(사용자의 task 해결을 도움), honest(정보를 조작하거나 오도하지 않음), harmless(물리적·심리적·사회적 해를 끼치지 않음)한 모델을 만드는 것이다.

해당 task에서 기존 연구 한계점

- 모델 크기 확장의 한계: 모델을 키우는 것만으로는 사용자 의도를 더 잘 따르게 되지 않는다. 175B GPT-3도 여전히 지시를 무시하거나 사실을 지어낸다.
- Prompting의 한계: few-shot prompt를 잘 설계하면(GPT-3 prompted) 성능이 개선되지만, 사용자가 매번 신중하게 prompt를 설계해야 하고 근본적인 해결책이 아니다.
- Public NLP 데이터셋 기반 instruction tuning(FLAN, T0)의 한계: 공개 NLP 데이터셋은 자동 평가가 쉬운 분류·QA 위주로 구성되어 있으나, 실제 API 사용 분포에서 분류와 QA는 약 18%에 불과하고 open-ended generation과 brainstorming이 약 57%를 차지한다. 또한 실제 사용 입력만큼의 다양성을 확보하기 어렵다.
- 기존 RLHF 연구의 한계: RLHF는 Atari·로봇 시뮬레이션에서 시작해 요약(summarization), 스타일 연속 생성 등 좁은 도메인에만 적용되어 왔고, 광범위한 언어 task 분포 전체에 대해 적용된 사례는 없었다.

논문의 contributions

- SFT → Reward Model → PPO로 이어지는 3단계 RLHF 파이프라인을 GPT-3에 적용해, 실제 API 프롬프트 분포 전반에서 지시를 따르는 모델 InstructGPT를 제안.
- 1.3B InstructGPT의 출력이 175B GPT-3보다 선호됨을 보임(파라미터 100배 이상 차이). 175B 기준으로 GPT-3 대비 85±3%, few-shot GPT-3 대비 71±4% 선호.
- Truthfulness 개선: TruthfulQA에서 truthful & informative 답변 비율이 GPT-3의 약 2배, closed-domain task의 hallucination 비율이 41% → 21%로 감소.
- Toxicity 소폭 개선(respectful prompt 조건에서 약 25% 감소), 단 bias는 개선되지 않음을 함께 보고.
- RLHF로 인한 public NLP 벤치마크 성능 하락(alignment tax)을 사전학습 gradient를 섞는 PPO-ptx로 크게 완화.
- 학습 데이터를 만들지 않은 held-out labeler에게도 선호가 일반화됨을 보이고, FLAN/T0 대비 실제 사용 분포에서 우월함을 보임.

2. Related Work

관련 연구를 네 갈래로 정리한다.

첫째, alignment 및 human feedback 학습. RLHF는 Christiano et al. (2017), Ibarz et al. (2018)에서 시뮬레이션 로봇과 Atari 게임을 위해 개발되었고, 이후 Ziegler et al. (2019), Stiennon et al. (2020), Wu et al. (2021) 등에서 텍스트 요약에 적용되었다. 대화, 번역, semantic parsing, 스토리 생성 등에서 human feedback을 보상으로 쓰는 연구도 존재한다. 저자들은 자신들의 작업을 "RLHF를 광범위한 언어 task 분포에서의 LM alignment에 직접 적용한 것"으로 위치시킨다. 즉 방법론 자체의 새로움보다는 적용 범위의 확장을 차별점으로 내세운다.

둘째, instruction following 학습. FLAN, T0, Natural Instructions 등 공개 NLP 데이터셋에 instruction을 붙여 fine-tuning하면 unseen task에 대한 zero/few-shot 성능이 오른다는 일관된 결과가 있다. 본 논문은 이들과 달리 실제 사용자가 API에 제출한 프롬프트와 사람의 선호 데이터를 사용하며, 실험에서도 FLAN·T0로 fine-tuning한 175B GPT-3를 직접 baseline으로 두어 차별성을 정량적으로 보인다.

셋째, LM의 위해성 평가. 편향, 개인정보 유출, misinformation, 악용 가능성 등이 문서화되어 왔고 toxicity(RealToxicityPrompts), stereotype, social bias(CrowS-Pairs, Winogender) 벤치마크가 존재한다. 본 논문은 이 벤치마크들을 평가에 그대로 활용한다.

넷째, 위해 완화를 위한 행동 수정. value-targeted 데이터셋 fine-tuning(PALMS), 사전학습 데이터 필터링, 안전 control token, word embedding 정규화, 보조 LM을 이용한 생성 steering 등이 있다. 본 논문은 이들을 대체하기보다 RLHF와 결합 가능한 보완 기법으로 언급하며 Discussion에서 future work로 연결한다.

Introduction에서 지적한 한계(FLAN/T0의 분포 불일치, RLHF의 좁은 도메인 적용)가 Related Work에서 그대로 대응되어 서술되어 있어 흐름이 일관적이다. 다만 RLHF 방법론 자체는 Stiennon et al. (2020)을 거의 그대로 따르므로, 기술적 차별성보다는 "데이터 분포와 적용 규모"의 차별성이 핵심이라는 점이 분명히 드러난다.

3. 제안 방법론

Main Idea

사람의 선호를 보상 신호로 사용해 사전학습된 GPT-3를 fine-tuning한다. 전체 과정은 3단계로 구성된다.

Step 1. Supervised Fine-Tuning (SFT)

- 약 40명의 labeler(Upwork, Scale AI)를 스크리닝 테스트로 선발. 민감 발화 플래깅 일치도, 랭킹 일치도, 민감 프롬프트에 대한 demonstration 작성 점수 등을 기준으로 함.
- 프롬프트에 대해 labeler가 바람직한 응답(demonstration)을 직접 작성하고, 이를 이용해 GPT-3를 supervised learning으로 fine-tuning.
- 데이터: 약 13k 프롬프트(labeler 작성 + API).
- 학습: 16 epoch, cosine LR decay, residual dropout 0.2. 1 epoch 이후 validation loss는 overfit되지만 RM 점수와 사람 선호는 계속 좋아 지므로, 모델 선택은 validation loss가 아니라 RM 점수 기준으로 함.

Step 2. Reward Model (RM) 학습

- 하나의 프롬프트에 대해 모델 출력 K개(K=4~9)를 labeler가 순위 매김 → C(K,2)개의 pairwise 비교 생성.
- SFT 모델에서 최종 unembedding layer를 제거하고 scalar를 출력하는 projection layer를 붙여 RM으로 사용. 175B RM은 학습이 불안정해 6B RM만 사용.
- Loss: $\text{loss}(\theta) = -1/C(K,2) \cdot E[\log \sigma(r\theta(x, y_w) - r\theta(x, y_l))]$. 선호된 응답 y_w 의 보상이 y_l 보다 크도록 학습.
- 핵심 구현 포인트: 한 프롬프트의 C(K,2)개 비교를 개별 데이터로 섞으면 각 completion이 K-1번 gradient update에 쓰여 1 epoch 안에 overfit된다. 그래서 한 프롬프트의 모든 비교를 하나의 batch element로 묶어 학습 → K번의 forward pass만 필요해 효율적이고 overfit도 방지.
- 데이터: 약 33k 프롬프트. 1 epoch, lr 9e-6, batch size 64(프롬프트 단위).
- RL 전에 labeler demonstration의 평균 보상이 0이 되도록 bias로 정규화.

Step 3. PPO를 이용한 강화학습

- 환경은 bandit 형태: 랜덤 프롬프트 제시 → 응답 생성 → RM이 보상 산출 → 에피소드 종료.
- RM over-optimization을 막기 위해 SFT 모델과의 per-token KL penalty를 보상에 추가 ($\beta = 0.02$).
- PPO-ptx: alignment tax를 줄이기 위해 사전학습 데이터의 log-likelihood gradient를 섞음. $\text{objective}(\phi) = E[r_\theta(x, y) - \beta \log(\pi_{\text{RL}}(y|x) / \pi_{\text{SFT}}(y|x))] + \gamma E_{\text{pretrain}}[\log \pi_{\text{RL}}(x)]$ $\gamma = 0$ 이면 PPO, $\gamma = 27.8$ 이면 PPO-ptx. 논문에서 InstructGPT는 PPO-ptx를 지칭.
- 데이터: 약 31k API 프롬프트(사람 라벨 없음). 256k episode, batch 512, minibatch 64, clip ratio 0.2, value function은 RM에서 초기화.
- Step 2와 3은 반복 가능: 현재 최선의 policy로 비교 데이터를 다시 모아 RM과 policy를 갱신.

데이터 측면에서는 OpenAI API Playground에 제출된 프롬프트를 사용하며, 긴 공통 prefix 기반 중복 제거, user ID당 200개 제한, user ID 기준 train/valid/test 분할, PII 필터링을 수행한다. 초기 모델 학습을 위해서는 labeler가 직접 plain / few-shot / user-based 프롬프트를 작성했다.

Contribution

- Introduction에서 언급한 내용과 방법론의 서술이 일치한다. "human preference를 reward signal로 사용"한다는 핵심 주장이 RM 학습과 PPO 단계로 구체화되어 있다.
- 제안 방법의 장점에 대한 근거가 실험 설계와 연결되어 있다.
 - 모델 크기 대비 효율: 같은 아키텍처에서 fine-tuning 데이터만 다르게 한 비교로 정당화.
 - Alignment tax 완화: KL 계수만 키우는 대안(β 를 기본값의 100배인 2.0까지)으로는 DROP/SQuAD 성능이 회복되지 않고 validation reward만 크게 떨어지는 반면, 사전학습 mix($\gamma \geq 20$)는 성능을 회복하면서 reward 하락이 적다는 ablation(Fig. 33, 34)으로 PPO-ptx 설계를 뒷받침.
 - RM 학습 방식: batch 구성 방식이 overfit을 막는 이유를 수식과 각주로 설명.
- 구현 가능성 측면에서 매우 상세하다. Appendix C에 모델 크기별 LR, batch size, epoch, 스케줄, PPO 하이퍼파라미터(EMA decay 0.992, GAE discount 없음, 사전학습 데이터 비율 8배 등)가 모두 명시되어 있다. 다만 labeler 데이터, API 프롬프트, GPT-3 가중치가 공개되지 않아 외부에서 정확한 재현은 사실상 불가능하다.
- 비용 측면의 기여도 제시: 175B SFT 학습 4.9 petaflops/s-days, 175B PPO-ptx 60 petaflops/s-days로 GPT-3 사전학습(3,640 petaflops/s-days)에 비해 매우 작다.

4. 실험 및 결과

Dataset

- API prompt distribution (주 평가): 학습에 포함되지 않은 고객의 프롬프트로 구성된 held-out test set. InstructGPT용으로 제출된 프롬프트(Instruct distribution)와 GPT-3용으로 제출된 프롬프트(GPT distribution) 두 가지로 평가해 baseline에 불리한 분포 편향을 통제.
- 학습 데이터 규모: SFT 약 13k, RM 약 33k, PPO 약 31k 프롬프트. 사용 사례 분포는 Generation 45.6%, Open QA 12.4%, Brainstorming 11.2%, Chat 8.4% 등. 96% 이상 영어.
- Public NLP datasets
 - 안전성: TruthfulQA(truthfulness), RealToxicityPrompts(toxicity), Winogender-CrowS-Pairs(bias)
 - 일반 능력: DROP, QuAC, SQuAD v2, HellaSwag, SST, RTE, WSC, WMT15 Fr→En, CNN/DM, Reddit TL;DR

Baseline

- GPT-3 (프롬프트 없이 그대로 사용)
- GPT-3 prompted: instruction-following 모드로 유도하는 few-shot prefix를 붙인 GPT-3. prefix는 저자 2인이 각 1시간씩 찾은 후보 중 RM 점수가 가장 높은 것을 선택.
- SFT: Step 1까지만 학습한 모델. 175B SFT가 주 평가의 비교 기준(win rate 계산 기준점).
- PPO: 사전학습 mix 없는 RLHF 모델.
- FLAN, T0: 175B GPT-3를 각 데이터셋 약 1M 예시로 fine-tuning한 모델(T0는 T0++ 사용, 96M에서 서브샘플링).
- 모델 크기는 1.3B, 6B, 175B 세 가지.

평가 지표는 175B SFT 대비 win rate, 1-7 Likert 점수, 메타데이터(지시 수행 실패, 제약조건 준수, hallucination, 고객 응대 적합성 등)이며, 최종 평가에서는 학습 때와 달리 helpfulness보다 truthfulness·harmlessness를 우선하도록 labeler에게 지시했다.

결과

- 사람 선호 평가: 모든 모델 크기에서 GPT < GPT prompted < SFT < PPO ≈ PPO-ptx 순으로 선호도가 계단식으로 상승. 1.3B PPO-ptx가 175B GPT-3보다 선호됨. 175B에서 GPT-3 대비 85±3%, few-shot GPT-3 대비 71±4%.
- 메타데이터: InstructGPT는 올바른 지시를 시도하는 비율, 명시적 제약조건 준수, 고객 응대 적합성이 높고 hallucination이 적음. 즉 더 신뢰할 수 있고 제어하기 쉬운 모델.
- Held-out labeler 일반화: 학습 데이터를 만들지 않은 labeler도 비슷한 선호를 보임. RM 5-fold 교차검증(labeler 그룹 단위)에서 held-out 그룹 정확도 69.6±0.9%로, 학습 그룹 72.4±0.4% 대비 소폭 하락에 그침. labeler 간 일치도는 training 72.6±1.5%, held-out 77.3±1.3%.
- FLAN/T0 비교: FLAN·T0는 GPT-3보다는 낮고 GPT-3 prompted와 비슷하며 SFT보다 못함. 175B InstructGPT가 FLAN 대비 78±4%, T0 대비 79±4% 선호. 공개 NLP 데이터셋이 실제 사용 분포를 반영하지 못한다는 주장을 뒷받침.
- Truthfulness: TruthfulQA에서 PPO 모델이 작지만 유의미하게 개선. "I have no comment" 지시가 있을 때 확신 없는 거짓보다 truthful하지만 uninformative한 답을 택함. 단 1.3B PPO-ptx는 같은 크기 GPT-3보다 약간 낮음.
- Toxicity: respectful prompt 조건에서 GPT-3보다 덜 toxic하지만 prompt가 없으면 이점이 사라짐. 오히려 편향적/toxic하게 출력하라고 지시하면 GPT-3보다 훨씬 toxic한 출력을 생성.
- Bias: Winogender, CrowS-Pairs에서 GPT-3 대비 개선 없음. respectful 지시 시 entropy가 낮아져(더 확신) 오히려 bias 지표가 악화.
- Alignment tax: PPO는 SQuAD v2, DROP, HellaSwag, WMT15 Fr→En 등에서 GPT-3 대비 성능 하락. PPO-ptx는 이를 대부분 회복하고 HellaSwag에서는 GPT-3를 넘음. 단 DROP, SQuAD v2, 번역에서는 여전히 뒤처짐.
- 정성 결과: 학습 데이터에 거의 없던 비영어 지시, 코드 요약/QA에도 어느 정도 일반화. 반면 거짓 전제를 그대로 받아들이거나, 단순 질문에 과도하게 hedging하거나, 여러 제약조건이 있는 지시에서 성능이 떨어지는 실수가 남아 있음.

Introduction에서 제시한 각 주장(선호도, truthfulness, toxicity, alignment tax 완화, held-out 일반화, FLAN/T0 대비 우위)마다 대응되는 실험이 빠짐없이 존재한다. 특히 bias 미개선, 1.3B PPO-ptx의 TruthfulQA 열세, toxic 지시 시 더 유해해지는 현상처럼 불리한 결과도 숨기지 않고 보고한 점이 검증의 신뢰도를 높인다.

5. 결론(배운점)

연구의 의의

- "모델을 키우는 것"보다 "사람의 선호에 맞추는 것"이 실제 사용자 만족도에 훨씬 효율적이라는 것을 대규모로 처음 입증했다. 1.3B 모델이 175B를 이기고, alignment 비용이 사전학습 대비 2% 미만이라는 결과는 이후 LLM 개발의 방향을 SFT + RLHF 중심으로 바꾸는 계기가 되었다.
- SFT → RM → PPO라는 파이프라인이 이후 ChatGPT를 비롯한 대화형 LLM의 표준 레시피가 되었고, PPO-ptx, KL penalty, 프롬프트 단위 batch로 RM을 학습하는 트릭 등 실무적인 설계 디테일이 많이 담겨 있다.
- Alignment tax라는 개념을 명시적으로 정의하고, 이를 낮추는 것이 왜 중요한지(높으면 aligned 모델이 채택되지 않음)을 정리했다.

한계점

- "누구에게 align하는가"의 문제. 결과적으로 맞춘 대상은 약 40명의 영어권 labeler, 지침을 작성한 연구자, OpenAI API 고객의 선호이며, 저자 스스로 이것이 보편적 human values가 아니라고 인정한다. 대부분의 비교가 1명에게만 라벨링되었고 labeler 간 일치도도 약 73% 수준이다.
- 사용자 지시를 너무 잘 따르기 때문에 유해한 지시에도 순응한다. 학습 시 helpfulness를 truthfulness·harmlessness보다 우선한 결과이며, 거절(refusal) 학습은 future work로 남겨졌다.
- Bias는 개선되지 않았고, 평가 대부분이 학습 labeler와 같은 풀의 사람에 의존한다.
- 데이터와 모델이 비공개로 재현이 어렵고, RM이 6B 하나로 고정되어 RM 크기·품질이 결과에 미치는 영향은 충분히 분석되지 않았다.

좋았던 점

- 방법론 자체는 Stiennon et al. (2020)과 거의 같지만, 실제 서비스 분포의 데이터, 체계적인 labeler 선발, 다양한 baseline(특히 FLAN/T0, prompted GPT-3)으로 주장을 단단하게 검증했다.
- PPO-ptx의 필요성을 KL 계수 증가라는 단순한 대안과 비교하는 ablation으로 보여준 점이 설득력 있다.
- 부정적 결과와 한계, 사회적 영향(5.2, 5.3, 5.5)을 매우 상세하게 다룬다.

아쉬웠던 점

- RLHF의 각 구성요소 기여도 분석이 일부 부족하다. 예를 들어 PPO 대신 RM 점수로 best-of-n이나 expert iteration을 하면 어느 정도 성능이 나오는지 비교가 없어, 성능 향상이 RL 자체에서 오는지 RM 신호에서 오는지 분리하기 어렵다.
- 평가 지표의 대부분이 학습 labeler와 동일한 지침을 받은 사람의 선호라서, 모델이 "labeler가 좋아하는 스타일"(예: hedging)을 학습했을 가능성을 완전히 배제하지 못한다. 실제로 과도한 hedging이 실수 유형으로 보고되었다.

배운점

- 학습 목적함수와 실제 원하는 목표의 불일치(misalignment)를 정의하고, 이를 사람의 선호라는 별도 신호로 메우는 사고방식이 인상적이었다. 사전학습 분포를 유지하는 장치(KL penalty, pretraining mix)를 함께 두지 않으면 보상 최적화가 기존 능력을 훼손한다는 점도 일반적인 fine-tuning 설계에 적용할 만한 교훈이다.
- 서빙 관점에서 보면, 같은 성능을 100배 작은 모델로 얻을 수 있다는 결과는 추론 비용과 메모리 효율 측면에서 alignment가 단순 품질 문제가 아니라 시스템 효율 문제와도 직결된다는 것을 보여준다.

CLIP - 1. Introduction and Motivating Work 요약

논문이 다루는 분야

- 자연어 지도(natural language supervision)를 이용한 시각 표현 학습 및 zero-shot transfer
- NLP에서는 raw text로부터의 task-agnostic 사전학습(autoregressive / masked LM)이 compute·모델·데이터 규모를 키우며 성능이 꾸준히 향상되었고, "text-to-text" 인터페이스 덕분에 별도 output head 없이 zero-shot transfer가 가능해짐 (예: GPT-3)
- 반면 컴퓨터 비전은 여전히 ImageNet 같은 crowd-labeled 데이터셋으로 사전학습하는 것이 표준
- 핵심 질문: 웹 텍스트로부터 직접 학습하는 확장 가능한 사전학습이 비전에서도 NLP와 같은 돌파구를 만들 수 있는가?

해당 task에서 기존 연구 한계점

- 텍스트-이미지 쌍으로 시각 표현을 학습하려는 시도는 오래전부터 존재
 - Mori et al. (1999): 이미지와 짝지어진 문서의 명사·형용사 예측
 - Quattoni et al. (2007), Srivastava & Salakhutdinov (2012): 캡션 기반 표현 학습, multimodal DBM
 - Joulin et al. (2016): YFCC100M 메타데이터를 bag-of-words multi-label 분류로 변환해 CNN 학습
 - Li et al. (2017): visual n-gram 예측으로 다른 데이터셋에 zero-shot transfer 시연
 - VirTex, ICMLM, ConVIRT (2020): transformer 기반 LM, masked LM, contrastive objective 활용
- 한계 1 — 낮은 성능: Li et al. (2017)의 ImageNet zero-shot 정확도는 11.5%로, 당시 SOTA(88.4%)는 물론 고전적 CV 방법(50%)보다도 낮음 → 자연어 지도 방식이 거의 쓰이지 않음
- 한계 2 — 약지도 학습의 제한된 감독 범위: Instagram 해시태그 예측(Mahajan et al., 2018), JFT-300M 클래스 예측(Kolesnikov et al., 2019; Dosovitskiy et al., 2020)은 성능은 좋지만 감독을 각각 1,000개 / 18,291개 클래스로 제한. 또한 고정된 softmax 분류기를 사용해 동적 출력이 불가능하고 zero-shot 능력이 제한됨
- 한계 3 — 규모 격차: 약지도 모델들은 수백만~수십억 장 이미지로 accelerator-years 단위 학습을 한 반면, VirTex·ICMLM·ConVIRT는 10~20만 장 이미지로 accelerator-days 단위 학습에 그침

논문의 contributions

- 규모 격차 해소: 인터넷에서 수집한 4억 개 (image, text) 쌍 데이터셋 구축
- ConVIRT를 단순화해 scratch부터 학습한 CLIP (Contrastive Language-Image Pre-training) 제안 — 자연어 지도로부터 효율적으로 학습하는 방법임을 보임
- compute 기준 약 2 orders of magnitude에 걸친 8개 모델을 학습해, transfer 성능이 compute에 대해 매끄럽게 예측 가능한 함수임을 관찰 (scaling law)
- GPT 계열처럼 사전학습 중 OCR, geo-localization, action recognition 등 다양한 task를 학습함
- 30개 이상 데이터셋에서 zero-shot transfer를 평가해, 많은 경우 task-specific 지도학습 모델과 경쟁 가능함을 보임
- linear probe 평가에서 공개된 최고 ImageNet 모델보다 성능이 높으면서 계산 효율도 더 좋음
- zero-shot CLIP은 동일 정확도의 지도학습 ImageNet 모델보다 훨씬 robust → task-agnostic 모델은 zero-shot 평가가 실제 능력을 더 잘 반영함을 시사
- 이러한 결과의 정책적·윤리적 함의를 Section 7에서 논의