

# 5주차

## (1) CLIP

### 1. Introduction



논문에서 다루고 있는 주제가 무엇인지와 해당 주제의 필요성이 무엇인가  
논문에서 제안하는 방법이 기존 방법의 문제점에 대응되도록 제안 되었는가

#### 논문이 다루는 분야

- 이미지와 자연어를 함께 학습하는 **Vision-Language Representation Learning** 연구
- 기존의 고정된 class label 대신 **자연어를 supervision으로 활용**하여 이미지 표현을 학습
- 대규모 image-text pair를 이용해 사전학습한 뒤 별도의 추가 학습 없이 **zero-shot transfer**를 수행하는 방법 제안
- NLP에서 대규모 사전학습 모델이 다양한 downstream task로 전이되는 방식을 computer vision에 적용하고자 함

#### 해당 task에서 기존 연구 한계점

- 기존 computer vision 모델은 ImageNet과 같이 **미리 정의된 class label**을 예측하도록 학습되는 경우가 많음
- 새로운 visual concept이나 task를 다루기 위해서는 **추가적인 labeled dataset과 fine-tuning**이 필요함
- 기존 natural language supervision 연구는 가능성을 보였지만 일반적인 benchmark에서 성능이 낮았음
  - 예: Visual N-Grams의 ImageNet zero-shot accuracy는 11.5%
- 기존 weak supervision 방법도 hashtag나 정해진 class를 사용하여 학습 가능한 visual concept의 범위가 제한됨
- 소규모 image-text dataset을 이용한 연구가 많아 **대규모 자연어 supervision의 효과를 충분히 검증하지 못함** 2103.00020v1

## 논문의 contributions

- 인터넷에서 수집한 **4억 개의 image-text pair**로 구성된 WIT(WebImageText) 데이터셋 구축
- 이미지와 텍스트의 올바른 pair를 찾도록 학습하는 **Contrastive Language-Image Pre-training(CLIP)** 제안
- 자연어로 class를 표현하여 별도의 task-specific training 없이 **zero-shot image classification** 수행
- 30개 이상의 vision dataset에서 OCR, action recognition, geo-localization, fine-grained classification 등 다양한 task로의 transfer 성능 평가
- ImageNet에서 **zero-shot으로 기존 supervised ResNet-50과 비슷한 성능**을 달성하여 자연어 supervision의 확장 가능성을 보임

## 2. Related Work



Introduction에서 언급한 기존 연구들에 대해 어떻게 서술하는가  
제안 방법의 차별성을 어떻게 표현하고 있는가

- 이미지와 텍스트를 함께 사용한 representation learning 자체는 새로운 아이디어가 아님
- 기존 연구에서는 caption의 단어나 phrase를 예측하거나 image-text를 이용한 language modeling 등을 활용
- VirTex, ICMLM, ConVIRT 등에서도 자연어를 활용한 visual representation learning의 가능성을 제시함
- 하지만 기존 연구는 상대적으로 **작은 데이터 규모**에서 학습되거나 zero-shot 성능이 낮다는 한계가 있었음
- CLIP은 기존 아이디어를 대규모 web image-text dataset과 **contrastive learning**으로 확장한 것이 핵심적인 차이
- 자연어 자체가 매우 다양한 visual concept을 표현할 수 있기 때문에 정해진 label set보다 유연한 supervision으로 활용 가능

## 3. 제안 방법론



Introduction에서 언급된 내용과 동일하게 작성되어 있는가  
Introduction에서 언급한 제안 방법이 가지는 장점에 대한 근거가 있는가  
제안 방법에 대한 설명이 구현 가능하도록 작성되어 있는가

## Main Idea

- 이미지와 해당 이미지에 대응하는 텍스트를 각각 **Image Encoder**와 **Text Encoder**로 embedding
- 하나의 batch에서 실제 image-text pair의 similarity는 높이고 잘못된 pair의 similarity는 낮추도록 **contrastive learning** 수행
- N개의 image-text pair가 있을 때 가능한  $N \times N$  조합 중 **실제 pair를 구분하도록 학습**
- cosine similarity를 계산한 뒤 symmetric cross-entropy loss를 사용하여 image와 text를 같은 embedding space에 정렬
- Image Encoder로는 **ResNet 또는 Vision Transformer(ViT)**, Text Encoder로는 Transformer를 사용
- Zero-shot classification에서는 `"A photo of a {label}."` 과 같은 자연어 prompt를 Text Encoder에 입력
- 각 class의 text embedding과 입력 image embedding의 similarity를 계산하여 가장 유사한 class를 예측
- 즉, Text Encoder가 자연어 class description을 이용해 **zero-shot classifier의 weight를 생성하는 역할**을 수행

## Contribution

- 이미지 caption 자체를 생성하는 방식보다 **image-text matching 문제로 단순화하여 학습 효율을 크게 개선**
- 기존 bag-of-words prediction 대비 contrastive objective를 사용했을 때 zero-shot transfer 학습 효율이 약 **4배 향상**
- class name을 고정된 label로 사용하는 대신 자연어로 표현하여 새로운 task에도 쉽게 적용 가능
- **Prompt Engineering과 Prompt Ensembling**을 통해 추가 학습 없이 zero-shot 성능을 높일 수 있음을 확인
  - ImageNet에서는 prompt engineering과 ensembling으로 약 5%의 성능 향상

## 4. 실험 및 결과



Introduction에서 언급한 제안 방법의 장점을 검증하기 위한 실험이 있는가

### Dataset

#### Pre-training

- 인터넷에서 수집한 **400M image-text pairs**
- 논문에서는 이를 **\*\*WIT(WebImageText)\*\***라고 명명
- 다양한 visual concept을 포함하기 위해 약 50만 개 query를 기준으로 데이터를 수집

#### Evaluation

- ImageNet
- CIFAR-10 / CIFAR-100
- STL10
- Food101
- Oxford-IIIT Pets
- Stanford Cars
- Flowers102
- SUN397
- UCF101 / Kinetics700
- EuroSAT, RESISC45, MNIST 등 **30개 이상의 다양한 vision dataset**에서 평가

### Baseline

- Visual N-Grams
- Fully supervised ResNet-50
- BiT
- SimCLRv2 등 기존 supervised / self-supervised 모델
- CLIP 내부에서는
  - **Zero-shot classifier**

- Few-shot linear probe
- Fully supervised linear probe를 비교하여 representation 및 zero-shot transfer 성능을 분석

## 결과

- ImageNet zero-shot accuracy가 76.2%로 기존 Visual N-Grams의 11.5%보다 크게 향상
- ImageNet의 128만 개 labeled training example을 사용하지 않고도 original ResNet-50 수준의 성능을 달성
- 27개 dataset 중 16개에서 zero-shot CLIP이 supervised ResNet-50 feature 기반 linear classifier보다 높은 성능을 보임
- Zero-shot CLIP은 동일한 CLIP feature에서 학습한 4-shot linear classifier와 평균적으로 비슷한 성능을 보임
- 다만 EuroSAT, RESISC45, PatchCamelyon, CLEVRCounts 등 전문적이거나 복잡한 task에서는 성능이 크게 떨어짐
- 대부분의 dataset에서 zero-shot 성능은 fully supervised linear probe보다 약 10~25% 낮아, zero-shot task learning에는 여전히 개선 여지가 있음

## 5. 결론 (배운점)



연구의 의의 및 한계점, 본인이 생각하는 좋았던/아쉬웠던 점 (배운점)

- 대규모 image-text pair만으로도 특정 class label에 의존하지 않는 **범용적인 visual representation**을 학습할 수 있음을 보여준 연구
- 자연어를 classifier의 입력으로 활용하면서 새로운 class나 task에 대해 **zero-shot으로 적용할 수 있다는 점**이 인상적이었음
- 특히 NLP의 대규모 pre-training + zero-shot transfer 패러다임을 computer vision에서도 성공적으로 구현했다는 점에서 의미가 큼
- Contrastive learning을 통해 복잡한 caption generation보다 훨씬 효율적으로 image-text 관계를 학습한 점도 좋았음
- 반면 성능이 **prompt 표현에 영향을 받고**, specialized task에서는 zero-shot 성능이 크게 떨어진다는 한계가 있음

- 웹에서 수집한 대규모 데이터를 사용하기 때문에 데이터에 존재하는 **사회적 편향이나 유해한 association**을 그대로 학습할 가능성도 고려해야 함
- 결과적으로 CLIP은 이미지 분류를 정해진 label 예측 문제에서 **자연어를 통해 task를 정의할 수 있는 형태로 확장했다는 점**에서 의의가 있다고 생각함

## (2) RLHF

### 1. Introduction



논문에서 다루고 있는 주제가 무엇인지와 해당 주제의 필요성이 무엇인가  
논문에서 제안하는 방법이 기존 방법의 문제점에 대응되도록 제안 되었는가

#### 논문이 다루는 분야

- Large Language Model의 **Instruction Following** 및 **AI Alignment** 연구
- 모델의 크기를 키우는 것만으로는 사용자의 의도를 잘 따르는 모델이 되지 않는다는 문제에서 출발
- GPT-3를 **human feedback을 이용해 fine-tuning**하여 사용자의 instruction을 더 잘 따르는 InstructGPT를 제안
- 모델이 **helpful, honest, harmless**하게 동작하도록 만드는 것을 주요 alignment 목표로 설정

#### 해당 task에서 기존 연구 한계점

- 기존 대규모 LM의 pre-training objective는 인터넷 문서에서 **다음 token을 예측하는 것**임
- 하지만 실제 사용자가 원하는 것은 질문이나 명령에 맞게 **유용하고 안전한 답변을 생성하는 것**이므로 두 objective 사이에 차이가 존재
- 따라서 모델의 크기가 커져도
  - 사용자의 instruction을 따르지 않거나
  - 사실이 아닌 내용을 생성하거나
  - biased/toxic한 답변을 생성하는 문제가 발생

- 즉, 높은 language modeling 성능이 곧 **사용자 의도와 의 alignment**를 의미하지 않음 2203.02155v1

## 논문의 contributions

- GPT-3에 Reinforcement Learning from Human Feedback(RLHF)을 적용하여 InstructGPT를 학습
- 전체 학습 과정을 세 단계로 구성
  - 사람의 demonstration으로 **Supervised Fine-Tuning(SFT)**
  - 여러 모델 응답에 대한 사람의 선호 순위로 **Reward Model(RM)** 학습
  - Reward Model의 점수를 최대화하도록 **PPO**를 이용해 모델 fine-tuning
- 실제 API 사용자 prompt와 labeler가 작성한 prompt를 활용하여 다양한 instruction에 대한 모델의 행동을 학습
- **1.3B InstructGPT가 175B GPT-3보다 human evaluation에서 선호되어** 모델 크기보다 human feedback 기반 alignment가 실제 사용성에 큰 영향을 줄 수 있음을 보임
- TruthfulQA와 closed-domain task에서 **truthfulness** 및 **hallucination**을 개선하고 toxicity도 일부 감소시킴
- RLHF로 일부 기존 NLP task의 성능이 감소하는 **alignment tax**가 발생할 수 있으며, pre-training objective를 함께 사용하는 PPO-ptx로 이를 완화할 수 있음을 보임
- 다만 저자들도 이 방법이 보편적인 **human values** 자체를 학습하는 것이 아니라 특정 **labeler와 연구자의 선호에 맞추는 것**이라는 한계를 명확히 밝힘