



Week5_예습과제_김재희

1. Introduction

논문이 다루는 분야

해당 task에서 기존 연구 한계점

논문의 contributions

2. Related Work

3. 제안 방법론

Main Idea

Contribution

4. 실험 및 결과

Dataset

Baseline

결과

5. 결론 (배운점)

1. Introduction



논문에서 다루고 있는 주제가 무엇인지와 해당 주제의 필요성이 무엇인가
논문에서 제안하는 방법이 기존 방법의 문제점에 대응되도록 제안 되었는가

논문이 다루는 분야

- 이미지 분류 (Image Classification), 특히 zero-shot 이미지 분류
- 자연어를 supervision으로 쓰는 비전 표현 학습
- OCR, 영상 행동 인식, geo-localization 등 30개 이상 비전 task에 transfer

해당 task에서 기존 연구 한계점

1. 고정된 라벨 집합

- 기존 비전 모델은 미리 정해진 카테고리(예: ImageNet 1000개)를 예측하도록 학습됨
- 새로운 개념이 필요하면 추가 라벨링이 필요해서 범용성이 떨어짐

2. Weak supervision 계열(Instagram 해시태그, JFT-300M)의 타협점

- supervision을 사람이 설계한 **1000개 / 18291개 클래스**로 제한함
- 자연어가 표현할 수 있는 훨씬 넓은 시각 개념을 활용하지 못함
- **static softmax classifier**를 써서 출력을 동적으로 바꿀 수 없음 → zero-shot 능력이 심하게 제한됨

3. 자연어 supervision 계열(VirTex, ICMLM, ConVIRT 등)의 한계

- 개념 증명(proof of concept) 수준이었음
- **규모가 작았음**: 10만~20만 장 이미지, accelerator days 수준 (weak supervision 계열은 수백만~수십억 장, accelerator years)

4. 성능 격차

- 자연어 supervision 연구는 아직 드물었고, 벤치마크 성능이 다른 접근법보다 많이 낮았음
- 예: Li et al. (2017)의 ImageNet zero-shot 정확도는 **11.5%** (당시 SOTA 88.4%, 고전적 비전 기법 50%보다도 낮음)

5. 학습 효율 (Figure 2)

- 이미지 캡션을 생성하는 transformer language model 방식은 zero-shot ImageNet 학습이 느림
- bag-of-words 예측 대비 3배 느리고, CLIP의 contrastive 방식은 거기서 4배 더 효율적

논문의 contributions

1. **새 데이터셋**: 인터넷에서 수집한 **4억 개의 (이미지, 텍스트) 쌍**
2. **CLIP (Contrastive Language-Image Pre-training)**: ConVIRT를 단순화해서 처음부터 학습한 자연어 supervision의 효율적인 학습 방법
3. **확장성 검증**: 연산량이 거의 100배(2 orders of magnitude) 차이 나는 **8개 모델**을 학습했고 transfer 성능이 연산량의 **부드럽게 예측 가능한 함수임**을 확인
4. **GPT처럼 사전학습 중에 다양한 task를 학습**: OCR, geo-localization, action recognition 등

5. **30개 이상 데이터셋에서 zero-shot 평가**: 기존 task-specific supervised 모델과 경쟁 가능한 수준
6. **Linear-probe 분석으로 재확인**: 공개된 최고의 ImageNet 모델보다 성능이 좋으면서 연산 효율도 더 높음
7. **Robustness 발견**: zero-shot CLIP은 같은 정확도의 supervised ImageNet 모델보다 **distribution shift에 훨씬 강함** → task-agnostic 모델의 zero-shot 평가가 모델의 실제 능력을 더 잘 반영한다는 시사

2. Related Work



Introduction에서 언급한 기존 연구들에 대해 어떻게 서술하는가
제안 방법의 차별성을 어떻게 표현하고 있는가

갈래	대표 연구	CLIP과의 관계
자연어 supervision 전 반	topic model, word/sentence vector, LM	범위가 너무 넓은 영역이라고 먼저 인정
이미지+텍스트로 표현 학습	Joulin 2016, VirTex, ConVIRT 등	직접적인 선행 연구
텍스트-이미지 retrieval	Mori 1999 ~ 이후 joint embedding 계열	CLIP의 사전학습 과제가 사실상 retrieval
Webly supervised learning	검색 엔진으로 이미지 수집	가장 가까운 개념 중 하나
비전+언어 joint 모델	VQA, commonsense reasoning 계열	목표가 다른 계열
다른 모달리티	영상(Stroud 2020), 오디오 (Alayrac 2020)	CLIP과 함께 자연어 supervision이 유망하다는 근거

3. 제안 방법론



Introduction에서 언급된 내용과 동일하게 작성되어 있는가
Introduction에서 언급한 제안 방법이 가지는 장점에 대한 근거가 있는가
제안 방법에 대한 설명이 구현 가능하도록 작성되어 있는가

Main Idea

- 배치의 N개 (이미지, 텍스트) 쌍에서 **$N \times N$ 조합 중 진짜 짝 N개를 맞추는** contrastive 학습
- 이미지 인코더, 텍스트 인코더를 같이 학습해서 **맞는 짝의 cosine 유사도는 $\uparrow$, 틀린 $N^2 - N$ 개는 $\downarrow$**
- **symmetric cross-entropy loss** (이미지 $\rightarrow$ 텍스트, 텍스트 $\rightarrow$ 이미지 평균)
- 추론 시: 클래스 이름을 A photo of a {object}.로 텍스트 인코더에 넣고, 이미지 임베딩과 가장 가까운 걸 선택

Contribution

1. 4억 쌍 데이터셋 WIT 구축
2. 효율성 기준으로 contrastive 목적함수 선택 (Fig 2에서 근거 제시)
3. 8개 모델로 스케일링 거동 분석
4. 단순한 구조로 prompt 기반 zero-shot transfer 가능하게 함

4. 실험 및 결과



Introduction에서 언급한 제안 방법의 장점을 검증하기 위한 실험이 있는가

Dataset

용도	데이터
사전학습	WIT (4억 쌍, 자체 구축)
평가	27개 데이터셋 평가 세트 (전체적으로는 30개 이상), Kornblith et al. (2019)의 12개 데이터셋, ImageNet, STL10, Stanford Cars, GTSRB, Kinetics700 등
Robustness	ImageNet 계열 distribution shift 데이터셋들
사람 비교	Oxford IIT Pets

Baseline

비교 대상	목적
Visual N-Grams (Li et al., 2017)	이전 zero-shot 결과와 비교 (Table 1)
ResNet-50 feature 위 linear classifier	fully supervised 기준선 (Fig 5)

비교 대상	목적
Noisy Student EfficientNet-L2, BiT, ViT, SimCLRv2, BYOL, MoCo, Instagram ResNeXt 등 50개 이상	linear probe 비교 (Fig 10, 11)
이미지 캡션 Transformer LM, bag-of-words 예측	학습 효율 비교 (Fig 2)
사람	few-shot 비교 (Table 2)

결과

주장	수치
ImageNet zero-shot	Visual N-Grams 11.5% → CLIP 76.2% (Table 1)
다른 zero-shot 비교	aYahoo 72.4 → 98.4, SUN 23.0 → 58.5 (Table 1)
학습 효율	BoW 예측보다 contrastive가 4배 효율적, Transformer LM보다 BoW가 3배 효율적 (Fig 2)
zero-shot vs supervised	zero-shot CLIP이 ResNet-50 linear probe를 27개 중 16개 에서 이김 (Fig 5)
일반 객체 분류	STL10에서 99.3%로 SOTA급
Linear probe	Noisy Student EfficientNet-L2보다 27개 중 21개 에서 우수. 27개 평균 개선폭 2.6% → 5%
연산 효율	모든 CLIP 모델이 비교 시스템보다 compute efficiency 우수
Robustness	같은 ImageNet 정확도의 supervised 모델보다 훨씬 robust. ImageNet에 supervised adaptation하면 정확도 +9.2%지만 robustness는 오히려 약간 하락 (Fig 14)

5. 결론 (배운점)



연구의 의의 및 한계점, 본인이 생각하는 좋았던/아쉬웠던 점 (배운점)

- NLP의 "task-agnostic 웹 스케일 사전학습" 공식이 **비전에서도 통한다**는 걸 보임
- 고정 라벨 집합 대신 **자연어 프롬프트로 분류기를 즉석에서 만드는 패러다임**을 제시 (후속 멀티모달 연구의 기반이 됨)
- 모델 평가 관점에서도, task-agnostic 모델의 zero-shot 평가가 ImageNet 같은 단일 벤치마크보다 실제 능력을 더 잘 반영한다는 시사