BERT

1. Introduction

논문이 다루는 분야

자연어 이해(Natural Language Understanding) 분야를 다루며, 특히 대규모 unlabeled 텍스트로 언어 표현(language representation)을 사전학습(pre-training)한 뒤 이를 다양한 downstream task(문장 분류, 자연어 추론, 질의응답, 개체명 인식 등)에 전이(transfer)하는 방법에 초점을 맞춘다. Downstream task는 크게 문장 간 관계를 전체적으로 파악하는 sentence-level task(NLI, paraphrasing 등)와 토큰 단위의 세밀한 출력이 필요한 token-level task(NER, QA 등)로 나뉜다.

해당 task에서 기존 연구 한계점

- 사전학습 언어 표현을 downstream task에 적용하는 방식은 두 가지가 있다. ELMo와 같은 **feature-based** 방식은 사전학습된 표현을 task별 아키텍처에 추가 feature로 넣고, OpenAI GPT와 같은 **fine-tuning** 방식은 task-specific 파라미터를 최소화하고 사전학습된 파라미터 전체를 미세조정한다.
- 두 방식 모두 사전학습 시 **단방향(unidirectional) 언어 모델**을 목적함수로 사용한다는 공통된 한계가 있다. GPT는 left-to-right 구조라 Transformer의 self-attention에서 각 토큰이 자신보다 앞선 토큰에만 attend할 수 있다.
- ELMo는 left-to-right와 right-to-left LM을 각각 독립적으로 학습한 뒤 이어붙이는(shallow concatenation) 방식이므로, 모든 층에서 양쪽 문맥을 동시에 조건으로 삼는 진정한 deep bidirectional 표현이라고 보기 어렵다.
- 이러한 제약은 sentence-level task에서는 sub-optimal한 수준이지만, 양방향 문맥이 결정적인 질의응답 같은 token-level task에서는 매우 해로울 수 있다.
- 기존 언어 모델 목적함수로는 양방향 학습이 불가능하다. 양방향으로 조건을 주면 각 단어가 간접적으로 "자기 자신을 볼 수 있게" 되어, 다층 구조에서 예측 대상 단어를 trivial하게 맞힐 수 있기 때문이다.

논문의 contributions

- **Masked Language Model(MLM)** 사전학습 목적함수를 도입하여 deep bidirectional Transformer의 사전학습을 가능하게 하였다. 입력 토큰 일부를 무작위로 마스킹하고 문맥만으로 원래 토큰을 예측하게 함으로써 왼쪽과 오른쪽 문맥을 동시에 활용한다.
- 문장 쌍의 관계를 학습하기 위한 **Next Sentence Prediction(NSP)** 과제를 함께 사용하여 text-pair 표현을 공동으로 사전학습하였다.
- 사전학습된 표현이 heavily-engineered task-specific 아키텍처의 필요성을 줄인다는 것을 보였다. BERT는 출력층 하나만 추가해 fine-tuning하는 방식으로 sentence-level과 token-level task 모두에서 SOTA를 달성한 최초의 fine-tuning 기반 표현 모델이다.
- 11개 NLP task에서 SOTA를 달성하였으며(GLUE 80.5, MultiNLI 86.7%, SQuAD v1.1 F1 93.2, SQuAD v2.0 F1 83.1 등), 코드와 사전학습 모델을 공개하였다.

2. Related Work

논문은 general language representation의 사전학습 연구를 세 갈래로 정리한다.

첫째, **unsupervised feature-based approaches**이다. 비신경망 방식과 word2vec, GloVe 같은 신경망 기반 word embedding이 대표적이며, 이를 확장한 sentence/paragraph embedding(Skip-thought, Paragraph vector 등)도 소개한다. ELMo는 left-to-right와 right-to-left LM에서 문맥 의존적(context-sensitive) feature를 추출해 QA, 감성 분석, NER 등에서 SOTA를 달성했지만, 두 단방향 표현을 이어붙인 것일 뿐 deeply bidirectional하지 않다는 점을 지적한다. 또한 cloze task로 강건한 표현을 학습할 수 있음을 보인 연구(Fedus et al.)도 언급하며 MLM과의 연관성을 드러낸다.

둘째, **unsupervised fine-tuning approaches**이다. Dai & Le, ULMFiT, OpenAI GPT처럼 unlabeled 텍스트로 문맥 표현을 생성하는 인코더를 사전학습한 뒤 supervised downstream task에 맞게 fine-tuning하는 방식으로, 처음부터 학습해야 하는 파라미터가 적다는 장점이 있다. 특히 GPT는 GLUE의 여러 sentence-level task에서 SOTA를 달성했으나 left-to-right LM 기반이라는 한계가 있다.

셋째, **transfer learning from supervised data**이다. 자연어 추론(InferSent)이나 기계번역(CoVe)처럼 대규모 supervised 데이터에서의 효과적인 전이를 다루며, 컴퓨터 비전에서 ImageNet 사전학습 모델을 fine-tuning하는 것의 중요성도 함께 언급한다.

차별성 측면에서, 논문은 BERT와 가장 유사한 GPT와 구체적으로 비교한다(부록 A.4). BERT는 bidirectional인 반면 GPT는 left-to-right이고, 학습 데이터(BooksCorpus vs. BooksCorpus+Wikipedia), [SEP]/[CLS] 및 문장 A/B embedding의 사전학습 여부, batch 크기와 fine-tuning learning rate 등에서도 차이가 있다. 저자들은 이러한 차이의 영향을 분리하기 위해 ablation을 수행하였고, 성능 향상의 대부분이 양방향성과 두 사전학습 과제에서 비롯됨을 보임으로써 제안 방법의 차별성을 실험적으로 뒷받침한다.

3. 제안 방법론

Main Idea

BERT는 **pre-training**과 **fine-tuning** 두 단계로 구성된다. 사전학습 단계에서는 unlabeled 데이터로 여러 과제를 학습하고, fine-tuning 단계에서는 사전학습된 파라미터로 초기화한 뒤 각 downstream task의 labeled 데이터로 모든 파라미터를 미세조정한다. 서로 다른 task 간에 아키텍처 차이가 최소화되어 있다는 것이 큰 특징이다.

모델 구조: 다층 양방향 Transformer encoder를 사용한다. 층 수 L, hidden size H, self-attention head 수 A라 할 때 BERT-Base(L=12, H=768, A=12, 파라미터 110M)와 BERT-Large(L=24, H=1024, A=16, 파라미터 340M) 두 가지 크기를 제시한다. BERT-Base는 GPT와 비교하기 위해 동일한 크기로 설정하였다. Feed-forward 크기는 4H이다.

입력 표현: 단일 문장과 문장 쌍(예: ⟨Question, Answer⟩)을 하나의 토큰 시퀀스로 표현한다. 어휘 30,000개의 WordPiece embedding을 사용하며, 모든 시퀀스의 첫 토큰은 특수 토큰 [CLS]로, 이 토큰의 마지막 hidden state($C \in \mathbb{R}^H$)를 분류 task의 집계 표현으로 사용한다. 두 문장은 [SEP] 토큰으로 구분하고, 각 토큰이 문장 A와 B 중 어디에 속하는지 나타내는 learned segment embedding을 더한다. 최종 입력 표현은 **Token embedding + Segment embedding + Position embedding**의 합이다.

Pre-training Task #1 – Masked LM: 각 시퀀스에서 WordPiece 토큰의 15%를 무작위로 선택하고, 해당 위치의 마지막 hidden vector를 어휘 전체에 대한 softmax에 넣어 원래 토큰을 예측한다(cross-entropy loss). 전체 입력을 복원하는 denoising auto-encoder와 달리 마스킹된 토큰만 예측한다. Fine-tuning 시에는 [MASK] 토큰이 나타나지 않아 사전학습과 불일치가 생기므로, 선택된 토큰의 i번째 위치를 (1) 80%는 [MASK]로, (2) 10%는 무작위 토큰으로, (3) 10%는 원래 토큰 그대로 둔다. 이렇게 하면 인코더가 어떤 단어를 예측해야 하는지, 어떤 단어가 바뀌었는지 알 수 없으므로 모든 입력 토큰에 대해 분포적 문맥 표현을 유지하게 된다.

Pre-training Task #2 – Next Sentence Prediction: QA나 NLI처럼 두 문장의 관계 이해가 중요한 task를 위해, 문장 A와 B를 고를 때 50%는 실제로 A 다음에 오는 문장(IsNext), 50%는 코퍼스의 무작위 문장(NotNext)으로 구성하고, [CLS]의 출력 C로 이를 이진 분류한다. 단순한 과제이지만 QA와 NLI에 매우 유익하다고 보고한다.

Pre-training 데이터 및 설정: BooksCorpus(8억 단어)와 English Wikipedia(25억 단어, 본문 텍스트만 추출)를 사용한다. 긴 연속 시퀀스를 추출하기 위해 문장 단위로 섞인 코퍼스(Billion Word Benchmark)가 아닌 문서 단위 코퍼스를 사용하는 것이 중요하다고 강조한다. 결합 길이가 512 토큰 이하가 되도록 두 구간을 샘플링하며, batch size 256 시퀀스(128,000 토큰/batch)로 1,000,000 step(33억 단어 기준 약 40 epoch) 학습한다. Adam(lr 1e-4, β1=0.9, β2=0.999, L2 weight decay 0.01), 첫 10,000 step learning rate warmup 후 linear decay, 모든 층에 dropout 0.1, GELU 활성화 함수를 사용한다. 학습 손실은 MLM likelihood 평균과 NSP likelihood 평균의 합이다. Attention 연산이 시퀀스 길이에 대해 제곱으로 비싸기 때문에 전체 step의 90%는 길이 128로, 나머지 10%는 길이 512로 학습해 position embedding을 학습시킨다. BERT-Base는 Cloud TPU 4개(TPU 칩 16개), BERT-Large는 Cloud TPU 16개(TPU 칩 64개)로 각각 4일이 소요되었다.

Fine-tuning: Transformer의 self-attention 덕분에 단일 문장이든 문장 쌍이든 입력과 출력만 바꾸어 끼우면 된다. 기존에는 문장 쌍을 독립적으로 인코딩한 뒤 bidirectional cross attention을 적용했으나, BERT는 문장 쌍을 이어붙여 self-attention으로 인코딩하므로 두 문장 간 bidirectional cross attention이 자연스럽게 포함된다. 입력 측에서 문장 A/B는 paraphrasing의 문장 쌍, entailment의 가설-전제 쌍, QA의 질문-지문 쌍, 분류/태깅의 텍스트-∅ 쌍에 대응된다. 출력 측에서 token-level task는 각 토큰의 표현을, 분류 task는 [CLS] 표현을 출력층에 넣는다.

- 분류(GLUE): [CLS] 출력 C에 분류층 가중치 $W \in \mathbb{R}^{K \times H}$를 추가해 log(softmax(CW^T))를 손실로 사용한다.
- SQuAD v1.1: start vector S와 end vector E만 새로 학습한다. 단어 i가 정답 시작일 확률은 $S \cdot T_i$의 softmax로 계산하고(끝 위치도 동일), $j \geq i$인 후보 span 중 $S \cdot T_i + E \cdot T_j$가 최대인 것을 예측한다.
- SQuAD v2.0: 정답이 없는 질문을 [CLS] 위치에서 시작하고 끝나는 span으로 취급한다. no-answer span 점수 $s_{null} = S \cdot C + E \cdot C$와 최적 non-null span 점수를 비교해, 차이가 dev set에서 선택한 threshold τ보다 클 때만 non-null 답을 예측한다.
- SWAG: 주어진 문장과 4개의 후보 이어짐 각각을 이어붙인 4개 입력을 만들고, [CLS] 표현과 task-specific vector의 내적을 softmax로 정규화해 점수를 낸다.

Fine-tuning 하이퍼파라미터는 대부분 사전학습과 동일하며, batch size {16, 32}, learning rate(Adam) {5e-5, 3e-5, 2e-5}, epoch 수 {2, 3, 4} 범위에서 dev set으로 선택할 것을 권장한다. 모든 결과는 동일한 사전학습 모델에서 출발해 Cloud TPU 1개로 최대 1시간, GPU로 몇 시간 내에 재현할 수 있다.

Contribution

Introduction에서 언급한 "단방향 언어 모델의 한계"에 대해, MLM이라는 간단한 목적함수 변경만으로 다층 Transformer 전체가 모든 층에서 양쪽 문맥을 동시에 참조하는 deep bidirectional 표현을 학습할 수 있게 하였다. 이 장점에 대한 근거로 저자들은 ablation을 통해 동일한 데이터·fine-tuning 방식·하이퍼파라미터 조건에서 MLM을 left-to-right LM으로 바꾸면 성능이 크게 떨어지고(특히 MRPC, SQuAD), LTR 모델 위에 BiLSTM을 얹어도 MLM에 미치지 못함을 보였다. 또한 ELMo처럼 LTR과 RTL 모델을 따로 학습해 결합하는 방식은 (a) 단일 bidirectional 모델보다 비용이 두 배이고, (b) QA처럼 RTL 모델이 질문에 조건화된 답을 낼 수 없는 task에서 비직관적이며, (c) 모든 층에서 양쪽 문맥을 쓸 수 있는 deep bidirectional 모델보다 표현력이 약하다고 논리적으로 비교한다.

아키텍처 측면에서는 task-specific 구조 설계 없이 출력층 하나만 추가하는 통일된 프레임워크로 sentence-level과 token-level task를 모두 다룰 수 있음을 보였다. 아울러 마스킹 비율 전략(80/10/10), 모델 크기, feature-based 적용 가능성 등에 대한 추가 실험을 제공해 설계 선택의 근거를 뒷받침하며, 사전학습 절차와 하이퍼파라미터를 부록에 상세히 기술해 재현 가능성을 높였다.

4. 실험 및 결과

Dataset

- **GLUE**(General Language Understanding Evaluation) benchmark: MNLI(대규모 함의 분류), QQP(Quora 질문 쌍 의미 동일성), QNLI(SQuAD를 변환한 질문-문장 이진 분류), SST-2(영화 리뷰 감성 이진 분류), CoLA(문법적 수용 가능성), STS-B(문장 유사도 1~5점 회귀), MRPC(뉴스 문장 쌍 paraphrase 여부), RTE(소규모 함의 분류). WNLI는 데이터 구성 문제로 제외하였다.
- **SQuAD v1.1**: Wikipedia 지문에서 정답 span을 찾는 크라우드소싱 질의응답 데이터셋(질문-답 쌍 약 10만 개)
- **SQuAD v2.0**: SQuAD v1.1에 지문 안에 정답이 없는 질문을 추가해 더 현실적으로 확장한 데이터셋

- **SWAG**(Situations With Adversarial Generations): 상식 추론을 평가하는 11.3만 개의 문장 쌍 완성 예제로, 주어진 문장 다음에 올 가장 그럴듯한 문장을 4개 후보 중에서 고른다.
- **CoNLL-2003 NER**: feature-based 접근을 평가하기 위한 개체명 인식 데이터셋
- 사전학습 코퍼스: BooksCorpus(8억 단어), English Wikipedia(25억 단어)

Baseline

- **GLUE**: Pre-OpenAI SOTA, BiLSTM+ELMo+Attn, OpenAI GPT
- **SQuAD v1.1**: 리더보드 상위 시스템(nlnet, QANet 등), BiDAF+ELMo, R.M. Reader, 사람(Human) 성능
- **SQuAD v2.0**: 리더보드 상위 시스템(unet, SLQA+ 등), 사람 성능
- **SWAG**: ESIM+GloVe, ESIM+ELMo, OpenAI GPT, 사람 성능(전문가 및 5개 주석 기준)
- **Ablation**: BERT-Base에서 NSP 제거(No NSP), left-to-right LM으로 학습하고 NSP도 제거(LTR & No NSP), 여기에 BiLSTM 추가(+BiLSTM)
- **NER feature-based**: ELMo, CVT, CSE 등 기존 SOTA와 비교하고, BERT의 다양한 층 조합(임베딩만, 마지막 hidden, 마지막 4개 층 합/연결 등)과 fine-tuning을 비교

결과

- **GLUE**: BERT-Base와 BERT-Large 모두 모든 task에서 기존 시스템을 큰 차이로 앞섰으며, 기존 SOTA 대비 평균 정확도를 각각 4.5%p, 7.0%p 향상시켰다. 가장 큰 task인 MNLI에서는 BERT-Large가 86.7%로 GPT(82.1%) 대비 4.6%p 향상되었고, 공식 리더보드 점수는 80.5로 GPT(72.8)를 크게 앞섰다. BERT-Large는 특히 학습 데이터가 매우 적은 task에서 BERT-Base보다 유의미하게 우수했다.
- **SQuAD v1.1**: TriviaQA로 먼저 fine-tuning한 뒤 SQuAD로 fine-tuning하는 데이터 증강을 사용했을 때, BERT-Large ensemble이 test F1 93.2를 기록해 리더보드 최상위 시스템보다 F1 1.5만큼 높았다. 단일 모델도 F1 91.8로 사람 성능(F1 91.2)을 넘었으며, TriviaQA 없이도 기존 시스템보다 큰 폭으로 우수했다.
- **SQuAD v2.0**: BERT-Large 단일 모델이 test F1 83.1을 기록해 기존 최고 시스템 대비 F1 5.1만큼 향상되었다(이 실험에서는 TriviaQA를 사용하지 않음).
- **SWAG**: BERT-Large는 test 정확도 86.3%로 ESIM+ELMo 대비 27.1%p, OpenAI GPT 대비 8.3%p 높았다.
- **사전학습 과제 ablation**(BERT-Base, dev set): NSP를 제거하면 QNLI(88.4→84.9), MNLI, SQuAD 성능이 하락해 NSP가 문장 관계 task에 유익함을 확인하였다. LTR & No NSP 모델은 No NSP 모델보다 모든 task에서 더 낮았고, 특히 MRPC(86.5→77.5)와 SQuAD(87.9→77.8)에서 크게 하락하였다. 토큰 수준 예측에서 오른쪽 문맥이 없기 때문이다. LTR 모델 위에 무작위 초기화한 BiLSTM을 얹으면 SQuAD는 개선되었지만(84.9) 여전히 bidirectional 모델보다 크게 낮았고 GLUE task에서는 오히려 성능이 떨어졌다.
- **모델 크기 ablation**: 층 수, hidden 크기, attention head 수를 늘릴수록 4개 GLUE task 모두에서 정확도가 일관되게 향상되었다. 학습 예제가 3,600개뿐인 MRPC에서도 마찬가지였다. 기계번역처럼 대규모 task에서 모델 크기를 늘리면 성능이 좋아진다는 것은 알려져 있었지만, 충분히 사전학습했다면 극단적으로 큰 모델이 매우 작은 task에서도 큰 이득을 준다는 것을 처음으로 설득력 있게 보였다고 주장한다.
- **Feature-based 접근(CoNLL-2003 NER)**: fine-tuning 없이 사전학습된 BERT의 마지막 4개 hidden layer를 연결(concat)해 2층 BiLSTM의 입력 feature로 사용했을 때 dev F1 96.1을 기록하였다. 이는 전체 모델을 fine-tuning한 경우(96.4)와 0.3 차이에 불과하여, BERT가 fine-tuning과 feature-based 접근 모두에 효과적임을 보였다.
- **마스킹 전략 ablation**(부록 C.2): 80/10/10 전략이 전반적으로 가장 좋았다. 특히 feature-based NER에서는 [MASK]만 사용하면 성능이 떨어져 사전학습과 fine-tuning의 불일치 문제가 실재함을 확인하였다. 반대로 무작위 토큰 치환만 사용하는 전략도 성능이 낮았다.
- **학습 step 수 ablation**(부록 C.1): BERT-Base를 1M step 학습하면 500k step보다 MNLI에서 약 1.0% 높아, 대규모 사전학습이 실제로 필요함을 보였다. MLM은 매 batch에서 15%의 토큰만 예측하므로 LTR보다 수렴은 다소 느리지만, 정확도는 학습 초기부터 LTR을 앞섰다.

5. 결론(배운점)

이 연구의 의의는 "Masked Language Model"이라는 단순한 목적함수 변경만으로 deep bidirectional Transformer의 사전학습을 가능하게 했고, 출력층 하나만 추가하는 통일된 fine-tuning 프레임워크로 문장 분류부터 질의응답, 개체명 인식까지 폭넓은 NLP task에서 SOTA를 달성했다는 데 있다. 이로써 "대규모 사전학습 후 fine-tuning"이 NLP의 표준 패러다임으로 자리 잡았고, 컴퓨터 비전의 ImageNet 사전학습처럼 NLP에서도 범용 사전학습 모델을 가져다 쓰는 시대를 열었다. RoBERTa, ALBERT, ELECTRA, SpanBERT, DistilBERT 등 수많은 후속 연구의 출발점이 되었다는 점에서도 파급력이 매우 크다.

한계점으로는 첫째, [MASK] 토큰이 fine-tuning 시에는 등장하지 않아 사전학습과 fine-tuning 사이의 불일치가 완전히 해소되지 않았다는 점이 있다(80/10/10 전략은 이를 완화할 뿐이다). 둘째, 매 시퀀스에서 15%의 토큰만 학습 신호로 사용하므로 데이터 효율이 낮고 사전학습 비용이 매우 크다. 셋째, 마스킹된 토큰들을 서로 독립적으로 예측한다고 가정하므로 마스킹된 토큰 간의 의존성을 모델링하지 못한다. 넷째, encoder-only 구조여서 텍스트 생성 task에는 적합하지 않고, 최대 입력 길이가 512 토큰으로 제한된다. 또한 NSP의 효과는 이후 RoBERTa 등에서 오히려 불필요하거나 해롭다는 결과가 나와, 본 논문의 NSP ablation 결론은 실험 설정에 따라 달라질 수 있음을 보여준다.

배운 점으로는, 언어 모델의 "단방향" 제약이 모델 구조가 아니라 목적함수에서 비롯된다는 점을 짚어내고, 이를 cloze task라는 오래된 아이디어로 풀어낸 문제 정의와 해결 방식이 인상 깊었다. 또한 GPT와 크기를 맞춘 BERT-Base를 별도로 설계해 공정하게 비교하고, NSP·LTR·BiLSTM·모델 크기·마스킹 비율·학습 step 수 등 설계 선택 하나하나를 ablation으로 검증한 실험 설계가 설득력을 크게 높였다고 생각한다. 아쉬운 점은 80/10/10 비율 같은 핵심 하이퍼파라미터가 체계적인 탐색보다는 경험적으로 정해진 측면이 있고, 사전학습 과제의 기여(특히 NSP)를 데이터 양이나 시퀀스 길이 같은 다른 요인과 완

전히 분리해 검증하지는 못했다는 점이다. 그럼에도 단순한 아이디어와 대규모 사전학습, 철저한 실험의 조합이 분야 전체의 패러다임을 바꿀 수 있음을 보여준 대표적인 연구라고 생각한다.

LMReason (Introduction 리뷰)

> **논문**: Language Models Can Easily Learn to Reason from Demonstrations **저자**: Dacheng Li, Shiyi Cao, Tyler Griggs, Shu Liu 외 (UC Berkeley, Anyscale) **학회**: Findings of EMNLP 2025 **리뷰 범위**: Abstract와 1. Introduction (Figure 1, 2 포함)

---

1. 연구 배경

최근 OpenAI o1, DeepSeek-R1, Qwen QwQ와 같은 대형 추론 모델(Large Reasoning Models, LRMs)은 **Long Chain-of-Thought(Long CoT)**를 통해 어려운 추론 문제를 해결한다. Long CoT는 단순히 풀이 단계를 길게 나열하는 것이 아니라, 중간에 자신의 사고를 돌아보는 **reflection**, 막다른 길에서 되돌아가는 **backtracking**, 중간 결과를 스스로 검증하는 **self-validation**을 포함한다는 점에서 기존의 Short CoT와 구별된다.

2. 문제 제기

저자들은 LLM이 Long CoT를 생성하도록 학습시키는 방법이 여전히 **열린 문제(open problem)**라고 지적한다. 근거는 다음 두 가지다.

- **비공개**: o1, QwQ 등은 학습 방법이 공개되지 않았다.
- **높은 재현 비용**: DeepSeek-R1은 방법이 공개되었지만 대규모 강화학습(RL)을 사용하므로 재현 비용이 매우 크다.

즉, "Long CoT를 이끌어내기 위해 어떤 학습 기법과 얼마만큼의 데이터가 필요한가"가 제대로 이해되지 않았다는 것이 이 논문의 출발점이다 (Abstract: *"the training techniques and data requirements to elicit Long CoT remain poorly understood"*).

3. 논문의 핵심 주장

Introduction은 크게 두 가지 주장을 순서대로 제시한다.

(1) Long CoT 학습은 데이터와 파라미터 측면에서 모두 효율적이다

- DeepSeek-R1이 생성한 **17k개 샘플**만으로 Qwen2.5-32B-Instruct를 full SFT하면, 다양한 수학과 코딩 과제에서 OpenAI o1-preview와 견줄 만한 성능을 얻는다.
  - Math-500 90.8% (+6.0), AIME 2024 56.7% (+40.0), AMC 2023 85.0% (+17.5), OlympiadBench 60.3% (+12.7), LiveCodeBench 57.0% (+8.1)
- **LoRA로 전체 파라미터의 5% 미만만 업데이트**해도 o1-preview 수준에 도달한다.
- 학습된 모델은 "Alternatively", "Wait, but" 같은 키워드를 쓰며 중간 사고를 되돌아보고 수정하는 길고 일관된 CoT를 생성하게 된다(Figure 1).

(2) 학습에 결정적인 것은 내용이 아니라 Long CoT의 구조다

저자들은 증류 데이터의 핵심 특성이 **Long CoT structure**라고 주장하며, 이를 두 종류의 통제 실험으로 뒷받침한다.

구분	변형 방법	결과
내용(content) 변형	숫자를 무작위로 바꾸기, 추론 키워드 삭제	성능에 거의 영향 없음. 숫자 50%를 바꿔도 AIME 2024에서 정확도가 3.3%p만 하락
구조(structure) 변형	응답을 추론 단계로 나눈 뒤 shuffle, insert, delete	성능이 크게 하락. 단계 67%를 섞으면 AIME 2024에서 13.3%p 하락

Figure 2는 이 대비를 한눈에 보여준다. 변형 비율이 높아질수록 구조를 변형한 데이터로 학습한 모델의 성능이 크게 떨어지는 반면, 내용을 변형한 경우에는 올바른 샘플로 학습한 모델(66.3%)에 가까운 성능이 유지된다.

4. Contributions

저자들이 명시한 기여는 다음 세 가지다.

1. LLM이 Long CoT 추론을 **데이터와 파라미터 측면에서 효율적으로** 학습할 수 있음을 보였다. 17k개 샘플 또는 5% 미만의 파라미터 업데이트만으로 Qwen2.5-32B-Instruct를 o1-preview 수준으로 끌어올렸다.
2. 학습에 중요한 것은 개별 추론 단계의 **내용이 아니라 Long CoT의 구조**임을 밝혔다. 이를 구조와 내용을 각각 변형하는 두 그룹의 통제 실험으로 검증하였다.
3. 모델 크기와 아키텍처, 데이터셋 크기, teacher 모델(DeepSeek-R1, QwQ-32B-Preview)에 걸친 **포괄적인 ablation**을 5개 수학·코딩 벤치마크에서 수행하였다.

5. Introduction 서술에 대한 평가

좋았던 점

- **문제 정의가 간결하다.** "Long CoT는 강력하지만 학습 방법이 비공개이거나 비싸다"라는 두 문장으로 연구의 필요성을 분명히 제시한다.
- **주장과 근거가 바로 연결된다.** 각 주장에 구체적인 수치(벤치마크별 성능 향상, 변형 비율별 하락폭)가 함께 제시되어 Introduction만 읽어도 핵심 결과를 파악할 수 있다.
- **Figure 1, 2를 잘 활용한다.** Figure 1은 "효율적으로 학습된다"는 첫 번째 주장을, Figure 2는 "구조가 핵심이다"는 두 번째 주장을 각각 시각적으로 뒷받침해 Introduction의 두 축과 정확히 대응된다.
- **직관에 반하는 발견을 앞세운다.** "숫자를 50% 바꿔도 성능이 거의 유지된다"는 결과는 독자의 흥미를 끌고, 이 논문이 단순히 재현 보고서가 아니라 분석적 기여가 있음을 드러낸다.

아쉬운 점

- **"왜 구조가 중요한가"에 대한 가설이 없다.** 구조가 중요하다는 관찰은 제시하지만, 그 이유(예: 모델이 사고 흐름의 패턴을 배운다는 해석)는 본문 4.1절에 가서야 짧게 언급된다. Introduction에서 동기나 가설을 조금 더 제시했다면 논지가 더 설득력 있었을 것이다.
- **"content"와 "structure"의 정의가 모호하다.** Introduction만 읽어서는 무엇이 내용이고 무엇이 구조인지 경계가 명확하지 않다. 예를 들어 추론 키워드("Wait" 등)는 reflection이라는 구조를 드러내는 신호로도 볼 수 있는데, 이를 내용 변형으로 분류한 이유가 설명되지 않는다.
- **수치 비교의 신뢰도에 대한 언급이 없다.** AIME 2024는 30문제로 구성되어 3.3%p가 1문제에 해당한다. 내용 변형 시의 소폭 하락이 실제 차이인지 노이즈인지 판단하려면 반복 실험 여부가 중요한데, Introduction에서는 이에 대한 언급 없이 단일 수치만 제시한다(본문에서 single run임을 밝힌다).
- **"Easily"라는 제목 표현이 다소 강하다.** 학습이 쉬운 것은 강력한 teacher(R1)가 고품질 trace를 이미 생성해 주었기 때문이며, 그 teacher를 만드는 데 든 막대한 RL 비용은 전제되어 있다. 또한 Ablation(5.3절)에서 student 모델에 따라 효과가 크게 다르다는 점이 드러나는데, Introduction에서는 Qwen2.5-32B-Instruct의 결과만 강조되어 일반화 가능성이 다소 과장되어 보인다.
- **동시기 연구와의 차별점이 Introduction에 없다.** s1, LIMO, STILL-2 등 비슷한 시기에 "적은 데이터로 추론 능력 증류"를 다룬 연구가 여럿 있는데, 이들과의 차이(파라미터 효율성, 구조 분석)는 Related Work에 가서야 언급된다.

6. 정리 및 생각해 볼 질문

Introduction은 **"Long CoT는 쉽게 배울 수 있고, 그 핵심은 구조다"**라는 메시지를 명확한 수치와 그림으로 효과적으로 전달한다. 특히 내용과 구조를 분리한 통제 실험이라는 아이디어가 이 논문을 단순한 증류 재현 연구와 구분 짓는 핵심이다. 다만 "왜 구조가 중요한가"에 대한 설명과 결과의 일반화 범위에 대해서는 본문을 읽으며 비판적으로 확인할 필요가 있다.

- 오답 trace로 학습해도 성능이 오른다면, 증류 데이터를 만들 때 정답 필터링(rejection sampling)은 꼭 필요할까?
- LoRA만으로 Long CoT를 배울 수 있다는 결과는 "능력은 사전학습에서 이미 형성되고, fine-tuning은 출력 형식만 바꾼다"는 Superficial Alignment Hypothesis(LIMA)와 어떻게 연결될까?
- 추론 키워드를 모두 지워도 성능이 유지된다면, 모델은 키워드가 아닌 무엇을 통해 reflection과 backtracking의 구조를 학습하는 것일까?