7주차

1. Language Models Can Easily Learn to Reason from Demonstrations (Dacheng Li et al.)

1. Introduction

> 💡 논문에서 다루고 있는 주제가 무엇인지와 해당 주제의 필요성이 무엇인가
> 논문에서 제안하는 방법이 기존 방법의 문제점에 대응되도록 제안 되었는가

논문이 다루는 분야

- Large Language Models(LLMs)의 reasoning 능력 학습
- Long Chain-of-Thought(Long CoT) 생성
- Reasoning distillation
- Supervised Fine-Tuning(SFT) 및 Low-Rank Adaptation(LoRA)
- 수학·코딩 문제 해결

해당 task에서 기존 연구 한계점

- OpenAI o1, DeepSeek-R1과 같은 reasoning model의 학습 과정이 대부분 공개되지 않음.
- Reinforcement Learning(RL) 기반 학습은 높은 계산 비용과 복잡한 학습 절차가 필요함.
- Long CoT reasoning을 학습하기 위해 어느 정도의 데이터와 parameter update가 필요한지 명확하지 않음.
- 기존 distillation 연구는 reasoning 능력보다 일반적인 응답 스타일이나 지식 전달에 초점을 둠.
- Long CoT에서 개별 reasoning step의 내용과 전체 reasoning 구조 중 어떤 요소가 중요한지 밝혀지지 않음.

논문의 contributions

- 17k개 이하의 Long CoT 데이터만으로 LLM의 reasoning 능력을 향상할 수 있음을 보임.
- 전체 parameter의 5% 미만만 업데이트하는 LoRA로도 효과적인 reasoning distillation이 가능함을 보임.
- Long CoT의 개별 내용보다 reflection, backtracking, self-validation이 포함된 전체 구조가 더 중요하다는 점을 확인함.
- 일부 reasoning 내용이 틀리거나 숫자가 손상되어도 성능 저하가 크지 않음을 보임.
- 반대로 reasoning step의 순서가 섞이거나 삭제·삽입되어 논리적 연결성이 깨지면 성능이 크게 하락함.

→ 기존 연구의 "비용이 크고 학습 과정이 불명확하다"는 문제에 대해, 적은 데이터와 parameter-efficient fine-tuning으로 Long CoT를 학습할 수 있다는 방법으로 대응

2. Related Work



Introduction에서 언급한 기존 연구들에 대해 어떻게 서술하는가
제안 방법의 차별성을 어떻게 표현하고 있는가

1) Test-Time Scaling

- 하나의 긴 reasoning 과정을 생성하는 방식
  - OpenAI o1
  - DeepSeek-R1
  - QwQ
- 여러 개의 답변을 생성하고 가장 좋은 답을 선택하는 방식
  - Best-of-N
  - Search-guided generation
  - Monte Carlo Tree Search(MCTS)

2) Reasoning 능력 향상 방법

- Iterative self-improvement
- Reinforcement Learning
- Reinforcement Learning with Verifiable Rewards(RLVR)

- DeepSeek-R1과 같은 pure RL 기반 reasoning model

3) Knowledge 및 Response Distillation

- Teacher model의 출력이나 logits를 이용해 Student model을 학습하는 방법
- 기존에는 주로 대화 능력이나 일반적인 지식 전달에 사용됨.
- 본 논문은 이를 Long CoT reasoning 능력의 distillation에 적용함.

제안 방법의 차별성

- RL을 통해 reasoning을 새롭게 발견하기보다, 기존 reasoning model의 출력에서 Long CoT 구조를 distill함.
- 기존 연구보다 적은 데이터와 적은 parameter update만 사용함.
- 단순히 정답이 포함된 데이터를 학습하는 것이 아니라, reasoning 과정의 구조적 특징을 분석함.
- Long CoT의 핵심이 reasoning keyword 자체가 아니라 step 간 논리적 연결성이라고 주장함.

3. 제안 방법론



Introduction에서 언급된 내용과 동일하게 작성되어 있는가
Introduction에서 언급한 제안 방법이 가지는 장점에 대한 근거가 있는가
제안 방법에 대한 설명이 구현 가능하도록 작성되어 있는가

Main Idea

- Reasoning model인 DeepSeek-R1 또는 QwQ-32B-Preview로 Long CoT 데이터를 생성함.
- 수학 및 코딩 문제 중 난도가 높은 문제를 선별함.
- 정답 여부를 exact matching 또는 code execution으로 검증함.
- Student model인 Qwen2.5-32B-Instruct에 SFT 또는 LoRA를 적용함.
- Long CoT의 내용과 구조를 변형해 어떤 요소가 reasoning 학습에 중요한지 분석함.

Contribution

- Long CoT의 성능 향상이 정확한 세부 내용의 암기 때문만은 아님을 보임.

- 개별 reasoning step의 오류에는 비교적 강하지만, 전체 reasoning 과정의 논리적 구조가 무너지면 성능이 크게 저하됨.

정확한 개별 문장이나 숫자 → Reflection, backtracking, self-validation이 연결된 전체 reasoning 구조

4. 실험 및 결과

> 💡 Introduction에서 언급한 제안 방법의 장점을 검증하기 위한 실험이 있는가

Dataset

- Math-500
- AIME 2024
- AMC 2023
- OlympiadBench
- LiveCodeBench
- 비추론 과제:
  - MMLU
  - ARC-C
  - Instruction-following Evaluation
  - MGSM

Baseline

- Qwen2.5-32B-Instruct
- QwQ
- OpenAI o1-preview
- DeepSeek-R1
- Short CoT fine-tuning
- Best-of-N sampling
- 다양한 Student model:

- Qwen2.5-7B-Math
- Qwen2.5-7B-Base
- Llama-3.1-8B
- Qwen2.5-14B-Base
- Qwen2.5-14B-Instruct
- Gemma2-27B-it
- Qwen2.5-32B-Instruct

결과

1) 적은 데이터로 reasoning 능력 향상

Qwen2.5-32B-Instruct에 17k개의 DeepSeek-R1 Long CoT sample을 학습한 결과:

- Math-500: 90.8%
- AIME 2024: 56.7%
- AMC 2023: 85.0%
- OlympiadBench: 60.3%
- LiveCodeBench: 57.0%
- OpenAI o1-preview와 비슷한 수준의 성능을 달성함.
- 7k개의 QwQ sample과 LoRA만 사용해도 17k sample full SFT와 비슷한 성능을 보임.

2) Long CoT 구조의 중요성

- 틀린 최종 답을 포함한 데이터로 학습해도 평균 정확도 63.1% 달성
- 숫자의 70%를 무작위로 변경해도 평균 정확도 약 62% 유지
- Reasoning keyword를 모두 제거해도 성능은 약 63% 유지
- 반면 reasoning step을 삭제·삽입·셔플하면 성능이 크게 하락
- Reasoning step 67%를 셔플한 경우 AIME 2024에서 올바른 데이터로 학습한 모델보다 정확도가 13.3% 하락

→ 단순히 긴 답변을 생성하거나 “Wait”, “Alternatively” 같은 표현을 사용하는 것만으로는 충분하지 않음. Step 간 논리적 연결성이 핵심임.

3) 데이터 크기 효과

- 4k부터 64k까지 데이터 양을 증가시킴.
- 16k sample만으로도 평균 성능이 54.2%에서 69.4%로 상승함.
- 데이터가 증가할수록 성능은 계속 향상되지만, 적은 양의 데이터만으로도 큰 폭의 개선이 가능함.

4) 일반 능력 보존

- Long CoT fine-tuning 후 MMLU, ARC-C, instruction-following, MGSM 성능이 크게 붕괴하지 않음.
- QwQ 자체는 instruction-following 및 multilingual task에서 성능 저하가 있었지만, distillation 모델은 기존 Qwen의 일반 능력을 대부분 유지함.

5) Best-of-N과 비교

- Long CoT fine-tuning 모델은 base model의 Best-of-2~16 sampling과 비슷한 성능을 보임.
- 여러 답변을 생성하지 않고도 fine-tuning을 통해 test-time reasoning 성능을 일부 내재화할 수 있음을 보임.

6) Short CoT와 비교

- Long CoT fine-tuning 모델은 Short CoT fine-tuning보다 높은 성능을 보임.
- 어려운 문제일수록 더 긴 reasoning trace와 더 많은 reflection·backtracking을 생성함.

5. 결론 (배운점)

> 💡 연구의 의의 및 한계점, 본인이 생각하는 좋았던/아쉬웠던 점 (배운점)

연구의 의의

- LLM의 reasoning 능력이 반드시 대규모 RL이나 막대한 데이터에만 의존하지 않는다는 점을 보임.
- Long CoT reasoning을 비교적 적은 데이터와 LoRA로 학습할 수 있음을 확인함.

- Reasoning 능력의 핵심이 정확한 문장이나 keyword보다 전체 reasoning 구조와 논리적 연결성에 있음을 제시함.
- 이후 reasoning dataset을 구축할 때 단순히 정답이 있는 풀이를 모으는 것보다 reflection, 오류 수정, backtracking이 포함된 과정을 확보하는 것이 중요함을 보여줌.

한계점

- SFT만 다루고 RL 기반 reasoning 학습과 직접 비교하지 않음.
- 7k~17k 중심의 소규모 데이터 실험이므로 대규모 distillation에서도 동일한 결과가 나타나는지는 불확실함.
- 수학·코딩 benchmark 중심이라 일반적인 reasoning task로의 확장 가능성은 제한적임.
- 일부 구조 변형 과정이 다른 LLM의 자동 분류에 의존함.
- 대부분의 실험이 single run으로 수행되어 통계적 유의성이나 재현성 검증이 부족함.
- Teacher model의 reasoning 스타일을 학습하는 것이 실제 reasoning 능력의 습득인지, 특정 형식의 모방인지 완전히 분리하지 못함.

2. BERT: Pre-training of Deep Bidirectional Transformers for Language Understanding

1. Introduction



논문에서 다루고 있는 주제가 무엇인지와 해당 주제의 필요성이 무엇인가
논문에서 제안하는 방법이 기존 방법의 문제점에 대응되도록 제안 되었는가

논문이 다루는 분야

- Natural Language Processing(NLP)
- Language model pre-training
- Transfer learning

- Sentence-level 및 token-level language understanding
- 대표 downstream task:
  - Natural Language Inference
  - Paraphrasing
  - Named Entity Recognition
  - Question Answering

해당 task에서 기존 연구 한계점

- 기존의 대표적인 사전학습 언어 모델은 주로 **unidirectional language model**을 사용함.
- OpenAI GPT와 같은 left-to-right 방식에서는 각 token이 이전 token만 참고할 수 있음.
- 이러한 구조는 문장 전체의 의미를 파악해야 하는 sentence-level task에 적합하지 않을 수 있음.
- 특히 Question Answering이나 Named Entity Recognition처럼 token-level의 세밀한 문맥 이해가 필요한 task에서는 양방향 정보를 활용하지 못하는 한계가 있음.
- ELMo는 left-to-right와 right-to-left 표현을 결합하지만, 두 방향의 표현을 독립적으로 학습하므로 deep bidirectional representation을 충분히 형성하지 못함.
- 기존의 feature-based 방식은 downstream task마다 별도의 task-specific architecture를 설계해야 함.
- 따라서 다양한 NLP task에 공통으로 적용할 수 있으면서, 양쪽 문맥을 동시에 활용하는 사전학습 방법이 필요함.

논문의 contributions

- 양방향 문맥을 동시에 활용하는 BERT를 제안함.
- Masked Language Model(MLM)을 통해 문장 내 일부 token을 가리고, 양쪽 문맥을 활용해 원래 token을 예측하도록 학습함.
- Next Sentence Prediction(NSP)을 추가하여 두 문장 사이의 관계도 함께 학습함.
- 별도의 복잡한 task-specific architecture를 크게 설계하지 않고, 사전학습된 BERT에 output layer만 추가해 여러 task에 적용함.
- Sentence-level과 token-level task 모두에서 높은 성능을 달성함.

- GLUE, MultiNLI, SQuAD 등 11개 NLP task에서 당시 state-of-the-art 성능을 기록함.
- 코드와 pretrained model을 공개하여 재현 및 활용 가능성을 높임.