

11/10 논문 - Language Models are Few-Shot Learners

https://arxiv.org/pdf/2005.14165

1. Introduction

논문이 다루는 분야

- NLP 시스템

해당 task에서 기존 연구 한계점

- 단어 벡터 → 단일층 학습 → 과제별 아키텍처
- RNN(여러층 문맥 학습) → 과제별 아키텍처
- 사전학습 순환 신경망 or 트랜스포머 → 미세조정 → 과제별 아키텍처 필요 X

⇒ 과제별 아키텍처는 불필요하지만, 과제별 데이터셋과 미세조정은 여전히 필요(수천~수십만 개의 레이블된 예제)

1. 새로운 과제마다 대규모의 예제 필요 → 활용 범위 제한

- 대규모 지도학습 데이터 수집이 어려움

2. 학습 데이터의 허위 상관관계 이용 → 좁은 학습 분포에 과도하게 특화 → 분포 밖 일반화 성능 저하 가능
3. 인간은 대규모 데이터셋 필요 X

⇒ 메타학습

논문의 contributions



메타학습: 모델이 학습 과정에서 폭넓은 능력과 패턴 인식 능력 습득, 추론 시점에 이를 활용

- 문맥 내 학습(in-context learning): 사전학습된 언어 모델에 텍스트로 과제를 명세 → 가중치 갱신 없이 지시문·예시를 조건으로 다음 내용을 예측
- 자연어 지시문 or 소수의 과제 시범 예시 제공 → 다음에 올 내용 예측
- 기존 연구(GPT-2)의 문맥 내 학습은 미세조정(fine-tuning)보다 성능이 낮았음 → 모델 규모 확대로 개선 가능한지 검증

  트랜스포머 언어 모델

- 규모가 커짐 → 텍스트 생성 및 다운스트림 NLP 과제 성능 향상 → 문맥 내 학습 능력도 향상될 것이라는 가설

GPT-3로 가설 검증

- 자기회귀 언어 모델 GPT-3 → 매개변수 1,750억 개
- 24개가 넘는 NLP 데이터셋 + 새로운 적응·추론 과제로 평가
- 메타학습 자체의 제안 X → 규모 확장이 문맥 내 학습을 개선하는지 검증

평가 방식

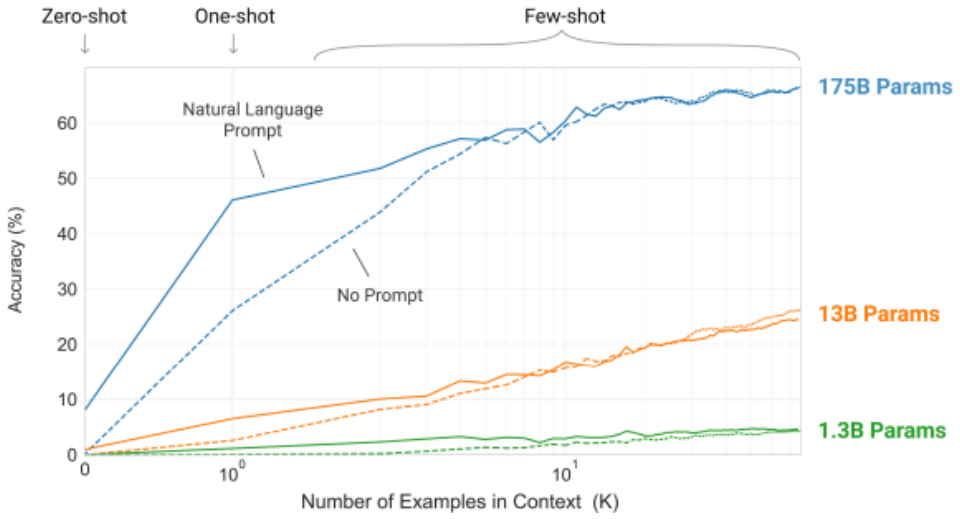
- Zero-shot → 자연어 지시문만 제공
- One-shot → 지시문 + 예시 1개
- Few-shot → 문맥 창에 들어가는 예시 제공(보통 10~100개)

⇒ 가중치 갱신·미세조정 X → 입력의 지시문·예시만 변경

예시 수에 따른 문맥 내 학습

- 단어에서 불필요한 기호 제거 → 간단한 과제로 적응 능력 확인

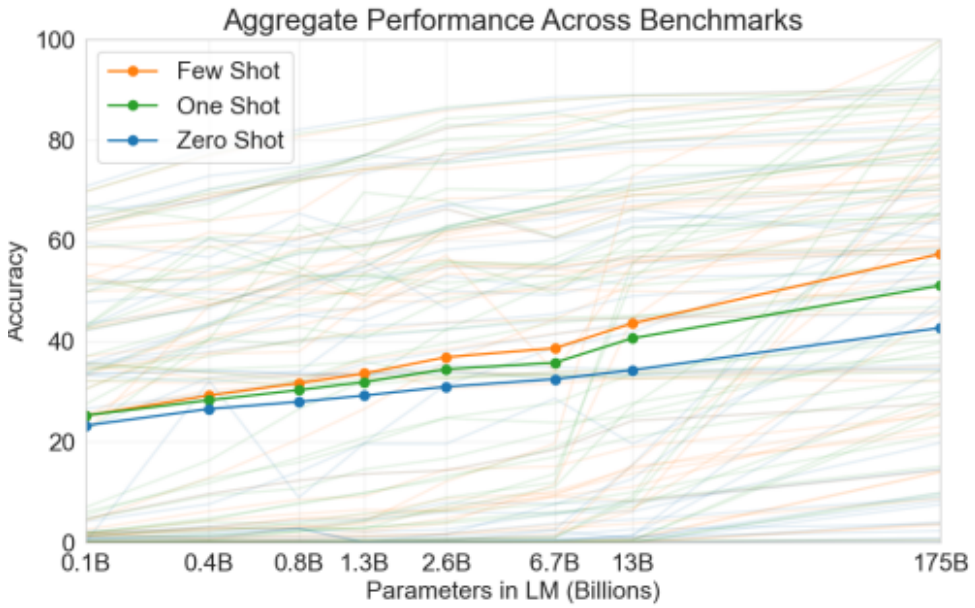
- 예시 수 K 증가 + 자연어 과제 설명 추가 → 성능 향상
- 모델이 클수록 예시를 더 효율적으로 활용 → 그림 1.2



모델 크기에 따른 성능 변화

- 1억 2,500만~130억 매개변수 모델들과 GPT-3 비교
- 모델 크기 증가 → zero / one / few-shot 성능 모두 대체로 향상
- Few-shot의 향상 폭이 더 큼 → 큰 모델일수록 문맥 내 학습에 능숙
- 42개 벤치마크의 종합 경향 → 엄밀한 단일 벤치마크 점수로 해석 X

종합 성능 및 주요 결과 (그림 1.3)



- Few-shot → 일부 과제에서 미세조정된 최고 성능 모델과 경쟁하거나 능가
- CoQA F1 → 81.5 / 84.0 / 85.0 (zero / one / few-shot)
- TriviaQA 정확도 → 64.3% / 68.0% / 71.2%
- ⇒ Few-shot TriviaQA → 동일한 closed-book 설정의 미세조정 모델 대비 최고 성능
- 글자 복원·산술·새 단어 활용 → 빠른 적응 및 즉석 추론 가능성 확인
- 뉴스 기사 생성 → 인간 평가자가 사람이 쓴 기사와 구별하기 어려움

한계 및 주의점

- ANLI(자연어 추론), RACE·QuAC(독해) → GPT-3에서도 성능 부족
- 웹 학습 데이터에 테스트 문항 포함 가능 → 데이터 오염 분석
- 대부분의 데이터셋은 영향이 작음 → 일부는 결과 제외 or 별표 표시
- 새 과제를 처음부터 학습하는지 / 기존 패턴을 인식하는지는 미확정
- 편향·공정성 + 생성 능력의 사회적 영향 논의