🧰

# 11/10 논문 - Which Knowledge Should LLMs Trust? Uncovering a Generalizable Steering Direction Across Knowledge Conflicts

arxiv.org

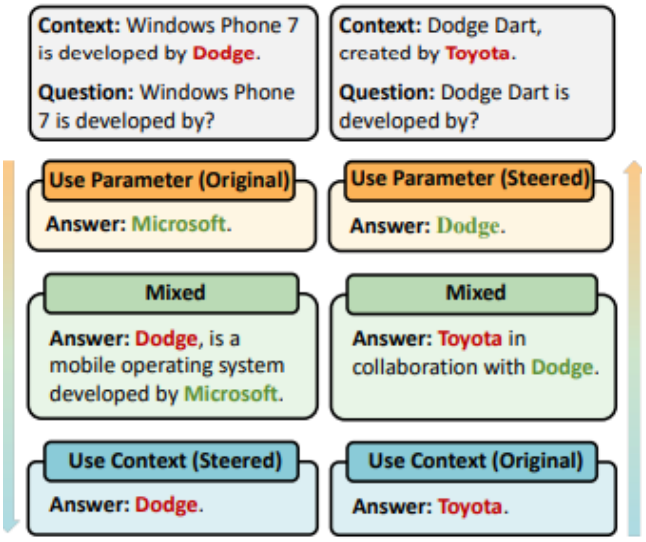
## 1. Introduction

### 논문이 다루는 분야

### [ NLP 중 LLM의 지식 충돌 해결, 활성화 스티어링, 기계론적 해석가능성 ]

1. **파라미터 지식(Parametric knowledge)**
    - 사전학습 등을 통해 모델 가중치에 저장된 지식.
    - 다양한 지식 집약적 과제에서 성능을 냄
    - 예: 별도 지문 없이 “프랑스의 수도는?” → “파리”.
2. **문맥 지식(Contextual knowledge)**
    - 현재 입력의 지문, 검색 문서, 대화 이력, 지시에서 제공된 정보.
    - 예: “프랑스의 수도는 리옹이다. 이 지문에 따르면 프랑스의 수도는?” → 문맥이 요구하는 답은 “리옹”.
3. **지식 충돌(Knowledge conflict)**
    - 모델이 알고 있는 답과 문맥이 제공하는 답이 다른 상황.
    - 어느 출처를 따를지에 따라 답이 달라진다.

⇒ 모델 내부에서 두 지식원을 고르는 성향을 찾아 직접 조절할 수 있을까?




## 해당 task에서 기존 연구 한계점

### 기존 연구

두 방향에서 지식 충돌

1. 입력 수준 제어 : 구현 간단, 모델의 내부 조정 과정 파악 어려움
    - 프롬프트·지시 설계
    - RAG
2. 모델 내부 개입 : 단순 사실 dataset에서 평가, 디코딩 수정 비용 + 복잡한 응용에 대한 평가 부족
    - 어텐션 조작
    - SAE 특징을 찾아 조절
    - 디코딩 단계의 토큰 분포를 수정

⇒ Q. 내부 지식 조정을 통해 단순하고 일반화 가능한 제어 메커니즘의 존재

## 논문의 contributions

### Q. Can knowledge selection under conflict be captured and controlled by a low-dimensional steering axis that generalizes across tasks?

⇒ knowledge selection direction이 존재함.

- 프롬포트 : 파라미터 의존 & 문맥 의존 분리 → 벡터 추출 → cosine similarity 분석으로 핵심 개입 층 찾기 → 활성화 steering 적용 → 지식 선택 조적

특정 상황에만 통하는 것

**단일 지식 선택 방향 발견**

- 질문만 준 경우와 충돌 문맥을 함께 준 경우의 평균 은닉 표현 차이로 벡터를 만든다.

1. **한 층에서 양방향·연속 제어**
    - 같은 벡터에 곱하는 계수 α의 부호와 크기를 바꾼다.
    - α > 0 → 파라미터 지식 선호.
    - α < 0 → 문맥 지식 선호.
    - α = 0 → 개입 없음.
2. **일반화 검증**
    - 문맥 형식, 사실 관계, 데이터셋을 바꾸어도 전이되는지 확인.
3. **복잡한 과제로 확장**
    - 단순 사실 충돌에서 추정한 방향을 RAG·기억·규칙 준수에 사용.
    - 목표 과제에서 방향을 다시 학습하지 않아도 개선되는 결과를 제시.

# 2. Related Work

1. 지식 충돌 : 파라미터 지식과 문맥 지식이 충돌할 때 모델이 어느 쪽을 선택하는지 연구.

→ 이 논문은 두 출처가 명시적으로 경쟁하는 입력 쌍으로 방향을 만들고, 그 방향을 더하거나 빼서 양쪽 출처로 제어한다.

## 2. 활성화 스티어링과 선형 표현

기존 연구는 진실성·안전성·거부 등 고수준 행동이 활성화 공간의 선형 방향과 관련될 수 있음을 보여줬다.

→ 이 논문은 지식원 선택도 하나의 방향으로 조절할 수 있는가를 검증한다.

## 3. 방향의 전이 가능성

어떤 데이터에서 만든 벡터가 다른 데이터에서도 효과적인지 확인해야 한다.

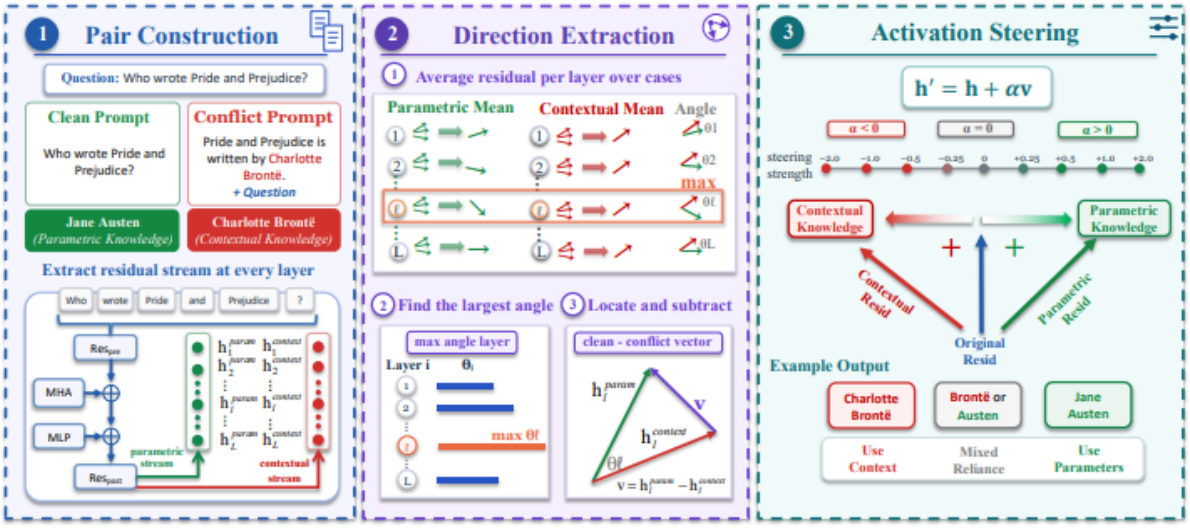
단, 여러 과제에 효과가 있다는 것만으로 지식 선택의 전체 메커니즘을 설명한 것은 아니다.

# 3. 제안 방법론

## Main Idea

**질문만 받았을 때의 내부 표현 – 충돌 문맥과 질문을 받았을 때의 내부 표현 = 파라미터 지식을 더 따르는 방향.**

그 방향을 현재 표현에 더하면 기존 지식 쪽으로, 빼면 문맥 쪽으로 이동시킨다.




## 1. 모델 구조와 개입 대상

a. 디코더 전용 Transformer 사용.

b. 기본 흐름: 토큰 임베딩 → 자기어텐션 + 잔차 연결 → MLP + 잔차 연결 → 다음 층 → 마지막 출력 분포.

c. Llama-3.1-8B-Instruct, Qwen3-8B, Gemma-2-9B-it, Mistral-7B-Instruct-v0.3의 네 지시 튜닝 모델을 평가.

d. 새 모델을 처음부터 학습하거나 기존 가중치를 미세조정하지 않는다. 추론할 때 특정 층의 활성화만 수정한다.

## 2. 입력 쌍 구성

a. **Clean prompt: 질문만 제공**

"프랑스의 수도는 어디인가?" → 파라미터 지식을 이용하면 "파리".

b. **Conflict prompt: 기존 지식과 충돌하는 지문 + 같은 질문**

"프랑스의 수도는 리옹이다. 프랑스의 수도는 어디인가?" → 문맥을 따르면 "리옹".

c. 방향 추정용 예시 선별

- 원래 질문과 이를 바꿔 쓴 네 질문에 정확히 답해야 한다.

- 충돌 문맥을 주었을 때는 삽입한 대안 답을 따라야 한다.

⇒ 기존 지식을 안정적으로 알고 있고, 문맥의 대안도 받아들이는 예시로 두 상태를 비교한다.

**주의:** 방향 추정을 위한 선별과, 전체 평가 집단을 같은 조건으로 단정하면 안 된다. 기본 평가는 먼저 clean 질문에 정확히 답한 예시를 충돌 문맥에서 평가하는 방식이다.

## 3. 어느 층을 조절할지 선택

a. 두 입력을 각각 모델에 통과시킨다.

b. 각 층에서 **각 프롬프트의 마지막 토큰** 잔차 표현을 추출하고 예시 전체의 평균을 낸다.

- 질문만 있는 입력과 문맥이 추가된 입력은 길이가 다르다.
- 같은 절대 토큰 번호가 아니라 각 입력의 마지막 위치를 비교한다.

c. 층마다 두 평균 벡터의 **코사인 유사도**를 계산한다.

- 유사도가 낮음 → 두 표현 사이 각도가 큼 → 두 상태가 잘 분리됨.
- 유사도가 가장 낮은 층을 개입 층 $\ell$로 선택.
- 출력 자체의 차이를 반영하는 마지막 층은 제외하고 앞선 적격 최소점을 사용.

⇒ 과제 점수를 모든 층에서 비교해 고르는 방식 대신, **표현의 각도 차이로 층을 찾는다.**

선택한 층: Llama 10, Qwen 21, Gemma 16, Mistral 16.

## 4. 지식 선택 벡터 추출

**v = clean 프롬프트의 평균 표현 – conflict 프롬프트의 평균 표현**

- 여러 예시의 평균 차이로 만든다.
- 같은 모델에서 만든 벡터를 그 모델의 다른 입력에 적용한다.
- 네 모델이 하나의 동일한 숫자 벡터를 공유한다는 뜻은 아니다.

→ v는 충돌 문맥을 따르는 상태에서 파라미터 지식을 더 따르는 상태로 향한다.

## 5. 추론 시 스티어링

**$h' = h + \alpha v$**

- h: 선택한 층에서 현재 충돌 입력의 마지막 토큰 표현.
- v: 미리 추정한 지식 선택 방향.
- α: 어느 쪽으로 얼마나 이동할지 정하는 계수.

a. α > 0: v를 더함 → 파라미터 지식 의존 증가.

b. α < 0: 반대 방향으로 이동 → 문맥 지식 의존 증가.

c. α = 0: 원래 모델과 동일.

d. 개입 위치: 선택한 한 층의 **MLP 이후 잔차 스트림(`resid_post`)**, 충돌 프롬프트의 마지막 토큰.

⇒ 모든 층과 모든 토큰을 수정하는 방식이 아니다.

### 6. 평가 방식

각 응답을 네 종류로 구분한다.

1. **파라미터만:** 기존 지식의 답은 포함하고 문맥 답은 포함하지 않음.
2. **문맥만:** 문맥 답만 포함.
3. **둘 다:** 두 답 문자열 모두 포함.
4. **둘 다 아님:** 어느 답도 없거나 거부·주제 이탈.

**Accpar = 파라미터 답만 포함한 항목 수 / 전체 평가 항목 수**

**Accctx = 문맥 답만 포함한 항목 수 / 전체 평가 항목 수**

- 둘 다·둘 다 아님도 분모에 포함 → 두 지표의 합이 꼭 100%는 아니다.
- 처음 생성된 최대 256토큰을 정규화한 뒤 문자열 매칭.
- 기본 생성 한도는 200토큰 → 더 짧은 출력은 전체 평가.
- 문자열이 둘 다 나오면, “A가 아니라 B”처럼 정정한 응답도 BOTH가 될 수 있다.
- 복잡한 과제에는 이 지표를 그대로 쓰지 않고 각 벤치마크 공식 평가기를 사용.

## Contribution

하나의 내부 제어 축으로 지식원 선택을 양방향으로 조절하고, 형식·관계·데이터셋·과제군을 바꾸어 그 축의 재사용 가능성을 검증했다.

# 4. 실험 및 결과

## Dataset

1. **NQ-Swap**
    - Natural Questions 지문의 답 개체를 다른 답으로 치환.
    - 원래 답과 치환 문맥의 답 중 어느 쪽을 고르는지 평가.

- 주요 방향 추정·전이 출발점. 학습/검증/테스트 = 70/15/15.

2. **MacNoise**
   - 검색 문맥을 교란한 QA 데이터.
   - 검색 결과에 잘못된 정보가 들어갔을 때 출처 선택 평가.
3. **ParaConflict**
   - 짧은 치환 문장과 길고 일관된 설명 형태의 합성 사실 충돌.
   - 같은 질문의 표현 형식을 바꾸어도 전이되는지 평가.
4. **CounterFact**
   - 국적·제조사·직업·종교·스포츠·최초 방송사 같은 사실 관계.
   - 한 관계에서 만든 방향이 다른 관계에 통하는지 평가.
5. **MemoTrap**
   - 암기한 문구의 익숙한 끝맺음과 새 지시가 요구하는 끝맺음의 충돌.
6. **복잡한 과제**
   - RAG: RGB, CRAG.
   - 기억: LoCoMo, LoCoMo-Plus, LongMemEval.
   - 규칙 준수: IFEval, FollowBench.

## Baseline

1. **Unsteered:** 개입하지 않은 원래 모델.
2. **Random split:** 무작위 분할 대조 방향. 의미 있는 지식원 대조 자체가 중요한지 확인하는 통제.
3. **기존 방법:** ContextFocus, CCS, CSKS, CK-PLUG, PH3, IRCAN, JUICE, SpARE.
   - 입력 정보 의존을 조절하거나 내부 구성 요소·표현에 개입하는 방법들과 비교.
   - 방법별 정확한 메커니즘은 해당 선행 논문을 봐야 하며, 본 논문의 비교표에 나온 이름만으로 같은 방식이라고 묶으면 안 된다.

**실험 설정**

- 모델 미세조정 없음, 추론 시 개입만 수행.
- NVIDIA A100 80GB 1대, bfloat16.
- 탐욕 디코딩, do_sample=False, max_new_tokens=200.

- 방향 추정은 학습 분할, α 선택은 검증 분할, 최종 결과는 테스트 분할 사용.
- 전이 실험은 목표 데이터에서 방향을 다시 추정하지 않음.
- 복잡한 과제는 NQ-Swap에서 정한 모델별 방향·층·계수를 고정해서 적용.

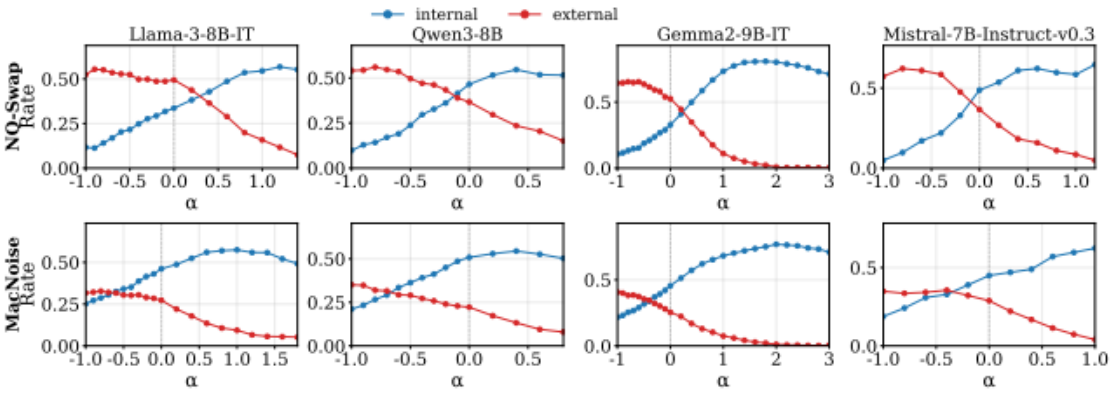
## 결과

1. 원하는 출처의 선택 비율 개선

| Method | NQ-Swap | | | | MacNoise | | | |
|---|---|---|---|---|---|---|---|---|
| | Llama-3.1 8B-Instruct | Qwen3-8B | Gemma-2 9B-IT | Mistral-7B Instruct-v0.3 | Llama-3.1 8B-Instruct | Qwen3-8B | Gemma-2 9B-IT | Mistral-7B Instruct-v0.3 |
| *Steer toward parametric knowledge ($Acc_{par}$)* | | | | | | | | |
| Unsteered | 33.7 | 46.5 | 32.8 | 42.2 | 46.1 | 50.8 | 45.5 | 50.3 |
| Random split | 32.2 ± 2.6 | 45.7 ± 1.9 | 33.5 ± 2.3 | 41.6 ± 2.1 | 45.8 ± 3.1 | 50.2 ± 2.4 | 44.9 ± 2.0 | 49.7 ± 2.5 |
| ContextFocus (Anand et al., 2026) | 44.6 (↑10.9) | 49.1 (↑2.6) | 45.2 (↑12.4) | 47.7 (↑5.5) | 50.2 (↑4.1) | 52.5 (↑1.7) | 51.3 (↑5.8) | 54.2 (↑3.9) |
| CCS (Minder et al., 2025) | 53.5 (↑19.8) | 50.8 (↑4.3) | 58.6 (↑25.8) | 52.1 (↑9.9) | 55.2 (↑9.1) | 53.1 (↑2.3) | 59.4 (↑13.9) | 56.8 (↑6.5) |
| CSKS (Wang et al., 2025b) | 52.4 (↑18.7) | 51.7 (↑5.2) | 66.3 (↑33.5) | 54.3 (↑12.1) | 53.7 (↑7.6) | 53.8 (↑3.0) | 63.6 (↑18.1) | 58.4 (↑8.1) |
| CK-PLUG (Zhao et al., 2025a) | 54.5 (↑20.8) | 52.9 (↑6.4) | 74.7 (↑41.9) | 56.2 (↑14.0) | 55.7 (↑9.6) | 53.4 (↑2.6) | 69.5 (↑24.0) | 59.7 (↑9.4) |
| PH3 (Li et al., 2025) | 48.3 (↑14.6) | 47.8 (↑1.3) | 61.5 (↑28.7) | 49.5 (↑7.3) | 49.5 (↑3.4) | 51.7 (↑0.9) | 54.7 (↑9.2) | 52.6 (↑2.3) |
| IRCAN (Shi et al., 2024) | 49.5 (↑15.8) | 51.4 (↑4.9) | 59.3 (↑26.5) | 50.8 (↑8.6) | 50.0 (↑3.9) | 52.4 (↑1.6) | 63.2 (↑17.7) | 53.9 (↑3.6) |
| JUICE (Jin et al., 2024) | 53.4 (↑19.7) | 53.3 (↑6.8) | 78.4 (↑45.6) | 57.1 (↑14.9) | 53.2 (↑7.1) | **56.1** (↑5.3) | 74.2 (↑28.7) | 60.5 (↑10.2) |
| SpARE (Zhao et al., 2025a) | **58.7** (↑25.0) | 49.2 (↑2.7) | 77.3 (↑44.5) | 55.4 (↑13.2) | **59.5** (↑13.4) | 52.3 (↑1.5) | 72.3 (↑26.8) | 57.6 (↑7.3) |
| Ours | 56.8 (↑23.1) | **54.6** (↑8.1) | **80.9** (↑48.1) | **59.0** (↑16.8) | 57.5 (↑11.4) | 54.5 (↑3.7) | **76.9** (↑31.4) | **61.6** (↑11.3) |
| *Steer toward contextual knowledge ($Acc_{ctx}$)* | | | | | | | | |
| Unsteered | 49.4 | 36.7 | 52.6 | 45.8 | 27.3 | 22.2 | 25.4 | 23.8 |
| Random split | 49.2 ± 2.8 | 37.1 ± 2.2 | 51.9 ± 2.6 | 45.3 ± 1.8 | 26.1 ± 0.7 | 21.8 ± 1.4 | 24.9 ± 1.6 | 23.4 ± 1.3 |
| ContextFocus (Anand et al., 2026) | 56.8 (↑7.4) | 42.3 (↑5.6) | 58.1 (↑5.5) | 51.2 (↑5.4) | 31.5 (↑4.2) | 25.7 (↑3.5) | 29.3 (↑3.9) | 27.1 (↑3.3) |
| CCS (Minder et al., 2025) | 52.3 (↑2.9) | 46.1 (↑9.4) | 60.7 (↑8.1) | 54.6 (↑8.8) | 30.1 (↑2.8) | 27.4 (↑5.2) | 32.5 (↑7.1) | 28.6 (↑4.8) |
| CSKS (Wang et al., 2025b) | 57.2 (↑7.8) | 49.7 (↑13.0) | 62.9 (↑10.3) | 56.8 (↑11.0) | 32.2 (↑4.9) | 30.1 (↑7.9) | 35.4 (↑10.0) | 29.7 (↑5.9) |
| CK-PLUG (Zhao et al., 2025a) | 53.4 (↑4.0) | 55.2 (↑18.5) | 64.3 (↑11.7) | 57.7 (↑11.9) | 30.9 (↑3.6) | 29.5 (↑7.3) | 37.7 (↑12.3) | 30.2 (↑6.4) |
| PH3 (Li et al., 2025) | 52.4 (↑3.0) | 51.5 (↑14.8) | 54.3 (↑1.7) | 49.1 (↑3.3) | 28.9 (↑1.6) | 28.5 (↑6.3) | 32.4 (↑7.0) | 25.7 (↑1.9) |
| IRCAN (Shi et al., 2024) | 55.2 (↑5.8) | 47.4 (↑10.7) | 57.3 (↑4.7) | 52.4 (↑6.6) | 31.7 (↑4.4) | 32.4 (↑10.2) | 36.1 (↑10.7) | 28.8 (↑5.0) |
| JUICE (Jin et al., 2024) | 54.5 (↑5.1) | 48.4 (↑11.7) | 66.9 (↑14.3) | 58.3 (↑12.5) | **34.0** (↑6.7) | 34.2 (↑12.0) | 38.5 (↑13.1) | 30.4 (↑6.6) |
| SpARE (Zhao et al., 2025a) | 52.7 (↑3.3) | 54.4 (↑17.7) | **68.3** (↑15.7) | 55.9 (↑10.1) | 30.9 (↑3.6) | 34.3 (↑12.1) | **42.4** (↑17.0) | 29.2 (↑5.4) |
| Ours | **55.5** (↑6.1) | **56.0** (↑19.3) | 65.4 (↑12.8) | **60.2** (↑14.4) | 32.8 (↑5.5) | **35.1** (↑12.9) | 40.6 (↑15.2) | **31.1** (↑7.3) |

→ **양쪽 방향으로 제어할 수 있다.** 다만 모든 모델·데이터셋·방향에서 기존 방법 중 최고인 것은 아니다. 예를 들어 NQ-Swap의 Llama 파라미터 선택은 SpARE 58.7이 제안 방법 56.8보다 높고, Gemma 문맥 선택도 SpARE 68.3이 제안 방법 65.4보다 높다.

## 2. α를 바꾸면 출처 선택이 연속적으로 변화




집단 수준: 대체로 α 증가 → 파라미터 비율 증가·문맥 비율 감소.

개별 예시: 한 출처의 답 → 두 답이 섞인 출력 → 다른 출처의 답.

예시, Llama의 파라미터 방향:

"첫 닌자 거북이는 언제 나왔는가?"

1999년 → "첫 만화는 1999년이 아니라 1984년에 출판되었다." → 1984년.

→ 단일 벡터의 크기를 바꾸며 선택 경향을 조절할 수 있다. **모든 개별 사례가 매끄럽게 전환되는 것은 아니고 실패 사례도 있다.**

## 3. 외부 근거가 강해져도, 질문이 어려워져도 효과

| Context occurrences | Unsteered parametric | Parametric steering | Unsteered contextual | Contextual steering |
|---|---|---|---|---|
| 1 | 33.7 | 56.8 | 49.4 | 55.5 |
| 2 | 30.5 | 55.2 | 54.2 | 58.1 |
| 4 | 25.4 | 53.6 | 61.8 | 62.4 |
| 8 | 17.1 | 47.9 | 73.5 | 74.8 |

문맥을 반복할수록 원래 모델은 문맥을 더 잘 따름. 그 상황에서도 파라미터 방향으로 이동시키는 효과가 유지됨.

| Difficulty | Unsteered parametric | Parametric steering | Unsteered contextual | Contextual steering |
|---|---|---|---|---|
| Easy | 42.6 | 62.4 | 45.8 | 56.2 |
| Medium | 33.1 | 56.1 | 49.6 | 57.3 |
| Hard | 12.4 | 49.8 | 64.2 | 74.3 |

→ 어려운 질문의 파라미터 선택 증가가 특히 큼(+37.4%p).

1. 단순히 "문맥에 민감해지는 방향"인가?

무문맥 입력을 기준으로 다음 세 입력과의 차이를 비교.

- 기존 지식과 **충돌**하는 문맥.
- 기존 지식과 **일치**하는 문맥.
- 질문과 **무관**한 문맥.

충돌 문맥과의 대조 방향이 전반적으로 가장 강한 출처 선택 효과를 냄.

예: ParaConflict의 파라미터 선택 비율

15.9(개입 없음) → 86.5(충돌 문맥 대조), 72.6(일치 문맥 대조), 74.0(무관 문맥 대조).

→ 문맥이 추가되었다는 일반적 효과만으로는 설명하기 어렵다는 저자들의 해석.

다만 방향 간 코사인 유사도는 약 0.875–0.899로 높다. **문맥 민감도와 완전히 무관한 별도 메커니즘이라고 단정하지는 않는다.**

## 5. 일반화 실험

a. **형식 간 전이**

짧은 치환형 문장으로 방향 추정 → 같은 사실을 길게 설명하는 일관된 문맥에 적용.

→ 특정 프롬프트 표면 형식에만 의존하지 않는 결과.

b. **지식 관계 간 전이**

국적에서 만든 방향 → 제조사·직업·종교·스포츠 등 다른 관계에 적용.

→ 한 종류의 사실 관계만 담은 방향이 아니라는 근거.

c. **데이터셋 간 전이**

NQ-Swap에서만 방향·계수를 선택 → 다른 데이터셋에 직접 적용.

| Dataset | Unsteered | Parametric direction | Contextual direction |
|---|---|---|---|
| ParaConflict | 100.0 | 98.0 | 85.5 |
| MacNoise | 100.0 | 80.8 | 86.7 |
| MemoTrap | 100.0 | 84.2 | 91.1 |
| CounterFact | 100.0 | 88.8 | 91.7 |

→ 전이 효과는 있지만 크기는 데이터셋마다 다름. CounterFact 문맥 방향은 +0.7%p로 작다.

## 6. RAG·기억·규칙 준수로 확장

| Model | Method | RAG | | Memory | | | Rule | |
|---|---|---|---|---|---|---|---|---|
| | | RGB | CRAG | LoCoMo | LoCoMo-Plus | LongMemEval | IFEval | FollowBench |
| Llama-3.1-8B-Instruct | Unsteered | 62.0±1.2 | 23.7±0.8 | 8.5±0.4 | 32.7±1.1 | 43.2±0.9 | 33.6±1.0 | 14.5±0.6 |
| | Random split | 64.0±1.4 | 24.7±0.9 | 8.5±0.4 | 32.7±1.0 | 42.8±0.8 | 33.9±1.1 | 12.9±0.5 |
| | ContextFocus | 69.0±0.3 | 24.5±1.8 | 10.6±1.8 | 34.9±2.1 | 44.1±0.9 | 33.4±1.7 | 13.1±1.3 |
| | JUICE | 62.0±1.1 | 23.7±0.7 | 7.6±0.3 | 34.2±1.9 | 42.5±2.8 | 31.0±0.9 | 13.8±1.4 |
| | CK-PLUG | 71.0±1.4 | 25.1±0.9 | 12.9±1.6 | 35.3±1.2 | 46.8±1.0 | 34.1±1.1 | 14.6±0.6 |
| | Ours | **82.0**±0.5 | **25.8**±1.0 | **13.2**±0.9 | **36.7**±1.3 | **45.4**±1.1 | **35.0**±1.2 | **14.9**±0.7 |
| Qwen3-8B | Unsteered | 72.0±1.4 | 27.5±1.0 | 9.8±0.5 | 28.2±0.9 | 42.8±0.9 | 34.9±1.1 | 15.7±0.5 |
| | Random split | 72.0±1.1 | 27.5±0.5 | 10.1±0.5 | 28.5±1.0 | 42.1±0.4 | 34.9±1.0 | 15.7±1.3 |
| | ContextFocus | 72.1±0.8 | 27.6±1.3 | 9.9±0.6 | 28.9±1.1 | 42.9±0.4 | 34.8±1.1 | 16.6±1.9 |
| | JUICE | 68.5±1.2 | 25.4±1.8 | 9.0±0.4 | 26.8±0.8 | 41.6±0.8 | 33.1±0.9 | 14.2±1.2 |
| | CK-PLUG | 74.3±0.5 | 28.3±1.1 | 10.6±0.6 | 33.5±1.2 | 44.1±1.0 | 35.4±1.2 | 16.6±0.8 |
| | Ours | **79.0**±1.6 | **30.0**±1.2 | **13.1**±0.7 | **45.4**±1.5 | **43.8**±1.1 | **36.2**±1.3 | **18.3**±0.9 |
| Gemma-2-9B-IT | Unsteered | 71.0±1.3 | 26.6±0.9 | 8.8±0.4 | 9.2±0.3 | 42.0±0.7 | 29.2±0.9 | 16.1±0.1 |
| | Random split | 72.0±0.7 | 26.9±0.9 | 8.8±0.5 | 11.0±0.4 | 41.7±0.9 | 29.8±1.2 | 15.7±0.7 |
| | ContextFocus | 77.0±1.1 | 26.9±1.2 | 8.7±0.2 | 11.1±1.2 | 42.1±1.3 | 29.7±0.7 | 16.1±1.8 |
| | JUICE | 75.0±1.2 | 25.0±0.6 | 8.2±0.7 | 9.6±0.3 | 41.1±0.7 | 27.9±0.3 | 15.0±0.6 |
| | CK-PLUG | 81.0±0.9 | 27.0±1.0 | 9.3±0.5 | 14.4±0.9 | 43.6±1.4 | 30.0±1.1 | 16.5±2.3 |
| | Ours | **88.0**±1.1 | **27.7**±1.1 | **10.5**±0.6 | **17.2**±0.6 | **44.2**±1.2 | **30.5**±0.9 | **17.0**±0.8 |
| Mistral-7B-Instruct-v0.3 | Unsteered | 81.0±1.5 | 27.3±1.0 | 9.4±0.5 | 32.7±1.1 | 40.2±0.8 | 25.1±0.8 | 14.9±0.4 |
| | Random split | 81.0±1.4 | 27.1±0.9 | 9.1±0.4 | 33.2±1.2 | 39.4±0.9 | 25.1±0.9 | 14.9±0.6 |
| | ContextFocus | 82.0±0.5 | 27.8±1.0 | 9.5±0.7 | 34.6±1.7 | 40.1±0.8 | 23.3±1.3 | 14.8±1.3 |
| | JUICE | 77.0±1.7 | 25.8±0.8 | 8.7±1.4 | 31.9±1.0 | 39.3±0.7 | 23.6±0.7 | 13.7±0.5 |
| | CK-PLUG | 82.0±0.6 | 28.2±1.1 | 9.9±0.4 | 33.1±1.3 | 41.6±1.5 | 26.4±1.0 | 15.3±1.1 |
| | Ours | **86.0**±1.2 | **28.5**±0.6 | **10.7**±0.6 | **35.9**±1.3 | **41.6**±1.0 | **29.4**±1.1 | **15.9**±0.8 |

- RGB는 의도적으로 틀린 검색 문맥을 제공. 문맥의 가짜 답을 따라야 평가상 정답.
- CRAG는 오래되거나 잡음이 있는 검색 결과 등 더 복잡한 근거 활용을 평가.
- 기억은 앞선 대화에서 관련 사실을 찾고 연결하는 능력.
- 규칙 준수는 출력 구조·길이·필수 내용·금지 사항을 지키는 능력.

→ 단순 사실 충돌에서 얻은 방향이 더 넓은 입력 활용 과제에도 도움이 된다.

## 7. 제거 실험과 비용

### a. **개입 표현 위치**

MLP 전후 잔차 표현을 비교. 저자들은 resid_post를 주요 설정으로 선택하지만, 표 8에는 resid_mid가 더 높은 모델·방향도 있음.

### b. **개입 층**

각도 차이가 큰 층에서 스티어링 효과도 강한 경향 → 코사인 기반 층 선택을 지지.

### c. **토큰 위치**

질문 마지막 토큰과 답변 마지막 토큰 비교. 질문 마지막 위치가 대체로 유리하지만 일부 파라미터 방향에서는 답변 마지막 위치가 더 좋음.

d. **충돌이 없는 입력**

원래 답 정확도가 완전히 보존되는 것은 아님.

예: MacNoise, 개입 없음 100.0 → 파라미터 방향 80.8 / 문맥 방향 86.7.

→ 원하는 출처를 강화하는 데 따른 부작용도 있음. 이 방법이 항상 정확도를 높인다는 뜻은 아니다.

e. **더 큰 모델**

Llama-3.1-70B, Qwen3-32B, Gemma-2-27B, Yi-34B에서도 전반적으로 비슷한 α–출처 선택 추세를 관찰.

# 5. 결론 (배운점)

## 의의

**LLM의 지식원 선택을 단일 잔차 스트림 방향으로 조절할 수 있다는 증거를 제시했다.**

1. 두 입력 조건의 평균 표현 차이로 방향을 구하는 비교적 간단한 방법.
2. 모델 가중치를 미세조정하지 않고 추론 시 내부 활성화에 개입.
3. 같은 방향의 부호·크기로 파라미터와 문맥 의존을 양방향 제어.
4. 형식·관계·데이터셋을 넘어, 복잡한 입력 활용 과제로 전이 가능성을 검증.

⇒ 핵심은 새로운 지식을 모델에 저장하는 것이 아니라 **이미 있는 지식과 새 입력 중 무엇을 더 따를지 조절하는 것**이다.

## 한계

**논문이 명시한 한계**

1. **화이트박스 접근 필요**
   - 내부 활성화를 수정해야 하므로 API만 제공되는 폐쇄형 모델에는 바로 적용 불가.
2. **단일 방향이 전체 메커니즘은 아님**
   - 실제 선택에는 여러 헤드·MLP 특징·디코딩 과정이 관여할 수 있음.
3. **문자열 기반 출처 매칭의 한계**
   - 유보, 정정, 부분 동의, 두 출처를 조합한 의미를 충분히 구분하지 못할 수 있음.
4. **복잡한 과제의 개선은 작거나 모델 역량에 의존**

- 모든 과제에서 큰 개선이 나타나는 것은 아님.

## 배운 점

1. **Steering은 모델 재학습과 다르다.** 가중치를 바꾸지 않아도 추론 중 표현을 수정해 답변 경향을 바꿀 수 있다.
2. **벡터의 부호를 반드시 확인해야 한다.** 이 논문은 v = clean − conflict이므로 양수는 파라미터, 음수는 문맥 방향이다.
3. **출처를 잘 따르는 것과 사실적으로 옳은 것은 다르다.** 반사실 문맥을 따르는 능력도 별도로 평가한다.
4. **두 답이 같이 나오는 응답의 처리도 중요하다.** 출처 매칭 비율만 보면 정정 문장과 모순된 혼합 문장을 같은 BOTH로 셀 수 있다.
5. **일반화는 단계적으로 확인해야 한다.** 형식 변경 → 관계 변경 → 데이터셋 변경 → 복잡한 과제로 확장.
6. **한 방향의 효과는 유용한 제어 축의 증거다.** 지식 선택의 모든 원인을 완전히 밝혔다는 결론은 아니다.