GPT-3. Language Models are Few-Shot Learners

1. Introduction

논문이 다루는 분야

자연어처리(NLP) 전반에서 **task-agnostic한 대규모 사전학습 언어 모델**을 다루며, 특히 모델 규모(scale)를 키우는 것만으로 별도의 gradient update나 fine-tuning 없이 **자연어 지시문과 소수의 예시(demonstration)만으로 새로운 task를 수행하는 능력(in-context learning)** 이 얼마나 향상되는지를 탐구한다. 이를 위해 175B 파라미터의 autoregressive 언어 모델인 GPT-3를 학습하고, 번역·질의응답·cloze·상식 추론·독해·산술 연산·단어 조작 등 매우 다양한 task에서 zero-shot / one-shot / few-shot 설정으로 평가한다.

해당 task에서 기존 연구 한계점

- NLP의 표현 학습은 word vector → 문맥을 반영하는 RNN 기반 표현 → 사전학습 Transformer를 직접 fine-tuning하는 방식으로 발전해 왔다. 마지막 단계에서 task-specific 아키텍처의 필요성은 사라졌지만, 여전히 **task마다 수천~수십만 개 규모의 labeled 데이터로 fine-tuning해야 한다**는 한계가 남아 있다.
- 이 한계는 세 가지 측면에서 문제가 된다.
  1. **실용성**: 문법 교정, 추상 개념의 예시 생성, 단편 소설 비평 등 유용한 언어 task는 매우 다양한데, 새로운 task마다 대규모 labeled 데이터를 구축하는 것은 현실적으로 어렵다.
  2. **일반화와 spurious correlation**: 사전학습에서 대규모 정보를 흡수한 표현력 높은 모델을 매우 좁은 task 분포로 fine-tuning하면, 학습 데이터의 spurious correlation을 활용하게 되어 분포 밖(out-of-distribution) 일반화가 약해진다. 따라서 벤치마크 상의 fine-tuned 성능이 실제 task 능력을 과대평가할 수 있다.
  3. **인간과의 차이**: 사람은 "이 문장이 기쁜지 슬픈지 말해 줘"와 같은 짧은 지시나 몇 개의 예시만으로도 새로운 언어 task를 수행하며, 여러 task와 기술을 자연스럽게 섞어 전환할 수 있다.
- GPT-2 등에서 제안된 **in-context learning**(모델의 입력에 자연어 지시와 예시를 넣어 조건화하는 방식)은 이 문제의 잠재적 해결책이지만, 기존 결과는 fine-tuning에 크게 못 미쳤다(예: Natural Questions에서 4% 수준, CoQA에서 55 F1로 SOTA 대비 35점 이상 낮음).

논문의 contributions

- 기존 비-희소(non-sparse) 언어 모델보다 10배 큰 **175B 파라미터의 autoregressive 언어 모델 GPT-3**를 학습하였다.
- **Zero-shot / One-shot / Few-shot** 이라는 세 가지 평가 설정을 명확히 정의하고, gradient update 없이 텍스트 상호작용만으로 task를 지정하는 방식으로 20여 개 이상의 NLP 데이터셋과 새로 설계한 task들에서 체계적으로 평가하였다.
- 125M~175B의 8개 모델을 학습하여, 모델 크기가 커질수록 성능이 매끄럽게 향상되며 **zero-shot과 few-shot 간의 성능 격차도 커진다는 것**, 즉 큰 모델일수록 더 뛰어난 meta-learner임을 보였다.
- 일부 task에서는 fine-tuned SOTA에 근접하거나 이를 능가하였다(예: LAMBADA few-shot 86.4%, TriviaQA few-shot 71.2%, CoQA few-shot 85.0 F1).
- 사람이 GPT-3가 생성한 뉴스 기사를 사람이 쓴 기사와 거의 구별하지 못한다는 것(정확도 약 52%)을 보였다.
- 대규모 웹 데이터 학습 시 발생하는 **test set contamination** 문제를 체계적으로 측정하는 방법론을 제시하였고, 편향(bias)·공정성·오용 가능성·에너지 사용 등 **broader impacts**를 함께 분석하였다.

2. Related Work

논문은 관련 연구를 다음과 같은 흐름으로 정리한다.

첫째, **언어 모델의 규모 확장**에 관한 연구이다. Transformer 기반 언어 모델의 파라미터는 GPT(117M) → BERT-Large(340M) → GPT-2(1.5B) → Megatron-LM(8.3B) → T5(11B) → Turing-NLG(17B)로 빠르게 증가해 왔으며, 규모가 커질 때마다 텍스트 생성과 downstream task 성능이 꾸준히 향상되었다. 특히 Kaplan et al.(2020)의 **scaling laws** 연구는 log loss가 모델 크기에 따라 매끄러운 멱법칙(power law)을 따른다는 것을 보였다. 논문은 log loss와 downstream task 성능이 잘 연관되므로 in-context learning 능력 역시 규모에 따라 향상될 것이라는 가설을 세우고, 이를 검증하는 것을 목표로 한다. 이와 반대 방향으로, ALBERT나 distillation처럼 모델 크기를 줄이면서 성능을 유지하는 연구도 언급한다.

둘째, **few-shot learning 및 meta-learning** 연구이다. MAML, RL^2, matching networks 등 meta-learning 문헌에서 "inner loop / outer loop" 구조를 빌려와, 사전학습을 outer loop로, 하나의 시퀀스 안에서 일어나는 in-context learning을 inner loop로 해석한다. GPT-2에서 처음 시도된 in-context learning 방식을 그대로 따르되 규모를 크게 키운 것이 차이점이다. 또한 Schick & Schütze(PET)처럼 소규모 모델로 few-shot 학습을 시도한 연구, 자연어 지시를 task 정의로 활용하는 연구(T5의 task prefix 등), multi-task fine-tuning 연구들을 소개한다.

셋째, **fine-tuning 기반 사전학습 모델 및 기타 접근**이다. BERT, RoBERTa, T5 등은 bidirectional 구조나 denoising objective를 사용하여 fine-tuning 시 높은 성능을 보인다. 논문은 이들과 달리 GPT-3가 autoregressive 구조라는 점이 일부 task(문장 비교 등)에서 약점이 될 수 있음을 인정하며, 이를 limitation 섹션에서 다시 논의한다.

차별성 측면에서 논문은 **"fine-tuning 없이, 규모만으로 in-context learning 능력이 어디까지 올라가는가"** 라는 질문에 집중한다는 점을 강조한다. 기존 연구들이 성능 향상을 위해 task-specific fine-tuning이나 아키텍처 개선에 집중했다면, GPT-3는 아키텍처를 GPT-2와 거의 동일하게 유지한 채 모델·데이터·연산량을 확장하고, few-shot 학습 능력 자체를 체계적으로 측정했다는 점에서 차별화된다. 다만 related work가 논문 후반부(6장)에 배치되어 있고 비교 분석보다는 문헌 나열에 가까운 편이라, 방법론적 차별성은 주로 Introduction과 실험 설정 정의에서 드러난다.

3. 제안 방법론

Main Idea

GPT-3의 핵심 아이디어는 **"충분히 큰 언어 모델은 사전학습 과정에서 다양한 기술과 패턴 인식 능력을 습득하며, 추론 시 입력으로 주어진 지시와 예시만으로 원하는 task를 빠르게 인식·적응할 수 있다"** 는 것이다. 즉, 별도의 파라미터 업데이트 없이 **context window 안에 task 설명과 예시를 넣는 것만으로 task를 지정**한다.

평가 설정 (Fine-tuning과의 비교)

- **Fine-tuning (FT)**: 사전학습 모델을 task별 labeled 데이터로 gradient update하는 기존 방식. 강한 성능을 보이지만 task마다 대규모 데이터가 필요하고, 분포 밖 일반화가 약하며 spurious feature를 학습할 위험이 있다. **GPT-3에서는 사용하지 않는다.**
- **Few-Shot (FS)**: 자연어 task 설명과 함께 K개의 예시(context-completion 쌍)를 입력으로 주고, 마지막 context에 대한 completion을 생성하게 한다. K는 보통 10~100개로, 모델의 context window(2048 tokens)에 들어가는 만큼 사용한다. Task-specific 데이터 요구량이 크게 줄지만, fine-tuned SOTA보다는 대체로 성능이 낮다.
- **One-Shot (1S)**: 예시를 단 하나만 제공한다. 사람이 task를 전달받는 방식과 가장 유사하다.
- **Zero-Shot (0S)**: 예시 없이 자연어 지시만 제공한다. 가장 편리하고 spurious correlation의 위험도 가장 적지만, 사람에게도 예시 없이는 task 형식이 모호한 경우가 있으므로 가장 어려운 설정이다.

예를 들어 영어→프랑스어 번역의 few-shot 입력은 다음과 같다.

```
Translate English to French:      ← task description
sea otter => loutre de mer         ← examples
peppermint => menthe poivrée
plush girafe => girafe peluche
cheese =>                          ← prompt
```

모델 구조: GPT-2와 동일한 Transformer decoder 구조(modified initialization, pre-normalization, reversible tokenization 포함)를 사용하되, Sparse Transformer와 유사하게 **dense attention과 locally banded sparse attention을 층마다 번갈아** 사용한다. 규모에 따른 성능 변화를 확인하기 위해 다음 8개 크기의 모델을 학습하였다. 모든 모델의 context window는 n_ctx = 2048 tokens이다.

모델	파라미터 수	n_layers	d_model	n_heads	d_head	Batch Size	Learning Rate
GPT-3 Small	125M	12	768	12	64	0.5M	6.0×10^{-4}
GPT-3 Medium	350M	24	1024	16	64	0.5M	3.0×10^{-4}
GPT-3 Large	760M	24	1536	16	96	0.5M	2.5×10^{-4}
GPT-3 XL	1.3B	24	2048	24	128	1M	2.0×10^{-4}
GPT-3 2.7B	2.7B	32	2560	32	80	1M	1.6×10^{-4}
GPT-3 6.7B	6.7B	32	4096	32	128	2M	1.2×10^{-4}
GPT-3 13B	13.0B	40	5140	40	128	2M	1.0×10^{-4}
GPT-3 175B	**175.0B**	**96**	**12288**	**96**	**128**	**3.2M**	**0.6×10^{-4}**

Feed-forward 층의 크기는 d_ff = 4 × d_model이며, 모델은 GPU 간 depth/width 방향 model parallelism으로 분할하여 학습한다.

학습 데이터: 약 1조 단어 규모의 Common Crawl을 기반으로 하되, 품질을 높이기 위해 세 단계 처리를 거쳤다.

1. 고품질 참조 코퍼스(WebText 등)와의 유사도를 기준으로 분류기를 학습하여 Common Crawl을 **필터링**
2. 데이터셋 내/간 **fuzzy deduplication**(MinHash 기반)으로 중복 문서 제거 및 held-out 검증셋 오염 방지
3. WebText2, Books1, Books2, 영어 Wikipedia 등 **고품질 코퍼스를 추가**

데이터셋	토큰 수	학습 혼합 비율	**300B 토큰 학습 시 epoch 수**
Common Crawl (filtered)	410B	60%	0.44
WebText2	19B	22%	2.9
Books1	12B	8%	1.9
Books2	55B	8%	0.43
Wikipedia	3B	3%	3.4

Common Crawl은 필터링 전 45TB(압축 기준)에서 570GB로 줄어들었다. 데이터셋 크기에 비례하지 않고 **품질이 높은 데이터를 더 자주 샘플링**하므로, Common Crawl과 Books2는 1 epoch 미만, 나머지는 2~3 epoch 정도 학습된다. 이는 약간의 overfitting을 감수하고 데이터 품질을 높이려는 선택이다. 모든 모델은 총 **300B 토큰**으로 학습된다.

학습 세부 사항: Adam($\beta_1 = 0.9$, $\beta_2 = 0.95$, $\varepsilon = 10^{-8}$), gradient norm clipping 1.0, 260B 토큰에 걸쳐 learning rate를 10%까지 cosine decay, 처음 375M 토큰 동안 linear warmup, batch size를 작은 값에서 점진적으로 증가, weight decay 0.1을 사용하였다. 문서 경계를 넘어 2048 토큰 시퀀스를 채우는 방식으로 학습 효율을 높였다. 큰 모델일수록 큰 batch와 작은 learning rate를 사용하며, 이는 gradient noise scale을 기반으로 결정하였다. 학습은 Microsoft가 제공한 고대역폭 클러스터의 V100 GPU에서 수행되었고, 175B 모델의 학습에는 약 3,640 petaflop/s-days의 연산이 소요되었다.

평가 방법

- Few-shot 예시 K개는 각 task의 학습셋에서 무작위로 뽑아 1~2개의 줄바꿈으로 구분해 넣는다. (학습셋이 없는 LAMBADA, StoryCloze는 dev셋에서 뽑는다.)
- **객관식 task**: 각 선택지 completion의 언어 모델 likelihood를 비교한다. 대부분 토큰 수로 정규화한 likelihood를 사용하며, ARC·OpenBookQA·RACE 등 일부 데이터셋에서는 P(completion | context) / P(completion | "Answer:")처럼 **unconditional probability로 정규화**하는 것이 dev셋에서 더 좋았다.
- **이진 분류 task**: 선택지를 "0/1" 대신 "True/False"와 같이 의미 있는 단어로 바꿔 객관식처럼 처리한다.
- **자유 형식 task**: beam width 4, length penalty α = 0.6의 beam search로 생성하고 F1, BLEU, exact match 등으로 평가한다.
- 공개된 test셋이 있으면 test셋으로, 그렇지 않으면 dev셋으로 결과를 보고한다.

Contribution

- **Introduction과의 일관성**: Introduction에서 제시한 문제의식(task별 대규모 labeled 데이터 의존, 좁은 분포 fine-tuning의 일반화 문제)에 대응하여, fine-tuning 없이 텍스트만으로 task를 지정하는 in-context learning을 일관되게 채택하였다. 0S/1S/FS 설정을 명확히 정의하여 "얼마나 적은 task-specific 정보로 task를 수행할 수 있는가"를 단계적으로 측정할 수 있게 하였다.
- **장점에 대한 근거**: 제안 방법의 핵심 주장인 "규모가 커질수록 in-context learning 능력이 향상된다"는 것을 8개 크기의 모델로 검증한다. 모델 크기가 커질수록 validation loss가 연산량에 대해 멱법칙을 따라 매끄럽게 감소하며, 대부분의 task에서 zero/one/few-shot 성능이 모두 향상되고 특히 **few-shot 성능의 기울기가 더 가파르다**는 것을 보임으로써 큰 모델이 context 속 정보를 더 효율적으로 활용함을 뒷받침한다. 예를 들어 단어에서 무작위 기호를 제거하는 단순 task에서, 175B 모델은 예시 수가 늘어날수록 성능이 크게 오르지만 작은 모델은 거의 변화가 없다.
- **재현 가능성**: 모델 하이퍼파라미터, 데이터 구성과 샘플링 비율, 최적화 설정, 평가 시 정규화 방식과 decoding 설정, 각 task별 프롬프트 형식(부록 G)까지 상세히 기술하여 구현에 필요한 정보는 대부분 제공한다. 다만 175B 모델의 학습에 막대한 연산 자원이 필요하고, 데이터 필터링 분류기의 세부 사항이나 Books1/Books2의 정확한 출처 등은 충분히 공개되지 않아 실제 재현은 사실상 어렵다.

4. 실험 및 결과

Dataset

총 9개 범주, 20개 이상의 데이터셋과 새로 설계한 task들에서 평가한다.

- **Language Modeling, Cloze, Completion**: PTB, LAMBADA, HellaSwag, StoryCloze
- **Closed-book Question Answering**: Natural Questions, WebQuestions, TriviaQA (외부 문서 검색 없이 모델 내부 지식만으로 답변)
- **Translation**: WMT'14 En↔Fr, WMT'16 En↔De, WMT'16 En↔Ro
- **Winograd-style Tasks**: Winograd Schema Challenge (WSC273), WinoGrande
- **Common Sense Reasoning**: PIQA, ARC (Easy / Challenge), OpenBookQA
- **Reading Comprehension**: CoQA, DROP, QuAC, SQuAD 2.0, RACE
- **SuperGLUE**: BoolQ, CB, COPA, RTE, WiC, WSC, MultiRC, ReCoRD
- **Natural Language Inference**: RTE, Adversarial NLI (ANLI R1~R3)
- **Synthetic and Qualitative Tasks**: 산술 연산(2~5자리 덧셈/뺄셈, 2자리 곱셈, 한 자리 복합 연산), 단어 조작(cycle letters, anagrams, random insertion, reversed words), SAT analogies, 뉴스 기사 생성, 새로운 단어 사용, 영어 문법 교정

Baseline

- **Fine-tuned SOTA**: 각 task에서 해당 데이터셋으로 fine-tuning된 최고 성능 모델(예: T5-11B, RoBERTa, ALUM, RAG 등)을 주요 비교 대상으로 삼는다. GPT-3는 fine-tuning을 하지 않으므로, 이는 일종의 상한선 역할을 한다.
- **BERT-Large 및 기타 fine-tuned 모델**: SuperGLUE 등에서 fine-tuned BERT-Large와 비교한다.
- **Zero-shot/few-shot 기존 SOTA**: GPT-2 등 기존 zero-shot 결과, 비지도 기계번역(XLM, MASS, mBART 등) 결과와 비교한다.
- **모델 크기별 비교**: 동일 구조의 125M~175B 모델 8개를 비교하여 규모에 따른 성능 변화를 분석한다.
- **인간 성능**: 뉴스 기사 판별, SAT analogies(대학 지원자 평균 57%) 등에서 사람과 비교한다.

결과

(1) Language Modeling, Cloze, Completion

- **PTB**: zero-shot perplexity 20.50으로 기존 SOTA를 15포인트 개선하였다. (Wikipedia 기반 LM 벤치마크는 학습 데이터 오염 우려로 제외)
- **LAMBADA**: zero-shot 76.2%로 기존 SOTA(68.0%)를 8% 앞섰고, few-shot에서는 **86.4%** 로 18% 이상 향상되었다. Few-shot 형식은 fill-in-the-blank 형태로 "정답이 반드시 한 단어"라는 정보를 모델에 알려줄 수 있어 효과적이었다. 단, one-shot(72.5%)은 zero-shot보다 낮았는데, 형식 인식에 여러 예시가 필요하기 때문으로 해석된다.
- **HellaSwag**: few-shot 79.3%로 1.5B fine-tuned 모델(75.4%)은 앞섰으나 SOTA(ALUM 85.6%)에는 못 미쳤다.

- **StoryCloze**: few-shot 87.7%로 fine-tuned SOTA(91.8%)보다 4.1% 낮다.

(2) Closed-book QA

- **TriviaQA**: zero-shot 64.3%, one-shot 68.0%, few-shot **71.2%** 로, 문서 검색을 사용하는 fine-tuned open-domain QA 모델 RAG(68.0%)를 few-shot에서 능가하였다.
- **WebQuestions**: few-shot 41.5%로 fine-tuned T5-11B+SSM(44.7%)에 근접하였다. Zero-shot(14.4%)에서 few-shot으로 크게 향상되어, 질문·답변 형식 분포가 사전학습 데이터와 다를 때 예시가 큰 도움이 됨을 보인다.
- **Natural Questions**: few-shot 29.9%로 fine-tuned SOTA(36.6%)에 못 미쳤다. 위키피디아의 세부 지식을 묻는 질문 특성상 모델 용량의 한계가 드러난다.
- 세 데이터셋 모두 모델 크기에 따라 성능이 매끄럽게 증가하여, 모델 용량이 곧 "지식 저장량"과 연결됨을 시사한다.

(3) Translation

- 학습 데이터의 93%가 영어이지만 7%의 비영어 텍스트만으로도 번역 능력을 보였다.
- **X→En 방향**에서 강했다: few-shot BLEU 기준 Fr→En 39.2, De→En 40.6, Ro→En 39.5로, 비지도 기계번역 SOTA를 능가하거나 근접하였다.
- **En→X 방향**은 약했다(En→Fr 32.6, En→De 29.7, En→Ro 21.0). 영어 위주로 학습된 BPE tokenizer의 영향 및 영어 생성 능력에 비해 비영어 생성 능력이 약한 점이 원인으로 분석된다.

(4) Winograd-style Tasks

- **WSC273**: zero/one/few-shot 88.3% / 89.7% / 88.6%로 fine-tuned SOTA(90.1%)에 근접했다. (단, 오염 분석에서 일부 오염 가능성이 확인됨)
- **WinoGrande**: zero-shot 70.2%, one-shot 73.2%, few-shot 77.7%로 fine-tuned RoBERTa(79%)에 근접했으나 SOTA(T5, 84.6%)와 인간 성능(94%)에는 못 미쳤다.

(5) Common Sense Reasoning

- **PIQA**: zero-shot 81.0%, few-shot 82.8%로 fine-tuned SOTA(79.4%)를 능가하였다. (오염 가능성으로 별표 표시)
- **ARC**: few-shot에서 Easy 70.1%, Challenge 51.5%로 fine-tuned SOTA(UnifiedQA, 각각 92.0%, 78.5%)와 큰 차이가 있다.
- **OpenBookQA**: few-shot 65.4%로 zero-shot 대비 크게 향상되었으나 SOTA(87.2%)에는 크게 못 미쳤다.

(6) Reading Comprehension

- **CoQA**: few-shot **85.0 F1**으로 fine-tuned SOTA(90.7)에 3~4점 차이로 근접하였다. 자유 형식의 대화형 데이터셋에서 가장 강한 성능을 보였다.
- **QuAC**(44.3 F1), **DROP**(36.5 F1), **RACE**(RACE-h 46.8%, RACE-m 58.1%) 등 구조화된 추론이나 이산적 연산이 필요한 데이터셋에서는 SOTA와 큰 격차가 있었다. **SQuAD 2.0**은 few-shot 69.8 F1로 zero-shot 대비 10점 가까이 향상되었다.

(7) SuperGLUE

- Task별로 학습셋에서 32개의 예시를 뽑아 few-shot 평가한 결과, test셋 평균 **71.8**로 fine-tuned BERT-Large(69.0)를 앞섰으나 fine-tuned SOTA(89.0)와는 차이가 컸다.
- COPA(92.0%)와 ReCoRD(90.2 acc / 91.1 F1)에서는 SOTA에 근접한 반면, **WiC(49.4%)는 우연 수준**이었다. WiC, RTE, CB처럼 두 문장(또는 두 단어 용법)을 비교해야 하는 task에서 특히 약했다.
- 예시 수 K를 늘릴수록 성능이 올라가며, 175B 모델은 task당 8개 미만의 예시로 BERT-Large를 넘어섰다.

(8) Natural Language Inference

- **ANLI**: 13B 이하 모델은 거의 우연 수준(~33%)이었고, 175B 모델도 few-shot R3에서 40.2%로 우연보다 조금 나은 정도였다. NLI는 GPT-3에게 여전히 매우 어려운 task로 남아 있다.

(9) Synthetic and Qualitative Tasks

- **산술 연산** (few-shot): 2자리 덧셈 100%, 2자리 뺄셈 98.9%, 3자리 덧셈 80.4%, 3자리 뺄셈 94.2%로 높았으나, 4자리(25~27%), 5자리(9~10%)로 갈수록 급격히 하락했다. 2자리 곱셈은 29.2%, 한 자리 복합 연산은 21.3%였다. 학습 데이터에서 " + =" 형태를 검색한 결과 3자리 덧셈 문제 중 정답과 일치하는 경우가 극히 적었고, 틀린 답에서 받아올림을 빠뜨리는 패턴이 나타나 단순 암기가 아닌 실제 연산을 시도하는 것으로 해석된다. 13B 이하 모델과 175B 모델 사이에 큰 성능 도약이 나타났다.
- **단어 조작** (few-shot): random insertion 제거 67.2%, cycle letters 37.9%, anagram A2 39.7%, A1 15.1%였으며 reversed words는 0.4%로 거의 풀지 못했다. BPE 토큰화가 글자 단위 조작을 어렵게 만들기 때문으로 분석된다.
- **SAT analogies**: few-shot 65.2%로 대학 지원자 평균(57%)을 넘었다.
- **뉴스 기사 생성**: 사람에게 실제 기사와 GPT-3 생성 기사를 구별하게 했을 때, 175B 모델이 생성한 약 200단어 기사에 대한 판별 정확도는 **약 52%** 로 우연 수준(50%)과 거의 차이가 없었다. 의도적으로 낮은 품질의 기사를 생성하는 control 모델에서는 정확도가 86%였으며, 모델이 커질수록 판별 정확도가 떨어지는 경향이 뚜렷했다. 약 500단어의 긴 기사에서도 정확도는 52% 수준이었다.
- **새로운 단어 사용 / 문법 교정**: 한 번 정의를 보여준 가상의 단어(예: "Gigamuru")를 문장에서 자연스럽게 사용하고, few-shot 예시만으로 비문법적 영어 문장을 교정하는 질적 결과를 제시하였다.

(10) Test Set Contamination 분석

- 학습 데이터 필터링 시 벤치마크와의 중복을 제거하려 했으나, 버그로 인해 일부 중복이 남았고 학습 비용 문제로 재학습하지 못했다.
- 이에 각 벤치마크에서 학습 데이터와 13-gram이 겹치는 예시를 제거한 **"clean" 버전**을 만들어 성능을 비교하였다. 대부분의 데이터셋에서 성능 변화는 미미했으며, PIQA와 Winograd 등 일부 영향이 의심되는 결과에는 별표를 표시하였다. 또한 모델이 학습 데이터에도 overfitting하지 않았으므로 (train/validation loss 격차가 작음) 오염의 영향이 제한적이라고 주장한다.

종합: 모델 규모가 커질수록 거의 모든 task에서 성능이 매끄럽게 증가하였고, few-shot 설정의 이득이 큰 모델에서 더 크게 나타나 "큰 언어 모델은 few-shot learner"라는 주장을 뒷받침한다. 한편 NLI, 일부 독해, 문장 비교 task에서는 여전히 fine-tuned 모델과 큰 격차가 존재한다.

5. 결론(배운점)

연구의 의의

- **패러다임의 전환**: "사전학습 → task별 fine-tuning"이라는 당시 지배적 패러다임에서 벗어나, **충분히 큰 모델은 프롬프트만으로 다양한 task를 수행할 수 있다**는 것을 대규모 실험으로 보였다. 이후 프롬프트 엔지니어링, in-context learning 연구, instruction tuning(InstructGPT), ChatGPT 등으로 이어지는 흐름의 출발점이 되었다는 점에서 의의가 매우 크다.
- **Scaling의 실증**: 8개 크기의 모델로 성능이 규모에 따라 예측 가능하게 증가함을 보여, scaling laws가 단순히 loss뿐 아니라 실제 downstream task 능력에도 적용됨을 확인했다. 특히 산술 연산처럼 특정 규모에서 성능이 급격히 뛰는 현상은 이후 "emergent abilities" 논의의 단초가 되었다.
- **책임 있는 연구 서술**: test set contamination을 정량적으로 분석하고, 성별·인종·종교에 대한 편향(예: 388개 직업 중 83%가 남성 대명사와 더 강하게 연관), 오용 가능성, 에너지 소비 등 사회적 영향을 상당한 분량으로 다룬 점도 인상적이었다.

논문이 밝힌 한계점

- 긴 텍스트 생성 시 의미 반복, 일관성 상실, 자기모순이 발생하며, "냉장고에 치즈를 넣으면 녹을까?" 같은 상식적 물리 추론에 약하다.
- Autoregressive 구조이므로 bidirectional 정보가 필요한 task(WiC, ANLI, 문장 비교, 독해 일부)에서 약하다. 저자들은 GPT-3 규모의 bidirectional 모델이나 denoising objective와의 결합을 향후 방향으로 제시한다.
- 사전학습의 sample efficiency가 낮다. 사람이 평생 접하는 것보다 훨씬 많은 텍스트를 학습해야 한다.
- Few-shot 학습이 정말 **새로운 task를 "학습"하는 것인지, 사전학습에서 이미 본 task를 "인식"하는 것인지** 모호하다.
- 추론 비용이 크고 해석 가능성이 낮으며, 예측이 잘 calibration되지 않고 학습 데이터의 편향을 그대로 반영한다.

좋았던 점

- Fine-tuning / few-shot / one-shot / zero-shot을 명확히 정의하고 동일한 모델에서 일관되게 비교한 실험 설계가 깔끔하다. "규모가 커질수록 few-shot의 이득이 커진다"는 핵심 주장을 그래프 하나(모델 크기 × 예시 수)로 직관적으로 보여 준 점이 설득력 있었다.
- 좋은 결과뿐 아니라 ANLI, WiC, reversed words처럼 **잘 안 되는 task도 숨기지 않고 보고**하여 모델의 능력과 한계를 균형 있게 파악할 수 있었다.
- 산술 연산에서 학습 데이터를 직접 검색해 암기 여부를 검증하거나, 13-gram 기반 clean subset을 만들어 오염 영향을 측정하는 등 결과의 신뢰도를 높이려는 분석이 꼼꼼했다.

아쉬웠던 점

- 175B 모델의 학습 비용이 매우 커서 외부 연구자가 재현하거나 검증하기 어렵고, 모델 가중치와 데이터셋 세부 사항(Books1/Books2 등)이 공개되지 않았다.
- 프롬프트 형식, 예시 선택과 순서 등에 따라 성능이 크게 달라질 수 있는데, 이에 대한 민감도 분석이 부족하다. 실제로 후속 연구들(예: Zhao et al., 2021의 calibration 연구)에서 GPT-3의 few-shot 성능이 예시 순서와 형식에 매우 민감하다는 것이 밝혀졌다.
- 오염 버그를 발견하고도 재학습하지 못해 일부 결과(PIQA, WSC 등)의 해석이 불확실하게 남았다.
- In-context learning이 **왜, 어떻게** 작동하는지에 대한 메커니즘 분석은 거의 없고, 주로 현상을 보고하는 데 그쳤다.

배운점

BERT가 "양방향 사전학습 + fine-tuning"으로 task별 아키텍처를 없앴다면, GPT-3는 한 걸음 더 나아가 **fine-tuning 단계 자체를 없앨 수 있는 가능성**을 보여 주었다는 점에서 두 논문을 연결해 이해할 수 있었다. 동시에 규모를 키우는 것만으로 많은 능력이 생겨나지만, bidirectional 정보가 필요한 task나 정밀한 추론에서는 구조적 한계가 여전히 남는다는 점도 확인할 수 있었다. 또한 "프롬프트에 무엇을 넣느냐"가 곧 모델에게 task를 정의하는 방법이 된다는 관점은, 이후 chain-of-thought prompting 등 LM reasoning 연구를 이해하는 데 중요한 배경 지식이 된다고 느꼈다. 마지막으로, 강력한 모델일수록 편향·오용·에너지 문제 등 사회적 영향에 대한 분석이 함께 이루어져야 한다는 점을 배웠다.

Which Knowledge Should LLMs Trust? Uncovering a Generalizable Steering Direction Across Knowledge Conflicts

> **저자**: Yibin Lou, Yi Hu, Jianhui Chen, Chenpeng Wang, Muhan Zhang, Liangming Pan (Peking University 외) **arXiv**: 2610.20067 (2026.10) **리뷰 범위**: Abstract와 1. Introduction (Figure 1, 2 포함)

1. Introduction

논문이 다루는 분야

LLM의 **지식 충돌(knowledge conflict)** 상황에서 일어나는 **지식 선택(knowledge selection)** 문제를 다룬다. LLM은 사전학습을 통해 방대한 세계 지식을 파라미터에 저장하며(**parametric knowledge**), 이 지식 덕분에 knowledge-intensive task에서 좋은 성능을 낸다. 한편 실제 응용에서는 검색된 문서(RAG), 여러 턴에 걸친 대화 기록(memory), 명시적으로 주어진 규칙(rule following)처럼 **프롬프트로 들어오는 외부 지식(contextual knowledge)** 도 안정적으로 반영해야 한다.

문제는 두 지식이 서로 다르거나 모순되는 경우가 많다는 점이다. 이때 모델이 어느 쪽이 정확한지 따지지 않고 잘못된 쪽에 의존하면 틀린 답을 내게 된다. 따라서 **LLM이 충돌하는 두 지식 중 무엇을 선택하는지 이해하고, 그 선택을 안정적으로 제어하는 것**이 중요한 열린 문제라고 저자들은 주장한다.

이 논문은 이 문제를 **mechanistic interpretability와 activation steering**의 관점에서 접근한다. Truthfulness, safety, emotion, refusal 같은 고수준 개념이 activation space에서 선형 방향(linear direction)으로 표현된다는 기존 연구처럼, "외부 지식을 따를지, 파라미터 지식을 따를지"라는 선택도 하나의 선형 방향으로 표현되는지 확인한다.

해당 task에서 기존 연구 한계점

저자들은 지식 충돌을 제어하려는 기존 연구를 두 갈래로 나누어 각각의 한계를 지적한다.

(1) 입력 단계 제어 (Input-level control)

- 명시적인 프롬프트나 지시문 설계(Choi et al., 2025; Merth et al., 2024)
- 검색된 문서를 정해진 슬롯에 넣거나 관련도를 표시하는 구조화된 RAG 템플릿(Cattan et al., 2025)
- **한계**: 구현은 쉽지만 모델 내부에서 두 지식을 어떻게 조정(arbitration)하는지 들여다볼 수 없다. 또한 모델이 context와 파라미터에 각각 얼마나 의존할지를 **간접적으로만** 제어할 수 있다.

(2) 내부 구성요소 개입 (Intervening on internal components)

- Attention 조작(Jin et al., 2024; Li et al., 2025)
- Sparse autoencoder(SAE) feature steering(Zhao et al., 2025a)
- Decoding 단계에서 토큰 분포 수정(Bi et al., 2025; Wang et al., 2025a)
- **한계**
  - 대부분 **단순한 사실(factual) 데이터셋에서만 평가**되었다. 검색 문서, 긴 대화 기록, 명시적 규칙이 얽힌 실제 응용 수준의 충돌에서는 검증되지 않았다.
  - Task마다 attribution 분석, feature 탐색, 별도 adaptation, decoding 수정이 필요해 **task-specific**하다.
  - 복잡한 응용 환경에서의 **robust한 평가가 부족**하다.

이를 정리하면, 기존 방법은 **"내부 메커니즘을 직접 제어하지 못하거나(입력 제어), 직접 제어하더라도 단순한 사실 task에 국한되고 일반화가 검증되지 않았다(내부 개입)"** 는 한계를 가진다. 여기서 저자들은 다음 연구 질문을 던진다.

> *"Can knowledge selection under conflict be captured and controlled by a low-dimensional steering axis that generalizes across tasks?"* (충돌 상황에서의 지식 선택을, task 간 일반화되는 저차원 steering 축으로 포착하고 제어할 수 있는가?)

논문의 contributions

제안 방법 개요

- Parametric knowledge에 의존하는 경우와 context에 의존하는 경우를 분리하도록 설계한 **프롬프트 쌍**의 hidden state를 대조하여 **knowledge selection direction**을 추출한다.
  - Clean prompt: 질문 q만 입력
  - Conflict prompt: 파라미터 지식과 충돌하는 passage + 질문 q
- 두 프롬프트의 평균 residual activation 사이의 **각도 차이(cosine similarity 기준)가 가장 큰 층 ℓ**을 개입할 층으로 선택한다.
- 해당 층에서 두 activation 평균의 차(**difference-in-means**)로 방향 v를 구한다.
- Conflict prompt의 마지막 토큰에 $\mathbf{h' = h + \alpha v}$ 형태로 부호가 있는 steering을 적용한다. α의 부호와 크기에 따라 출력이 parametric 답변과 contextual 답변 사이에서 연속적으로 이동하며, 그 중간에서는 두 답을 섞거나 망설이는 응답이 나타난다(Figure 1).

평가 설계 저자들은 하나의 사실 충돌 설정에서만 방향을 찾으면 그것이 재사용 가능한 제어 메커니즘이 아니라 해당 설정에서만 통하는 **지름길(local shortcut)** 일 수 있다고 보았다. 이를 배제하기 위해 4개의 모델 아키텍처에서 다음과 같이 단계적으로 평가한다.

- **통제된 사실 충돌 설정**: 짧은 프롬프트와 경쟁하는 답변 구조는 유지하면서 사실의 표현 형식(format), 관계 범주(relation category), 데이터셋을 바꾼다.
- **복잡한 task**: 단순 사실 충돌에서 학습한 방향을 그대로 RAG, memory, rule following task에 적용한다.

명시된 contributions

1. 통제된 사실 충돌 벤치마크에서 찾은 **하나의 residual stream 방향**만으로 4개 모델 계열에서 지식 선택을 **양방향·연속적으로 제어**할 수 있음을 보였다.
2. 같은 방향이 context 형식, 지식 범주, 사실 충돌 데이터셋이 달라져도 **다양한 지식 충돌 설정에 걸쳐 일반화**됨을 보였다.
3. 더 중요하게, 이 방향이 **RAG, memory, rule following 같은 복잡한 task의 성능도 향상**시킨다. 저자들은 이를 서로 다른 task가 **외부 지식을 받아들이는 공통된 방향**을 공유할 수 있다는 근거로 해석한다.

Introduction 서술에 대한 평가

주제와 필요성 "LLM은 충돌하는 지식 중 무엇을 믿는가"라는 주제와 그 필요성이 첫 문단에서 명확히 드러난다. 특히 RAG, memory, rule following처럼 실제로 많이 쓰이는 응용을 예로 들어, 지식 충돌이 이론적 호기심에 그치지 않고 실용적으로도 중요한 문제임을 설득력 있게 제시한다.

기존 한계와 제안 방법의 대응 관계 제안 방법은 기존 연구의 한계에 비교적 잘 대응된다.

기존 연구의 한계	제안 방법의 대응
입력 제어는 내부 메커니즘을 직접 제어하지 못함	Residual stream에 직접 개입하여 지식 선택을 제어
내부 개입 방법은 task마다 attribution·feature 탐색 등이 필요	Difference-in-means로 찾은 단일 방향, 단일 층 개입이라는 단순한 구조
단순 사실 데이터셋에서만 평가됨	단순 사실 충돌에서 학습한 방향을 RAG, memory, rule following으로 transfer하여 평가
복잡한 환경에서 robust한 평가 부족	4개 모델 계열, 형식·범주·데이터셋을 바꾼 여러 transfer 설정에서 평가

좋았던 점

- **연구 질문이 명확하다.** 기존 연구의 한계를 정리한 직후 이탤릭체로 연구 질문을 제시하고, 이후 방법론, 평가 설계, contribution이 모두 이 질문에 대한 답으로 이어져 논리 흐름이 깔끔하다.
- **"지름길일 수도 있다"는 반론을 스스로 제기한다.** 한 설정에서 찾은 방향이 우연히 통하는 shortcut일 가능성을 먼저 언급하고, 이를 배제하기 위해 단계적인 일반화 실험을 설계했다고 밝힌다. 주장의 강도에 맞게 검증 범위를 설정했다는 점이 설득력을 높인다.
- **Figure 1, 2가 Introduction의 내용과 잘 대응된다.** Figure 1은 "연속적인 제어"라는 핵심 현상을, Figure 2는 프롬프트 구성 → 층 선택 → 방향 추출 → steering으로 이어지는 방법 전체를 한눈에 보여 준다.
- **기존 interpretability 연구와 자연스럽게 연결한다.** Refusal direction(Arditi et al., 2024) 등 선형 표현 연구의 흐름 위에 "지식 선택"이라는 새로운 개념을 올려놓아, 접근법의 동기가 자연스럽다.

아쉬운 점 / 의문점

- **제목의 질문에 직접 답하지 않는 것으로 보인다.** 제목은 "LLM은 어떤 지식을 믿어야 하는가"이지만, Introduction에서 제시하는 방법은 외부 지식 쪽으로 (또는 반대로) **일관되게 밀어 주는** 방향이다. 실제로는 context가 틀린 경우(예: 잘못된 문서가 검색된 경우)도 많은데, 이때 어느 쪽이 정확한지 판단해 선택하는 문제는 Introduction만 봐서는 다뤄지지 않는다. 첫 문단에서 지적한 "부정확한 출처에 무분별하게 의존하는 문제"와 steering 방향이 어떻게 연결되는지 더 설명이 필요해 보인다.
- **"외부 지식 선호"와 "context sensitivity"의 구분이 모호하다.** 찾은 방향이 정말 "지식 선택"이라는 개념을 표현하는 것인지, 아니면 단순히 "프롬프트 내용에 더 주의를 기울이는 정도"를 표현하는 것인지 Introduction에서는 구분되지 않는다. (본문 4.4절 제목이 "Knowledge Selection Is More Than Context Sensitivity"인 것으로 보아 본문에서 다루는 듯하다.)
- **Steering의 부작용에 대한 언급이 없다.** Context 쪽으로 steering하면 충돌이 없는 일반 질문이나 context가 틀린 경우의 성능이 떨어질 수 있다. Introduction에서는 이러한 trade-off가 언급되지 않는다. (본문 4.5절 "Preserving Performance Without Conflict"에서 다루는 것으로 보인다.)
- **Clean prompt와 conflict prompt의 차이가 "passage 유무"이기도 하다.** 두 프롬프트는 의존하는 지식뿐 아니라 입력 길이, passage 존재 여부도 다르다. 따라서 difference-in-means로 얻은 방향이 지식 선택 외에 "passage가 있다"는 표면적 특성까지 함께 담고 있을 가능성이 있는데, 이를 어떻게 통제했는지 Introduction만으로는 알 수 없다.
- **"4개 모델 계열"의 구체적인 정보가 없다.** 어떤 모델과 규모에서 실험했는지 Introduction에서 밝히지 않아 결과의 일반화 범위를 가늠하기 어렵다.

생각해 볼 질문

- Context가 틀렸을 때는 parametric 쪽으로, 맞을 때는 context 쪽으로 α의 부호를 **입력에 따라 자동으로 정하는** 방법도 가능할까? 그렇다면 이 방향은 "어떤 지식을 믿어야 하는가"라는 제목의 질문에 더 직접적으로 답할 수 있을 것이다.
- RAG, memory, rule following이 "외부 지식을 받아들이는" 공통 방향을 공유한다면, instruction following이나 in-context learning 능력도 같은 방향과 관련이 있을까?

- Refusal direction처럼 이 방향도 모델 규모가 커질수록 더 선형적이고 뚜렷하게 나타날까? (부록 F "Scaling to Larger Models"와 연결해 확인해 볼 만하다.)