

Week10_예습과제_김재희

1. Introduction

2. Approach

    2.1 Model and Architectures

    2.2 Training Dataset

    2.3 Training Process

    2.4 Evaluation

3. Results

    3.1 Language Modeling, Cloze, and Completion Task

    3.2 Closed Book Question Answering

    3.3 Translation

    3.4 Winograd-Style Tasks

    3.5 Common Sense Reasoning

    3.6 Reading Comprehension

    3.7 SuperGLUE

    3.8 NLI

    3.9 Synthetic and Qualitative Tasks

4. Measuring and Preventing Memorization Of Benchmark

5. Limitations

6. Broader Impacts

7. Related Work

8. Conclusion

2005.14165

1. Introduction

최근 몇 년간 자연어 처리 시스템에서는 사전 학습된 언어 표현을 기반으로 한 모델이 주목을 받고 있다. 초기에는 단어 벡터를 사용해 단일 계층 표현을 학습하고 이를 작업별 아키텍

처에 입력했으며, 이후 다중 계층 표현과 문맥 상태를 갖춘 RNN을 사용해 더 강력한 표현을 형성했다. 최근에는 사전 학습된 언어 모델이나 트랜스포머 언어 모델이 직접 파인튜닝되어 작업별 아키텍처의 필요성을 제거했다.

그러나 이 접근 방식의 주요 한계는 아키텍처가 작업에 구애받지 않더라도 여전히 작업별 데이터셋과 작업별 파인튜닝이 필요하다는 것이다. 원하는 작업에서 강력한 성능을 달성하려면 일반적으로 해당 작업에 특화된 수천에서 수십만 개의 예제로 구성된 데이터셋으로 파인튜닝해야 한다. 이 연구에서는 이러한 한계를 제거하고자 한다.

1. 모든 새로운 작업마다 대규모의 레이블이 지정된 예제 데이터셋이 필요하다는 점은 언어 모델의 적용 가능성을 제한한다. 이러한 작업 중 다수는 대규모 지도 학습 데이터셋을 수집하기 어려우며 특히 새로운 작업마다 이 과정을 반복해야 할 때 더욱 그렇다.
2. 사전 학습을 통해 정보를 흡수하도록 설계된 모델이 매우 좁은 작업 분포에서 파인튜닝되는 사전 학습 후 파인튜닝 패러다임에 문제를 일으킬 수 있다. 모델이 학습 분포에 지나치게 특화되어 그 외부에서는 잘 일반화되지 못하기 때문이다. 따라서 특정 벤치마크에서 파인튜닝된 모델의 성능이 명목상 인간 수준이라 하더라고, 이는 실제 작업에서의 성능을 과장한 것일 수 있다.
3. 인간은 대부분의 언어 작업을 배우기 위해 대규모 지도 학습 데이터셋을 필요로 하지 않는다. 자연어로 된 간단한 지시나 아주 적은 수의 시연만으로도 인간이 새로운 작업을 최소한 합리적인 수준의 역량으로 수행할 수 있게 되기에 충분한 경우가 많다.

이러한 문제를 해결하기 위한 방법 중 하나는 메타 학습이다. 모델이 학습 시점에 광범위한 기술과 패턴 인식 능력을 개발하고 추론 시점에 해당 능력을 사용하여 원하는 과제에 빠르게 적응하거나 이를 인식하는 것을 의미한다. 하지만 이 방식은 여전히 파인튜닝보다 낮은 결과를 보여준다. 메타 학습이 언어 과제를 해결하기 위한 실용적은 방법으로 기능하려면 상당한 개선이 필요하다.

또 최근 몇 년 동안 트랜스포머 언어 모델은 170억 개의 파라미터까지 상당히 커졌다. 이 증가는 텍스트 합성 또는 하위 NLP 과제에서의 개선을 가져왔으며 많은 하위 과제와 밀접한 상관관계를 보이는 로그 손실이 규모에 따라 원활한 개선 추세를 따른다는 증거가 존재한다. in-context 학습은 모델의 파라미터 내에 많은 기술과 과제를 흡수하는 것을 포함하므로 이 학습 능력 또한 규모가 커짐에 따라 유사하게 강력한 향상을 보일 가능성이 있다.

본 연구에서는 1,750억 개의 파라미터를 가진 자기회귀 언어 모델인 GPT-3을 학습시키고 이 학습의 in-context 학습 능력을 측정함으로써 해당 가설을 검증한다. 각 작업에 대해 세 가지 조건 하에서 GPT-3을 평가했다. (few-shot 학습, one-shot 학습, zero-shot 학습)

전반적으로 NLP 작업에서 GPT-3는 제로샷 및 원샷 환경에서 유망한 결과를 달성하며 퓨샷 환경에서는 때때로 SOTA와 경쟁하거나 능가하기도 한다.

또 GPT-3는 빠른 적응력이나 즉각적인 추론을 테스트하기 위해 설계된 작업들에서 원샷 및 퓨샷 숙련도를 보여준다. 또 퓨샷 환경에서 GPT-3가 인간 평가자가 인간이 작성한 기사와

구분하기 어려워하는 합성 뉴스 기사를 생성할 수 있음을 보여준다.

2. Approach

본 연구는 Language Models are Unsupervised Multitask Learners의 접근 방식을 계승하되 모델의 크기, 학습 데이터의 규모와 다양성, 그리고 학습 시간을 대폭 늘려 성능을 극대화하는 데 중점을 뒀다.

또 단순히 사전 학습된 모델을 사용하는 것을 넘어, 추론 시 입력 문맥을 어떻게 구성하느냐에 따라 모델이 작업을 얼마나 잘 수행하는지를 체계적으로 분류하고 비교했다.

모델의 범용성을 테스트하기 위해 다음과 같은 4가지 설정으로 평가를 진행했다.

- fine-tuning: 특정 작업 데이터셋을 사용해 모델 가중치를 직접 업데이트하는 전통적인 방식이다. 본 논문에서는 직접 수행하지 않았다.
- few-shot: 모델 가중치를 수정하지 않고, 입력 문맥 안에 작업 예시를 10~100개 포함하여 모델이 스스로 패턴을 파악하게 함. 주요 장점은 작업별 데이터에 대한 필요성을 크게 줄이고 크지만 좁은 범위의 fine-tuning 데이터셋으로부터 지나치게 편향된 분포를 학습할 가능성을 줄인다는 것이다. 해당 연구에서는 특히 few-shot 결과들을 강조하는데, 이는 많은 결과가 최첨단 파인튜닝에 약간 뒤처지는 수준이기 때문이다.
- one-shot: 설명과 함께 단 하나의 예시만 입력으로 제공한다.
- zero-shot: 예시 없이 자연어 설명만으로 모델이 작업을 즉각적으로 수행하도록 요구하는 방법이다.

2.1 Model and Architectures

기본 아키텍처: GPT-3은 이전 버전인 GPT-2의 기본 구조를 그대로 따른다. 여기에는 학습 안정성을 위한 수정된 가중치 초기화, 층별 정규화 방식, 가역 토큰화 기법 등이 포함된다.

어텐션 메커니즘 개선: GPT-2와의 주요 차이점이다. GPT-3에서는 일반적인 dense 어텐션 외에도 국소적으로 밴드화된 희소 어텐션 패턴을 교차로 사용한다.

연구진은 모델 크기가 성능에 미치는 영향을 체계적으로 파악하기 위해 125만 개부터 1,750억 개의 매개변수를 가진 총 8개의 모델을 훈련했다.

실험에서는 scaling laws를 검증했다. 충분한 데이터로 학습할 경우, 모델의 규모가 커짐에 따라 validation loss가 power law를 따르며 감소할 것이라는 예측을 실제 대규모 모델을 통해 확인하고자 했다.

2.2 Training Dataset

연구진은 데이터의 품질을 높이기 위해 세 가지 접근 방식을 취했다.

1. Common Crawl 데이터 정제

해당 데이터는 양적으로는 매우 방대하지만 품질이 낮고 노이즈가 많다는 단점이 있다.

연구진은 고품질의 참조 코퍼스와의 유사성을 계산하여 필터링을 수행함으로써 학습 데이터의 평균적인 질을 개선했다.

2. 중복 제거

서 수준에서 퍼지 중복 제거를 수행했다. 이는 데이터셋 내부는 물론 외부 데이터셋 간에도 중복되는 텍스트를 제거하는 과정이다.

이 과정을 통해 모델이 동일한 데이터를 반복 학습하여 발생하는 과적합을 방지하고 검증 데이터셋의 신뢰도를 확보했다.

3. 고품질 코퍼스 혼합

Common Crawl만 사용하는 대신 WebText2, Books1, Books2, Wikipedia와 같이 엄선된 고품질 데이터를 학습 믹스에 추가했다.

각 데이터셋의 가중치를 다르게 설정하여 품질이 높다고 판단되는 데이터는 학습 과정에서 여러 번(2~3회) 노출되도록 하고 일반적인 Common Crawl 데이터는 오히려 한 번 미만으로 노출되도록 조정했다.

2.3 Training Process

- 배치 크기와 학습률의 관계: 선행 연구인 Scaling Laws for Neural Language Models와 RL2^22를 참고하여 모델의 크기가 커질수록 더 큰 배치 크기를 사용할 수 있지만 학습률은 더 낮게 설정해야 한다는 점을 활용했다.
- 그레디언트 노이즈 스케일: 최적의 배치 크기를 결정하기 위해 학습 도중 그레디언트 노이즈 스케일을 측정하여 이를 지표로 삼았다. 이는 대규모 모델 학습에서 효율적인 수렴을 돕기 위한 전략이다.
- 모델 병렬화(Model Parallelism): 1750억 개의 매개변수를 가진 GPT-3를 하나의 GPU에 담을 수 없기 때문에 연산 효율을 위해 모델을 여러 GPU에 분산하여 처리했다. 구체적으로는 행렬 곱셈 내에서의 연산 병렬화와 네트워크 층 간의 병렬화를 혼합하여 메모리 부족 문제를 해결했다.
- 컴퓨팅 환경: Microsoft에서 제공하는 고대역폭 클러스터의 V100 GPU를 활용하여 학습이 진행되었다.

2.4 Evaluation

- Few-shot 학습의 평가 절차
  평가 대상이 되는 각 예제에 대해 해당 작업의 학습 데이터셋에서 무작위로 K개의 예제를 추출한다.
  이 K개의 예제들은 모델에게 일종의 참고 자료로 제공된다.

예제들 사이는 줄바꿈을 사용하여 구분하며 이를 통해 모델이 무엇을 해야 하는지를 문맥 내에서 파악하게 한다.

- 데이터셋별 특수 상황
  LAMBADA, StoryCloze: 일반적인 의미의 지도 학습 데이터셋이 없으므로 개발 세트에서 참고 예제를 추출하여 테스트 세트를 평가한다.
  Winograd (Original): 단일 데이터셋으로 구성되어 있어,해당 데이터셋 내에서 직접 참고 예제를 추출한다.
- 평가 메커니즘의 핵심
  이 방식은 모델의 파라미터를 변경하는 미세 조정을 완전히 배제한다.
  대신 입력 시퀀스 내에 포함된 정보만을 바탕으로 다음 단어를 예측하게 함으로써 모델의 문맥 내 학습 능력을 정밀하게 측정한다.

3. Results

3.1 Language Modeling, Cloze, and Completion Task

언어 모델링(Language Modeling)의 의미: 가장 기본적인 언어적 지능을 측정하는 작업이다. 주어진 문맥 다음에 올 적절한 단어나 문장을 확률적으로 예측하며 PTB와 같은 전통적인 데이터셋을 통해 모델이 얼마나 유창하고 정확하게 문장을 생성하는지 검증한다.
Cloze 및 완성 작업의 활용:
Cloze 작업: 문장 중간에 빈칸을 두고 알맞은 단어를 맞히는 방식이다.
완성 작업: 불완전한 문장이나 문단을 제시하고 모델이 문맥을 파악하여 뒷내용을 논리적으로 이어가는 작업이다.

평가 방식의 확장: 단순히 단어를 맞히는 것을 넘어 문맥 내 학습 능력을 활용한다. 예를 들어, LAMBADA 데이터셋의 경우 단순히 문장의 마지막 단어를 예측하는 것뿐만 아니라 few-shot 방식을 통해 빈칸에 들어갈 단어는 무엇인가?와 같은 형식으로 작업을 정의하여 모델의 적응력을 극대화했다.
데이터 오염 관리: 논문은 훈련 데이터와 평가 데이터 간의 중복 문제를 민감하게 다룬다. PTB와 같은 오래된 데이터셋은 훈련 데이터에 포함되지 않았을 가능성이 높아 순수한 성능 지표로 활용되지만 Wikipedia 등에서 파생된 데이터는 훈련 시 노출되었을 가능성이 커 평가에서 제외하거나 엄격히 관리한다.

3.2 Closed Book Question Answering

핵심 개념: 일반적인 질의응답 시스템은 외부 데이터베이스나 검색 엔진에서 관련 텍스트를 찾아 모델에게 제공하는 Open-book 방식을 사용한다. 반면 폐쇄 도서 방식은 모델이 학습 과정에서 습득한 정보를 바탕으로 스스로 답을 생성해야 하므로 더 높은 수준의 언어 모델 능력을 요구한다.
왜 어려운가: 질문의 범위가 매우 광범위하고 모델이 학습한 내용 이외의 정보는 전혀 얻을

수 없기 때문에 모델의 지식 보유량과 추론 능력이 성능을 결정짓는 핵심 요소가 된다.
GPT-3의 도전: 이 논문에서는 GPT-3가 별도의 미세 조정 없이도 학습된 지식만으로 기존의 복잡한 QA 시스템과 대등하거나 능가하는 성능을 보일 수 있음을 증명하려 한다.
성능 평가: TriviaQA, WebQuestions, Natural Questions 등의 벤치마크를 통해 모델 크기가 커짐에 따라 폐쇄 도서 환경에서의 지식 검색 및 답변 능력이 얼마나 매끄럽게 확장되는지를 측정한다.

3.3 Translation

학습 환경의 차이: 기존의 비지도 기계 번역은 단일 언어 데이터셋과 역번역 기술을 조합하여 모델을 학습시킨다. 반면 GPT-3는 다양한 언어가 섞인 거대한 데이터셋을 단일 목표로 학습하며 번역을 위한 별도의 사용자 정의 설계가 없다.
Zero-shot vs. Few-shot 성능:
Zero-shot: 오직 자연어로 된 작업 지시만 주어질 경우 최신 비지도 기계 번역 결과보다 낮은 성능을 보인다.
Few-shot: 단 1개에서 64개의 예시만 입력으로 주어져도 성능이 급격히 향상된다. 특히 영어로 번역하는 방향에서 비지도 학습 SOTA 모델들을 뛰어넘거나 경쟁력 있는 성능을 보여준다.

모델 규모와 성능의 비례: 언어 쌍과 상관없이 모델의 크기가 커질수록 번역 성능이 매끄럽게 상승하는 경향을 보인다. 이는 모델의 파라미터가 더 많은 지식과 언어적 패턴을 흡수했음을 시사한다.
한계점: 영어 중심의 학습 데이터 비율 때문에 반대 방향의 번역이나 특정 언어 쌍에서는 여전히 성능 개선의 여지가 크다. 특히 과거 GPT-2에서 사용된 Byte-level BPE tokenizer를 그대로 재사용했기 때문에 영어 이외의 언어 처리에서 제약이 발생할 수 있다.

3.4 Winograd-Style Tasks

Winograd Schema Challenge (WSC)의 정의: 이 과제는 대명사가 문법적으로는 모호하지만 인간에게는 문맥상 어떤 명사를 가리키는지 명확한 문장들을 해결하는 능력. 예를 들어 "트로피가 가방에 들어가지 않았다. 왜냐하면 그것이 너무 컸기 때문이다"라는 문장에서 '그것'이 트로피인지 가방인지 파악하는 논리적 추론이 필요하다.
기존 연구와의 차별점: 과거에는 이러한 과제를 풀기 위해 특정한 데이터셋으로 모델을 미세 조정해야 했으나 이 논문은 별도의 학습 없이 Zero-shot, One-shot, Few-shot 설정만으로도 모델이 뛰어난 성능을 보일 수 있음을 입증하고자 한다.
평가 결과:
기존의 Winograd Schema Challenge에서는 GPT-3가 88% 이상의 정확도를 기록하며 최첨단 모델 및 인간의 수행 능력과 매우 근접한 결과를 보여주었다.
더 어려운 버전인 Winogrande 데이터셋에서도 GPT-3는 Few-shot 설정에서 77.7%의 성능을 기록하며 기존의 미세 조정된 모델들과 경쟁할 만한 수준의 능력을 보여주었다.

결론: 모델의 크기가 커질수록 Few-shot 학습을 통한 성능 향상이 두드러지며 이는 대규모 언어 모델이 단순히 단어를 암기하는 것이 아니라 문맥 내에서 패턴을 파악하여 상식적 추론을 수행할 수 있는 잠재력을 가졌음을 시사한다.

3.5 Common Sense Reasoning

PhysicalQA (PIQA): 물리적 세계가 어떻게 작동하는지에 대한 질문을 통해 모델이 세계에 대한 기초적 이해를 갖추고 있는지 테스트한다. GPT-3는 이 과제에서 zero-shot, one-shot, few-shot 모든 설정에서 이전의 fine-tuned RoBERTa 모델보다 뛰어난 성능을 보이며 SOTA를 기록했다.
ARC (AI2 Reasoning Challenge): 3학년에서 9학년 수준의 과학 시험 문제들로 구성된 데이터셋. Challenge버전과 Easy 버전으로 나뉘는데 GPT-3는 Easy 버전에서 fine-tuned RoBERTa와 대등하거나 약간 앞서는 성능을 보였으나 Challenge 버전에서는 UnifiedQA와 같은 특화 모델들에 비해 여전히 큰 격차를 보였다.
OpenBookQA: 초등학교 수준의 과학 교과서 지식을 기반으로 한 질문들로 모델이 외부 지식과 추론을 결합할 수 있는지 평가한다. GPT-3는 설정에 따라 성능 향상을 보였으나 여전히 최고 수준의 모델들과는 차이가 있다.

3.6 Reading Comprehension

다양한 형식의 데이터셋 활용: GPT-3의 독해 능력을 입증하기 위해 요약형, 객관식, 범위 기반 정답 형식 등 총 5개의 데이터셋을 활용했다. 또한, 단순한 단일 질문뿐만 아니라 대화형 질문 환경까지 포함하여 평가의 폭을 넓혔다.
성능의 편차: 데이터셋마다 GPT-3가 보여주는 성능 차이가 크다. 이는 모델이 문제의 형식이나 대화의 구조에 따라 정보를 파악하는 능력에 차이가 있음을 시사한다.
주요 결과:
CoQA: 대화형 데이터셋으로 GPT-3는 사람의 평가 결과와 불과 3점 정도의 차이만을 보이는 뛰어난 성능을 기록했다.
QuAC: 교사와 학생의 대화 구조를 이해해야 하는 이 데이터셋에서는 기존의 ELMo 기반 모델보다 성능이 낮게 나타나 복잡한 대화 흐름 파악에 한계가 있음을 보여주었다.
DROP: 수치적 계산과 논리적 추론이 필요한 데이터셋에서는 기존 BERT 기반 모델을 상회했으나기호 시스템을 결합한 최신 기술과는 여전히 격차가 있었다.
SQuAD 2.0: Few-shot 학습을 통해 성능이 크게 향상되었으며 기존의 Fine-tuned 방식 모델보다도 우수한 성적을 거두었다.
RACE: 중·고등학교 수준의 영어 시험 데이터셋에서는 최신 모델(SOTA) 대비 약 45% 낮은 성능을 보이며 전반적인 독해 모델들 중 초창기 수준에 머물렀다.

3.7 SuperGLUE

SuperGLUE는 기존의 자연어 이해 벤치마크인 GLUE의 후속으로 훨씬 더 어렵고 도전적인 과제들로 구성된 표준화된 데이터셋 모음이다.

질문 답변, 상식 추론, 문장 간 관계 파악, 의미론적 유사성 등 언어 모델의 복합적인 추론 능력을 평가하는 8가지 하위 작업들로 이루어져 있다.
단순한 패턴 매칭을 넘어선 고도의 언어 이해력을 요구하기 때문에 현대 NLP 모델의 성능을 비교하는 가장 중요한 기준 중 하나로 사용된다.

GPT-3의 평가 방식:

이 논문에서는 GPT-3의 Few-shot 학습 능력을 증명하기 위해 각 작업당 32개의 예시를 문맥으로 제공하여 별도의 미세 조정 없이 바로 평가를 진행했다.
이는 기존 모델들이 방대한 데이터로 개별 작업을 훈련했던 것과는 대조적인 방식으로 모델이 학습한 사전 지식만으로 얼마나 작업을 잘 수행할 수 있는지 측정하는 데 초점을 둔다.

3.8 NLI

NLI의 정의: NLI는 두 문장 사이의 논리적 관계를 이해하는 능력을 평가하는 작업이다. 일반적으로 첫 번째 문장이 주어졌을 때, 두 번째 문장(가설)이 첫 번째 문장을 논리적으로 함의하는지, 모순되는지, 혹은 중립인지를 분류하는 문제로 구성된다.
성능 평가:
이 연구에서는 SuperGLUE의 일부인 RTE 데이터셋과 더 어려운 ANLI 데이터셋을 사용하여 성능을 평가했다.
ANLI는 모델을 속이기 위해 설계된 적대적 질문들이 포함된 3단계의 데이터셋이다.

주요 결과:
GPT-3 모델들 중 가장 규모가 큰 모델조차도 NLI 작업에서는 상당히 어려움을 겪는 것으로 나타났다.
대부분의 작은 모델들은 Few-shot 설정에서도 랜덤 추측 수준의 성능을 보였으며 175B 매개변수를 가진 GPT-3만이 ANLI Round 3에서 어느 정도 유의미한 성능을 보이기 시작했다.

시사점: NLI는 언어 모델이 단순히 문장의 표면적인 패턴을 학습하는 것을 넘어 문장 간의 깊은 논리적 맥락을 파악해야 하므로 언어 모델에게 매우 어려운 과제임을 시사한다.

3.9 Synthetic and Qualitative Tasks

평가 목적: 기존의 정형화된 NLP 벤치마크를 넘어 모델이 낯선 규칙을 즉석에서 파악하고 연산이나 논리적 추론을 수행할 수 있는지 확인한다.
검증 방식: Few-shot, One-shot, Zero-shot 설정을 모두 활용하여 모델이 소수의 예시만으로 얼마나 빠르게 새로운 작업 패턴을 습득하는지 측정한다.
주요 실험 과제:
산술 연산: 2~5자리 수의 덧셈, 뺄셈, 곱셈 등 기초적인 계산 능력을 테스트한다. 이는 모델이 단순히 텍스트 패턴을 암기하는 것을 넘어 실제로 계산 규칙을 이해하고 있는지 확인하는 척도가 된다.
단어 조작: 단어의 철자를 뒤섞거나 특정 글자를 삽입/삭제하는 과제를 통해 모델의 BPE 토

큰 단위 너머의 문자 수준 이해도를 시험한다.
SAT 유추: 단어 간의 관계를 파악해야 하는 SAT 유형의 문제를 통해 고차원적인 언어적 추론 능력을 평가한다.
정성적 평가: 새로운 단어를 정의하고 이를 활용해 문장을 만드는 과제나 문법 교정, 뉴스 기사 생성 등을 통해 인간 수준의 작문 능력을 정성적으로 확인한다.

4. Measuring and Preventing Memorization Of Benchmark

데이터 오염 문제: 모델의 사전 학습 데이터셋은 웹 크롤링을 통해 수집된다. 이 과정에서 테스트셋이나 개발셋에 포함된 문장들이 학습 데이터에 섞여 들어갈 수 있으며, 모델이 이를 기억하여 평가 시 높은 점수를 기록하는 오염 현상이 발생할 수 있다.
연구의 어려움: 인터넷 규모의 데이터셋에서 특정 벤치마크 데이터가 포함되어 있는지 완벽하게 식별하는 것은 매우 어렵다. 아직 학계에 정립된 표준 관행이 없기 때문이다.
GPT-3의 접근 방식:
연구진은 가능한 한 학습 데이터와 평가 데이터 간의 중복을 사전에 제거하려 했으나 처리 과정의 버그로 인해 완벽하게 수행하지 못했다.
따라서 보수적인 방식으로 13-gram 이상의 중복이 발견되는 예시를 오염된 데이터로 간주하고 이를 제외한 클린 버전 데이터셋에서 모델을 다시 평가했다.

결론: 대부분의 벤치마크에서 전체 데이터셋 점수와 클린 데이터셋 점수 사이에 큰 차이가 없음을 확인했다. 이는 모델의 성능 향상이 단순히 데이터 기억에 의한 것이 아니라 모델의 구조적 학습 능력과 규모 확장에 따른 일반화 능력임을 시사한다.

5. Limitations

텍스트 생성의 품질 및 논리적 오류: GPT-3는 인간이 작성한 글과 구별하기 어려운 수준의 텍스트를 생성하지만, 여전히 반복적인 문장 사용, 논리적 비약, 그리고 사실관계가 틀린 내용을 생성하는 경우가 있다. 특히 모델이 학습 과정에서 참조한 구체적인 사실관계에 접근할 수 없기 때문에 발생하는 현상이다.
복잡한 언어 작업의 어려움: 문장 간의 관계를 파악해야 하는 작업이나 두 문장의 의미 동일성 여부를 판단하는 작업에서 상대적으로 낮은 성능을 보인다. 이는 모델이 문장 수준의 미세한 의미 차이나 복잡한 추론을 수행하는 데 있어 여전히 한계가 있음을 시사한다.
데이터 오염 문제: 인터넷 데이터를 대규모로 수집하여 학습함에 따라 벤치마크 테스트셋이 학습 데이터에 포함될 가능성이 높다. 이는 모델의 성능을 실제보다 과대평가하게 만들 수 있으며 본 논문에서도 이를 방지하기 위해 필터링을 시도했으나 완벽하게 차단하지 못한 사례가 존재함을 인정했다.
구조적 한계: 이전 모델인 GPT-2의 아키텍처를 스케일업하는 방식을 취했기 때문에 모델 구조 자체가 가진 근본적인 한계는 여전히 존재한다.

사회적 영향 및 편향성: 거대 언어 모델이 가진 일반적인 문제인 사회적 편향성과 유해한 텍스트 생성 가능성은 GPT-3에서도 여전히 해결해야 할 과제로 남아 있다.

6. Broader Impacts

잠재적 오용: GPT-3의 뛰어난 텍스트 생성 능력은 사람과 구분하기 어려운 가짜 뉴스, 혐오 표현, 혹은 자동화된 설득 캠페인 등을 생성하는 데 악용될 위험이 있다. 논문은 이러한 기술이 사회적 혼란을 야기할 가능성을 경고한다.
공정성, 편향성 및 표현:
GPT-3는 인터넷상의 방대한 데이터를 학습했기 때문에 데이터 속에 포함된 성별, 인종, 종교 등에 관한 고정관념이나 편견을 그대로 습득할 위험이 있다.
논문은 모델이 특정 인구 통계학적 그룹에 대해 차별적이거나 편향된 출력을 생성할 수 있음을 인정하고 이를 개선하기 위한 연구가 필요함을 강조한다.

에너지 사용:
1750억 개의 매개변수를 가진 GPT-3와 같은 초거대 모델을 학습시키는 데는 엄청난 양의 연산 자원과 전력이 소모된다.
이는 환경에 미치는 영향뿐만 아니라 모델의 접근성을 특정 거대 기업으로 제한하여 기술적 불평등을 초래할 수 있다는 점도 시사한다.

연구 발전 방향과의 연결:
이 논문은 모델의 크기가 커짐에 따라 인간이 생성한 텍스트와의 구별이 점점 어려워짐을 입증했다. 이러한 결과는 이후 연구들이 **AI Agents Under Threat**와 같은 보안 강화 연구나 **COMPL-AI Framework**와 같이 AI의 윤리적 사용을 규제하기 위한 정책적 프레임워크를 개발하는 데 중요한 근거가 되었다. 모델의 능력이 향상될수록 이를 관리하고 통제할 수 있는 안전장치 연구가 더욱 중요해지고 있다.

7. Related Work

- **모델 효율화의 중요성**: 거대 모델을 직접 사용하는 것은 비용과 자원 소모가 크기 때문에 **Model Distillation**과 같은 기술을 통해 성능은 유지하면서도 더 효율적인 버전을 만드는 방식이 중요해졌다. 이는 큰 모델을 학습시킨 뒤 실제 서비스 환경에 맞는 최적화된 모델을 배포하는 전략을 제안한다.
- **알고리즘적 진보**: 이미지 인식이나 신경망 기계 번역에서 나타난 것처럼 알고리즘 개선을 통해 모델의 연산 효율성을 높이는 연구가 지속적으로 이루어지고 있다.
- **규모의 확장**: 모델의 매개변수와 연산량을 늘리는 것이 성능 향상의 핵심적인 방법론으로 자리 잡았다. 과거에는 LSTM 기반의 모델을 10억 개 이상의 매개변수로 확장하려는 시도가 있었으며 최근에는 **Transformer** 아키텍처를 기반으로 매개변수와 FLOPS를 비례하여 확장하는 연구가 주류를 이룬다.

8. Conclusion

효율성 개선: GPT-3는 거대한 자원을 요구한다. 이를 개선하기 위해 Distilling the Knowledge in a Neural Network와 같이 지식 증류 기술을 통해 작은 모델로 큰 모델의 성능을 모사하거나 최신 경량화 기법을 적용하는 연구들이 활발하다.
지시 학습으로의 진화: GPT-3는 다음 단어 예측이 기본 목적이었으나 이후 연구들은 사용자의 의도를 더 잘 이해하도록 지시 기반의 데이터셋으로 미세 조정한 모델로 발전했다.
추론 능력의 강화: GPT-3가 보여준 즉석 학습능력을 넘어 논리적 추론이나 단계적 사고를 더욱 강화하려는 노력이 이어지고 있다.