

# 11/17 논문 - Chain-of-Thought Prompting Elicits Reasoning in Large Language Models

논문 원문: Chain-of-Thought Prompting Elicits Reasoning in Large Language Models

## 1. Introduction

### 논문이 다루는 분야

**[NLP]**

**- LLM의 추론 능력, In-context Learning, Chain-of-Thought Prompting**

**1. 추론(Reasoning)**

문제의 조건과 지식을 연결해 답을 도출하는 능력. 이 논문은 산술 추론, 상식 추론, 기호 추론을 다룬다.

- 산술 추론: 문장 속 수량 관계를 해석하고 여러 단계로 계산.
- 상식 추론: 배경지식을 연결해 타당성을 판단.
- 기호 추론: 정해진 규칙에 따라 글자를 조작하거나 상태를 추적.

**2. In-context Learning / Few-shot Prompting**

모델 가중치를 업데이트하지 않고 프롬프트에 소수의 예시를 넣어 과제 수행을 유도한다.

**3. Chain of Thought(CoT)**

최종 답에 도달하기까지 생성하는 일련의 중간 추론 단계. 일반적인 질문–정답 예시를 질문–풀이 과정–정답으로 확장한다.

⇒ 충분히 큰 언어 모델에 풀이 과정이 포함된 예시를 몇 개 보여주면, 추가 학습 없이 복잡한 추론 능력을 이끌어낼 수 있을까?

## 해당 task에서 기존 연구 한계점

1. **모델 크기 증가만으로는 부족:** 일반적인 prompting에서 일부 추론 과제는 모델을 키워도 성능 향상이 제한적이다.
2. **풀이 과정 데이터 구축 비용:** 기존 rationale 기반 학습은 대규모 고품질 풀이 주석과 추가 학습이 필요하다. 질문–정답보다 풀이 과정을 작성하는 일이 더 복잡하다.
3. **Standard few-shot의 한계:** 정답만 보여주면 문제를 어떤 단계로 분해해야 하는지 예시에서 직접 확인하기 어렵다.

⇒ 자연어 풀이의 장점과 few-shot learning의 장점을 결합하면서, 대규모 주석과 fine-tuning 부담을 줄일 필요가 있다.

## 논문의 contributions

1. **CoT prompting 제안:** 〈입력, 중간 추론 과정, 출력〉 예시만으로 단계적 문제 해결을 유도.
2. **다양한 추론 영역 검증:** 산술·상식·기호 추론에서 효과를 확인.
3. **규모에 따른 효과 분석:** 충분히 큰 모델에서 효과가 두드러지고 작은 모델에서는 오히려 성능이 하락할 수 있음을 보임.
4. **추가 학습 없는 높은 성능:** PaLM 540B는 8개 CoT 예시로 GSM8K 56.9%를 기록. Standard 17.9% 대비 +39.0%p.
5. **Ablation·강건성 분석:** 출력 길이, 수식, 설명 순서, 예시 작성자와 구성의 영향을 비교.

# 2. Related Work

### 1. 자연어 풀이 기반 추론

풀이 과정을 생성하도록 모델을 학습하거나 fine-tuning한다. Cobbe 등은 GSM8K와 verifier를 활용한다. 본 논문은 소수의 풀이 예시를 프롬프트에 넣으며 추가 학습을 하지 않는다는 점이 다르다.

### 2. Few-shot / Instruction-based 접근

질문–정답 예시나 과제 지시를 통해 수행 능력을 끌어낸다. 기존 접근이 입력의 지시와 표현을 개선했다면, CoT는 예시의 출력 부분을 중간 추론까지 확장한다.

### 3. Scratchpad와 프로그램 실행

프로그램의 최종 결과를 바로 예측하지 않고 중간 계산을 생성한다. CoT는 자연어를 활용해 수학 외에도 상식 판단 등으로 적용 범위를 넓힌다.

### 4. Natural Language Explanations(NLE)

기존 NLE는 예측과 동시에 또는 예측 이후 설명을 생성해 해석가능성을 높이는 데 주로 관심을 둔다. CoT는 최종 답 이전에 중간 단계를 생성해 과제 성능을 높이는 것이 주목적이다. 생성된 설명이 내부 계산에 충실하다는 보장은 없다.

**5. 기호·신경기호 추론**

수식·프로그램·실행 가능한 연산을 사용하는 연구와 관련된다. 자연어는 적용 범위가 넓지만 형식적으로 검증된 정확성을 보장하지 않는다.

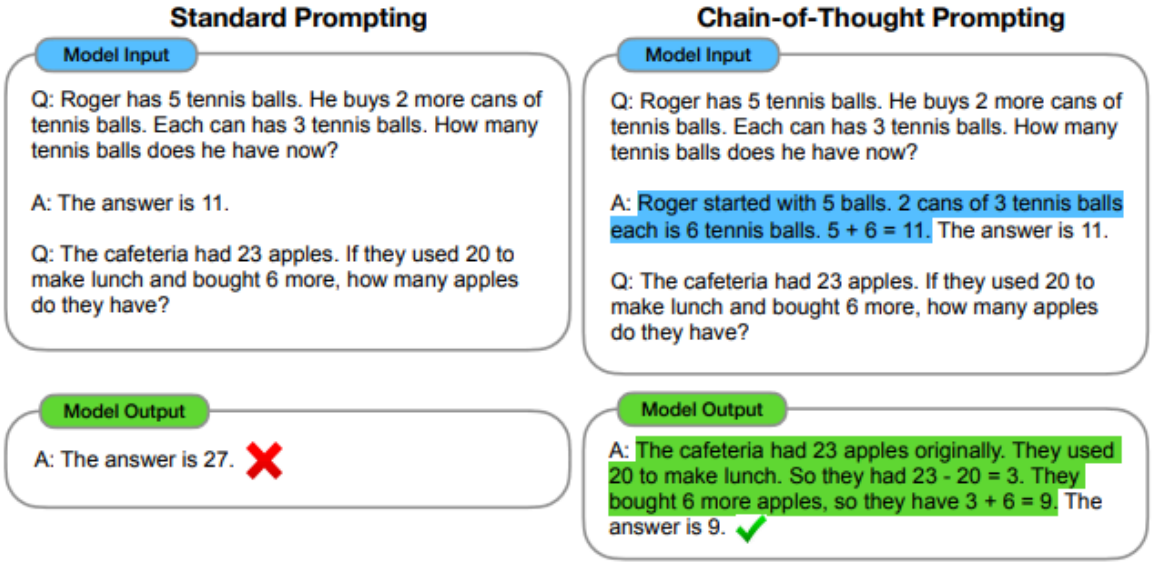
# 3. 제안 방법론

## Main Idea

**정답만 보여주는 대신, 정답에 도달하는 풀이 과정까지 예시로 제공한다.**

| 방식 | 예시 구성 | 모델 출력 |
|---|---|---|
| Standard prompting | 질문 → 정답 | 최종 답 |
| CoT prompting | 질문 → 중간 풀이 → 정답 | 중간 풀이 후 최종 답 |

**예시**




**절차**

1. 소수의 예시 문제를 준비한다.
2. 각 예시에 중간 추론 과정과 정답을 작성한다.
3. 예시들을 프롬프트에 넣고 새로운 질문을 추가한다.

4. 모델이 중간 추론을 생성한 뒤 최종 답을 출력한다.

모델의 가중치는 업데이트하지 않는다. 본 논문의 핵심은 풀이 예시를 제공하는 few-shot CoT이며, 예시 없이 지시문만 사용하는 zero-shot CoT와 구분한다.

### Contribution

1. **문제 분해:** 복잡한 문제를 작은 단계로 나누고 이전 단계의 결과를 다음 단계의 문맥으로 활용한다.
2. **추가 계산:** 중간 토큰을 생성하며 더 많은 계산을 수행할 수 있다. 다만 생성량만 늘려서는 동일한 효과가 나지 않는다.
3. **오류 분석 단서:** 문제 이해, 숫자 대응, 계산, 단계 누락 등을 출력에서 점검할 수 있다.
4. **범용성:** 자연어 중간 단계를 통해 산술·상식·기호 조작으로 확장한다.
5. **학습 효율:** 별도의 과제별 fine-tuning 없이 하나의 모델을 활용한다.

## 4. 실험 및 결과

### Dataset

| 영역 | Dataset | 평가 내용 |
|---|---|---|
| 산술 | GSM8K (1,319문항) | 여러 단계의 초등 수학 문장제 |
| 산술 | SVAMP (1,000) | 표현과 구조를 변화시킨 문장제 |
| 산술 | ASDiv (2,096) | 다양한 유형·표현의 문장제 |
| 산술 | AQuA (254) | 객관식 대수 문장제 |
| 산술 | MAWPS | SingleOp·SingleEq·AddSub·MultiArith |
| 상식 | CSQA | 배경지식과 의미 이해 |
| 상식 | StrategyQA | 여러 지식을 연결하는 Yes/No 판단 |
| 상식 | Date Understanding | 기준 날짜 추론과 날짜 계산 |
| 상식 | Sports Understanding | 선수·종목·동작 조합의 타당성 |
| 상식·계획 | SayCan | 자연어 요청을 로봇 행동 계획으로 변환 |
| 기호 | Last Letter Concatenation | 각 단어의 마지막 글자 연결: Amy Brown → yn |
| 기호 | Coin Flip | 뒤집기 여부를 구분하고 최종 동전 상태 추적 |

### Baseline

- **Standard few-shot:** 동일 모델에 질문–정답 쌍만 제공하는 핵심 기준선.
- **기존 지도학습 결과:** 과제별 학습·fine-tuning 및 verifier 활용 연구와 비교. 학습 조건이 다름에 유의.
- **Equation only:** 자연어 풀이 대신 수식만 중간 단계로 제공.
- **Variable compute only:** 의미 있는 풀이 대신 점 기호를 생성해 추가 생성량의 영향을 분리.
- **Reasoning after answer:** 정답을 먼저 출력하고 설명을 나중에 생성.

### 실험 설정

LaMDA, GPT 계열, PaLM, UL2 20B, Codex를 평가한다. GPT 파라미터 수는 논문에서 추정·표기한 값이다. 산술은 AQuA를 제외하고 공통 8개 예시, AQuA는 4개 예시를 사용한다. 기본 생성은 greedy decoding이며 추가 fine-tuning은 없다. LaMDA는 예시 순서를 바꾼 5개 seed 평균, 다른 모델의 주요 결과는 단일 순서다. Self-consistency 다수결은 후속 연구로 언급되며 기본 실험과 구분한다.

## 결과

### ① 산술 추론 — PaLM 540B (Appendix Table 1·2)

Table 1: Chain of thought prompting outperforms standard prompting for various large language models on five arithmetic reasoning benchmarks. All metrics are accuracy (%). Ext. calc.: post-hoc external calculator for arithmetic computations only. Prior best numbers are from the following. *a*: Cobbe et al. (2021). *b* & *e*: Pi et al. (2022), *c*: Lan et al. (2021), *d*: Piękos et al. (2021).

| | Prompting | GSM8K | SVAMP | ASDiv | AQuA | MAWPS |
|---|---|---|---|---|---|---|
| Prior best | N/A (finetuning) | 55[a] | 57.4[b] | 75.3[c] | 37.9[d] | 88.4[e] |
| UL2 20B | Standard | 4.1 | 10.1 | 16.0 | 20.5 | 16.6 |
| | Chain of thought | 4.4 (+0.3) | 12.5 (+2.4) | 16.9 (+0.9) | 23.6 (+3.1) | 19.1 (+2.5) |
| | + ext. calc | 6.9 | 28.3 | 34.3 | 23.6 | 42.7 |
| LaMDA 137B | Standard | 6.5 | 29.5 | 40.1 | 25.5 | 43.2 |
| | Chain of thought | 14.3 (+7.8) | 37.5 (+8.0) | 46.6 (+6.5) | 20.6 (-4.9) | 57.9 (+14.7) |
| | + ext. calc | 17.8 | 42.1 | 53.4 | 20.6 | 69.3 |
| GPT-3 175B (text-davinci-002) | Standard | 15.6 | 65.7 | 70.3 | 24.8 | 72.7 |
| | Chain of thought | 46.9 (+31.3) | 68.9 (+3.2) | 71.3 (+1.0) | 35.8 (+11.0) | 87.1 (+14.4) |
| | + ext. calc | 49.6 | 70.3 | 71.1 | 35.8 | 87.5 |
| Codex (code-davinci-002) | Standard | 19.7 | 69.9 | 74.0 | 29.5 | 78.7 |
| | Chain of thought | 63.1 (+43.4) | 76.4 (+6.5) | 80.4 (+6.4) | 45.3 (+15.8) | 92.6 (+13.9) |
| | + ext. calc | 65.4 | 77.0 | 80.0 | 45.3 | 93.3 |
| PaLM 540B | Standard | 17.9 | 69.4 | 72.1 | 25.2 | 79.2 |
| | Chain of thought | 56.9 (+39.0) | 79.0 (+9.6) | 73.9 (+1.8) | 35.8 (+10.6) | 93.3 (+14.2) |
| | + ext. calc | 58.6 | 79.8 | 72.6 | 35.8 | 93.5 |

Table 2: Standard prompting versus chain of thought prompting on five arithmetic reasoning benchmarks. Note that chain of thought prompting is an emergent ability of model scale—it does not positively impact performance until used with a model of sufficient scale.

| | | GSM8K | | SVAMP | | ASDiv | | AQuA | | MAWPS | |
|---|---|---|---|---|---|---|---|---|---|---|---|
| Model | | standard | CoT | standard | CoT | standard | CoT | standard | CoT | standard | CoT |
| UL2 | 20B | 4.1 | **4.4** | 10.1 | **12.5** | 16.0 | **16.9** | 20.5 | **23.6** | 16.6 | **19.1** |
| LaMDA | 420M | 2.6 | 0.4 | 2.5 | 1.6 | 3.2 | 0.8 | 23.5 | 8.3 | 3.2 | 0.9 |
| | 2B | 3.6 | 1.9 | 3.3 | 2.4 | 4.1 | 3.8 | 22.9 | 17.7 | 3.9 | 3.1 |
| | 8B | 3.2 | 1.6 | 4.3 | 3.4 | 5.9 | 5.0 | 22.8 | 18.6 | 5.3 | 4.8 |
| | 68B | 5.7 | **8.2** | 13.6 | **18.8** | 21.8 | **23.1** | 22.3 | 20.2 | 21.6 | **30.6** |
| | 137B | 6.5 | **14.3** | 29.5 | **37.5** | 40.1 | **46.6** | 25.5 | 20.6 | 43.2 | **57.9** |
| GPT | 350M | 2.2 | 0.5 | 1.4 | 0.8 | 2.1 | 0.8 | 18.1 | 8.7 | 2.4 | 1.1 |
| | 1.3B | 2.4 | 0.5 | 1.5 | 1.7 | 2.6 | 1.4 | 12.6 | 4.3 | 3.1 | 1.7 |
| | 6.7B | 4.0 | 2.4 | 6.1 | 3.1 | 8.6 | 3.6 | 15.4 | 13.4 | 8.8 | 3.5 |
| | 175B | 15.6 | **46.9** | 65.7 | **68.9** | 70.3 | **71.3** | 24.8 | **35.8** | 72.7 | **87.1** |
| Codex | - | 19.7 | **63.1** | 69.9 | **76.4** | 74.0 | **80.4** | 29.5 | **45.3** | 78.7 | **92.6** |
| PaLM | 8B | 4.9 | 4.1 | 15.1 | **16.8** | 23.7 | **25.2** | 19.3 | **21.7** | 26.2 | **30.5** |
| | 62B | 9.6 | **29.9** | 48.2 | 46.7 | 58.7 | **61.9** | 25.6 | 22.4 | 61.8 | **80.3** |
| | 540B | 17.9 | **56.9** | 69.4 | **79.0** | 72.1 | **73.9** | 25.2 | **35.8** | 79.2 | **93.3** |

⇒ 복잡한 다단계 문제에서 향상이 크다. MAWPS의 쉬운 SingleOp는 94.1% → 94.1%지만, MultiArith는 42.2% → 94.7%다. PaLM의 GSM8K 56.9%는 논문이 비교한 기존 fine-tuning+verifier 약 55%를 넘어선다.

### GSM8K의 모델별 비교 — 외부 계산기 없음

첨부 v6의 추가 결과까지 포함하면 이 표의 최고 CoT 정확도는 Codex의 63.1%다. 본문에서 강조하는 PaLM 결과와 구분한다.

### ② 모델 크기에 따른 효과

작은 모델은 유창하지만 논리적으로 틀린 풀이를 만들 수 있다. GSM8K에서 LaMDA 420M은 2.6% → 0.4%, 8B는 3.2% → 1.6%, 137B는 6.5% → 14.3%다. 저자들은 큰

모델에서 두드러지는 효과를 창발적 능력으로 해석한다. 단, 100B는 절대 경계가 아니다. PaLM 62B도 9.6% → 29.9%로 개선된다.

**③ 상식 추론 — PaLM 540B (Appendix Table 4)**

Table 4: Standard prompting versus chain of thought prompting on five commonsense reasoning benchmarks. Chain of thought prompting is an emergent ability of model scale—it does not positively impact performance until used with a model of sufficient scale.

| | | CSQA | | StrategyQA | | Date | | Sports | | SayCan | |
|---|---|---|---|---|---|---|---|---|---|---|---|
| Model | | standard | CoT | standard | CoT | standard | CoT | standard | CoT | standard | CoT |
| UL2 | 20B | 34.2 | **51.4** | 59.0 | 53.3 | 13.5 | **14.0** | 57.9 | **65.3** | 20.0 | **41.7** |
| LaMDA | 420M | 20.1 | 19.2 | 46.4 | 24.9 | 1.9 | 1.6 | 50.0 | 49.7 | 7.5 | 7.5 |
| | 2B | 20.2 | 19.6 | 52.6 | 45.2 | 8.0 | 6.8 | 49.3 | 57.5 | 8.3 | 8.3 |
| | 8B | 19.0 | 20.3 | 54.1 | 46.8 | 9.5 | 5.4 | 50.0 | 52.1 | 28.3 | 33.3 |
| | 68B | 37.0 | **44.1** | 59.6 | **62.2** | 15.5 | **18.6** | 55.2 | **77.5** | 35.0 | **42.5** |
| | 137B | 53.6 | **57.9** | 62.4 | **65.4** | 21.5 | **26.8** | 59.5 | **85.8** | 43.3 | **46.6** |
| GPT | 350M | 14.7 | 15.2 | 20.6 | 0.9 | 4.3 | 0.9 | 33.8 | 41.6 | 12.5 | 0.8 |
| | 1.3B | 12.0 | 19.2 | 45.8 | 35.7 | 4.0 | 1.4 | 0.0 | 26.9 | 20.8 | 9.2 |
| | 6.7B | 19.0 | **24.0** | 53.6 | 50.0 | 8.9 | 4.9 | 0.0 | 4.4 | 17.5 | **35.0** |
| | 175B | 79.5 | 73.5 | 65.9 | 65.4 | 43.8 | **52.1** | 69.6 | **82.4** | 81.7 | **87.5** |
| Codex | - | 82.3 | 77.9 | 67.1 | **73.2** | 49.0 | **64.8** | 71.7 | **98.5** | 85.8 | **88.3** |
| PaLM | 8B | 19.8 | **24.9** | 55.6 | 53.5 | 12.9 | 13.1 | 55.1 | **75.2** | 34.2 | **40.0** |
| | 62B | 65.4 | **68.1** | 58.4 | **63.4** | 29.8 | **44.7** | 72.1 | **93.6** | 65.8 | **70.0** |
| | 540B | 78.1 | **79.9** | 68.6 | **77.8** | 49.0 | **65.3** | 80.5 | **95.4** | 80.8 | **91.7** |

⇒ 수학 외의 지식 연결·판단에도 도움이 된다. CSQA의 향상은 작고, GPT 계열의 일부 과제에서는 하락한다. 본문 §4의 StrategyQA 75.6%와 부록 표의 77.8%가 달라, 여기서는 부록 표를 기준으로 했다.

**④ 기호 추론과 길이 일반화 — PaLM 540B**

Table 5: Standard prompting versus chain of thought prompting enables length generalization to longer inference examples on two symbolic manipulation tasks.

| | | Last Letter Concatenation | | | | | | Coin Flip (state tracking) | | | | | |
|---|---|---|---|---|---|---|---|---|---|---|---|---|---|
| | | 2 | | OOD: 3 | | OOD: 4 | | 2 | | OOD: 3 | | OOD: 4 | |
| Model | | standard | CoT | standard | CoT | standard | CoT | standard | CoT | standard | CoT | standard | CoT |
| UL2 | 20B | 0.6 | **18.8** | 0.0 | 0.2 | 0.0 | 0.0 | 70.4 | 67.1 | 51.6 | 52.2 | 48.7 | 50.4 |
| LaMDA | 420M | 0.3 | **1.6** | 0.0 | 0.0 | 0.0 | 0.0 | 52.9 | 49.6 | 50.0 | 50.5 | 49.5 | 49.1 |
| | 2B | 2.3 | **6.0** | 0.0 | 0.0 | 0.0 | 0.0 | 54.9 | **55.3** | 47.4 | 48.7 | 49.8 | 50.2 |
| | 8B | 1.5 | **11.5** | 0.0 | 0.0 | 0.0 | 0.0 | 52.9 | **55.5** | 48.2 | 49.6 | 51.2 | 50.6 |
| | 68B | 4.4 | **52.0** | 0.0 | **0.8** | 0.0 | **2.5** | 56.2 | **83.2** | 50.4 | **69.1** | 50.9 | **59.6** |
| | 137B | 5.8 | **77.5** | 0.0 | **34.4** | 0.0 | **13.5** | 49.0 | **99.6** | 50.7 | **91.0** | 49.1 | **74.5** |
| PaLM | 8B | 2.6 | **18.8** | 0.0 | 0.0 | 0.0 | **0.2** | 60.0 | **74.4** | 47.3 | **57.1** | 50.9 | **51.8** |
| | 62B | 6.8 | **85.0** | 0.0 | **59.6** | 0.0 | **13.4** | 91.4 | **96.8** | 43.9 | **91.0** | 38.3 | **72.4** |
| | 540B | 7.6 | **99.4** | 0.2 | **94.8** | 0.0 | **63.0** | 98.1 | **100.0** | 49.3 | **98.6** | 54.8 | **90.2** |

⇒ 예시보다 긴 입력에도 규칙을 반복 적용하지만, 길이가 늘면 성능이 낮아진다. 단순 합성 과제 결과를 모든 복잡한 추론의 일반화로 확대할 수는 없다.

### ⑤ Ablation — LaMDA 137B / GSM8K

Table 6: Ablation and robustness results for arithmetic reasoning datasets. Chain of thought generally outperforms ablations by a large amount. "Equation only" performs in between standard prompting and chain of thought prompting, as it allows for intermediate reasoning steps via equations but does not leverage natural language. Chain of thought prompting has variance (as expected) when used with prompts written by different annotators or when using other exemplars, but still outperforms standard prompting by a large margin. Standard deviation shown is for different order of few-shot prompting exemplars, with five different random seeds. Results here are shown for LaMDA 137B, as additional queries for GPT-3 and PaLM are both limited and expensive.

| | GSM8K | SVAMP | ASDiv | MAWPS |
|---|---|---|---|---|
| Standard prompting | 6.5 ±0.4 | 29.5 ±0.6 | 40.1 ±0.6 | 43.2 ±0.9 |
| Chain of thought prompting | 14.3 ±0.4 | 36.7 ±0.4 | 46.6 ±0.7 | 57.9 ±1.5 |
| Ablations | | | | |
| · equation only | 5.4 ±0.2 | 35.1 ±0.4 | 45.9 ±0.6 | 50.1 ±1.0 |
| · variable compute only | 6.4 ±0.3 | 28.0 ±0.6 | 39.4 ±0.4 | 41.3 ±1.1 |
| · reasoning after answer | 6.1 ±0.4 | 30.7 ±0.9 | 38.6 ±0.6 | 43.6 ±1.0 |
| Robustness | | | | |
| · different annotator (B) | 15.5 ±0.6 | 35.2 ±0.4 | 46.5 ±0.4 | 58.2 ±1.0 |
| · different annotator (C) | 17.6 ±1.0 | 37.5 ±2.0 | 48.7 ±0.7 | 60.1 ±2.0 |
| · intentionally concise style | 11.1 ±0.3 | 38.7 ±0.8 | 48.0 ±0.3 | 59.6 ±0.7 |
| · exemplars from GSM8K ($\alpha$) | 12.6 ±0.6 | 32.8 ±1.1 | 44.1 ±0.9 | 53.9 ±1.1 |
| · exemplars from GSM8K ($\beta$) | 12.7 ±0.5 | 34.8 ±1.1 | 46.9 ±0.6 | 60.9 ±0.8 |
| · exemplars from GSM8K ($\gamma$) | 12.6 ±0.7 | 35.6 ±0.5 | 44.4 ±2.6 | 54.2 ±4.7 |

수식만으로는 복잡한 문장의 의미를 충분히 처리하기 어렵고, 추가 토큰이나 사후 설명만으로 같은 개선을 얻지 못한다. 최종 답 이전에 의미 있는 중간 단계를 생성하는 것이 중요하다는 근거다. 다만 자연어만이 유일한 추론 방식임을 증명한 것은 아니다.

### ⑥ Robustness

풀이 작성자·문체·예시 구성·순서·개수를 바꾸어도 산술 과제에서는 대체로 이득이 유지된다. GSM8K에서 Standard 6.5%, 기본 CoT 14.3%, 작성자 B 15.5%, C 17.6%, 간결한 풀이 11.1%다. 그러나 동전 과제는 작성자에 따라 약 99.6%와 71.4%의 차이를 보여 프롬프트 설계의 영향이 남는다.

### ⑦ 오류 분석 — 오답 50개 (Appendix D.2)

| 오류 유형 | 비율 |
|---|---|
| 계산 오류만 존재 | 8% |
| 숫자·기호 대응 오류 | 16% |
| 필요한 한 단계 누락 | 22% |

| 오류 유형 | 비율 |
| --- | --- |
| 의미 이해·일관성 등 큰 수정 필요 | 54% |

46%는 비교적 작은 수정으로 고칠 수 있었지만 나머지는 근본적 수정이 필요했다. PaLM 62B의 오류 45개 분석에서는 540B로 키웠을 때 의미 이해 오류 20개 중 6개, 단계 누락 18개 중 12개, 기타 7개 중 4개가 해결됐다. 작은 정성 분석이므로 인과관계를 확정하지는 못한다.

**⑧ 외부 계산기**

생성된 수식의 산술을 외부 계산기로 처리하면 GSM8K에서 PaLM 56.9% → 58.6%, Codex 63.1% → 65.4%가 된다(Table 1). 계산 실수를 줄일 수 있지만 문제 이해 오류나 잘못된 식까지 해결하지 못하며 모든 데이터셋에서 개선되는 것도 아니다.

# 5. 결론 (배운점)

## 의의

소수의 중간 풀이 예시만으로 추가 학습 없이 LLM의 추론 성능을 높일 수 있음을 보였다. 모델 크기뿐 아니라 능력을 끌어내는 프롬프트와 출력 구조가 중요하다. Standard prompting의 성능은 모델 능력의 하한일 수 있다.

## 한계

- 정답이 맞아도 풀이가 틀릴 수 있다. 특히 객관식·이진 과제는 우연한 정답이 가능하다.
- 출력된 풀이가 내부 계산에 충실한지, 인간과 같은 추론인지 규명하지 못했다.
- 큰 모델과 긴 생성에 따른 비용·지연이 발생한다.
- 모든 과제·모델에서 성능이 향상되지 않으며 프롬프트에 민감하다.
- 대규모 풀이 주석으로 확대하면 비용이 크고, 일부 모델의 접근 제한은 재현성을 제약한다.
- 모델 크기와 학습량 등의 요인을 완전히 분리하지 못했고, 오류 분석 표본도 작다.

## 배운 점

① 문제를 어떻게 표현하고 어떤 출력 형식을 유도하는지가 성능을 크게 바꾼다.

② 단계적 풀이의 효과는 동일 모델 기준선과 ablation으로 확인해야 한다.

③ 최종 답의 정확성, 풀이의 타당성, 내부 계산에 대한 충실성은 구분해야 한다.

④ 다단계 문제·충분한 모델 능력에서 특히 유용하지만, 단순 문제까지 항상 CoT가 유리한 것은 아니다.

**핵심: 충분한 능력을 가진 언어 모델에 중간 풀이가 포함된 소수의 예시를 제공하면, 추가 학습 없이 다양한 다단계 추론 과제의 성능을 높일 수 있다.**