

11/17 논문 - Masked Autoencoders Are Scalable Vision Learners

https://arxiv.org/pdf/2111.06377

1. Introduction

논문이 다루는 분야

- 컴퓨터 비전
- 자기지도 표현 학습(Self-supervised Visual Representation Learning)
  - 이미지의 일부를 가리고 누락된 픽셀을 복원하는 사전학습
  - 대량의 라벨 없이도 대규모 비전 모델이 유용한 시각적 특징을 학습

해당 task에서 기존 연구 한계점

1. 라벨 데이터 의존성: 모델이 커질수록 ImageNet 규모의 데이터에도 과적합하기 쉬우며, 수억 장의 라벨 데이터가 필요해진다.
2. 구조적 차이: 기존 CNN은 마스크 토큰과 위치 임베딩을 적용하기 어려웠다. ViT의 등장으로 이 장벽은 줄어들었다.
3. 이미지의 높은 중복성: 언어와 달리 이미지는 인접 영역의 정보가 많이 겹친다. 조금만 가리면 주변 패치만으로 복원할 수 있어 객체·장면의 의미를 이해할 필요가 적다.
4. 복원 목표의 차이: 단어 예측은 의미 정보를 직접 다루지만 픽셀 복원은 낮은 수준의 정보에 집중할 수 있다. 따라서 의미 있는 잠재 표현을 학습하려면 디코더 설계가 중요하다.

논문의 contributions

1. 높은 마스킹 비율: 이미지 패치의 약 75%를 무작위로 가려 중복성을 줄이고, 이미지 전체를 이해해야 해결할 수 있는 자기지도 학습 과제를 만든다.

2. 비대칭 인코더–디코더: 인코더는 보이는 패치 약 25%만 처리한다. 가벼운 디코더에 마스크 토큰을 추가해 누락된 픽셀을 복원한다.
3. 효율성과 확장성: 위 두 설계를 결합해 사전학습 시간을 3배 이상 단축하고 메모리 사용량을 줄여 대규모 모델 학습을 가능하게 한다.
4. 성능 및 전이 학습: ImageNet-1K만 사용한 ViT-Huge는 미세조정 후 정확도 87.8%를 달성했다. 객체 탐지·인스턴스 분할·의미 분할에서도 지도학습 사전학습보다 좋은 성능을 보였으며, 모델 규모를 키울 때 성능이 크게 향상되었다.

핵심: 이미지의 대부분을 가리고 복원하게 하는 단순한 과제로, 라벨 없이도 대규모 비전 모델을 효율적으로 사전학습할 수 있다.